



Cyber-Physische Systeme – WS 26/27

Gelesen von Prof. Dr. Daniel Gaida

29.08.2026

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme


Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Seite 1

Technology
Arts Sciences
TH Köln

Inhalt

- Modell der Umgebung



Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
 - Objektdetektion, -tracking, Bildsegmentierung
 - Spracherkennung
 - Verhaltensmodellierung von Fußgängern, Fahrzeugen
- Lernen in virtuellen Umgebungen (in einer Simulation)
 - 3D Simulation
 - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
 - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, ...)
 - SLAM – Simultaneous Localization and Mapping

Lernziel

Die Studierenden können geeignete Technologien zur Modellierung der Umgebung eines CPS auswählen, indem sie

- die Umgebung ihres CPS identifizieren und beschreiben,
- aus Deep Learning basierten Technologien wie Objekt Detektion, Objekt Tracking, Bildsegmentierung und Spracherkennung geeignete Technologien wählen,
- im Bedarfsfall 3D Simulationen zur Erstellung von Trainingsdaten nutzen,
- eine Karte der Umgebung erstellen können und
- geeignete Bibliotheken und Tools zur Modellierung der Umgebung des CPS wählen,

um später die Umgebung von Cyber-physischen Systemen modellieren zu können.


Welche Rolle spielt Computer Vision für CPS?

Ziel: CPS muss mit Umgebung interagieren können




Welche Rolle spielt Computer Vision für CPS?

Ziel: Benennung der Objekte in der Szene - Objektdetektion




Welche Rolle spielt Computer Vision für CPS?

Objektdetektion



Welche Rolle spielt Computer Vision für CPS?

Objektdetektion



- YOLOv8
- Erkennt nur 80 verschiedene Objektkategorien (Autos, Fahrräder, Tiere, Regenschirme, ...)




Welche Rolle spielt Computer Vision für CPS?


Objektdetektion

Deep Learning Modell

- YOLO – You only look once
 - Redmon, J., & Farhadi, A. (2015). You only look once: Unified, real-time object detection. In Proc. IEEE CVPR (pp. 779-788).
- YOLO26 – plug & play
 - <https://github.com/ultralytics/ultralytics>
- Fertig trainierte Modelle in unterschiedlichen Größen herunterladbar
- Trainiert an COCO Datensatz
 - 80 verschiedene Objektkategorien (Autos, Fahrräder, Tiere, Regenschirme, ...)




KI, Machine Learning und Deep Learning – Was ist der Unterschied?



- Künstliche Intelligenz als Oberbegriff
 - Logisches Schließen, wissensbasierte Systeme
 - Optimierung
 - Statistische Analyse (maschinelles Lernen)


Künstliche Intelligenz (KI) beschäftigt sich mit Methoden, die es einem Computer ermöglichen, solche Aufgaben zu lösen, die, wenn sie vom Menschen gelöst werden, Intelligenz erfordern.

KI, Machine Learning und Deep Learning – Was ist der Unterschied?



- Künstliche Intelligenz als Oberbegriff
 - Logisches Schließen, wissensbasierte Systeme
 - Optimierung
 - Statistische Analyse (maschinelles Lernen)
- Maschinelles Lernen
 - Systeme die aus Erfahrung & Beispielen lernen
 - Erkennen von Mustern in Daten
 - Eigenständiges Erlernen von Regeln

KI, Machine Learning und Deep Learning – Was ist der Unterschied?



- Künstliche Intelligenz als Oberbegriff
 - Logisches Schließen, wissensbasierte Systeme
 - Optimierung
 - Statistische Analyse (maschinelles Lernen)
- Maschinelles Lernen
 - Systeme die aus Erfahrung & Beispielen lernen
 - Erkennen von Mustern in Daten
 - Eigenständiges Erlernen von Regeln
- Deep Learning
 - Ein Teilgebiet des maschinellen Lernens
 - Hype durch Erfolge in Bild- und Spracherkennung und Sprachverarbeitung

Was ist Maschinelles Lernen?


„[Maschinelles Lernen ist das] Fachgebiet, das Computern die Fähigkeit zu lernen verleiht, ohne explizit programmiert zu werden.“

Arthur Samuel, 1959

- Ein Spamfilter ist ein maschinelles Lernprogramm, das aus Beispielen für Spam-E-Mails (z.B. vom Nutzer markierten) und gewöhnlichen E-Mails (Nicht-Spam) lernt, Spam zu erkennen.
- Die vom Nutzer markierten Lernbeispiele nennt man den Trainingsdatensatz.
- Die Aufgabe besteht darin, neue E-Mails als Spam zu kennzeichnen.
- Maschinelles Lernen lernt diese Aufgabe aus dem Trainingsdatensatz, in dem es Muster/Zusammenhänge erkennt und wendet das erlernte Wissen auf neue E-Mails an, um Spam zu erkennen.

Warum wird Maschinelles Lernen verwendet?

Traditionelles Programmieren vs. Maschinelles Lernen



Traditionelle Programmierung

- Alle Regeln werden explizit programmiert
- Jede Regel basiert auf einer logischen Grundlage
- Die Maschine gibt eine Ausgabe aus, die der logischen Anweisung folgt
- Komplexe Systeme benötigen viele Regeln

→ Instandhaltung kann schnell untragbar werden



Maschinelles Lernen

- Soll dieses Problem überwinden
- Regeln werden basierend auf der Korrelation zwischen Ein- & Ausgabe erlernt
- Regeln müssen nicht explizit geschrieben werden
- Algorithmen passen sich neuen Daten an

Training von Deep Learning Modellen

Objektdetektion

Bevor Sie ein Deep Learning Modell selbst erstellen und trainieren:

- Es gibt sehr viele an sehr großen Datensätzen trainierte Modelle, die Sie herunterladen und direkt nutzen können
- Sie können dieses Modell auch als initiales Modell nutzen, welches Sie mit Ihren eigenen Daten verbessern können
 - Transfer Learning
 - Knowledge Distillation
- YOLO26 als Beispiel
- <https://huggingface.co/models>
- <https://modelzoo.co/>

Objektdetektion mit Deep Learning

Trainingsdatensatz

```
0 0.0414228 0.659696 0.0828456 0.299007
11 0.0199709 0.268372 0.0397828 0.0651804
0 0.349451 0.584807 0.152251 0.418149
0 0.913659 0.58147 0.172332 0.45871
```

Trainingsdaten

- Bilder


Markieren der Bilder (Labeling)

- Um jedes zu detektierende Objekt ist ein Rahmen zu zeichnen
- Pro Bild können mehrere Objekte markiert werden

Label

- Koordinaten des Rahmens
- Klasse des Objekts
- Für jedes Bild stehen Label in einer txt-Datei

Use your mouse to drag a box around an object to add a label. Then click **Save labels** to advance to the next item.



<https://www.edgeimpulse.com/blog/3-ways-to-do-ai-assisted-labeling-for-object-detection>

Objektdetektion mit Deep Learning

Kostenlose Tools, die das Labeling beschleunigen


- <https://www.cvat.ai/>
- <https://roboflow.com/#annotate>
- <https://pypi.org/project/labelImg/>
- ...

Bereits gelabelte Datensätze (Erster Schritt):

- <https://paperswithcode.com/datasets?task=object-detection&page=1> (233 Object Det. Datensätze)
- Autonomes Fahren, Medizin, ...
- <https://datasetsearch.research.google.com/>
- Wenn nicht genau der richtige Datensatz dabei ist, hilft es meistens dennoch das Modell auf dem ähnlichsten Datensatz zu trainieren und das Modell dann auf einem eigenen Datensatz weiter zu trainieren (Transfer Learning, finetuning)

Objektdetektion mit Deep Learning



Training – sehr viele Bilder und deren Label



```
0 0.0414228 0.659696 0.0828456 0.299007
11 0.0199709 0.268372 0.0397828 0.0651804
0 0.349451 0.584807 0.152251 0.418149
0 0.913659 0.58147 0.172332 0.45871
```

Objektdetektion mit Deep Learning

Inferenz



YOLO Objektdetektion testen

```
pip install ultralytics
```

```
from ultralytics import YOLO
```


```
model = YOLO("yolo26n.pt") # load an official model
```

```
# Predict with the model
```

```
results = model("https://ultralytics.com/images/bus.jpg")
```

<https://docs.ultralytics.com/tasks/detect/>

Siehe Notebook: [01_objektdetektion_yolo26.ipynb](#)



Welche Rolle spielt Computer Vision für CPS?


Ziel: Objekt Tracking

Objekt Tracking

- Eindeutige Objekt Detektion von beweglichen Objekten über eine Sequenz von Frames

YOLO hat Objekt Tracking integriert

<https://docs.ultralytics.com/modes/track/>



<https://github.com/ifzhang/ByteTrack>

Sehr gutes Tutorial von Roboflow zu Objekt Tracking mit YOLOv8 (14 Min.):


https://www.youtube.com/watch?v=Mt9iHFd0_Bo

Welche Rolle spielt Computer Vision für CPS?


Ziel: Objekt Tracking

Vorgehensweise:

- Tracking-by-Detection
 - Objekt Detektion (bspw. mit YOLO)
 - Tracking der detektierten Objekte
 - Kalman Filter prädiziert wo Objekt in nächstem Frame sein könnte. In dieser Region wird dann für das nächste Frame Objekt Detektion ausgeführt.



<https://github.com/ifzhang/ByteTrack>




Welche Rolle spielt Computer Vision für CPS?


Ziel: Objekt Tracking

Vorgehensweise:

- Tracking-by-Detection
 - Objekt Detektion (bspw. mit YOLO)
 - Tracking der detektierten Objekte
 - Kalman Filter prädiziert wo Objekt in nächstem Frame sein könnte. In dieser Region wird dann für das nächste Frame Objekt Detektion ausgeführt.
 - Re-Identifikation (ist das Objekt noch das gleiche?)



<https://github.com/ifzhang/ByteTrack>




Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Tracking

In YOLO integriert („State of the Art“ des Objekt Trackings):

- ByteTrack, <https://github.com/ifzhang/ByteTrack>
- Beibehalten von Bounding Boxen, die temporär nur einen geringen Score erhalten



Y. Zhang et al., ByteTrack: Multi-Object Tracking by Associating Every Detection Box, 2022

- BoT-SORT, <https://github.com/NirAharon/BoT-SORT>
 - Erweiterung von ByteTrack um Kompensation der Bewegung der Kamera, verbesserter Zustandsvektor des Kalman Filters, ...

YOLO26 Objekttracking testen

```
from ultralytics import YOLO
```

```
model = YOLO("yolo26n.pt") # Load an official Detect model
```

```
# Perform tracking with the model with ByteTrack
```

```
results = model.track("https://youtu.be/LNwODJXcvt4", show=True, tracker="bytetrack.yaml")
```

<https://docs.ultralytics.com/modes/track/>

s. Notebook: [02_objekttracking_yolo26.ipynb](#)

Welche Rolle spielt Computer Vision für CPS?


Ziel: 3D Objekt Tracking (Detektion)

Mit Lidar (oder Radar) Daten können Sie Objekte als 3D Objekte tracken/detektieren

- K. Chen et al., MVLidarNet: Real-Time Multi-Class Scene Understanding for Autonomous Driving using multiple views, 2020
- Popov et al., NV RadarNet: Real-Time Radar Obstacle and Free Space Detection for Autonomous Driving, 2023

Bibliotheken:

- github.com/open-mmlab/mmdetection3d
- github.com/isl-org/Open3D-ML



Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Detektion von beliebigen Objektkategorien

- Algorithmen der Objekt Detektion funktionieren nur für die Objektkategorien für die sie trainiert wurden
- YOLO wurde trainiert mit COCO Datensatz
 - 80 verschiedene Objektkategorien (Autos, Fahrräder, Tiere, Regenschirme, ...)
- Mit Trainingsdaten von weiteren Objektkategorien können Sie auch diese detektieren
- Was ist, wenn Sie „beliebige“ Objektkategorien detektieren möchten?
 - Open-Vocabulary Objekt Detektion
 - Trainiert mit Millionen von Bildern aus dem Internet und deren Bildbeschriftungen
- YOLOE - Real-Time Seeing Anything
 - <https://docs.ultralytics.com/models/yoloe>

Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Detektion von beliebigen Objektkategorien

- Open-Vocabulary Objekt Detektion
- <https://github.com/ailab-cvc/yolo-world>



Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Detektion von beliebigen Objektkategorien

```
from ultralytics import YOLO
```

```
model = YOLO("yoloe-11s-seg.pt")           # Initialize a model
```

```
model.set_classes(["person", "bus"])        # Define custom classes
```


```
results = model.predict("path/to/image.jpg") # Run inference to detect your custom classes
```

```
results[0].show()                           # Show results
```

s. Notebook [03_AppObjectDetection.ipynb](#)

Welche Rolle spielt Computer Vision für CPS?


Ziel: Bildsegmentierung



Welche Rolle spielt Computer Vision für CPS?

Ziel: Bildsegmentierung

- Es gibt keine objektive Definition einer „richtigen“ Segmentierung!
- Segmentierung wird durch Menschen vorgegeben



Subject 1

Subject 2

Subject 3

Welche Rolle spielt Computer Vision für CPS?

Ziel: Bildsegmentierung



Bildsegmentierung mit Deep Learning

Trainingsdaten

Eingangsdaten




Ausgangsdaten



Quelle für Trainingsdaten: <https://paperswithcode.com/datasets?task=semantic-segmentation> (261 Datensätze)

Bildsegmentierung mit Deep Learning

Training des Deep Learning Modells (bspw. Autoencoder)




Bildsegmentierung mit Deep Learning

Instance Segmentation vs. Semantic Segmentation


<https://blog.roboflow.com/difference-semantic-segmentation-instance-segmentation/>




Image Recognition



Semantic Segmentation



Object Detection



Instance Segmentation

Bildsegmentierung mit Deep Learning


YOLO26 kann auch Instance Segmentation (<https://docs.ultralytics.com/tasks/segment/>)

Gutes Tutorial zu YOLOv8 zu Image Segmentation und Objekt Detektion, nur Inferenz (13 Min.)

<https://www.youtube.com/watch?v=75LI9MI9eEo>

```
from ultralytics import YOLO  
model = YOLO("yolo26n-seg.pt") # load a model  
# Predict with the model  
results = model("https://ultralytics.com/images/bus.jpg")
```

s. Notebook: [06_objektdetektion_yolo26.ipynb](#)



Welche Rolle spielt Computer Vision für CPS?


Bildsegmentierung: Instance Segmentation mit YOLOv8



Open-Vocabulary Image Segmentation

Segment Anything Modell (SAM 3)

- github.com/facebookresearch/segment-anything
- <https://docs.ultralytics.com/models/sam-3>
- Foundation Modell für Bildsegmentierung; Promptable
- FastSAM (<https://docs.ultralytics.com/models/fast-sam/>)
 - YOLOv8 Segmentierungsmodell und anschließend Fokus auf die gewünschten Begriffe
- Grounded Segment Anything
 - Grounding DINO (Open-Vocabulary Objekt Detektion) – lokalisiert die Objekte; geg. Prompt
 - <https://github.com/IDEA-Research/Grounding-DINO-1.5-API>
 - Segment Anything Modell – segmentiert die lokalisierten Objekte
 - <https://github.com/IDEA-Research/Grounded-SAM-2>



Open-Vocabulary Image Segmentation

```
from ultralytics import FastSAM

# Define an inference source
source = "path/to/bus.jpg"

# Create a FastSAM model
model = FastSAM("FastSAM-s.pt") # or FastSAM-x.pt

# Run inference on an image
everything_results = model(source, device="cpu", retina_masks=True, imgsz=1024,
conf=0.4, iou=0.9)

# Run inference with texts prompt
results = model(source, texts="a photo of a dog")
```

YOLOv8 testen – auf dem Smartphone



The banner features the Ultralytics YOLOv8 logo on the left, followed by the text 'YOLOv8.2' and 'Unleashing Next-Gen AI Capabilities'. A yellow button labeled 'Discover more' is positioned below the text. To the right, a list of features is presented with corresponding icons: a laptop for 'YOLOv9 training and deployment', binoculars for 'Advanced tracking with YOLOv8-OBB', a gear for 'Zero-shot promptable YOLO-Worldv2 models', a speedometer for '40% faster ultralytics import speed', and a Raspberry Pi for 'YOLOv8.2 with Raspberry Pi 5 CI and tutorials'. On the far right, there is a QR code and the text 'Download the App', along with buttons for 'GET IT ON Google Play' and 'Download on the App Store'.

ultralytics
YOLOv8

YOLOv8.2

Unleashing Next-Gen AI Capabilities

Discover more

- YOLOv9 training and deployment
- Advanced tracking with YOLOv8-OBB
- Zero-shot promptable YOLO-Worldv2 models
- 40% faster ultralytics import speed
- YOLOv8.2 with Raspberry Pi 5 CI and tutorials

Download the App

GET IT ON
Google Play


Download on the
App Store

3D Bildsegmentierung

<https://github.com/isl-org/Open3D-ML>

Bildquelle:


<https://paperswithcode.com/task/3d-semantic-segmentation>



Objektdetektion, -tracking und -segmentierung

Zusammenfassung

- Mit YOLO-Modellen von Ultralytics kann man viele Bilderkennungs-Anwendungen recht einfach starten




Fragen?

- In welchen Projekten wird eine Kamera genutzt?
- Werden Sie Objektdetektion oder Bildsegmentierung benötigen?




Welche Rolle spielt Computer Vision für CPS?

Ziel: 3D Struktur (Oberflächennormale)




Welche Rolle spielt Computer Vision für CPS?

Ziel: 3D Struktur (Oberflächennormale)



Raum




Legende

Welche Rolle spielt Computer Vision für CPS?

Ziel: Finden von Greifpunkten

Bin Picking

- Finden von Greifpunkten an Objekten



Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?



Blickwinkel Variation

Beleuchtung



Credit: Flickr user michaelpaul

Skalierung

Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?



Variation innerhalb einer Klasse



Bewegung (Source: S. Lazebnik)

Background clutter



Occlusion

Quelle: Intro to Computer Vision (CS5670),
Cornell Tech, Spring 2021



29.08.2026

Seite 54

Quelle: Computer Vision (CS 4476),
Georgia Tech, Fall 2019

ology
ciences
In



29.08.2026

Seite 55

Quelle: Computer Vision (CS 4476),
Georgia Tech, Fall 2019

Technology
Sciences
öln



Quelle: Computer Vision (CS 4476),
Georgia Tech, Fall 2019



Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig? - Unterm Strich

Wahrnehmung ist von Natur aus ein mehrdeutiges Problem

- Viele verschiedene 3D-Szenen können zu einem bestimmten 2D-Bild führen.
- Wir müssen oft auf Vorwissen über die Struktur der Welt zurückgreifen
- Deep Learning Modelle haben das „Vorwissen über die Struktur der Welt“ aus Millionen von Trainingsbildern erlernt



Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig? - Unterm Strich

Was denken Sie antwortet GPT-4vision?



ChatGPT

Das Bild zeigt eine Straßenmalerei eines Coca-Cola-Flaschenbildes, das so gestaltet ist, dass es, aus einer bestimmten Perspektive betrachtet, dreidimensional erscheint. Dies ist ein Beispiel für eine anamorphe Illusion, bei der durch die Verzerrung der Zeichnung und die Wahl des Standpunktes der Kamera eine optische Täuschung erzeugt wird, die Tiefe und Volumen suggeriert, wo tatsächlich nur eine flache Oberfläche vorhanden ist.

Die Person im Bild kniet neben der Straßenmalerei und lächelt in die Kamera, was den Eindruck erweckt, als würde sie neben einer echten, großen Flasche sitzen. Sie scheint die Illusion zu genießen und ist Teil der Inszenierung, die dazu dient, die Täuschung für den Betrachter zu verstärken.

Die Kreiden, die neben dem Bild auf dem Boden liegen, deuten darauf hin, dass die Malerei kürzlich fertiggestellt wurde oder dass der Künstler seine Arbeit noch präsentiert. Solche Straßenkunstwerke sind oft temporär und können als eine Form von öffentlicher Kunst betrachtet werden, die Passanten überrascht und erfreut.



Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
 - Objektdetektion, -tracking, Bildsegmentierung
 - **Spracherkennung**
 - Verhaltensmodellierung von Fußgängern, Fahrzeugen
- Lernen in virtuellen Umgebungen (in einer Simulation)
 - 3D Simulation
 - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
 - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, ...)
 - SLAM – Simultaneous Localization and Mapping

Einsatz von Spracherkennung und Sound Classification in CPS

Spracherkennung in CPS:

- Steuerung von Robotern und Maschinen durch Sprachbefehle.
- Interaktion mit autonomen Systemen (z.B. Sprachsteuerung in Smart Homes oder Fabriken).
- Verbesserung der Mensch-Maschine-Interaktion durch natürliche Sprache.

Sound Classification:

- Erkennung von Umgebungsgeräuschen zur Reaktion auf sicherheitskritische Ereignisse (z.B. Maschinenlärm, Alarmer, Warnsignale).
- Ziel: Unfallprävention (z.B. Maschinenstopps bei anomalen Geräuschen).

Emotionserkennung:

- Mensch-Roboter-Interaktion durch Erkennung emotionaler Zustände verbessern (z.B. Roboter im Gesundheitswesen/Therapie, die auf emotionale Signale reagieren).

Aktueller Stand der Forschung – Spracherkennung

Deep Learning und neuronale Netze:

- Moderne Spracherkennungssysteme basieren auf tiefen neuronalen Netzen wie Transformer-Modellen (z.B. OpenAI's Whisper v3, huggingface.co/openai/whisper-large-v3).
- Große Fortschritte durch vortrainierte Modelle, die natürliche Sprache verstehen und interpretieren.

Verbesserungen bei der Genauigkeit:

- Forschung fokussiert sich auf die Reduzierung von Fehlern in lauten Umgebungen und Multilingualität.
- Verwendung von Self-Supervised Learning zur Verarbeitung großer Mengen unbeschrifteter Daten.

```
import torch
```

```
from transformers import pipeline
```

```
pipe = pipeline("automatic-speech-recognition", "openai/whisper-large-v3", torch_dtype=torch.float16, device="cuda:0")
```

https://huggingface.co/spaces/hf-audio/whisper-large-v3/blob/main/whisper_notebook.ipynb

Aktueller Stand der Forschung – Keyword Detection

Keyword Spotting (KWS):

- Erkennung von Schlüsselwörtern („Wake Words“) wie „Hey Siri“ oder „Alexa“ durch sehr kleine CNNs zur Ausführung auf eingebetteter Hardware.

Forschungsansätze:

- Entwicklung von kleinen Modellen mit geringem Speicher- und Energieverbrauch (TinyML).
- Steigerung der Genauigkeit durch Federated Learning, das verteilte Datenverarbeitung erlaubt, ohne zentrale Datenpools zu benötigen.
- [Keyword Spotting with the NDP120-Powered Arduino Nicla Voice](#) (Edge Impulse, Youtube)



Arduino Pro - Nicla Voice

Edge Impulse


AI for Any Edge Device
Docker Containers

Build datasets, train models, and optimize libraries to run directly on device; from the smallest microcontrollers to gateways with the latest neural accelerators (and anything in between).

[Get Started](#) [Talk to an AI Expert](#)

The diagram on the right illustrates the Edge Impulse workflow. It features a central icon representing a neural network or data processing unit. Surrounding this center is a circular path with four distinct stages, each marked by an icon and a label: 'Build' (top, database icon), 'Train' (right, puzzle piece icon), 'Optimize' (bottom, code/arrow icon), and 'Deploy' (left, cube icon). The path is highlighted with a green-to-blue gradient, indicating a continuous cycle.

Federated Learning



Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
 - Objektdetektion, -tracking, Bildsegmentierung
 - Spracherkennung
 - **Verhaltensmodellierung von Fußgängern, Fahrzeugen**


- Lernen in virtuellen Umgebungen (in einer Simulation)
 - 3D Simulation
 - Von der Simulation in die Realität (Sim2real)

- Statische Modelle der Umgebung (Karte)
 - Semantische Karte
 - SLAM – Simultaneous Localization and Mapping


Verhaltensmodellierung von Fußgängern

Nutzung von Datenbasierten Modellen

- Lernen Wahrscheinlichkeiten für verschiedene Trajektorien
- Daten
 - Fußgänger und andere Objekte, Fahrzeuge, ...
 - Trajektorien der Fußgänger
 - Tätigkeiten der Fußgänger (Gesten)
 - Infrastruktur (Zebrastreifen, Schilder, ...)



Verhaltensmodellierung von Fußgängern



Verhaltensmodellierung von Fußgängern


Gestenerkennung – Human Pose Estimation – geht auch mit YOLOv8



Verhaltensmodellierung von Fahrzeugen

Nutzung von Datenbasierten Modellen

- Lernen Wahrscheinlichkeiten für verschiedene Trajektorien
- Daten
 - Fahrzeuge und andere Objekte, Fußgänger, ...
 - Trajektorien der Fahrzeuge
 - Infrastruktur (Fahrbahnmarkierungen, Zebrastreifen, Schilder, ...)



Verhaltensmodellierung von Fahrradfahrern - Beispiel



- Objektdetektion/-tracking
 - Fahrradfahrer
 - Schilder
- Gestenerkennung
 - Handzeichen und Drehung des Gesichts
- Fahrbahnmarkierung

Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
 - Objektdetektion, -tracking, Bildsegmentierung
 - Spracherkennung
 - Verhaltensmodellierung von Fußgängern, Fahrzeugen

- **Lernen in virtuellen Umgebungen (in einer Simulation)**
 - **3D Simulation**
 - **Von der Simulation in die Realität (Sim2real)**

- Statische Modelle der Umgebung (Karte)
 - Semantische Karte
 - SLAM – Simultaneous Localization and Mapping

Lernen durch Simulation

- Training von Deep Learning Modellen benötigt sehr viele Daten
- Erhebung ist teuer, zeitintensiv, aufwändig, ...
- Lösung:
 - Erstellen der Daten in einer fotorealistischen Simulationsumgebung
 - Weiterer Vorteil: Daten sind bereits gelabelt
 - Training des Deep Learning Modells mit den simulierten Daten
 - Fine-Tuning des trainierten Modells mit **wenigen** realen Daten

Was ist eine Simulation?

- Eine Simulation ist eine virtuelle Welt, die eine Teilmenge von Merkmalen der realen Welt enthält.
- Im Zusammenhang mit der Robotik sind Simulationen virtuelle Welten, die es Entwicklern ermöglichen, produktiver zu arbeiten.
- Simulationen sind modernen Videospielen insofern sehr ähnlich, als sie realistische Physiksimulationen, eine Vorstellung von Zeit und grafische Darstellungen der realen Welt enthalten.

3D Simulation

CARLA, Open Source, <https://carla.readthedocs.io/en/latest/>



Simulation von

- Sensoren
 - Kamera, Lidar, GPS, ...
- Physik (Trägheit, Reibung, ...)
- Wetter, Licht, ...

3D Simulation

Objektdetektion in CARLA




3D Simulation

Nvidia DRIVE Sim – We are not accepting new partners currently



3D Simulation

Nvidia Isaac Sim (kostenlos, Datenschutz problematisch)



3D Simulation

Nvidia Omniverse & Amazon



3D Simulation

Nvidia Omniverse & Amazon



29.08.2026

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://www.youtube.com/watch?v=LUnZXBL_IqA

Seite 82

3D Simulation

Nvidia Omniverse & Siemens



3D Simulation

Gazebo, Open Source




3D Simulation

Gazebo, Open Source



<https://raw.githubusercontent.com/turtlebot/TurtleBot4Lessons/main/media/tb4.png>




3D Simulation

Habitat-Lab, Open Source

Simulation von Innenräumen

- Navigation („Gehe in die Küche“)
- Anweisungen folgen („Drehe dich nach rechts, gehe durch die Tür, ...“)
- Beantwortung von Fragen („Welche Farbe hat die Haustür?“)



3D Simulation

ThreeDWorld, Open Source


“TDW is a 3D virtual world simulation platform, utilizing state-of-the-art video game engine technology”

<https://threedworld.org/>



Weitere Simulationen

- EnergyPlus, „EnergyPlus™ is a whole building energy simulation program that engineers, architects, and researchers use to model both energy consumption - for heating, cooling, ventilation, lighting and plug and process loads - and water use in buildings.“, Quelle: <https://energyplus.net/>
- Flatland, How to efficiently manage dense traffic on complex railway networks?, <https://flatland.aicrowd.com/intro.html>



Von der Simulation in die Realität

Sim2Real, sim-to-real

Sim2real bezieht sich auf den Prozess der Übertragung einer in einer simulierten Umgebung erlernten Strategie oder eines Modells auf eine reale Umgebung.


- Schließen des „reality gaps“ (Lücke zwischen Simulation und Realität)

Simulation → Realität

Sim2Real, sim-to-real

Domain Randomization:

- Anwendung von zufälligen Transformationen auf ein Simulationsmodell, um die Generalisierung auf unbekannte Umgebungen zu verbessern.
- Training einer Roboterhand, um den Zauberwürfel (Rubik's Cube) zu lösen
- Simulation verschieden aussehender Roboterhände, damit KI lernt, dass Aussehen der Hand keine Rolle spielt



Simulation → Realität

Sim2Real, sim-to-real


Domain Randomization:

- Randomisierung von visuellen Merkmalen, aber auch von physikalischen Parametern (Reibung, Masse, Größe von Objekten, ...)

- Ziel:

„Die Hauptidee hinter diesen Methoden ist das Lernen in einer großen Anzahl von simulierten Umgebungen mit dem Ziel, ein robustes Modell oder eine robuste Strategie zu erlernen, die die physische Welt als eine weitere Variation "sieht" und ohne jegliche Anpassung übertragen wird.“

[Quelle: K. Dimitropoulos et al., A Brief Survey of Sim2Real Methods for Robot Learning, 2022]



Simulation → Realität

Sim2Real, sim-to-real



Simulation → Realität


Sim2Real, sim-to-real

Werden Modelle/Strategien immer besser in der realen Welt funktionieren, wenn die Simulationen immer besser/realistischer werden?

- Scheinbar nicht
- “Our results show that, contrary to expectation, adding fidelity does not help with learning; performance is poor due to slow simulation speed (preventing large-scale learning) and overfitting to inaccuracies in simulation physics.” aus: J. Truong et al., Rethinking Sim2Real: Lower Fidelity Simulation Leads to Higher Sim2Real Transfer in Navigation, 2022
- Übersetzung: “Unsere Ergebnisse zeigen, dass die Erhöhung der Genauigkeit entgegen den Erwartungen nicht zum Lernen beiträgt; die Leistung ist aufgrund der langsamen Simulationsgeschwindigkeit (die ein Lernen in großem Maßstab verhindert) und der Überanpassung an Ungenauigkeiten in der Simulationsphysik schlecht.”

Simulation → Realität

Sim2Real, sim-to-real



Simulation → Realität

Sim2Real, sim-to-real



Simulation → Realität

Sim2Real, sim-to-real

Inhalt

Modellierung der Umgebung von CPS:



- Modellierung mit KI/Deep Learning
 - Objektdetektion, -tracking, Bildsegmentierung
 - Spracherkennung
 - Verhaltensmodellierung von Fußgängern, Fahrzeugen

- Lernen in virtuellen Umgebungen (in einer Simulation)
 - 3D Simulation
 - Von der Simulation in die Realität (Sim2real)

- **Statische Modelle der Umgebung (Karte)**
 - **SLAM – Simultaneous Localization and Mapping**
 - Semantische Karte

HD Karte für autonomes Fahren


High Definition map



SLAM - Simultaneous Localization and Mapping


Wenn Sie keine Karte der Umgebung haben...

- Erstellung einer Karte der Umgebung durch ein autonom fahrendes System (bspw. Roboter)
- Problem:
 - Roboter weiß selbst nicht wo er sich befindet




SLAM - Simultaneous Localization and Mapping

Karte des Raumes 1.242 mit Teil des Flures
erstellt durch Turtlebot mit SLAM



SLAM - Simultaneous Localization and Mapping


Karte des Flures vor
Raum 1.242 erstellt durch
Turtlebot mit SLAM




SLAM - Simultaneous Localization and Mapping

Wenn Sie keine Karte der Umgebung haben...

- Erstellung einer Karte der Umgebung durch ein autonom fahrendes System (bspw. Roboter)
- Problem:
 - Roboter weiß selbst nicht wo er sich befindet
- Roboter hat Sensoren mit denen er seine Bewegung messen kann. Bspw.:
 - Odometer (misst lineare Geschwindigkeit)
 - Inertialmesssystem (misst Orientierung)



Dead Reckoning (Koppelnavigation)



Berechnung der aktuellen Position eines fahrenden Roboters auf der Grundlage einer zuvor ermittelten Position.

Mit Hilfe eines grundlegenden Kinematikmodells kann die relative Position des Fahrzeugs anhand von Messungen

- der Fahrgeschwindigkeit in Längsrichtung und
 - des aktuellen Lenkwinkels
- bestimmt werden.

Problem: Bestimmte Position wird mit der Zeit immer ungenauer.


SLAM - Simultaneous Localization and Mapping

Graph SLAM

- Landmark – Fixpunkt, dessen Position bekannt ist



Sensing the environment



29.08.2026

Prof. Dr. Daniel Gaida


Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Seite 109

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania

Sensing the environment



29.08.2026


Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania

Sensing the environment



Prof. Dr. Daniel Gaida


Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik


R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania

Alright, let's try to make a map.


In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...




In an ideal world...



In an ideal world...



In an ideal world...



29.08.2026


Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania

In an ideal world...



29.08.2026

Prof. Dr. Daniel Gaida


Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania

Wie lokalisieren wir uns in dieser Umgebung?


Partikelfilter: Vergleich Lidar-Messung mit Karte




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...



But in the real world...



But in the real world...



29.08.2026

Seite 137


Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme


Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania


But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...




But in the real world...



But in the real world...



But in the real world...





SLAM overview



Generally 2 different approaches:

- Filtering-based
 - Use Extended Kalman Filter or Particle Filter for state estimation and build the map based on that estimation
 - Examples are GMapping, HectorSLAM
- Graph-based
 - Use pose graphs to store constraints between pose estimations
 - Use optimization for loop-closure to correct for pose estimations
 - Examples are KartoSLAM and Cartographer
 - We'll be using slam_toolbox, also graph-based



Pose Graphs: Edge Constraints





Pose Graphs: Edge Constraints





Pose Graphs: Edge Constraints





Pose Graphs: Edge Constraints





Pose Graphs: Edge Constraints




Pose Graphs: Edge Constraints





Pose Graphs: Edge Constraints





Pose Graphs





Pose Graphs





Pose Graphs





Pose Graphs





Pose Graphs





Pose Graphs





Pose Graphs





Pose Graphs




Pose Graphs



Pose Graphs



Pose Graphs



29.08.2026

Prof. Dr. Daniel Gaida


Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik


Seite 168

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania


Pose Graphs




Pose Graphs




Pose Graphs




Pose Graphs




Pose Graphs




Pose Graphs




Pose Graphs




Pose Graphs




Pose Graphs




Pose Graph Optimization: Loop closure




Pose Graph Optimization: Loop closure



Pose Graph Optimization: Loop closure



Pose Graph Optimization: Loop closure



29.08.2026

Prof. Dr. Daniel Gaida


Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik


Seite 181

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering,
University of Pennsylvania


Pose Graph Optimization: Loop closure




Pose Graph Optimization: Loop closure




Pose Graph Optimization: Loop closure



Pose Graph Optimization: Loop closure



SLAM - Simultaneous Localization and Mapping



SLAM - Zusammenfassung

Graph-basiertes SLAM ist sensorunabhängig. Es werden nur 2 Arten von Sensoren benötigt:


- Einen, der relative Transformationen zwischen Posen (Position + Orientierung) messen kann (IMS, Odometrie, Wheel-Encoder usw.). Dieser Sensor wird verwendet, um Beschränkungen zwischen den berechneten Posen zu erstellen.
- Ein Sensor, der die absolute Beobachtung der Umgebung messen kann. (LiDARs, Kameras, usw.). Dieser Sensor wird für das Schließen von Schleifen (Loop Closure) verwendet.

Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
 - Objektdetektion, -tracking, Bildsegmentierung
 - Spracherkennung
 - Verhaltensmodellierung von Fußgängern, Fahrzeugen
- Lernen in virtuellen Umgebungen (in einer Simulation)
 - 3D Simulation
 - Von der Simulation in die Realität (Sim2real)
- **Statische Modelle der Umgebung (Karte)**
 - SLAM – Simultaneous Localization and Mapping
 - **Semantische Karte**

Semantische Karte (Semantic Mapping)



Semantische Karte (Semantic Mapping)

Workshop (15 Minuten)

Diskutieren Sie in Ihren Projektteams:

- Welche Sensoren und Aktoren nutzen Sie in Ihrem Projekt?
- Was ist die Umgebung in Ihrem Projekt?
- Wie modellieren Sie die Umgebung?
- Können Sie irgendeines der Themen von heute und letzter Woche in Ihrem Projekt nutzen?

Präsentation:

- Jedes Team präsentiert kurz ihr Thema und ihre Ergebnisse (2-3 Minuten)

Nächste Vorlesung und Fragen

- Robot Operating System
- Fragen?