Vorabfragen

- Ihr CPS soll in einer Fabrik Werkzeuge erkennen, darunter eine selten verwendete Spezialzange. Sie laden ein fertig trainiertes YOLO-Modell herunter. Was passiert vermutlich?
  a) Es erkennt die Zange, weil sie ein Objekt ist.
  b) Es erkennt sie nur, wenn sie einer der trainierten Kategorien ähnelt, und kann sie dann falsch benennen.
  c) Es meldet “unbekanntes Objekt”.
  d) Es lernt die Zange automatisch beim ersten Sehen.
- Sie trainieren einen Roboter in einer Simulation. Je realistischer die Simulation wird, desto besser sollte er in der Realität funktionieren. Stimmt das? Nennen Sie einen Grund dafür oder dagegen.
- Sie stehen mit verbundenen Augen in einem unbekannten Raum und sollen eine Karte zeichnen. Sie dürfen nur zählen, wie viele Schritte Sie in welche Richtung gehen. Was wird schiefgehen, und was bräuchten Sie, um den Fehler zu korrigieren?

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln



Cyber-Physische Systeme – WS 26/27

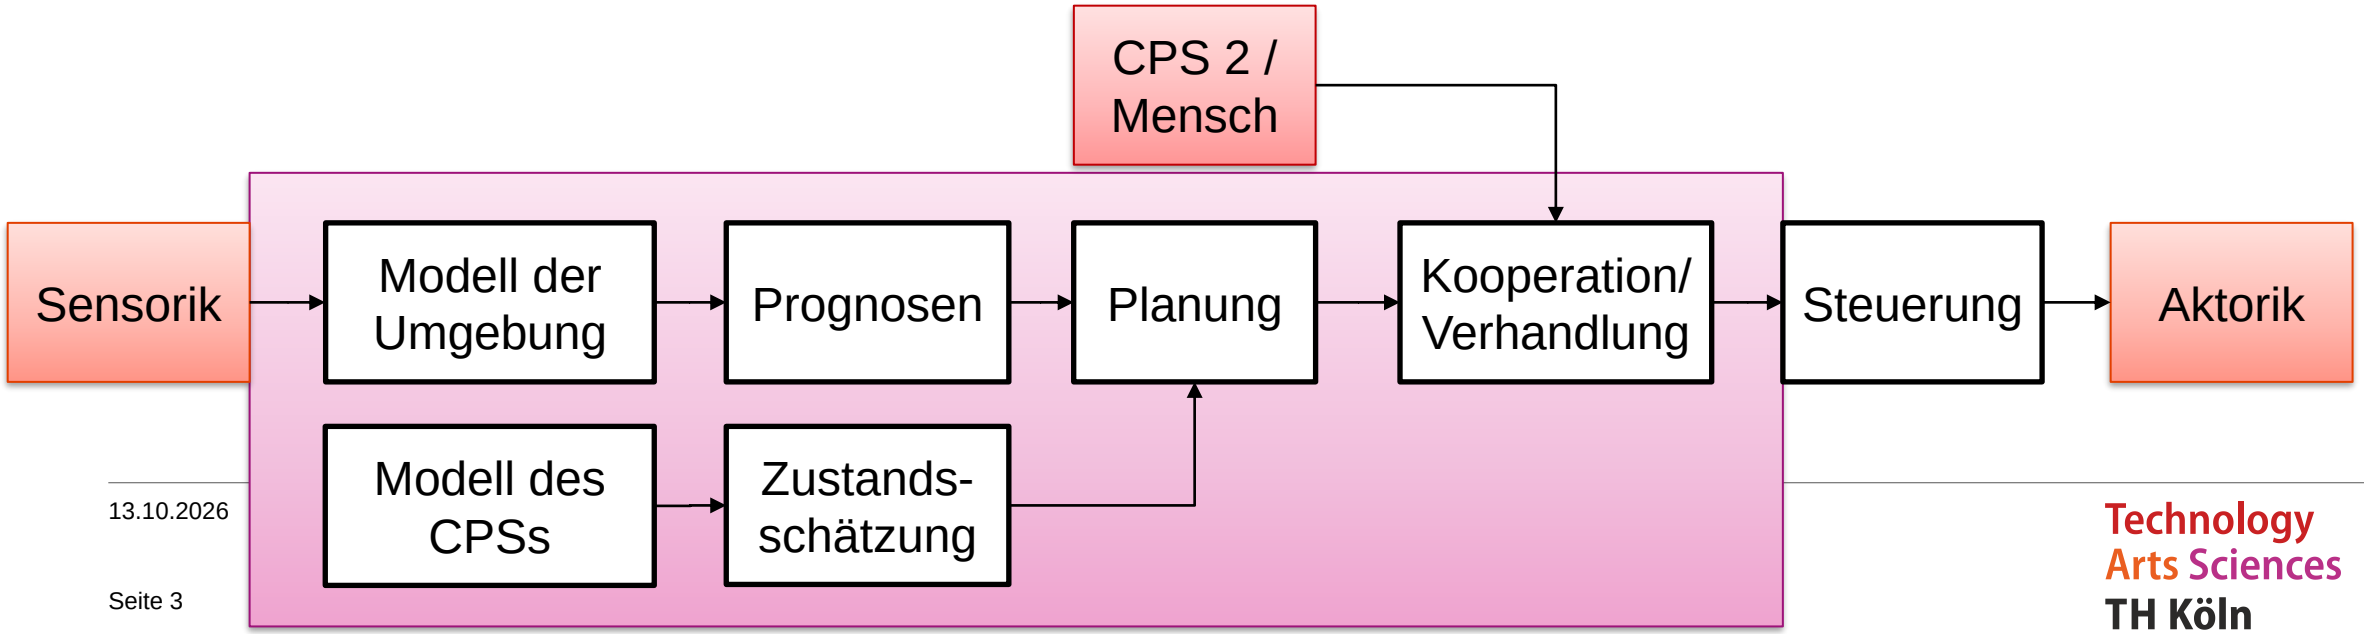
Gelesen von Prof. Dr. Daniel Gaida

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Technology
Arts Sciences
TH Köln

Inhalt

- Modell der Umgebung



Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - Spracherkennung
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - World Models
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
  - SLAM – Simultaneous Localization and Mapping
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)

Lernziel

Die Studierenden können geeignete Technologien zur Modellierung der Umgebung eines CPS auswählen, indem sie

- die Umgebung ihres CPS identifizieren und beschreiben,
- aus Deep Learning basierten Technologien wie Objekt Detektion, Objekt Tracking, Bildsegmentierung und Spracherkennung geeignete Technologien wählen,
- im Bedarfsfall 3D Simulationen zur Erstellung von Trainingsdaten nutzen,
- eine Karte der Umgebung erstellen und
- geeignete Bibliotheken und Tools zur Modellierung der Umgebung des CPS wählen,

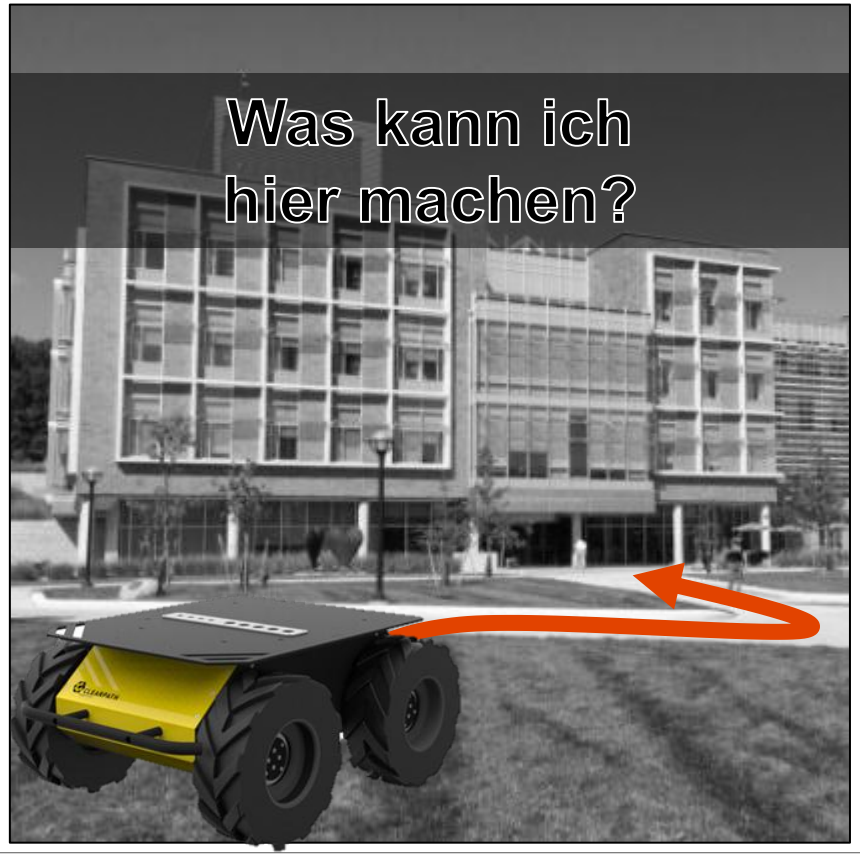
um später die Umgebung von Cyber-physischen Systemen modellieren zu können.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Welche Rolle spielt Computer Vision für CPS?

Ziel: CPS muss mit Umgebung interagieren können



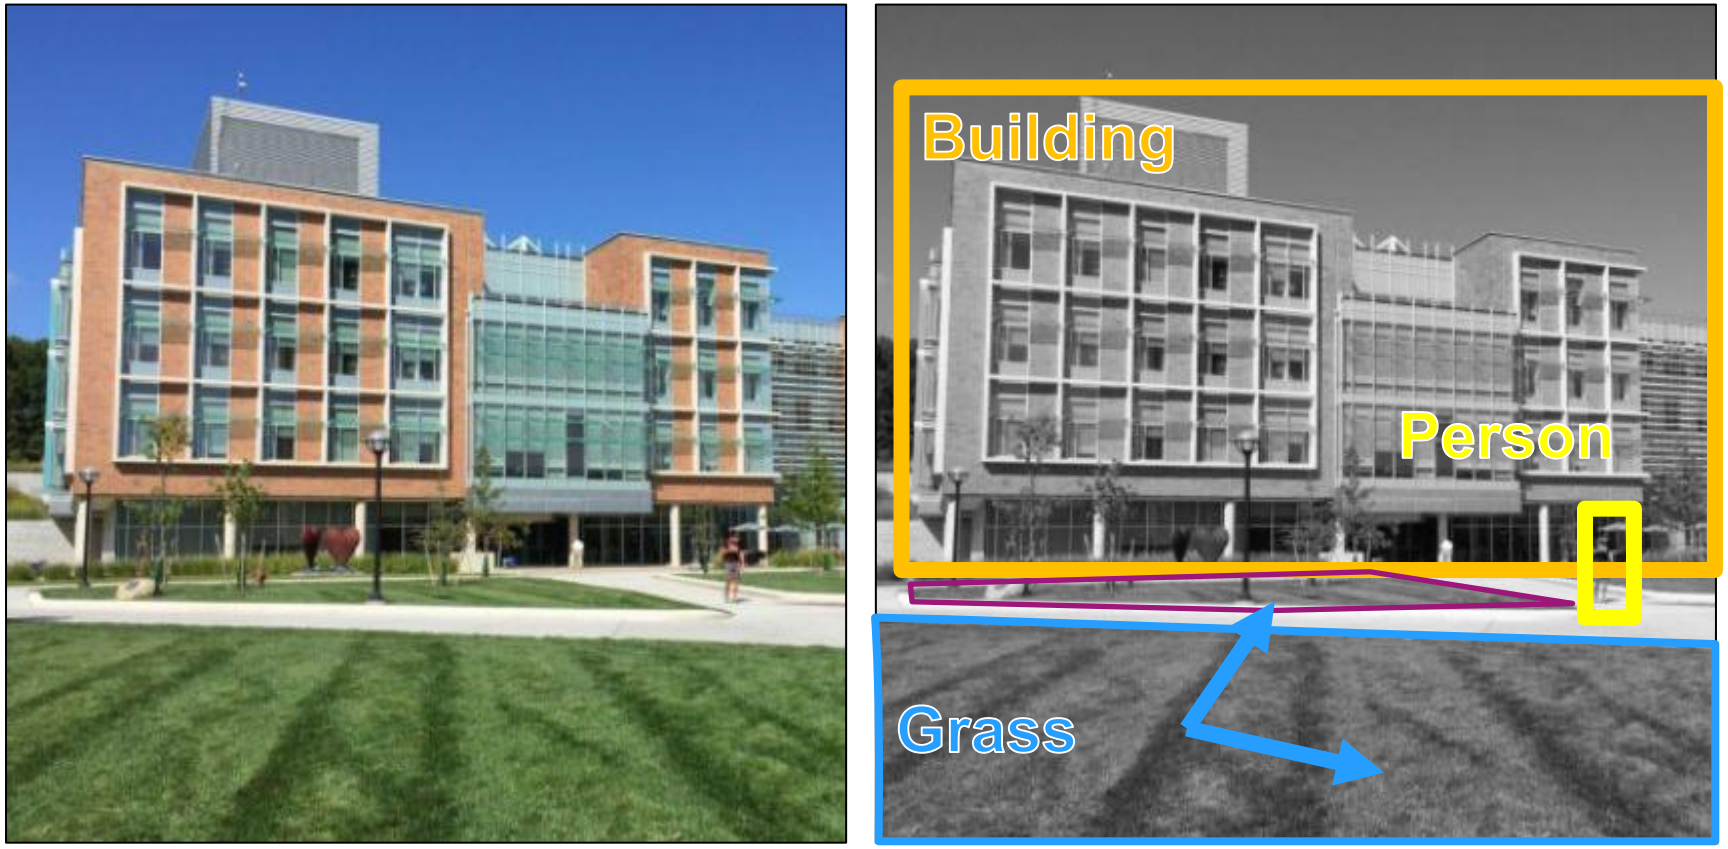


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: Computer Vision (EECS 442), Uni Michigan, Winter 21

Welche Rolle spielt Computer Vision für CPS?

Ziel: Benennung der Objekte in der Szene - Objektdetektion

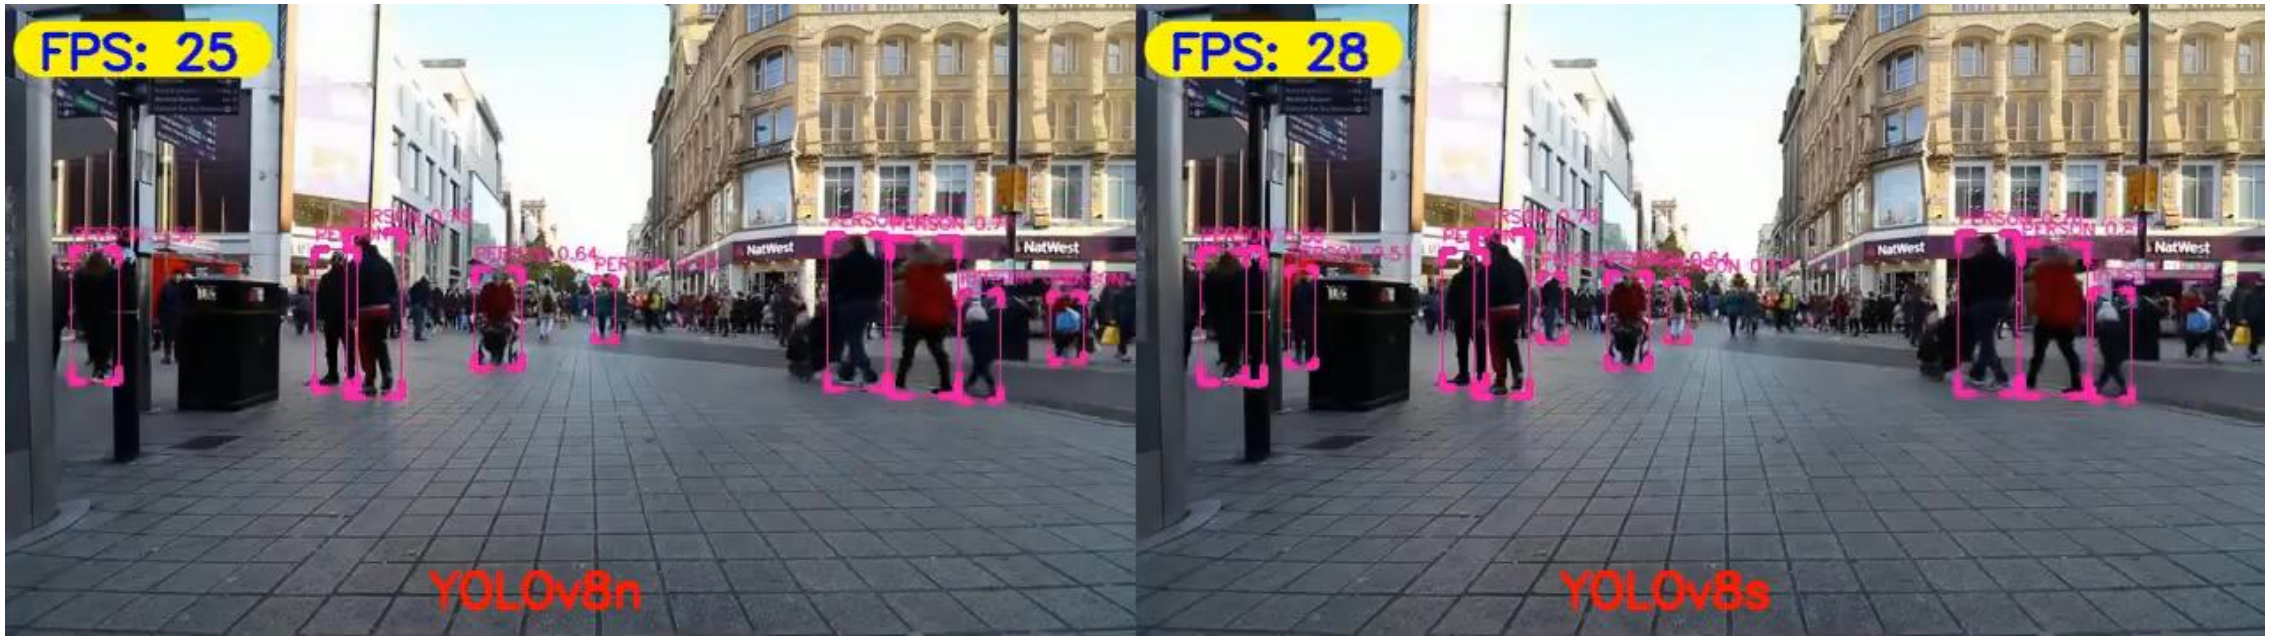


Quelle: Computer Vision (EECS 442), Uni Michigan, Winter 21

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

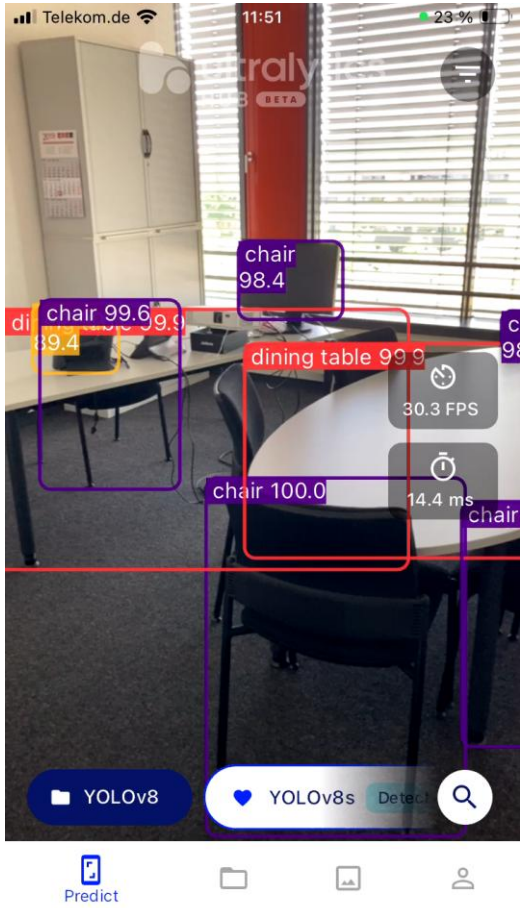
Welche Rolle spielt Computer Vision für CPS?

Objektdetektion



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
https://www.youtube.com/watch?v=YSgm0DQ9F9g

Welche Rolle spielt Computer Vision für CPS?
Objektdetektion



- YOLOv8
- Erkennt nur 80 verschiedene Objektkategorien (Autos, Fahrräder, Tiere, Regenschirme, …)



https://github.com/ultralytics/ultralytics

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Welche Rolle spielt Computer Vision für CPS?

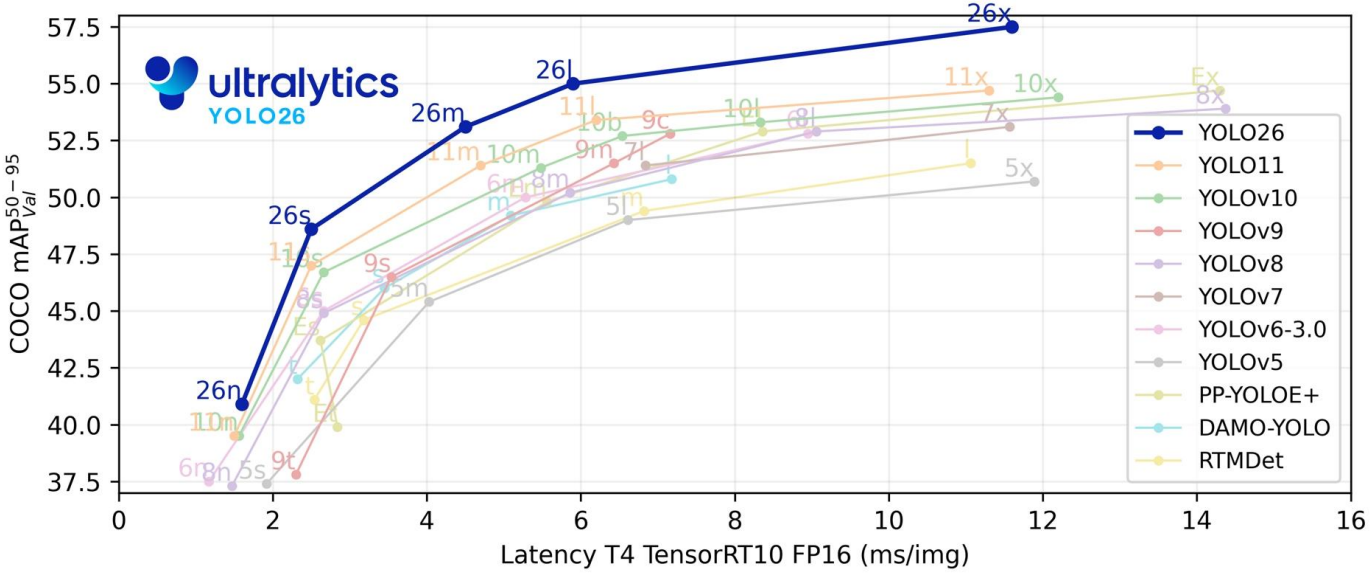
Objektdetektion

Deep Learning Modell

- YOLO – You only look once
- Redmon, J., & Farhadi, A. (2015). You only look once: Unified, real-time object detection. In Proc. IEEE CVPR (pp. 779-788).

- YOLO26 – plug & play
  https://github.com/ultralytics/ultralytics

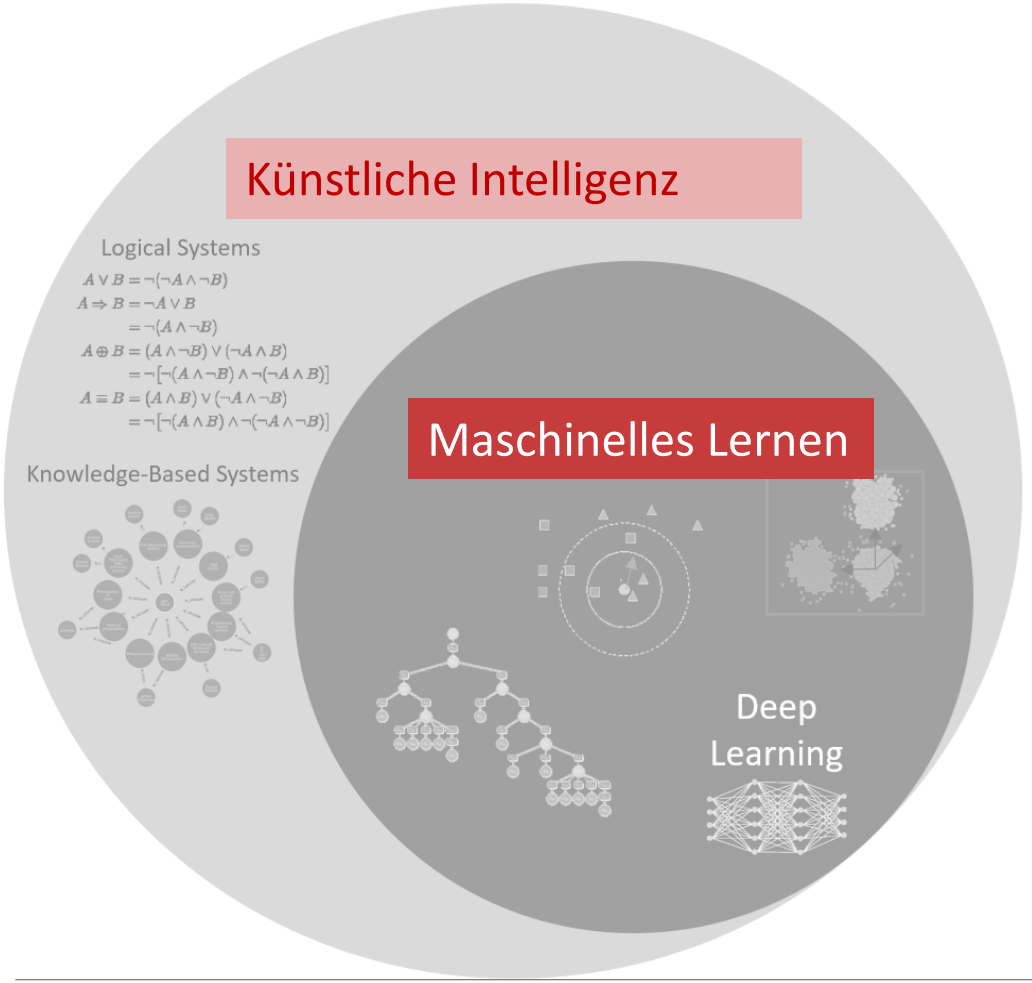
- Fertig trainierte Modelle in unterschiedlichen Größen herunterladbar
- Trainiert an COCO Datensatz
  - 80 verschiedene Objektkategorien (Autos, Fahrräder, Tiere, Regenschirme, …)



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bild: https://docs.ultralytics.com/models/yolo26#overview

KI, Machine Learning und Deep Learning – Was ist der Unterschied?



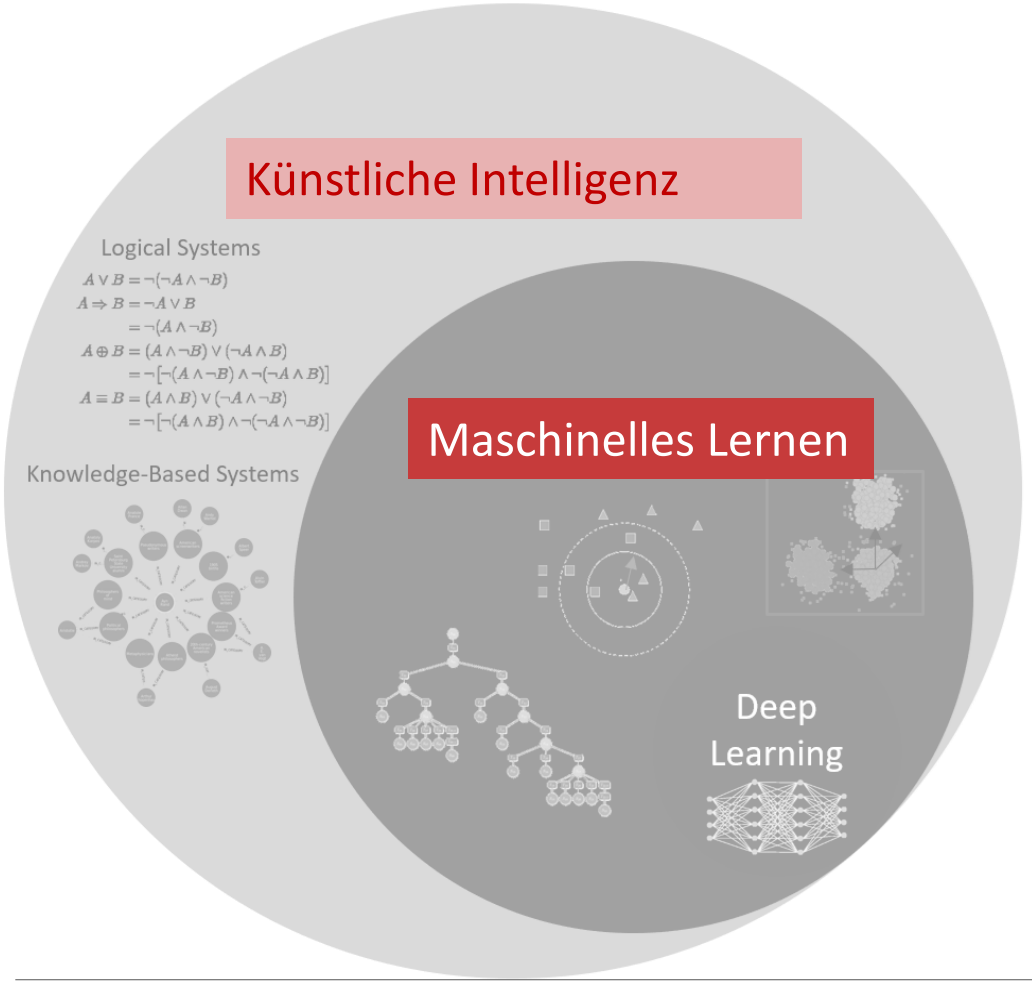
- Künstliche Intelligenz als Oberbegriff
  - Logisches Schließen, wissensbasierte Systeme
  - Optimierung
  - Statistische Analyse (maschinelles Lernen)

Künstliche Intelligenz (KI) beschäftigt sich mit Methoden, die es einem Computer ermöglichen, solche Aufgaben zu lösen, die, wenn sie vom Menschen gelöst werden, Intelligenz erfordern.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: data-science-blog.com

KI, Machine Learning und Deep Learning – Was ist der Unterschied?



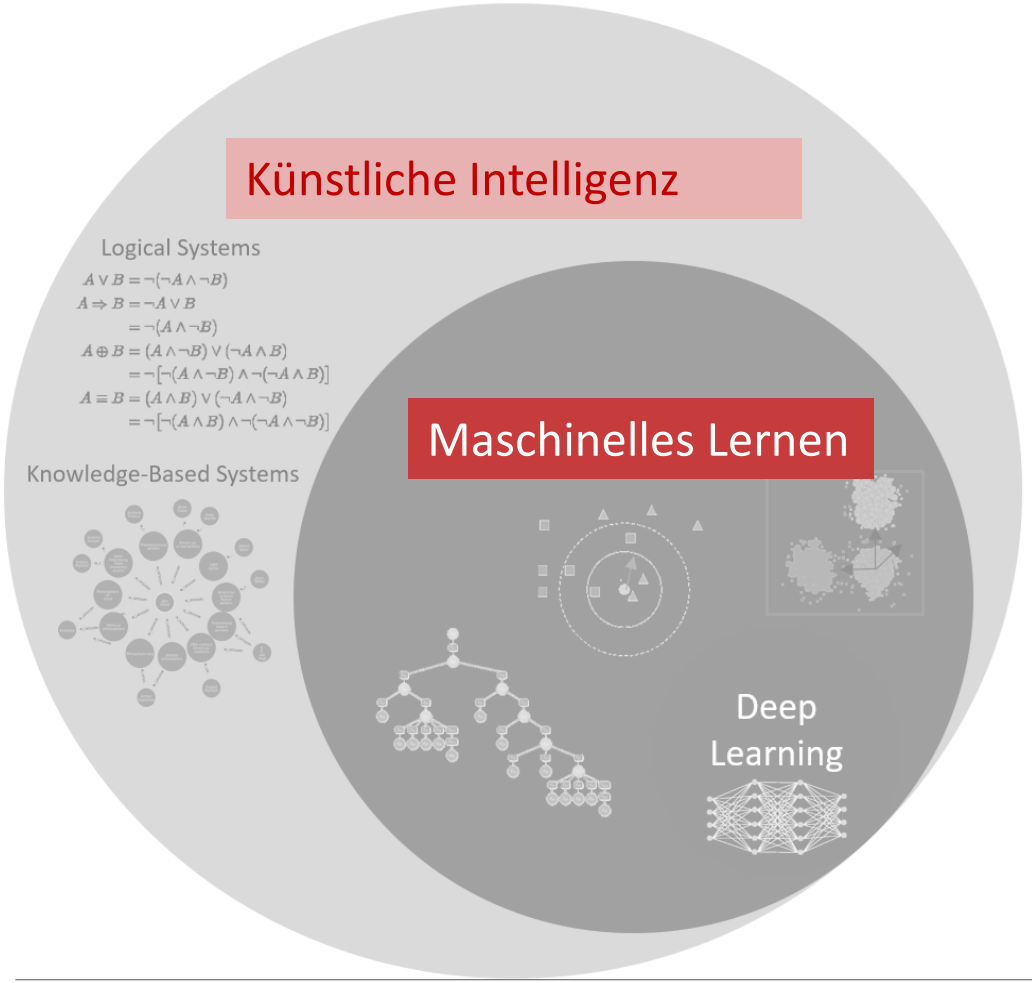
- Künstliche Intelligenz als Oberbegriff
  - Logisches Schließen, wissensbasierte Systeme
  - Optimierung
  - Statistische Analyse (maschinelles Lernen)

- Maschinelles Lernen
  - Systeme die aus Erfahrung & Beispielen lernen
  - Erkennen von Mustern in Daten
  - Eigenständiges Erlernen von Regeln

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: data-science-blog.com

KI, Machine Learning und Deep Learning – Was ist der Unterschied?



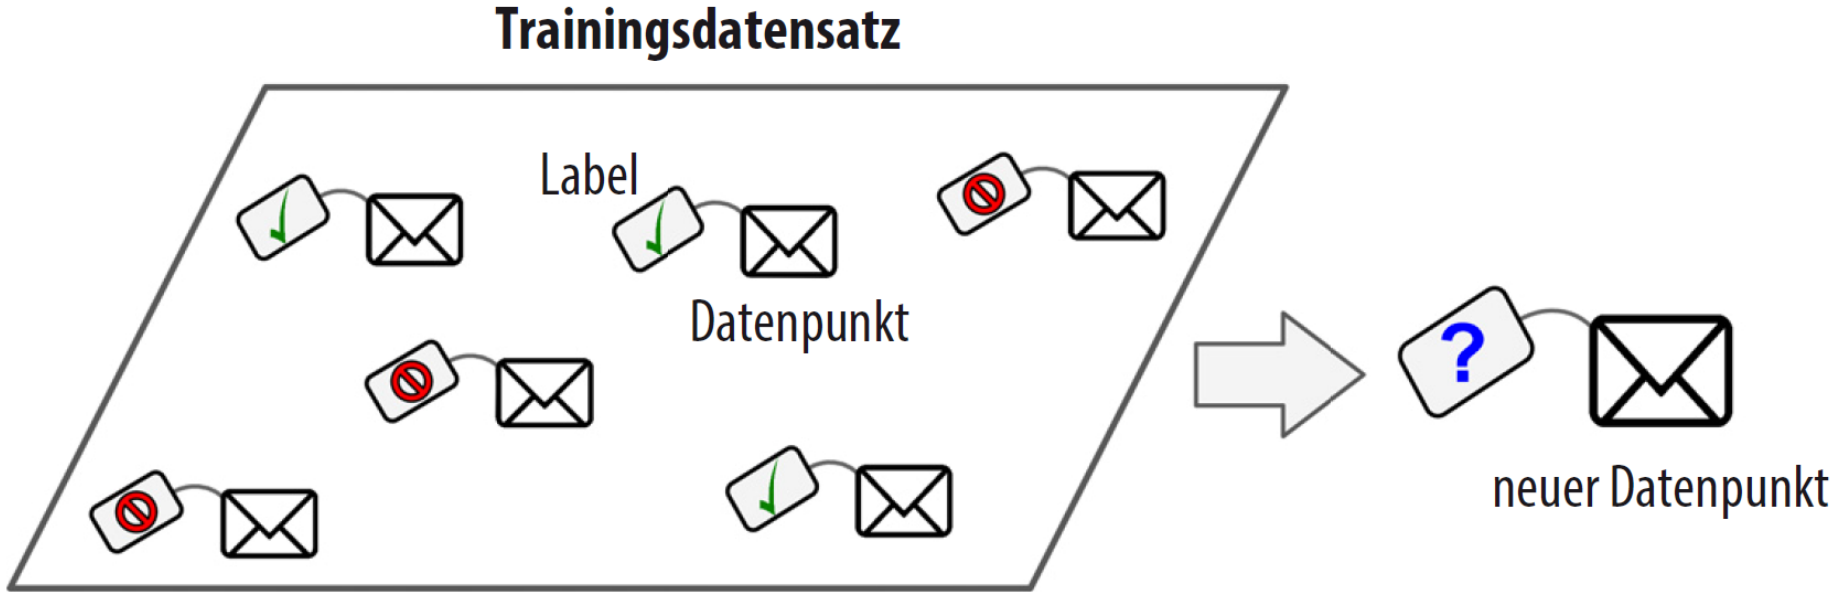
- Künstliche Intelligenz als Oberbegriff
  - Logisches Schließen, wissensbasierte Systeme
  - Optimierung
  - Statistische Analyse (maschinelles Lernen)
- Maschinelles Lernen
  - Systeme die aus Erfahrung & Beispielen lernen
  - Erkennen von Mustern in Daten
  - Eigenständiges Erlernen von Regeln
- Deep Learning
  - Ein Teilgebiet des maschinellen Lernens
  - Hype durch Erfolge in Bild- und Spracherkennung und Sprachverarbeitung

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: data-science-blog.com

Was ist Maschinelles Lernen?

- Ein Spamfilter ist ein maschinelles Lernprogramm, das aus Beispielen für Spam-E-Mails (z.B. vom Nutzer gelabelten) und gewöhnlichen E-Mails (Nicht-Spam) lernt, Spam zu erkennen.
- Maschinelles Lernen lernt diese Aufgabe aus dem Trainingsdatensatz, in dem es Muster/Zusammenhänge erkennt und wendet das erlernte Wissen auf neue E-Mails an, um Spam zu erkennen.

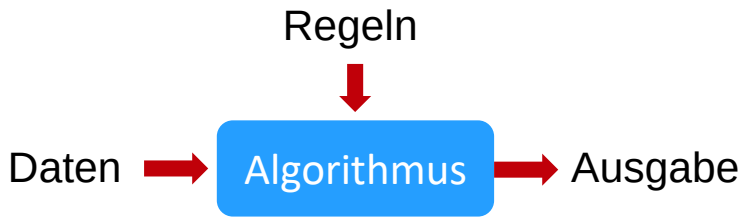


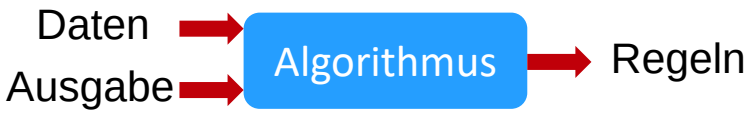
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bild: Géron, Aurélien. Hands-on machine learning with Scikit-Learn, Keras, and TensorFlow: Concepts, tools, and techniques to build intelligent systems. O'Reilly Media, 2019.

Warum wird Maschinelles Lernen verwendet?

Traditionelles Programmieren vs. Maschinelles Lernen





Traditionelle Programmierung

- Alle Regeln werden explizit programmiert
- Jede Regel basiert auf einer logischen Grundlage
- Der Algorithmus gibt eine Ausgabe aus, die der logischen Anweisung folgt
- Komplexe Systeme benötigen viele Regeln

→ **Instandhaltung kann schnell untragbar werden**

Maschinelles Lernen

- Soll dieses Problem überwinden
- Regeln werden basierend auf der Korrelation zwischen Daten und Ausgabe erlernt
- Regeln müssen nicht explizit geschrieben werden
- Wenn sich Daten ändern, können Regeln aktualisiert werden

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Quelle der Folie: Hahn-Schickard

Training von Deep Learning Modellen

Objektdetektion

Bevor Sie ein Deep Learning Modell selbst erstellen und trainieren:

- Es gibt sehr viele an sehr großen Datensätzen trainierte Modelle, die Sie herunterladen und direkt nutzen können
- Sie können dieses Modell auch als initiales Modell nutzen, welches Sie mit Ihren eigenen Daten verbessern können
  - Transfer Learning
  - Knowledge Distillation

- YOLO26 als Beispiel

- https://huggingface.co/models
- https://modelzoo.co/

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Objektdetektion mit Deep Learning

Trainingsdatensatz

```
0 0.0414228 0.659696 0.0828456 0.299007
11 0.0199709 0.268372 0.0397828 0.0651804
0 0.349451 0.584807 0.152251 0.418149
0 0.913659 0.58147 0.172332 0.45871
```

Trainingsdaten

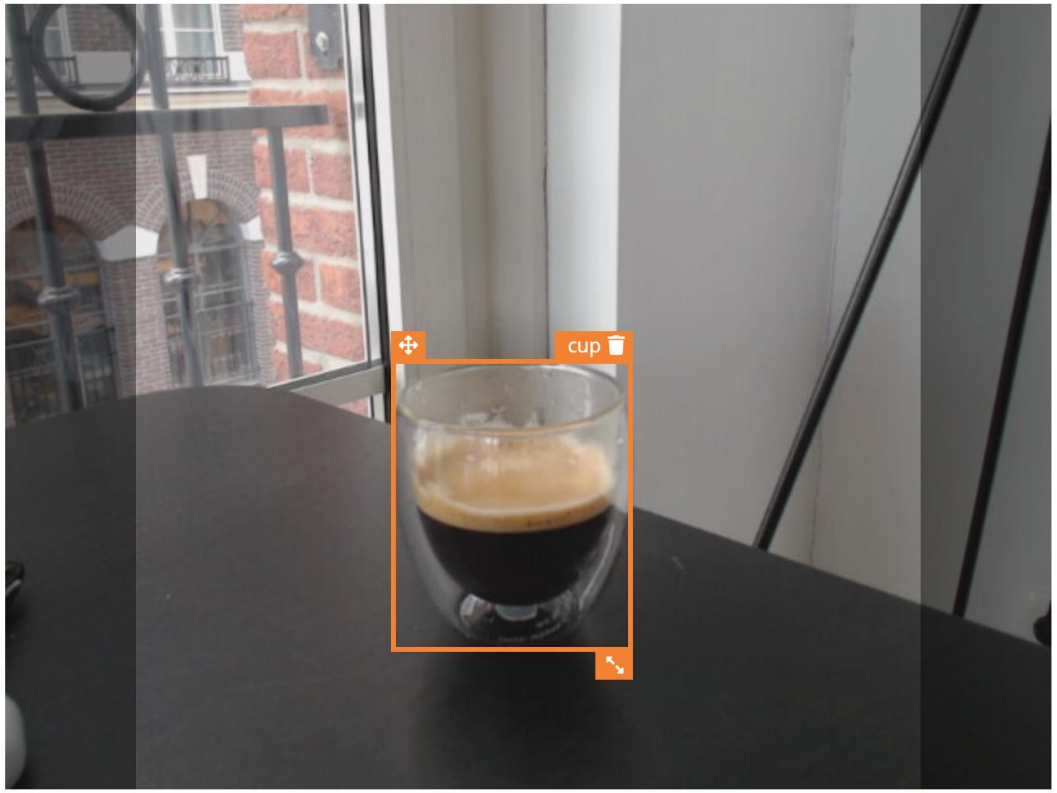
- Bilder

Markieren der Bilder (Labeling)

- Um jedes zu detektierende Objekt ist ein Rahmen zu zeichnen
- Pro Bild können mehrere Objekte markiert werden

Label

- Koordinaten des Rahmens
- Klasse des Objekts
- Für jedes Bild stehen Label in einer txt-Datei



https://www.edgeimpulse.com/blog/3-ways-to-do-ai-assisted-labeling-for-object-detection

https://www.youtube.com/watch?v=gRAyOPjQ9_s
Sehr gutes Tutorial zu YOLOv8 Training und Inferenz (15 Min.)

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Objektdetektion mit Deep Learning

Kostenlose Tools, die das Labeling beschleunigen

- https://www.cvat.ai/
- https://roboflow.com/#annotate
- https://pypi.org/project/labelImg/
- …

Bereits gelabelte Datensätze (Erster Schritt):

- https://paperswithcode.com/datasets?task=object-detection&page=1 (233 Object Det. Datensätze)
- Autonomes Fahren, Medizin, …
- https://datasetsearch.research.google.com/
- Wenn nicht genau der richtige Datensatz dabei ist, hilft es meistens dennoch das Modell auf dem ähnlichsten Datensatz zu trainieren und das Modell dann auf einem eigenen Datensatz weiter zu trainieren (Transfer Learning, finetuning)

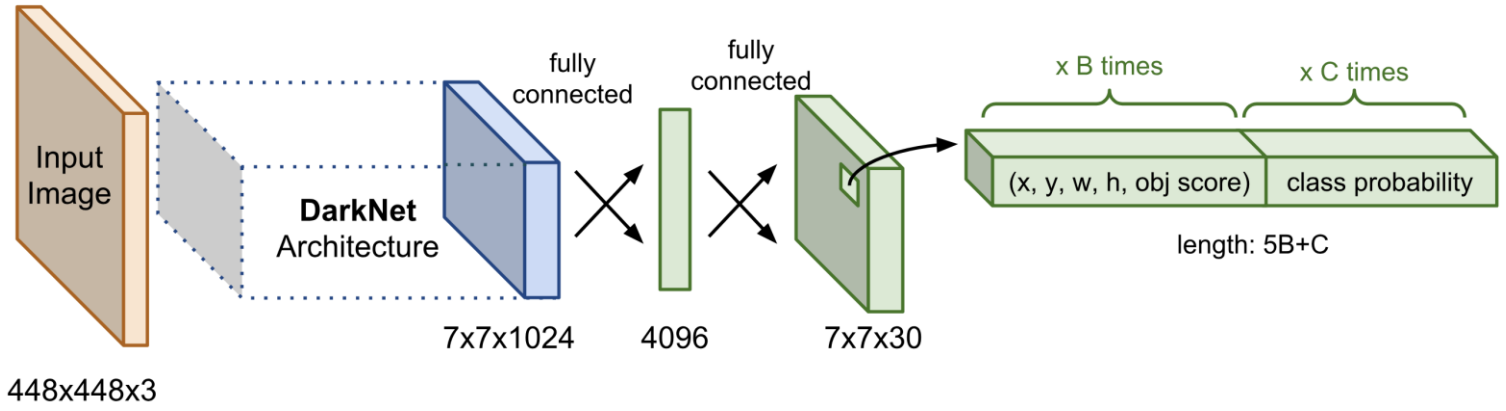
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Objektdetektion mit Deep Learning

Training – sehr viele Bilder und deren Label



```
0 0.0414228 0.659696 0.0828456 0.299007
11 0.0199709 0.268372 0.0397828 0.0651804
0 0.349451 0.584807 0.152251 0.418149
0 0.913659 0.58147 0.172332 0.45871
```



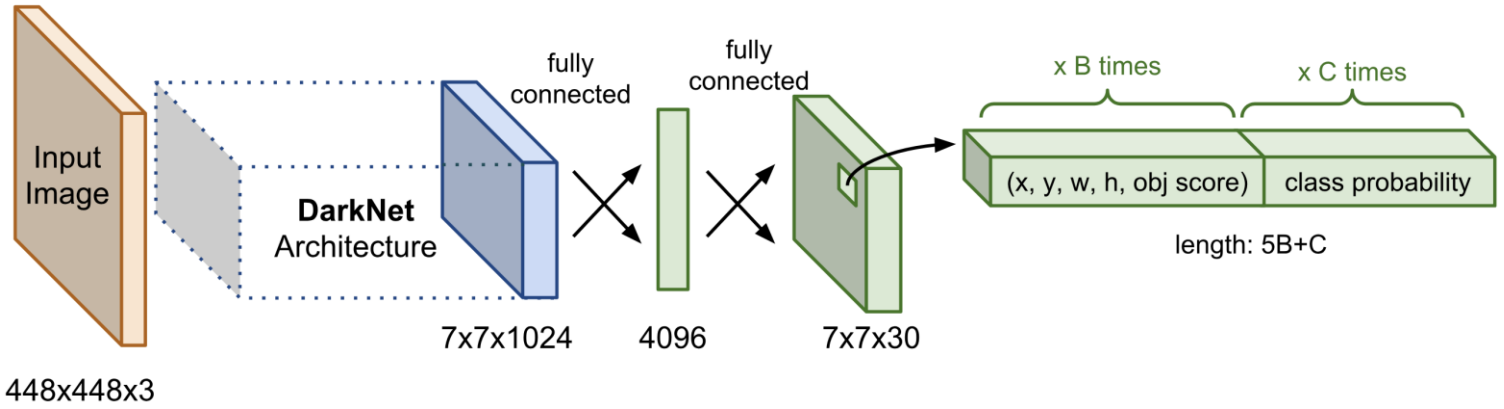
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

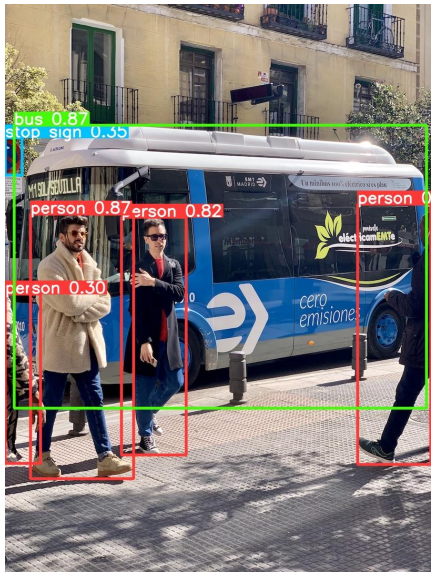
https://lilianweng.github.io/posts/2018-12-27-object-recognition-part-4/

Objektdetektion mit Deep Learning

Inferenz







Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://lilianweng.github.io/posts/2018-12-27-object-recognition-part-4/

YOLO Objektdetektion testen

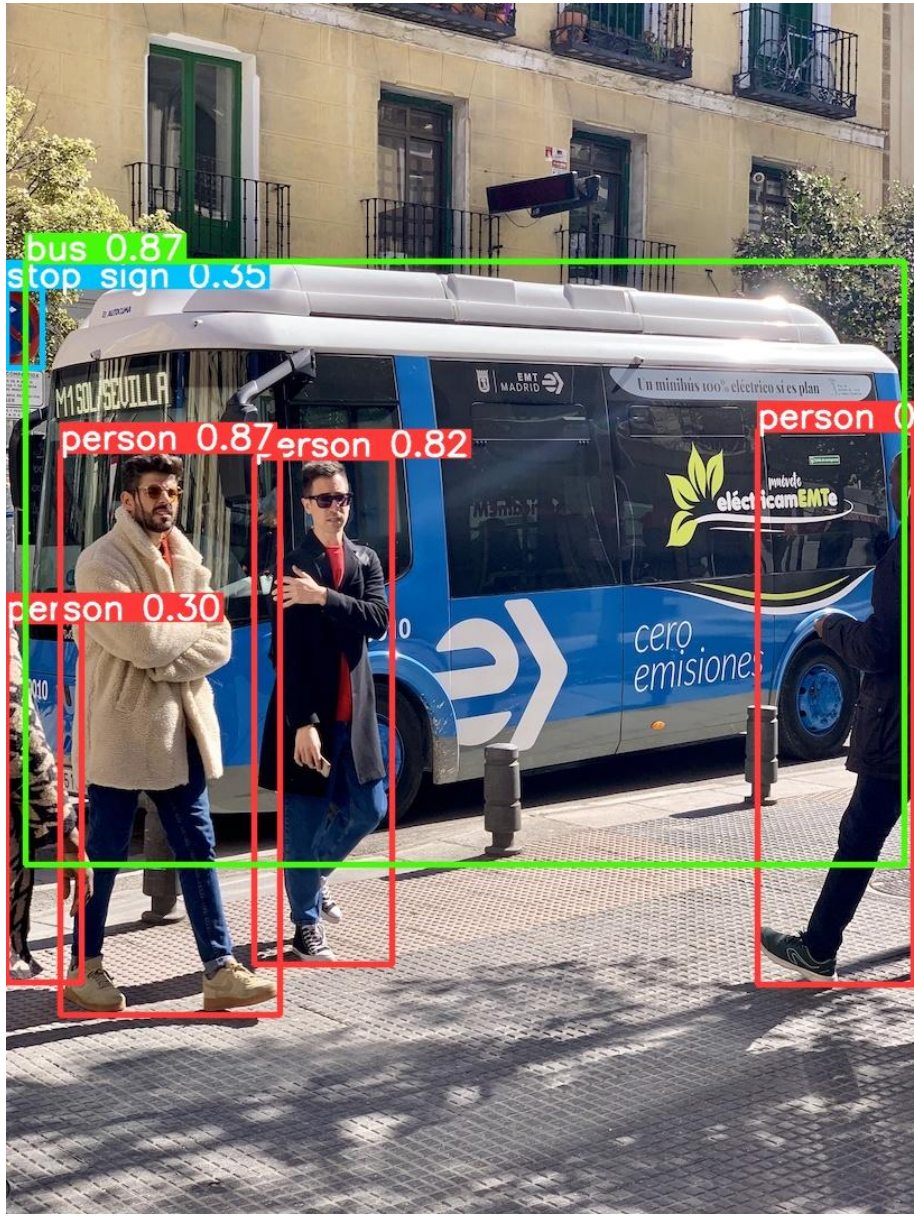
pip install ultralytics

from ultralytics import YOLO

model = YOLO("yolo26n.pt") # load an official model
Predict with the model
results = model("https://ultralytics.com/images/bus.jpg")

https://docs.ultralytics.com/tasks/detect/

Siehe Notebook: 01_objektdetektion_yolo26.ipynb



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Welche Rolle spielt Computer Vision für CPS?

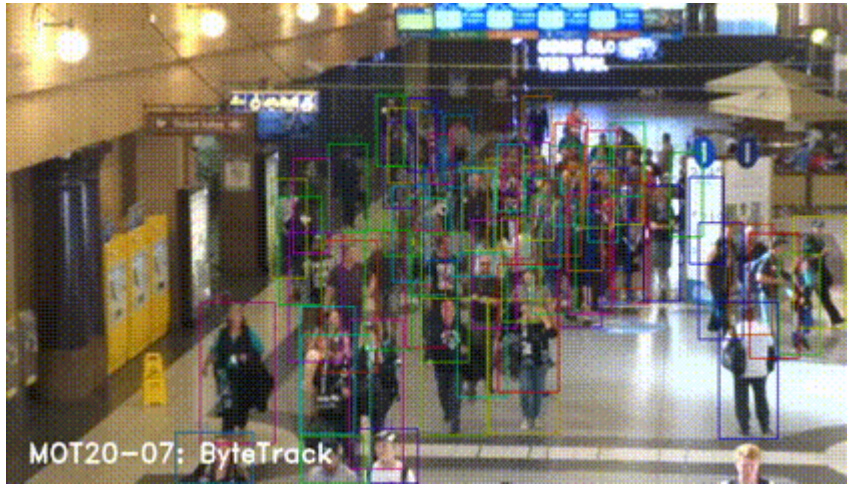
Ziel: Objekt Tracking

Objekt Tracking

- Eindeutige Objekt Detektion von beweglichen Objekten über eine Sequenz von Frames

YOLO hat Objekt Tracking integriert

https://docs.ultralytics.com/modes/track/



https://github.com/ifzhang/ByteTrack

Sehr gutes Tutorial von Roboflow zu Objekt Tracking mit YOLOv8 (14 Min.):

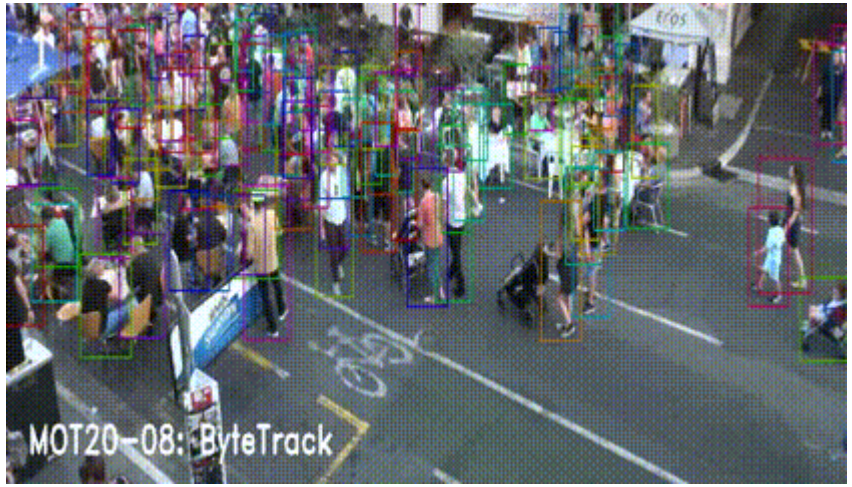
https://www.youtube.com/watch?v=Mi9iHFd0_Bo

Welche Rolle spielt Computer Vision für CPS?

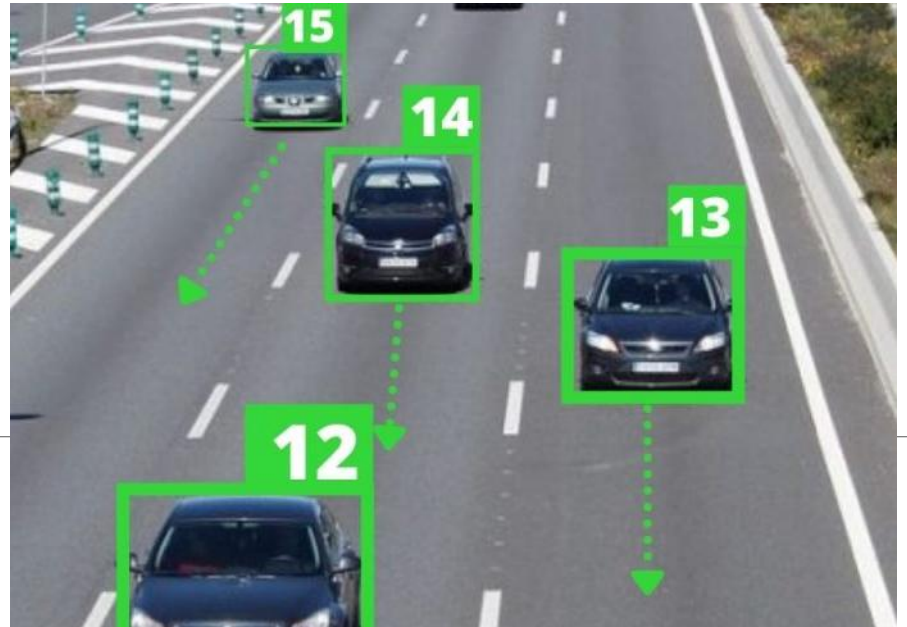
Ziel: Objekt Tracking

Vorgehensweise:

- Tracking-by-Detection
  - Objekt Detektion (bspw. mit YOLO)
  - Tracking der detektierten Objekte
    - Kalman Filter prädiziert wo Objekt in nächstem Frame sein könnte. In dieser Region wird dann für das nächste Frame Objekt Detektion ausgeführt.



https://github.com/ifzhang/ByteTrack



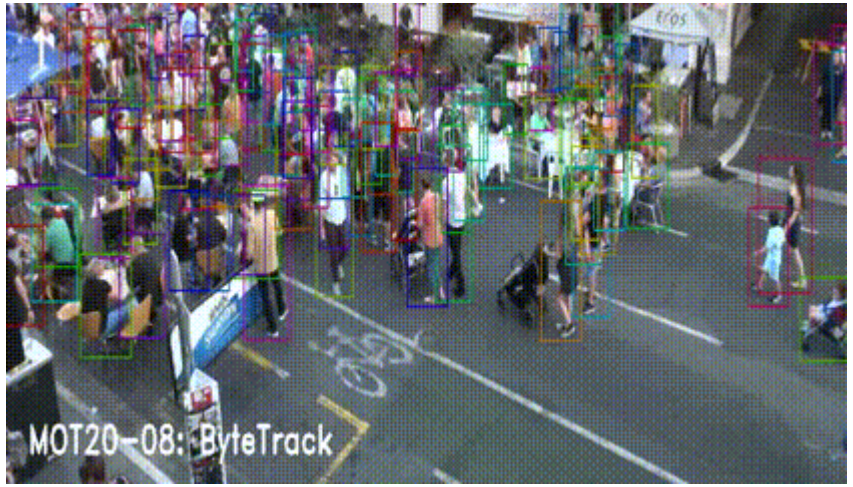
https://pysource.com/2021/11/02/kalman-filter-predict-the-trajectory-of-an-object/

Welche Rolle spielt Computer Vision für CPS?

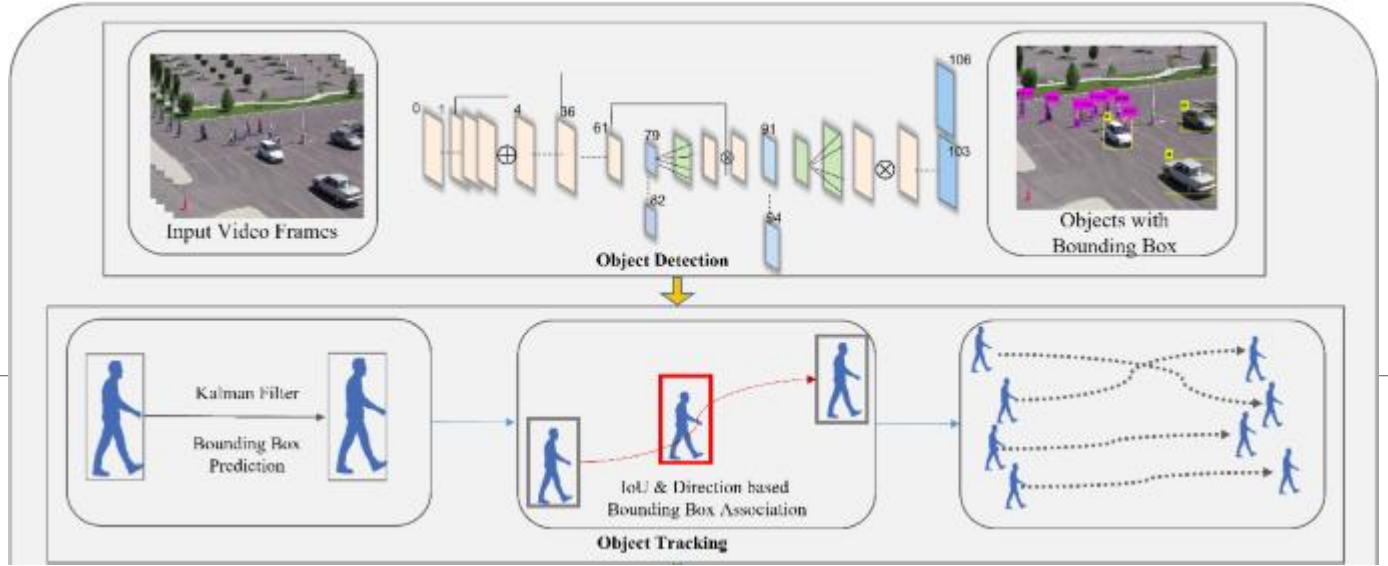
Ziel: Objekt Tracking

Vorgehensweise:

- Tracking-by-Detection
  - Objekt Detektion (bspw. mit YOLO)
  - Tracking der detektierten Objekte
    - Kalman Filter prädiziert wo Objekt in nächstem Frame sein könnte. In dieser Region wird dann für das nächste Frame Objekt Detektion ausgeführt.
  - Re-Identifikation (ist das Objekt noch das gleiche?)



https://github.com/ifzhang/ByteTrack



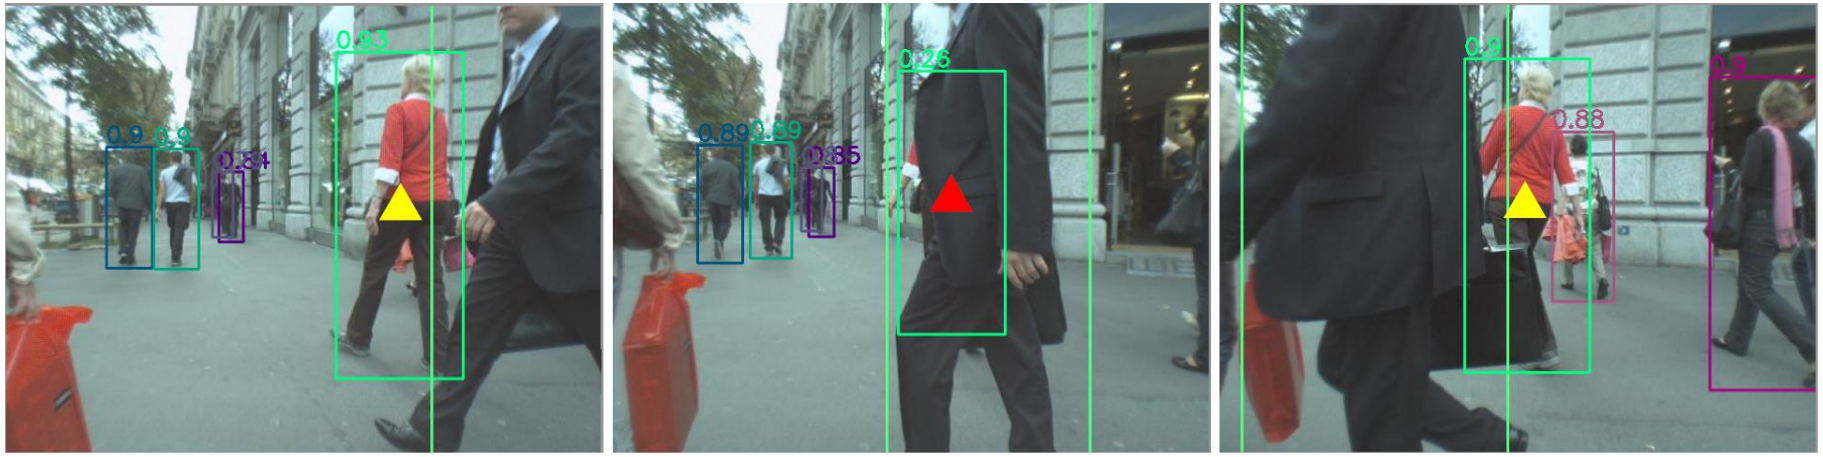
A. Patel et al., Motion-compensated online object tracking for activity detection and crowd behavior analysis, The visual Computer, 2022

Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Tracking

In YOLO integriert („State of the Art“ des Objekt Trackings):

- ByteTrack, https://github.com/ifzhang/ByteTrack
- Beibehalten von Bounding Boxen, die temporär nur einen geringen Score erhalten



Y. Zhang et al., ByteTrack: Multi-Object Tracking by Associating Every Detection Box, 2022

- BoT-SORT, https://github.com/NirAharon/BoT-SORT
  - Erweiterung von ByteTrack um Kompensation der Bewegung der Kamera, verbesserter Zustandsvektor des Kalman Filters, …

YOLO26 Objekttracking testen

```
from ultralytics import YOLO

model = YOLO("yolo26n.pt")  # Load an official Detect model

# Perform tracking with the model with ByteTrack
results = model.track("https://youtu.be/LNwODJXcvt4", show=True, tracker="bytetrack.yaml")
```

https://docs.ultralytics.com/modes/track/

s. Notebook: 02_objekttracking_yolo26.ipynb

Welche Rolle spielt Computer Vision für CPS?

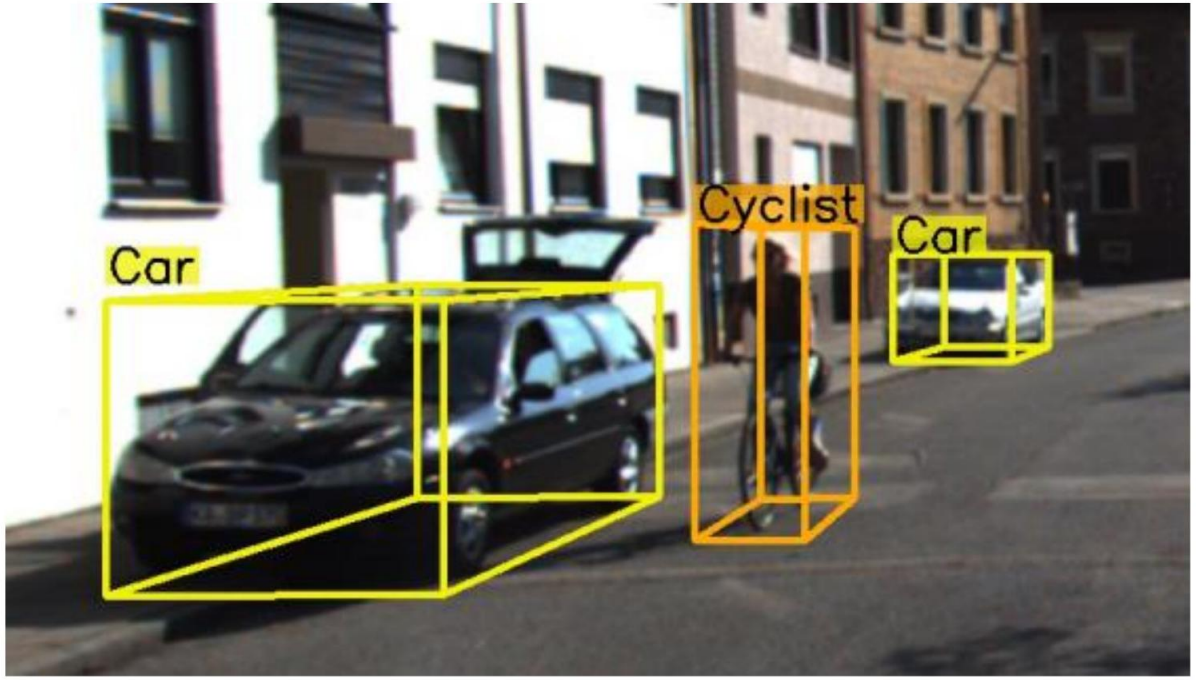
Ziel: 3D Objekt Tracking (Detektion)

Mit Lidar (oder Radar) Daten können Sie Objekte als 3D Objekte tracken/detektieren

- K. Chen et al., MVLidarNet: Real-Time Multi-Class Scene Understanding for Autonomous Driving using multiple views, 2020
- Popov et al., NVRadarNet: Real-Time Radar Obstacle and Free Space Detection for Autonomous Driving, 2023

Bibliotheken:

- github.com/open-mmlab/mmdetection3d
- github.com/isl-org/Open3D-ML



Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Detektion von beliebigen Objektkategorien

- Algorithmen der Objekt Detektion funktionieren nur für die Objektkategorien für die sie trainiert wurden
- YOLO wurde trainiert mit COCO Datensatz
  - 80 verschiedene Objektkategorien (Autos, Fahrräder, Tiere, Regenschirme, …)
- Mit Trainingsdaten von weiteren Objektkategorien können Sie auch diese detektieren
- Was ist, wenn Sie „beliebige“ Objektkategorien detektieren möchten?
  - Open-Vocabulary Objekt Detektion
  - Trainiert mit Millionen von Bildern aus dem Internet und deren Bildbeschriftungen
  - YOLOE - Real-Time Seeing Anything
    - https://docs.ultralytics.com/models/yoloe

Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Detektion von beliebigen Objektkategorien

- Open-Vocabulary Objekt Detektion
- https://github.com/ailab-cvc/yolo-world



Welche Rolle spielt Computer Vision für CPS?

Ziel: Objekt Detektion von beliebigen Objektkategorien

```
from ultralytics import YOLO

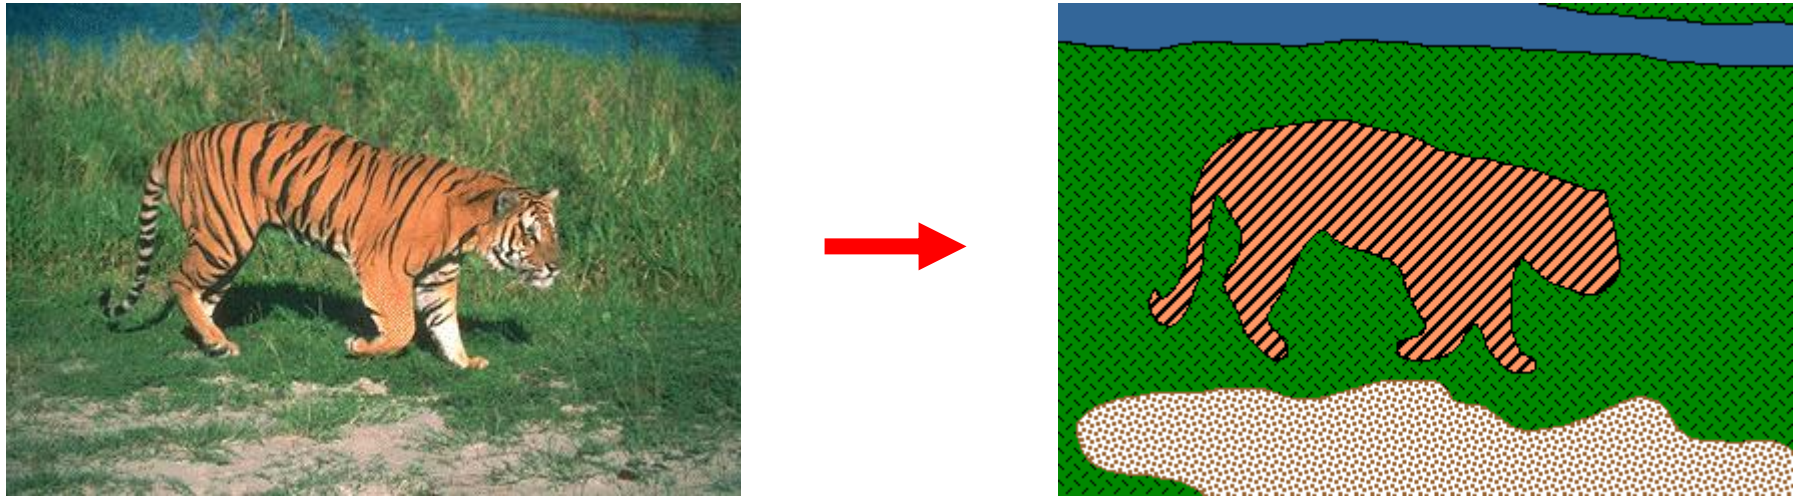
model = YOLO("yoloe-11s-seg.pt")          # Initialize a model
model.set_classes(["person", "bus"])      # Define custom classes

results = model.predict("path/to/image.jpg")  # Run inference to detect your custom classes
results[0].show()                             # Show results
```

s. Notebook 03_AppObjectDetection.ipynb

Welche Rolle spielt Computer Vision für CPS?

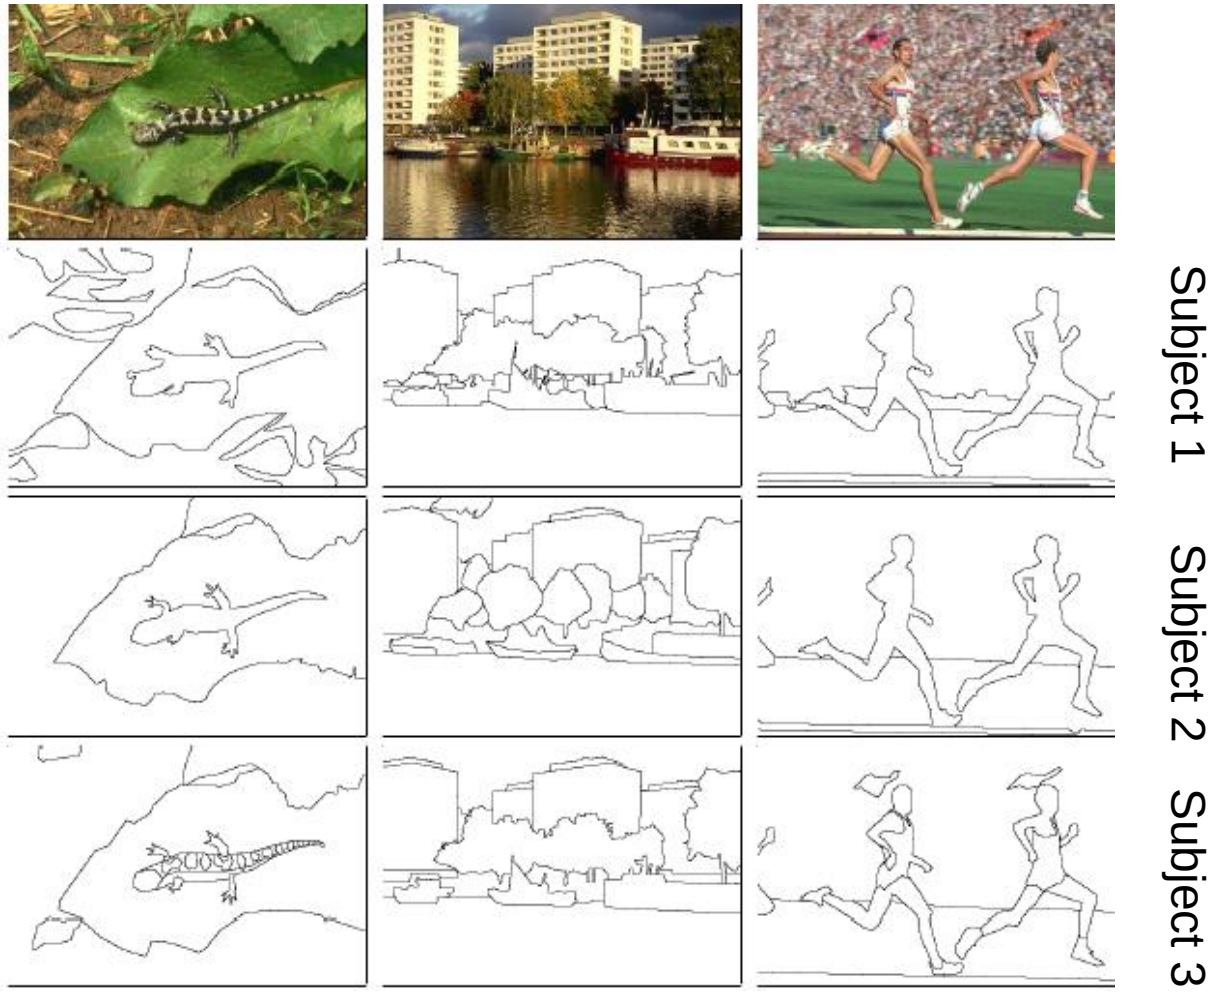
Ziel: Bildsegmentierung



Welche Rolle spielt Computer Vision für CPS?

Ziel: Bildsegmentierung

- Es gibt keine objektive Definition einer „richtigen“ Segmentierung!
- Segmentierung wird durch Menschen vorgegeben

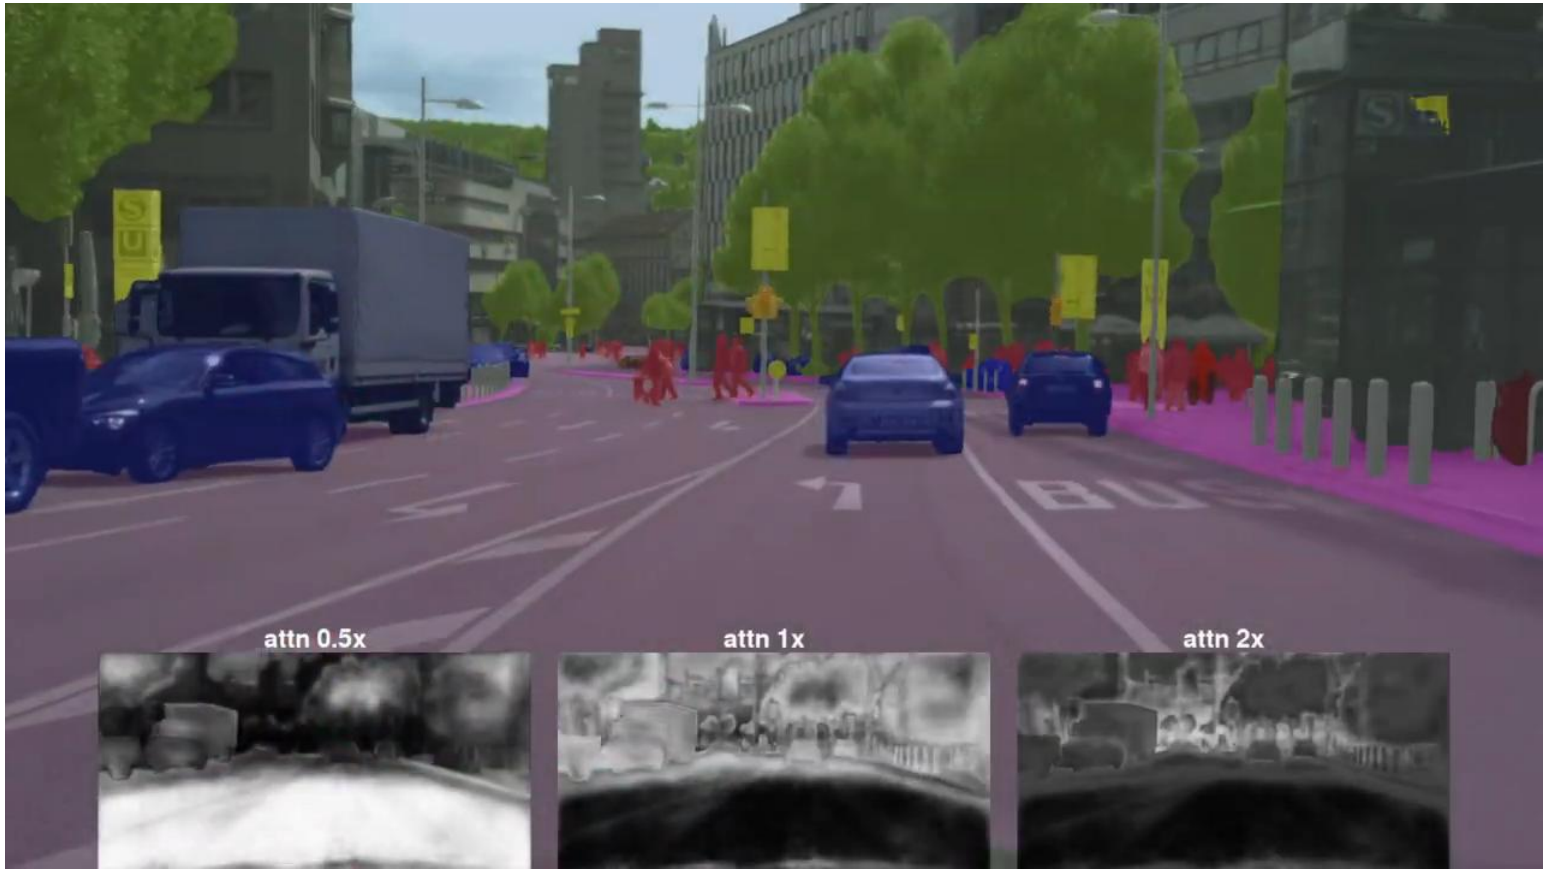


http://www.eecs.berkeley.edu/Research/Projects/CS/vision/grouping/resources.html

Quelle: Computer Vision (16-385), CMU, Spring 2020

Welche Rolle spielt Computer Vision für CPS?

Ziel: Bildsegmentierung



Bildsegmentierung mit Deep Learning

Trainingsdaten

Eingangsdaten



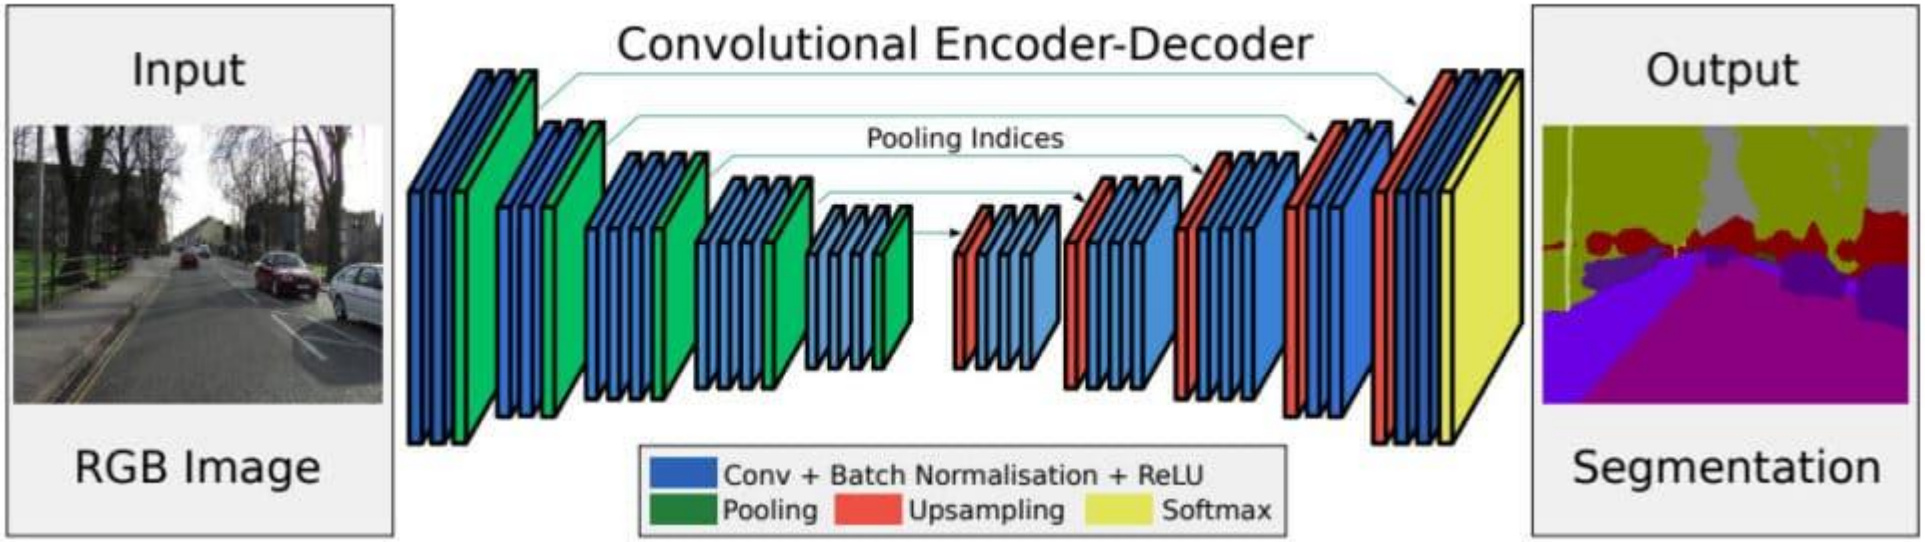
Ausgangsdaten



Quelle für Trainingsdaten: https://paperswithcode.com/datasets?task=semantic-segmentation (261 Datensätze)

Bildsegmentierung mit Deep Learning

Training des Deep Learning Modells (bspw. Autoencoder)



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

V. Badrinarayanan et al., SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation, 2016

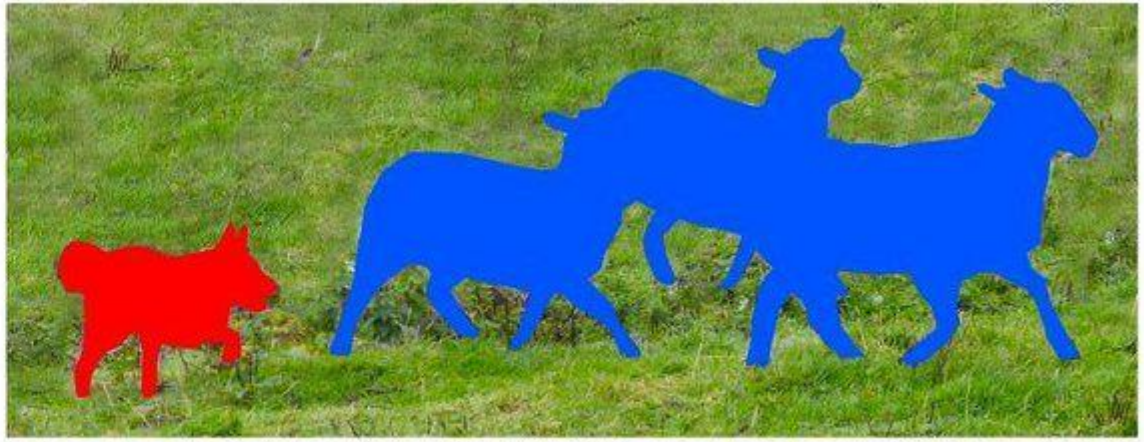
Bildsegmentierung mit Deep Learning

Instance Segmentation vs. Semantic Segmentation

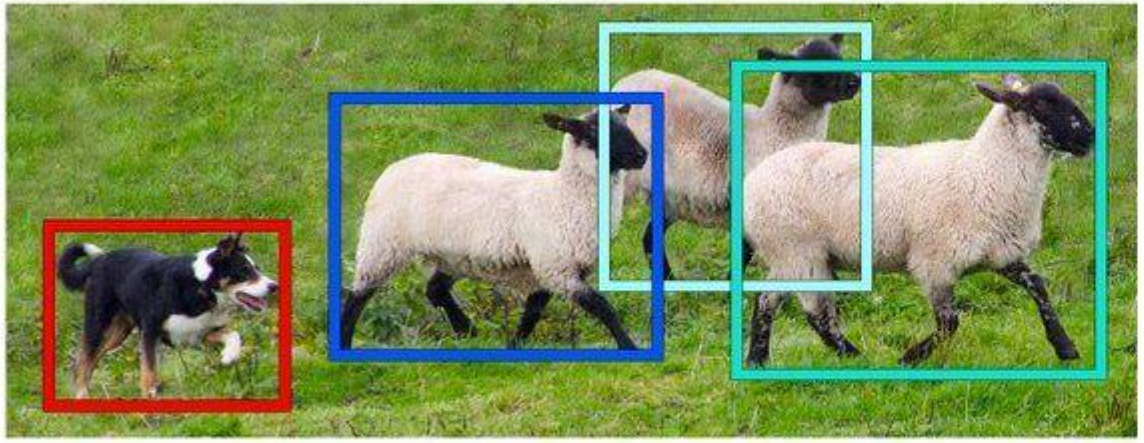
https://blog.roboflow.com/difference-semantic-segmentation-instance-segmentation/



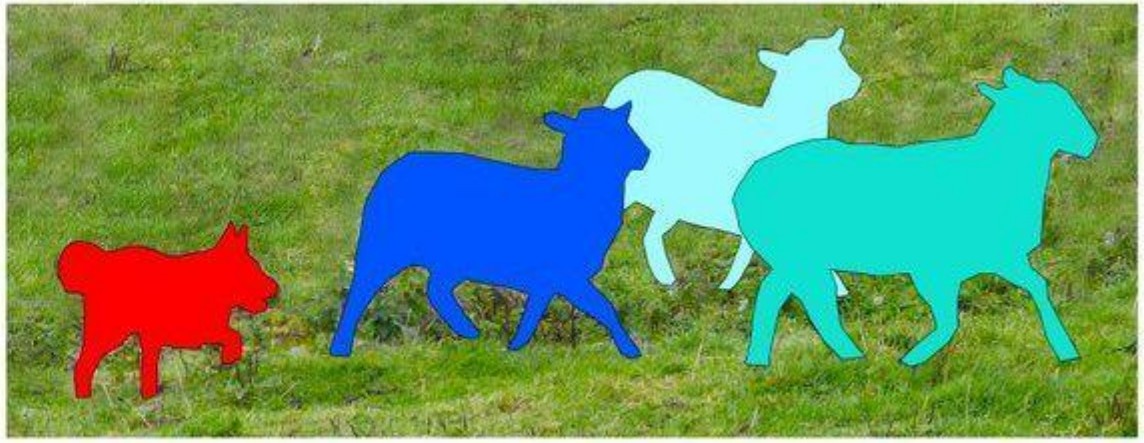
Image Recognition



Semantic Segmentation



Object Detection



Instance Segmentation

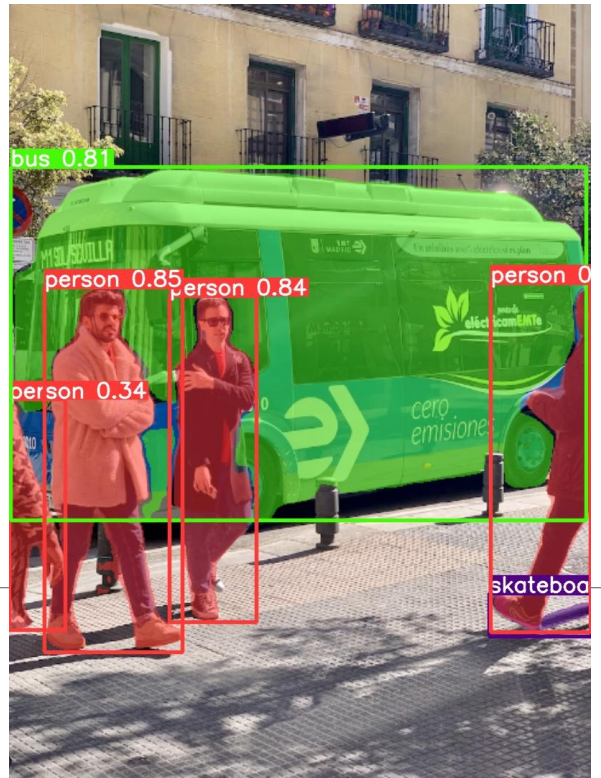
Bildsegmentierung mit Deep Learning

YOLO26 kann auch Instance Segmentation (https://docs.ultralytics.com/tasks/segment/)

Gutes Tutorial zu YOLOv8 zu Image Segmentation und Objekt Detektion, nur Inferenz (13 Min.)
https://www.youtube.com/watch?v=75LI9MI9eEo

```
from ultralytics import YOLO
model = YOLO("yolo26n-seg.pt")  # load a model
# Predict with the model
results = model("https://ultralytics.com/images/bus.jpg")
```

s. Notebook: 06_objektdetektion_yolo26.ipynb



Welche Rolle spielt Computer Vision für CPS?

Bildsegmentierung: Instance Segmentation mit YOLOv8



Open-Vocabulary Image Segmentation



Segment Anything Modell (SAM 3)

- github.com/facebookresearch/segment-anything
- https://docs.ultralytics.com/models/sam-3
- Foundation Modell für Bildsegmentierung; Promptable

- FastSAM (https://docs.ultralytics.com/models/fast-sam/)
  - Yolov8 Segmentierungsmodell und anschließend Fokus auf die gewünschten Begriffe

- Grounded Segment Anything
  - Grounding DINO (Open-Vocabulary Objekt Detektion) – lokalisiert die Objekte; geg. Prompt
    - https://github.com/IDEA-Research/Grounding-DINO-1.5-API
  - Segment Anything Modell – segmentiert die lokalisierten Objekte
  - https://github.com/IDEA-Research/Grounded-SAM-2

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle:
https://huggingface.co/docs/transformers/v4.46.0/en/model_doc/sam

Open-Vocabulary Image Segmentation

```
from ultralytics import FastSAM


# Define an inference source
source = "path/to/bus.jpg"
# Create a FastSAM model
model = FastSAM("FastSAM-s.pt")  # or FastSAM-x.pt
# Run inference on an image
everything_results = model(source, device="cpu", retina_masks=True, imgsz=1024,
conf=0.4, iou=0.9)


# Run inference with texts prompt
results = model(source, texts="a photo of a dog")
```

Jupyter Notebook zu FastSAM

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://docs.ultralytics.com/models/fast-sam/

Multimodale Large Language Modelle: Meta Llama4

Which tools in the image can be used for measuring length?



Provide bounding boxes for every recognized item.



Quelle: https://www.deeplearning.ai/short-courses/building-with-llama-4/

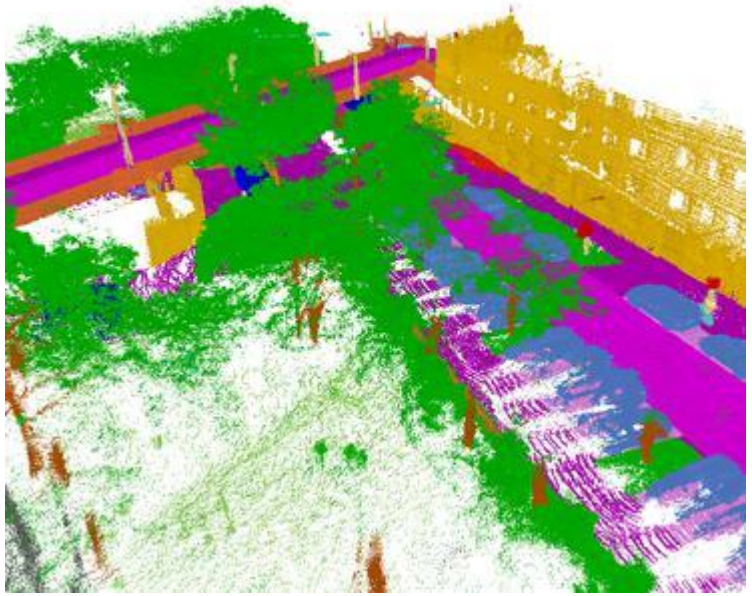
3D Bildsegmentierung

Segmentierung der Punktwolken von Lidar (oder Radar) Sensordaten

https://github.com/isl-org/Open3D-ML

Bildquelle:

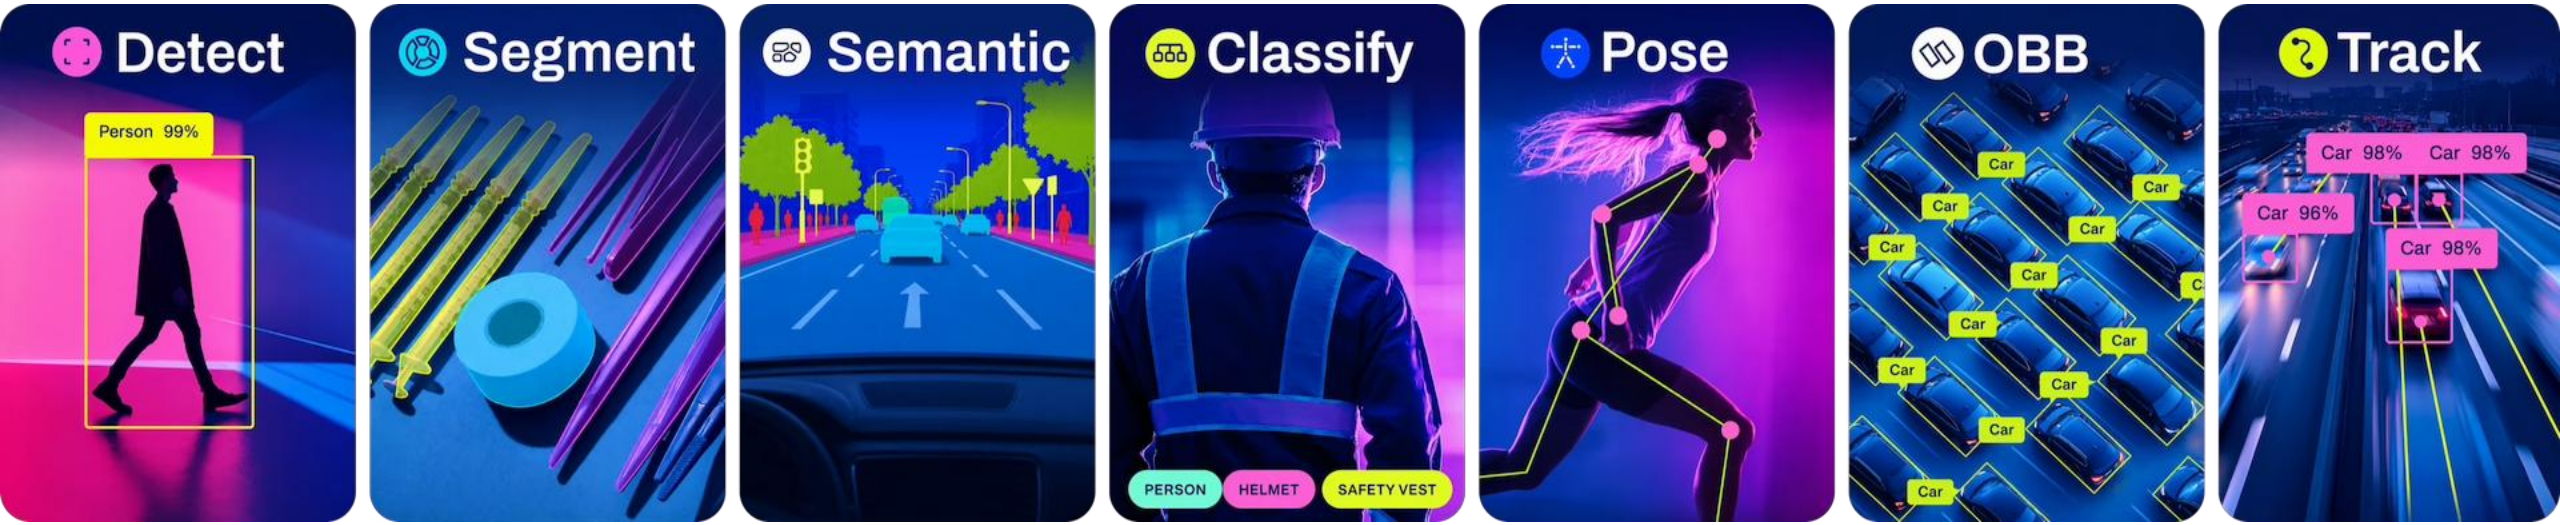
https://paperswithcode.com/task/3d-semantic-segmentation



Objektdetekion, -tracking und -segmentierung

Zusammenfassung

- Mit YOLO-Modellen von Ultralytics kann man viele Bilderkennungs-Anwendungen recht einfach starten

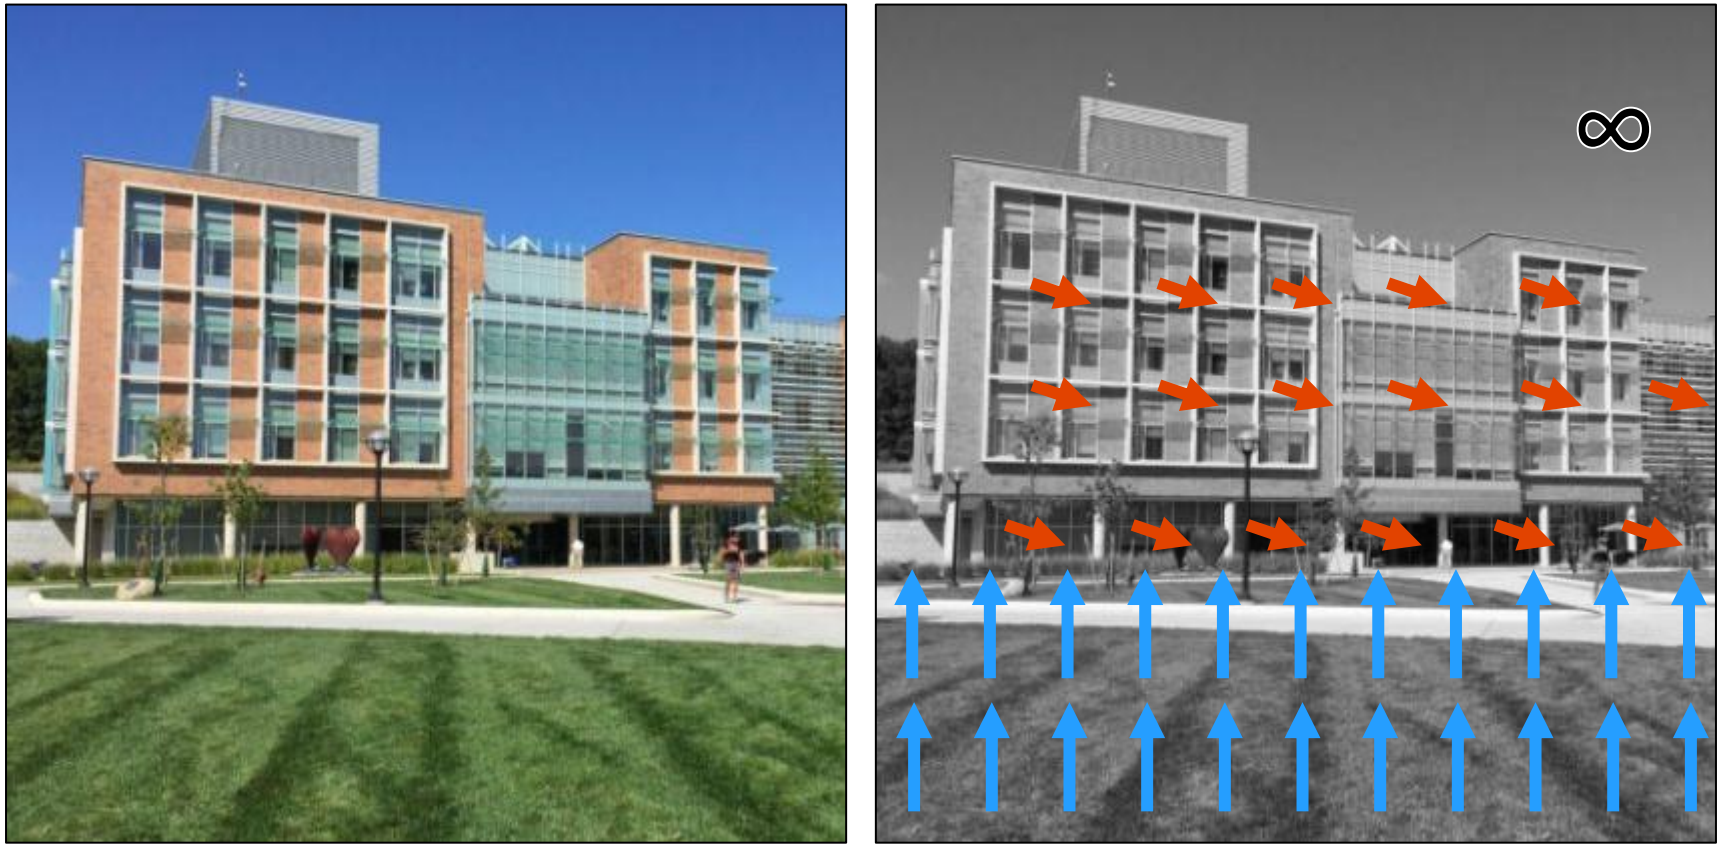


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle:
https://docs.ultralytics.com/tasks

Welche Rolle spielt Computer Vision für CPS?

Ziel: 3D Struktur (Oberflächennormale)

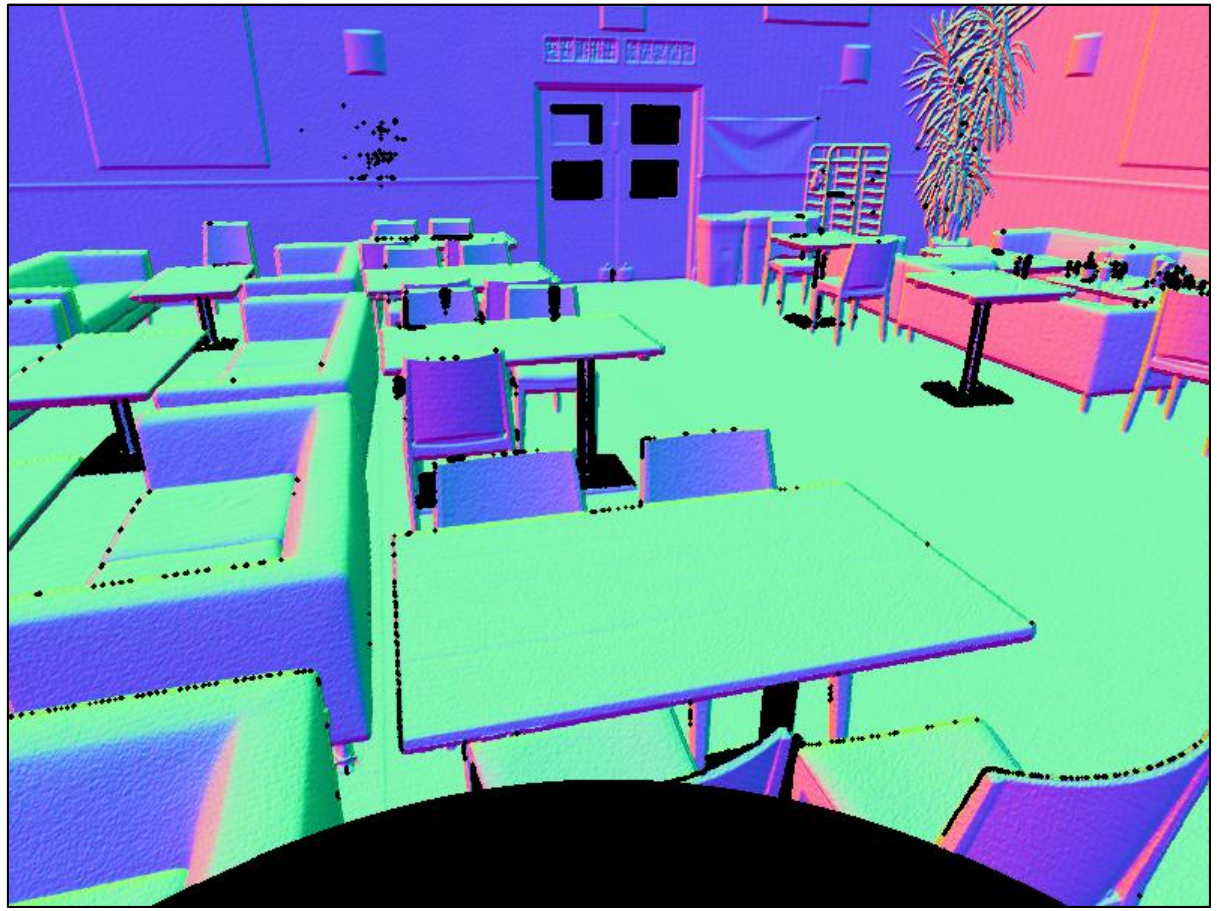


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: Computer Vision (EECS 442), Uni Michigan, Winter 21

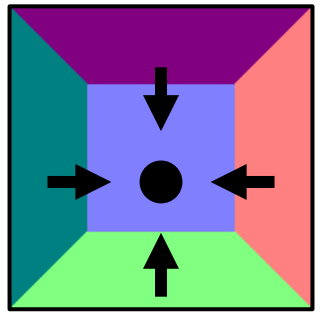
Welche Rolle spielt Computer Vision für CPS?

Ziel: 3D Struktur (Oberflächennormale)





Raum



Legende

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: Computer Vision (EECS 442), Uni Michigan, Winter 21

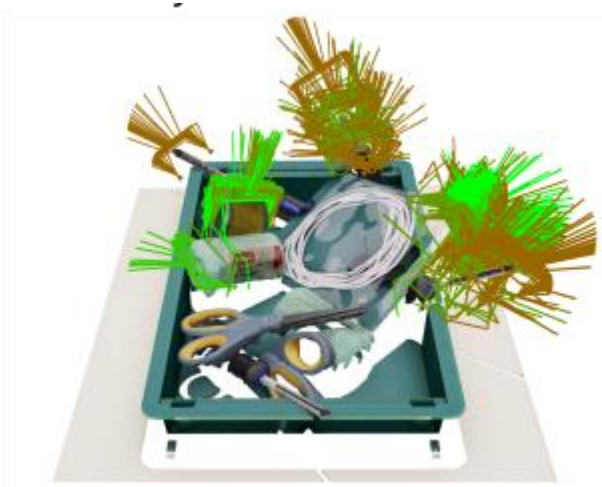
Welche Rolle spielt Computer Vision für CPS?

Ziel: Finden von Greifpunkten

Bin Picking

- Finden von Greifpunkten an Objekten





Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: https://github.com/maximiliangilles/MetaGraspNet
https://github.com/graspnet/anygrasp_sdk
https://github.com/luyh20/FGC-GraspNet
https://h-freax.github.io/thinkgrasp_page/

Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - **Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?**
  - Spracherkennung
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - World Models
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
  - SLAM – Simultaneous Localization and Mapping
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)

Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?



Blickwinkel Variation

Beleuchtung





Skalierung

Quelle: Intro to Computer Vision (CS5670), Cornell Tech, Spring 2021

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?



Variation innerhalb einer Klasse



Bewegung (Source: S. Lazebnik)

Background clutter





Occlusion

Quelle: Intro to Computer Vision (CS5670), Cornell Tech, Spring 2021

Wettbewerb: “Überlisten Sie YOLO”

Teilen Sie sich in Teams auf und testen Sie YOLO auf dem Smartphone.

Das Team, das die meisten Fehler provoziert, gewinnt. Es zählen:

- ein Objekt, das fälschlich als “Person” erkannt wird,
- eine Person, die nicht erkannt wird (Verdeckung, Pose, Verkleidung),
- ein Phantomobjekt (Spiegelung, Plakat, Foto eines Objekts).



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln



Quelle: Computer Vision (CS 4476), Georgia Tech, Fall 2019

ology
ciences
In



Quelle: Computer Vision (CS 4476), Georgia Tech, Fall 2019



Quelle: Computer Vision (CS 4476), Georgia Tech, Fall 2019



Quelle: Computer Vision (CS 4476), Georgia Tech, Fall 2019

Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig? - Unterm Strich

Wahrnehmung ist von Natur aus ein mehrdeutiges Problem

- Viele verschiedene 3D-Szenen können zu einem bestimmten 2D-Bild führen.
- Wir müssen oft auf Vorwissen über die Struktur der Welt zurückgreifen

- Deep Learning Modelle haben das „Vorwissen über die Struktur der Welt“ aus Millionen von Trainingsbildern erlernt



Quelle: Intro to Computer Vision (CS5670), Cornell Tech, Spring 2021
Image source: F. Durand

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig? - Unterm Strich

Was denken Sie antwortet GPT-4vision?

ChatGPT

Das Bild zeigt eine Straßenmalerei eines Coca-Cola-Flaschenbildes, das so gestaltet ist, dass es, aus einer bestimmten Perspektive betrachtet, dreidimensional erscheint. Dies ist ein Beispiel für eine anamorphe Illusion, bei der durch die Verzerrung der Zeichnung und die Wahl des Standpunktes der Kamera eine optische Täuschung erzeugt wird, die Tiefe und Volumen suggeriert, wo tatsächlich nur eine flache Oberfläche vorhanden ist.

Die Person im Bild kniet neben der Straßenmalerei und lächelt in die Kamera, was den Eindruck erweckt, als würde sie neben einer echten, großen Flasche sitzen. Sie scheint die Illusion zu genießen und ist Teil der Inszenierung, die dazu dient, die Täuschung für den Betrachter zu verstärken.

Die Kreiden, die neben dem Bild auf dem Boden liegen, deuten darauf hin, dass die Malerei kürzlich fertiggestellt wurde oder dass der Künstler seine Arbeit noch präsentiert. Solche Straßenkunstwerke sind oft temporär und können als eine Form von öffentlicher Kunst betrachtet werden, die Passanten überrascht und erfreut.



Image source: F. Durand

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - **Spracherkennung**
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - World Models
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
  - SLAM – Simultaneous Localization and Mapping
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)

Einsatz von Spracherkennung und Sound Classification in CPS

Spracherkennung in CPS:

- Steuerung von Robotern und Maschinen durch Sprachbefehle.
- Interaktion mit autonomen Systemen (z.B. Sprachsteuerung in Smart Homes oder Fabriken).
- Verbesserung der Mensch-Maschine-Interaktion durch natürliche Sprache.

Sound Classification:

- Erkennung von Umgebungsgeräuschen zur Reaktion auf sicherheitskritische Ereignisse (z.B. Maschinenlärm, Alarme, Warnsignale).
- Ziel: Unfallprävention (z.B. Maschinenstopps bei anomalen Geräuschen).

Emotionserkennung:

- Mensch-Roboter-Interaktion durch Erkennung emotionaler Zustände verbessern (z.B. Roboter im Gesundheitswesen/Therapie, die auf emotionale Signale reagieren).

Aktueller Stand der Forschung – Spracherkennung

Deep Learning und neuronale Netze:

- Moderne Spracherkennungssysteme basieren auf tiefen neuronalen Netzen wie Transformer-Modellen (z.B. OpenAI‘s Whisper v3, huggingface.co/openai/whisper-large-v3).
- Große Fortschritte durch vortrainierte Modelle, die natürliche Sprache verstehen und interpretieren.

Verbesserungen bei der Genauigkeit:

- Forschung fokussiert sich auf die Reduzierung von Fehlern in lauten Umgebungen und Multilingualität.
- Verwendung von Self-Supervised Learning zur Verarbeitung großer Mengen unbeschrifteter Daten.

https://dgaida.github.io/speech2text/dev/

Demo auf GPU-Laptop

Aktueller Stand der Forschung – Keyword Detection

Keyword Spotting (KWS):

- Erkennung von Schlüsselwörtern („Wake Words“) wie „Hey Siri“ oder „Alexa“ durch sehr kleine CNNs zur Ausführung auf eingebetteter Hardware.

Forschungsansätze:

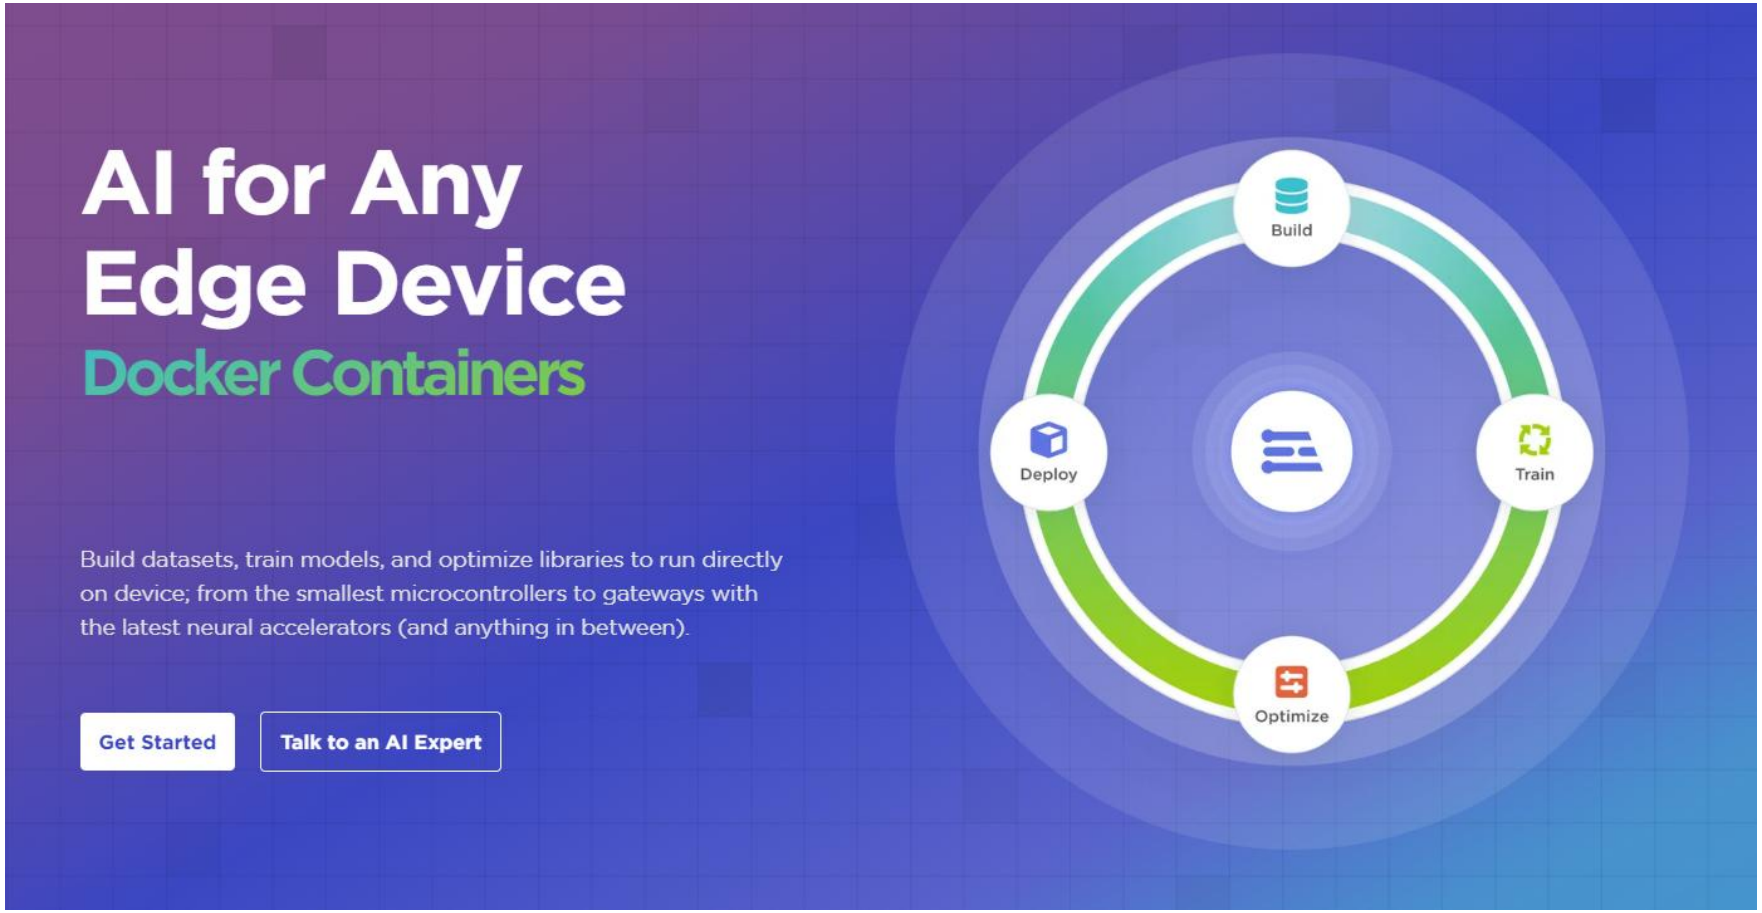
- Entwicklung von kleinen Modellen mit geringem Speicher- und Energieverbrauch (TinyML).
- Steigerung der Genauigkeit durch Federated Learning, das verteilte Datenverarbeitung erlaubt, ohne zentrale Datenpools zu benötigen.

- Keyword Spotting with the NDP120-Powered Arduino Nicla Voice (Edge Impulse, Youtube)



Arduino Pro - Nicla Voice

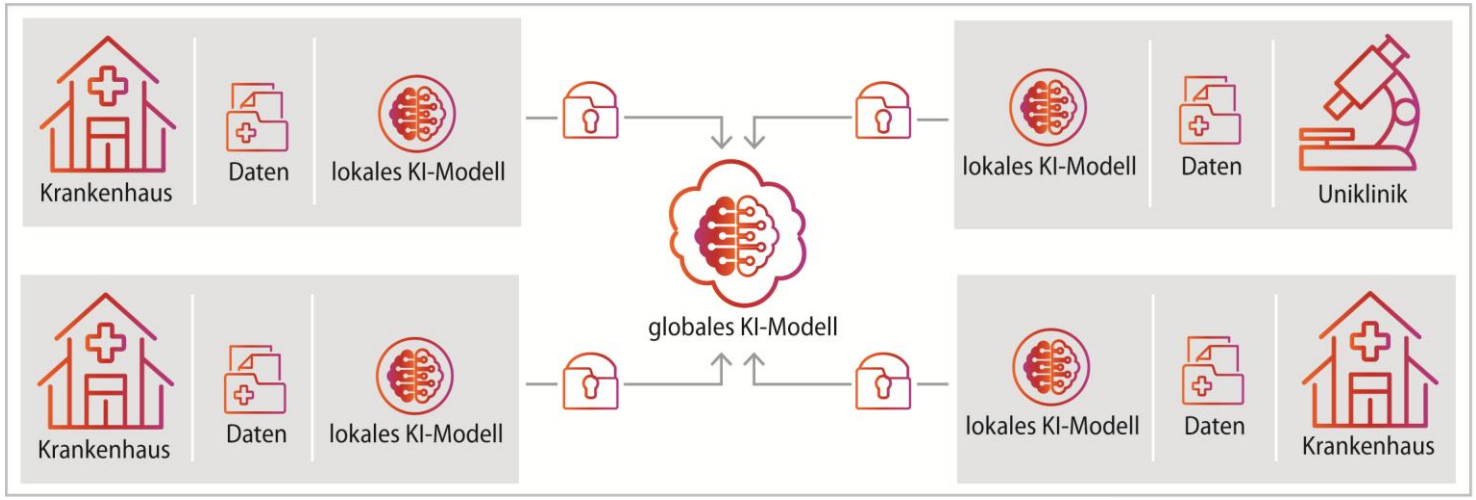
Edge Impulse



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://edgeimpulse.com/

Federated Learning



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Inhalt

Modellierung der Umgebung von CPS:

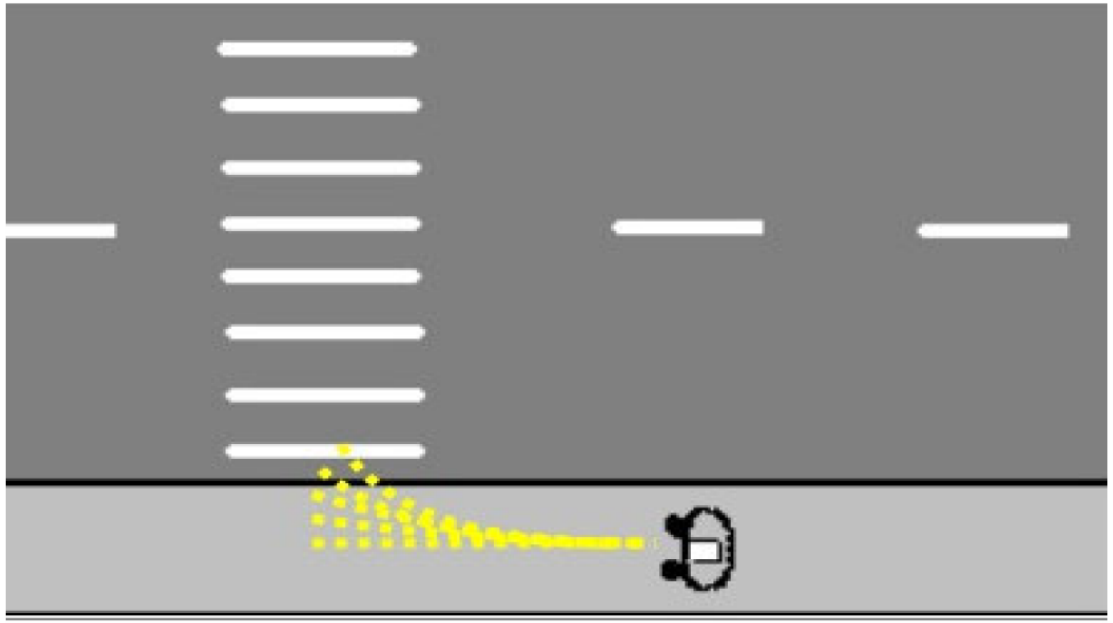
- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - Spracherkennung
  - **Verhaltensmodellierung von Fußgängern, Fahrzeugen**
  - World Models
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
  - SLAM – Simultaneous Localization and Mapping
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)

Verhaltensmodellierung von Fußgängern

Nutzung von Datenbasierten Modellen

- Lernen Wahrscheinlichkeiten für verschiedene Trajektorien
- Daten
  - Fußgänger und andere Objekte, Fahrzeuge, …
  - Trajektorien der Fußgänger
  - Tätigkeiten der Fußgänger (Gesten)
  - Infrastruktur (Zebrastreifen, Schilder, …)

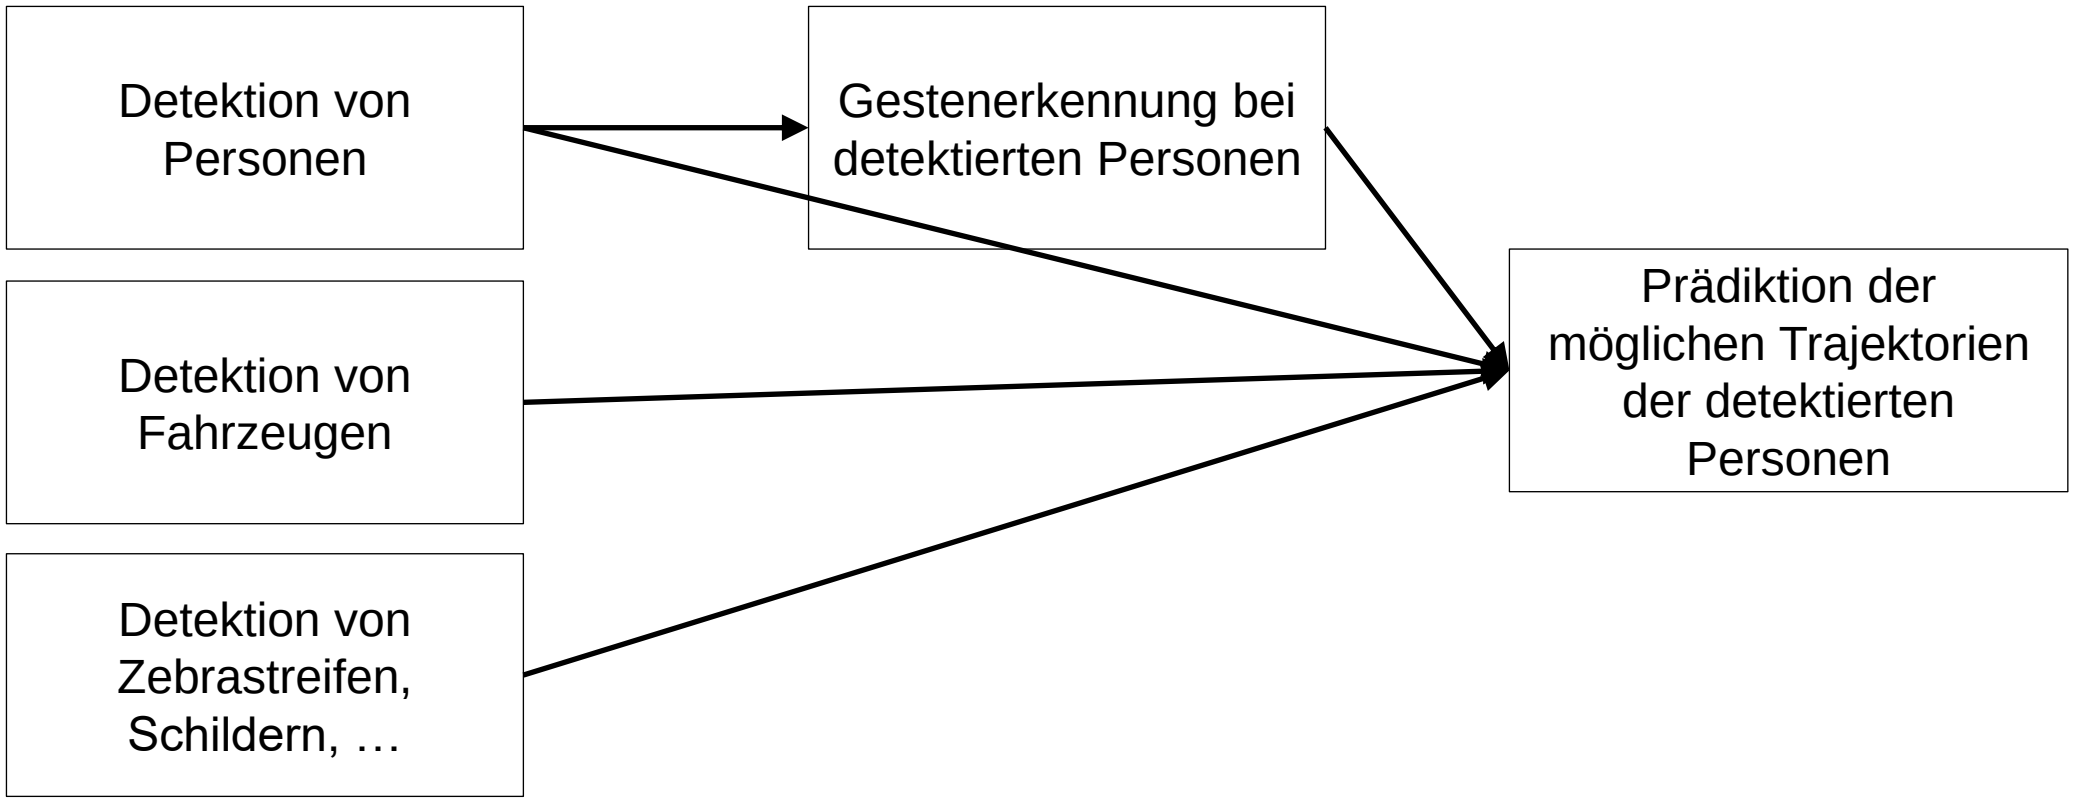




Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

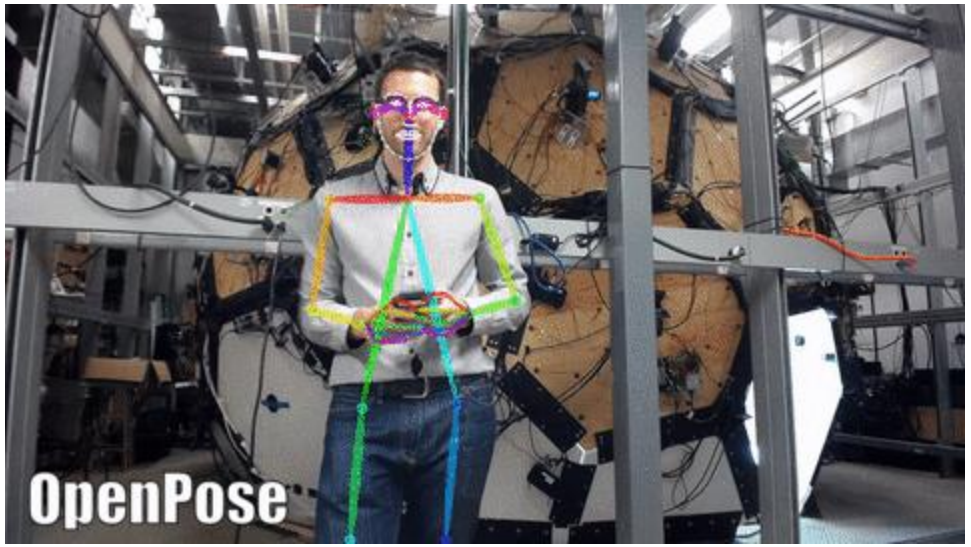
M. Gulzar et al., A Survey on Motion Prediction of Pedestrians and Vehicles for Autonomous Driving, 2021

Verhaltensmodellierung von Fußgängern



Verhaltensmodellierung von Fußgängern

Gestenerkennung – Human Pose Estimation – geht auch mit YOLOv8

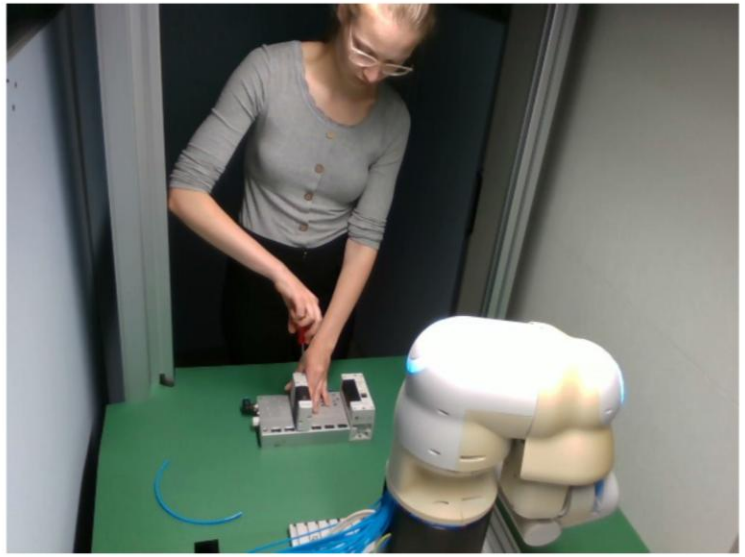


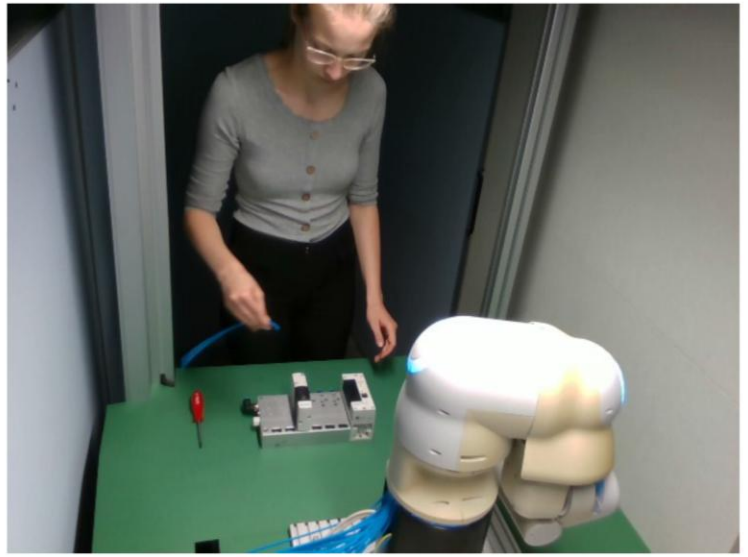


Tätigkeitserkennung von Personen



Bildquelle: https://learnopencv.com/deep-learning-based-human-pose-estimation-using-opencv-cpp-python/

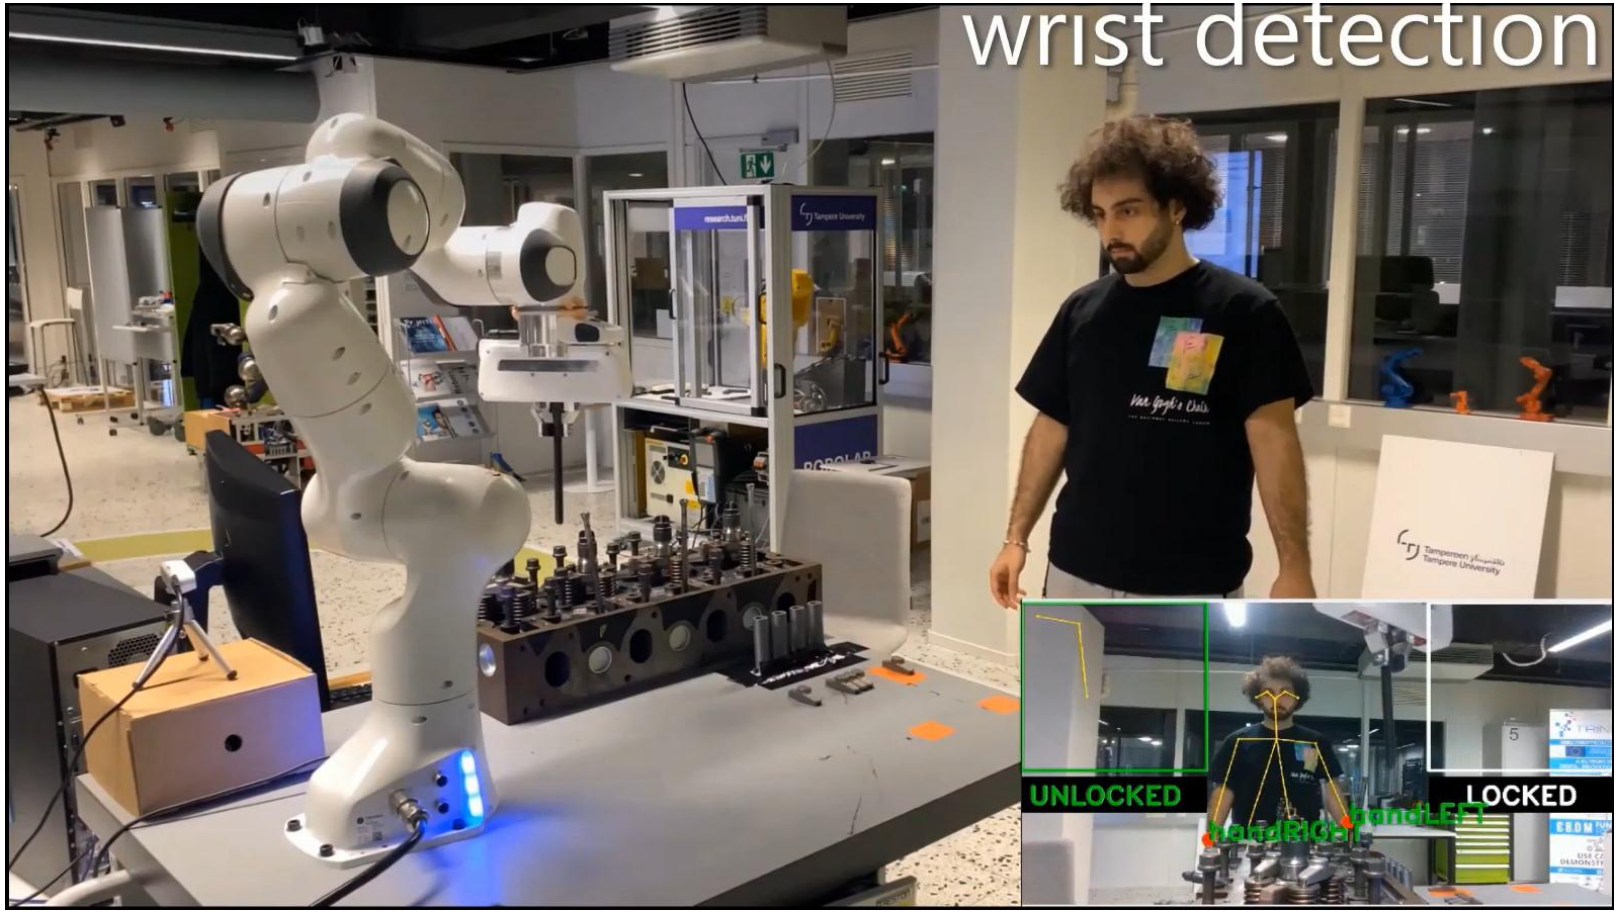




Quelle: Lagamtzis, D., Schmidt, F., Seyler, J. R., & Dang, T. (2022). CoAx: Collaborative Action Dataset for Human Motion Forecasting in an Industrial Workspace. In *ICAART (3)* (pp. 98-105).

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Tätigkeitserkennung von Personen



https://www.youtube.com/watch?v=3z3yiLdznrY

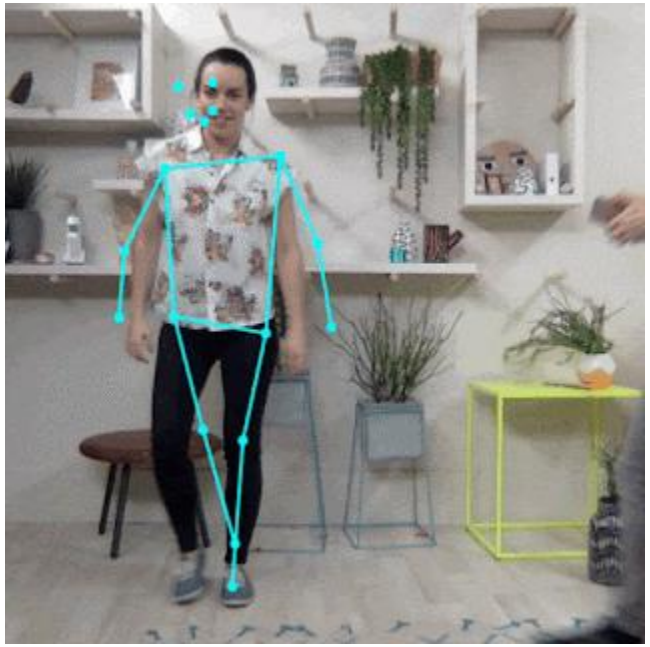
Angleraud, A., Ekrekli, A., Samarawickrama, K., Sharma, G., & Pieters, R. (2024). Sensor-based human–robot collaboration for industrial tasks. Robotics and Computer-Integrated Manufacturing, 86, 102663.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Tätigkeitserkennung von Personen
Aktivität

Gehen Sie zu und erlauben Sie dem Browser einen Zugriff auf Ihre Kamera:

- https://storage.googleapis.com/tfjs-models/demos/posenet/camera.html

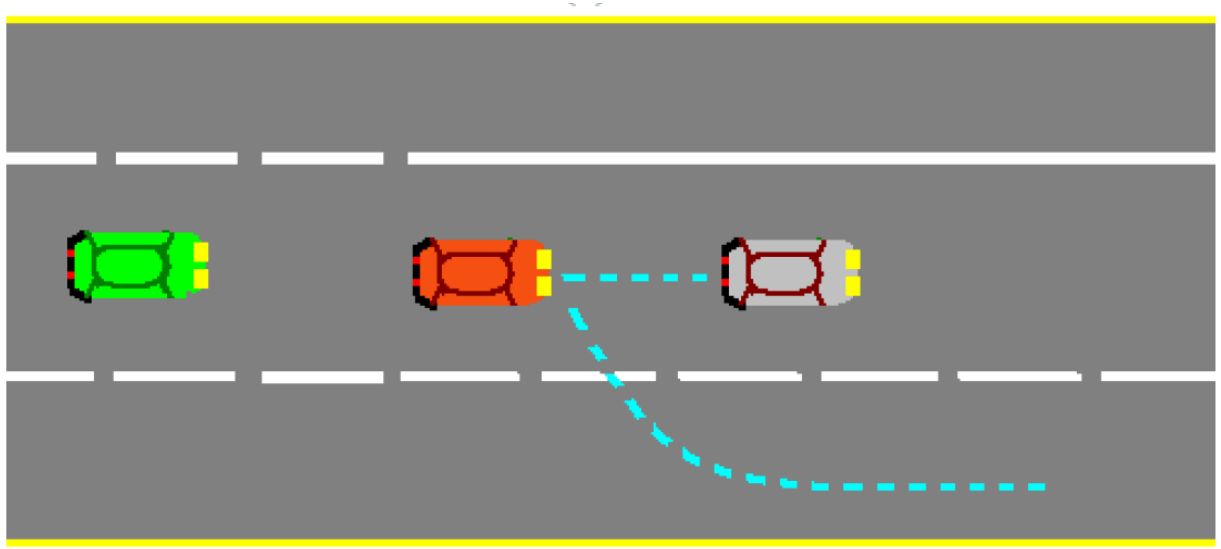


Quelle:
https://blog.tensorflow.org/2018/05/real-time-human-pose-estimation-in.html

Verhaltensmodellierung von Fahrzeugen

Nutzung von Datenbasierten Modellen

- Lernen Wahrscheinlichkeiten für verschiedene Trajektorien
- Daten
  - Fahrzeuge und andere Objekte, Fußgänger, …
  - Trajektorien der Fahrzeuge
  - Infrastruktur (Fahrbahnmarkierungen, Zebrastreifen, Schilder, …)



M. Gulzar et al., A Survey on Motion Prediction of Pedestrians and Vehicles for Autonomous Driving, 2021

Verhaltensmodellierung von Fahrradfahrern - Beispiel



- Objektdetektion/-tracking
  - Fahrradfahrer
  - Schilder
- Gestenerkennung
  - Handzeichen und Drehung des Gesichts
- Fahrbahnmarkierung

https://www.youtube.com/watch?v=JHGjMWPwWTo
Polizei NRW Kids

Übung: Verhaltensmodellierung von Studierenden in der Mensa

- Ein mobiler Roboter sieht um 12:30 Uhr eine stehende/gehende Person in der Mensa
- Anhand welcher Daten kann der Roboter Vorhersagen für das Verhalten der Person in den nächsten Sekunden machen?

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - Spracherkennung
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - **World Models**
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- Statische Modelle der Umgebung (Karte)
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)
  - SLAM – Simultaneous Localization and Mapping

World Models: Der „interne Simulator“ für CPS

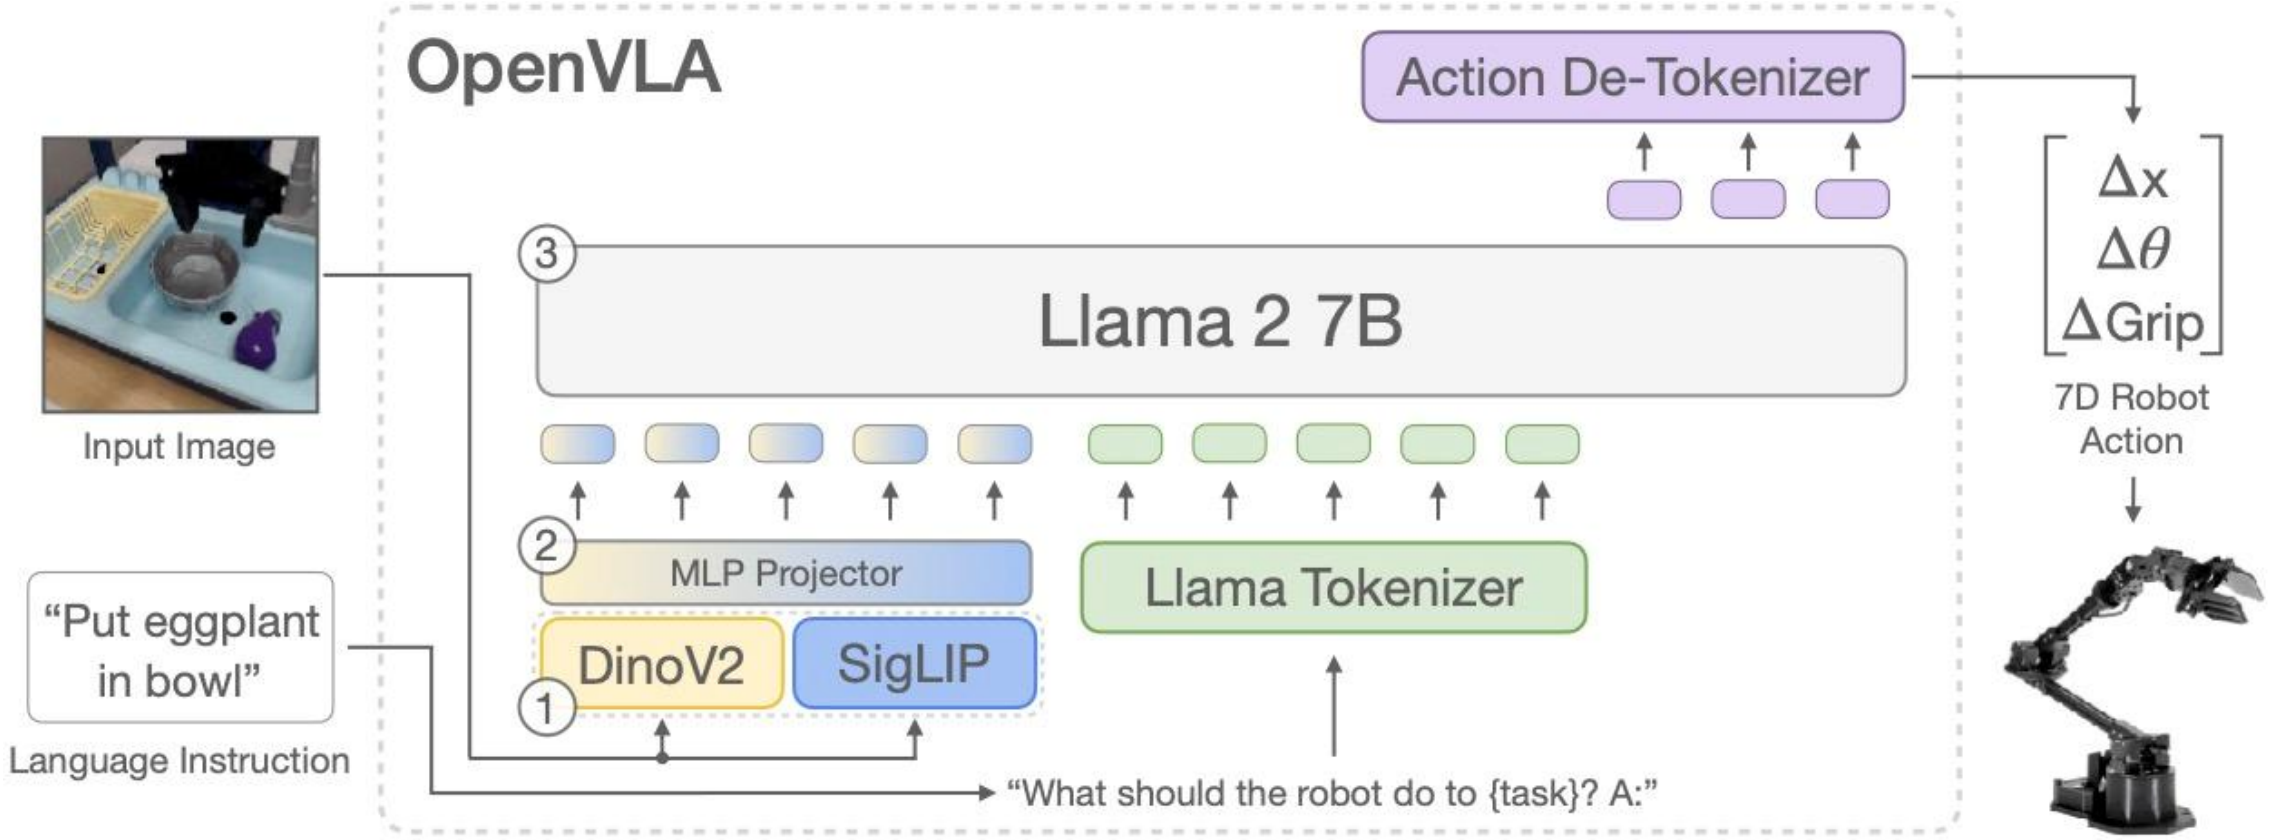
- Was ist ein World Model?
  - Ein generatives Modell, das die Übergangsdynamik der Umgebung erlernt: Es prognostiziert zukünftige Umweltzustände auf Basis aktueller Beobachtungen und geplanter Aktionen.
  - Es fungiert als lernfähiger digitaler Zwilling bzw. mentaler Simulator der physikalischen Welt.

- Das Versprechen:
  1. Plausibel: Behält geometrische Strukturen und physikalische Objektpermanenz über die Zeit stabil bei
  2. Steuerbar: Reagiert kausal und differenziert auf konkrete Steuereingriffe des Roboters
  3. Handlungswirksam: Führt zu messbar besseren Entscheidungen, sicherer Planung und Fehlerkorrektur zur Laufzeit

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

World Models

Evolution der Robotersteuerung: Vision-Language-Action Modelle



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: https://openvla.github.io/

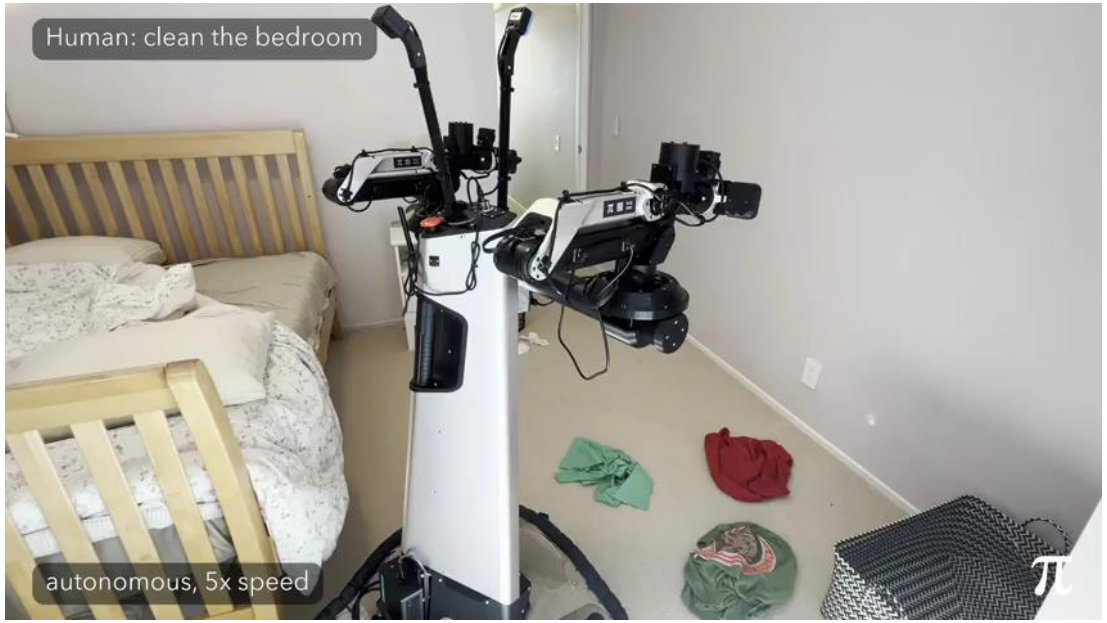
World Models

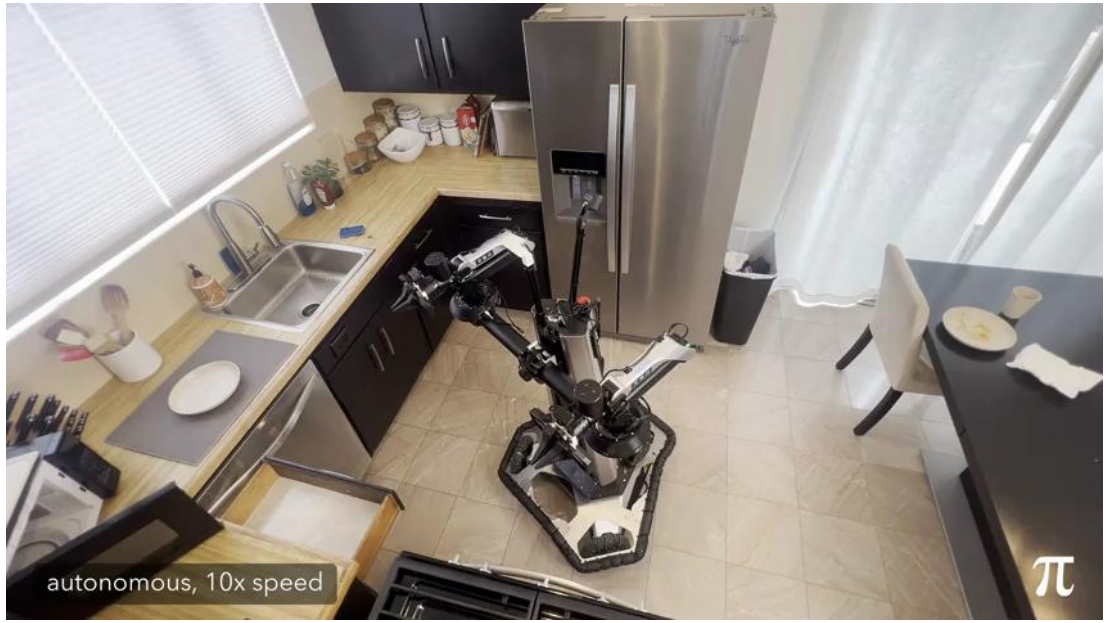
Evolution der Robotersteuerung: Von reaktiven Reflexen (VLAs)...

- Das Prinzip von Vision-Language-Action (VLA):
  - Internet-vortrainierte Vision-Language-Modelle (VLMs) werden mit Demonstrationsdaten feingetunt, um Sprachbefehle und Kamerabilder direkt auf Roboteraktionen abzubilden
- Der große Durchbruch:
  - Hohe semantische Generalisierung: Roboter verstehen neuartige Objekte und sprachliche Anweisungen ohne aufgabenspezifische Neuprogrammierung.
- Warum VLAs für CPS an Grenzen stoßen:
  - Rein reaktive Steuerung: Ein Standard-VLA besitzt keinen Mechanismus, um die zeitlichen oder physikalischen Konsequenzen seiner Handlungen vorab zu modellieren.
  - Keine kausale Vorausschau: Bei Verdeckungen (z. B. Hand verdeckt Greifobjekt) oder unvorhergesehenen Störungen fehlt dem Modell das Verständnis dafür, wie sich die Umwelt physikalisch weiterentwickeln sollte

Physical Intelligence: π0.5: a VLA with Open-World Generalization

Räume das Schlafzimmer auf





Quelle:
https://www.pi.website/blog/pi05

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

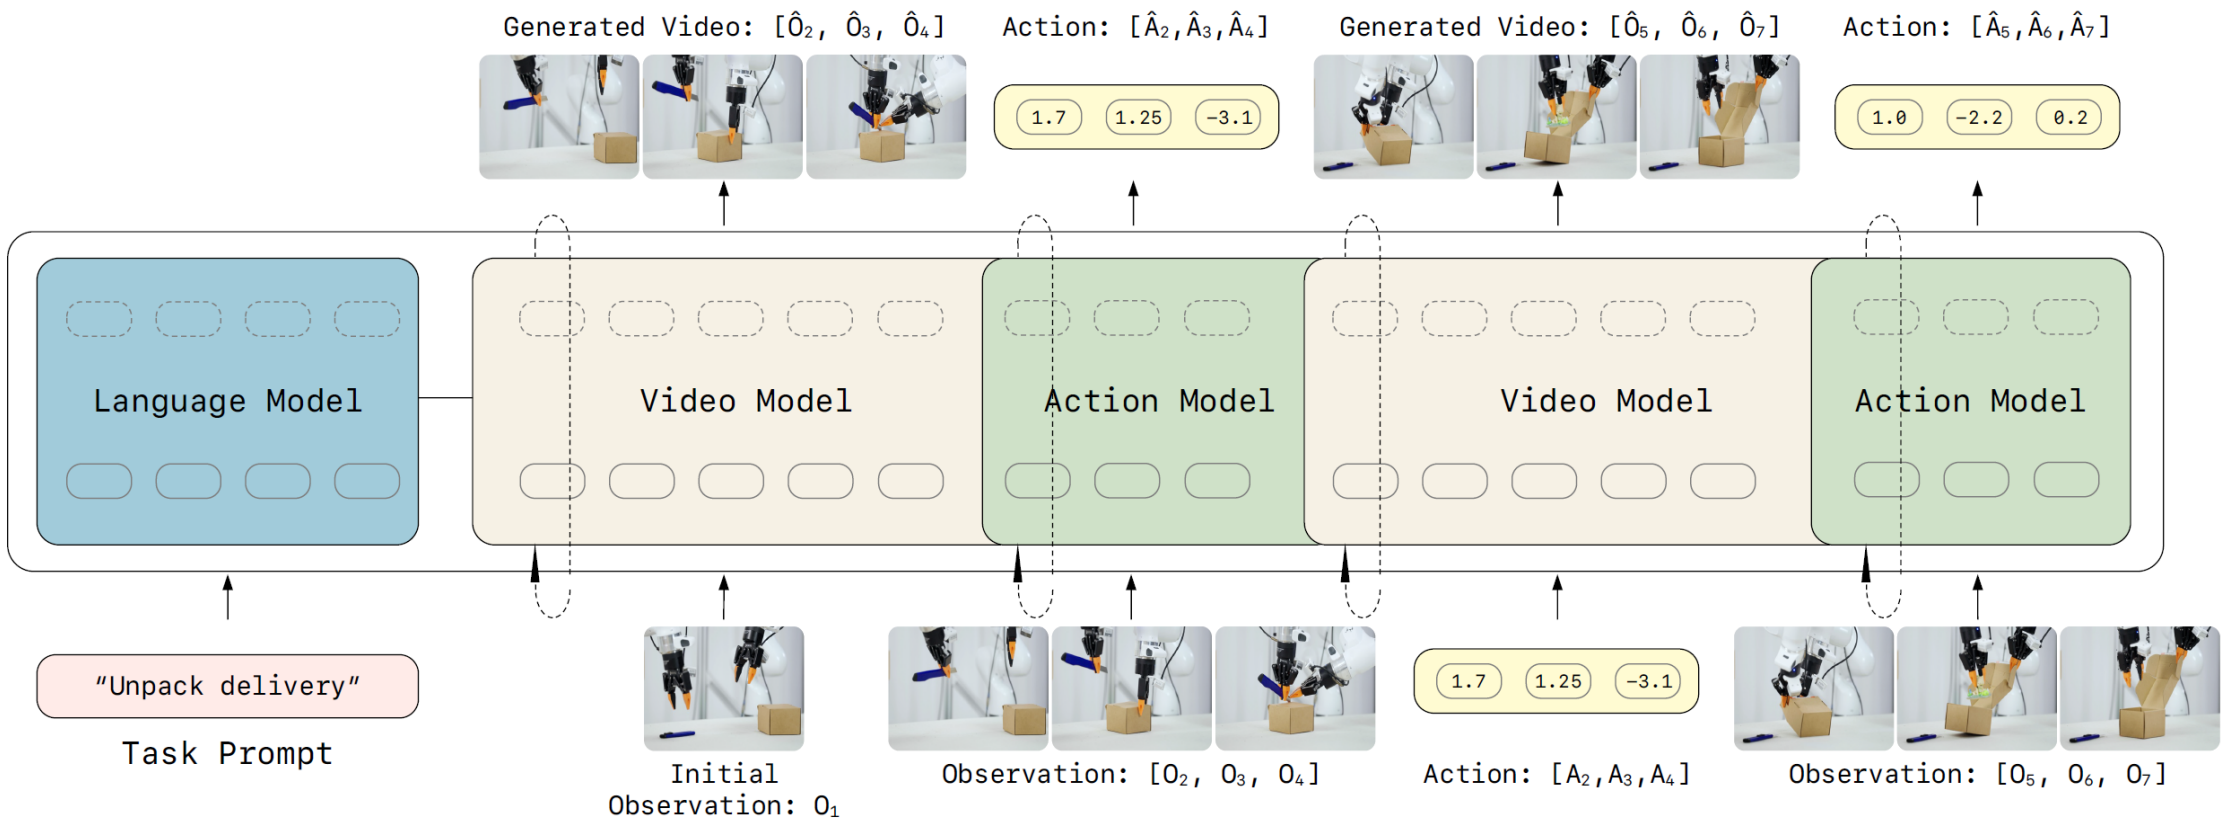
World Models

...zu World Action Models: Vorausschau und Aktion vereint

- Der Paradigmenwechsel zu World Action Models:
  - Kopplung von Zustandsvorhersage und Aktionsauswahl
  - Die antizipierte Zukunft bleibt direkt im Aktionspfad: Sie dient unmittelbar dazu, Aktionen zu generieren, zu bewerten oder zu filtern
- Der Mehrwert für robuste Cyber-Physische Systeme:
  - Laufzeit-Verifikation: Weicht die echte Sensorbeobachtung von der prognostizierten Folgebeobachtung ab (z. B. Objekt rutscht ab), erkennt das System den Fehler sofort und korrigiert ihn.
  - Sichere Imagination: CPS können neue oder riskante Interaktionen in der internen Simulation durchspielen, ohne reale Hardware zu beschädigen

World Models

...zu World Action Models: Vorausschau und Aktion vereint



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: Li, L., Zhang, Q., Luo, Y., Yang, S., Wang, R., Han, F., ... & Xu, Y. (2026). Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*.

World Models

...zu World Action Models: Vorausschau und Aktion vereint



Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Videoquelle: Li, L., Zhang, Q., Luo, Y., Yang, S., Wang, R., Han, F., ... & Xu, Y. (2026). Causal world modeling for robot control. *arXiv preprint arXiv:2601.21998*.

Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - Spracherkennung
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - World Models
- **Lernen in virtuellen Umgebungen (in einer Simulation)**
  - **3D Simulation**
  - **Von der Simulation in die Realität (Sim2real)**
- Statische Modelle der Umgebung (Karte)
  - SLAM – Simultaneous Localization and Mapping
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)

Lernen durch Simulation

- Training von Deep Learning Modellen benötigt sehr viele Daten
- Erhebung ist teuer, zeitintensiv, aufwändig, …

- Lösung:
  - Erstellen der Daten in einer fotorealistischen Simulationsumgebung
    - Weiterer Vorteil: Daten sind bereits gelabelt

  - Training des Deep Learning Modells mit den simulierten Daten
  - Fine-Tuning des trainierten Modells mit **wenigen** realen Daten

Was ist eine Simulation?

- Eine Simulation ist eine virtuelle Welt, die eine Teilmenge von Merkmalen der realen Welt enthält.
- Im Zusammenhang mit der Robotik sind Simulationen virtuelle Welten, die es Entwicklern ermöglichen, produktiver zu arbeiten.
- Simulationen sind modernen Videospielen insofern sehr ähnlich, als sie realistische Physiksimulationen, eine Vorstellung von Zeit und grafische Darstellungen der realen Welt enthalten.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

3D Simulation

CARLA, Open Source, https://carla.readthedocs.io/en/latest/



Simulation von

- Sensoren
  - Kamera, Lidar, GPS, …
- Physik (Trägheit, Reibung, …)
- Wetter, Licht, …

https://leaderboard.carla.org/

3D Simulation

Objektdetektion in CARLA



Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

A. Ünal, J. Kolodziejski Ribeiro: Objektdetektion und ihre Auswertung in einem realitätsnahen 3D-Simulator, Praxisprojekt, 2022

3D Simulation

Nvidia DRIVE Sim – We are not accepting new partners currently

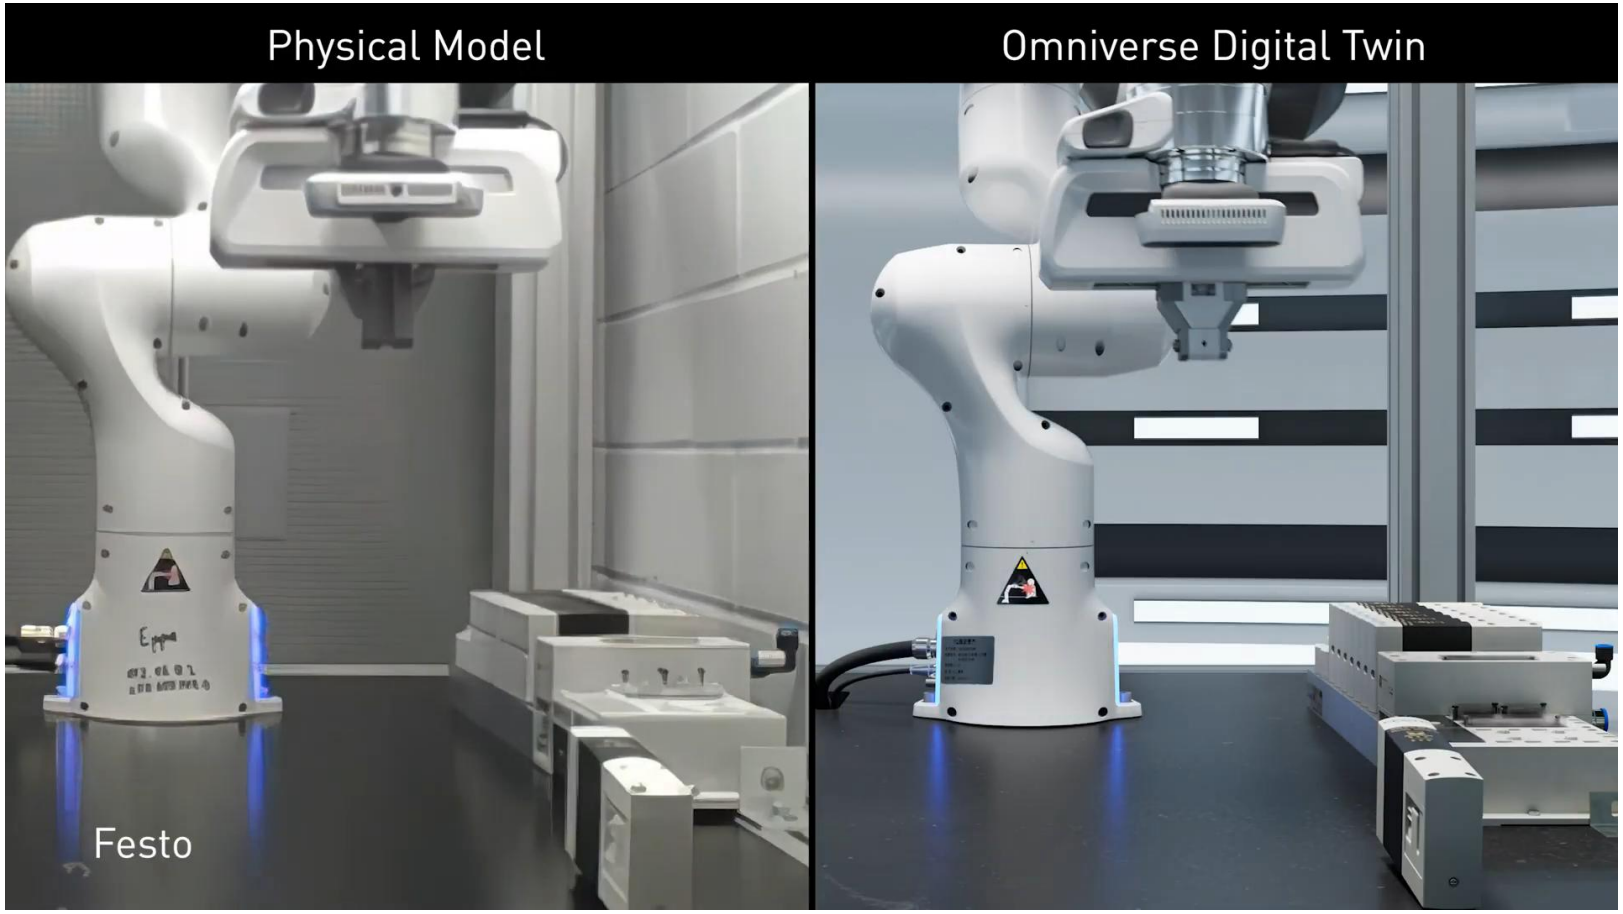


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://developer.nvidia.com/drive/simulation

3D Simulation

Nvidia Isaac Sim (kostenlos, Datenschutz problematisch)

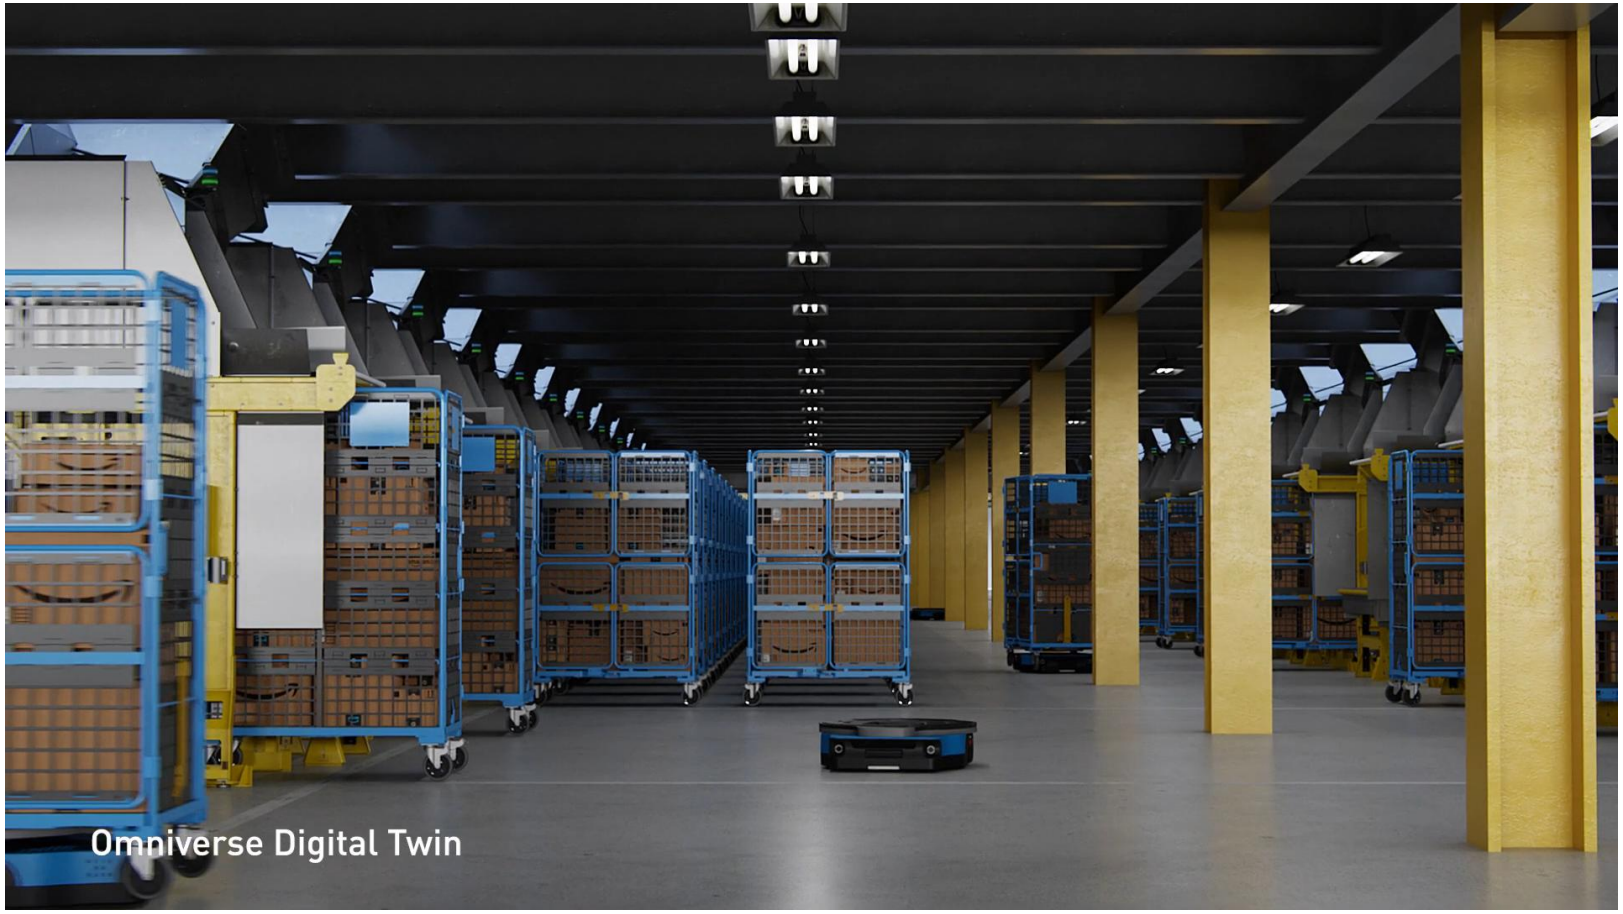


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://developer.nvidia.com/isaac-sim

3D Simulation

Nvidia Omniverse & Amazon



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://www.youtube.com/watch?v=-VQLqs6s9y0

3D Simulation

Nvidia Omniverse & Amazon



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://www.youtube.com/watch?v=LUnZXBL_lqA

3D Simulation

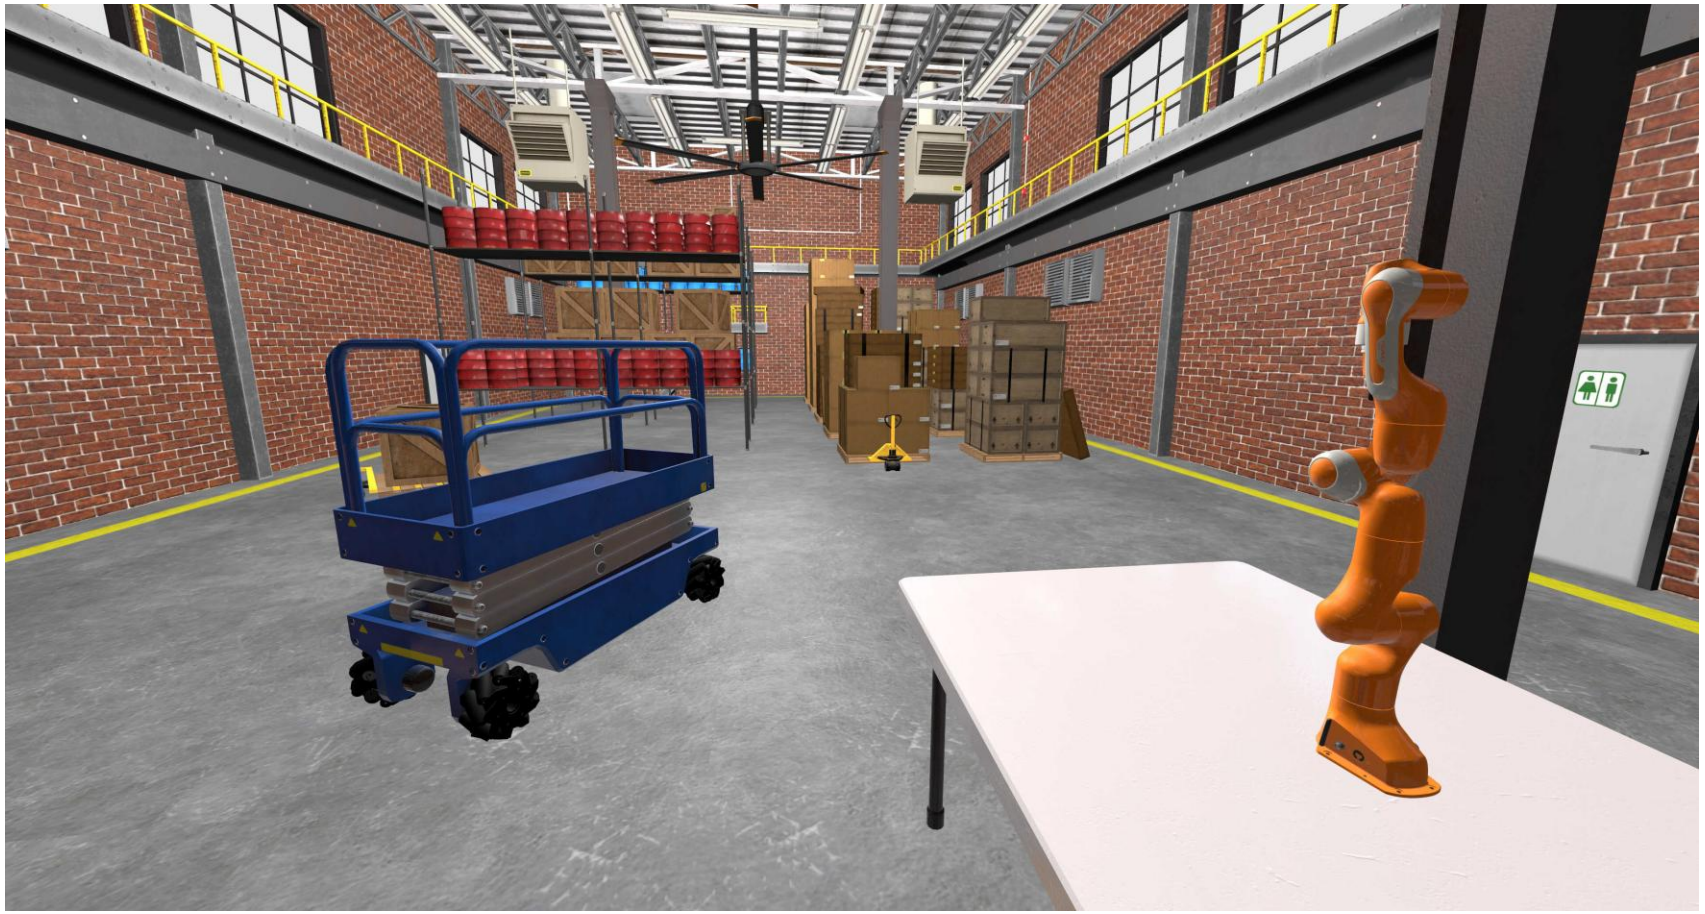
Nvidia Omniverse & Siemens



https://www.youtube.com/watch?v=t6ppwWZUSEc

3D Simulation

Gazebo, Open Source



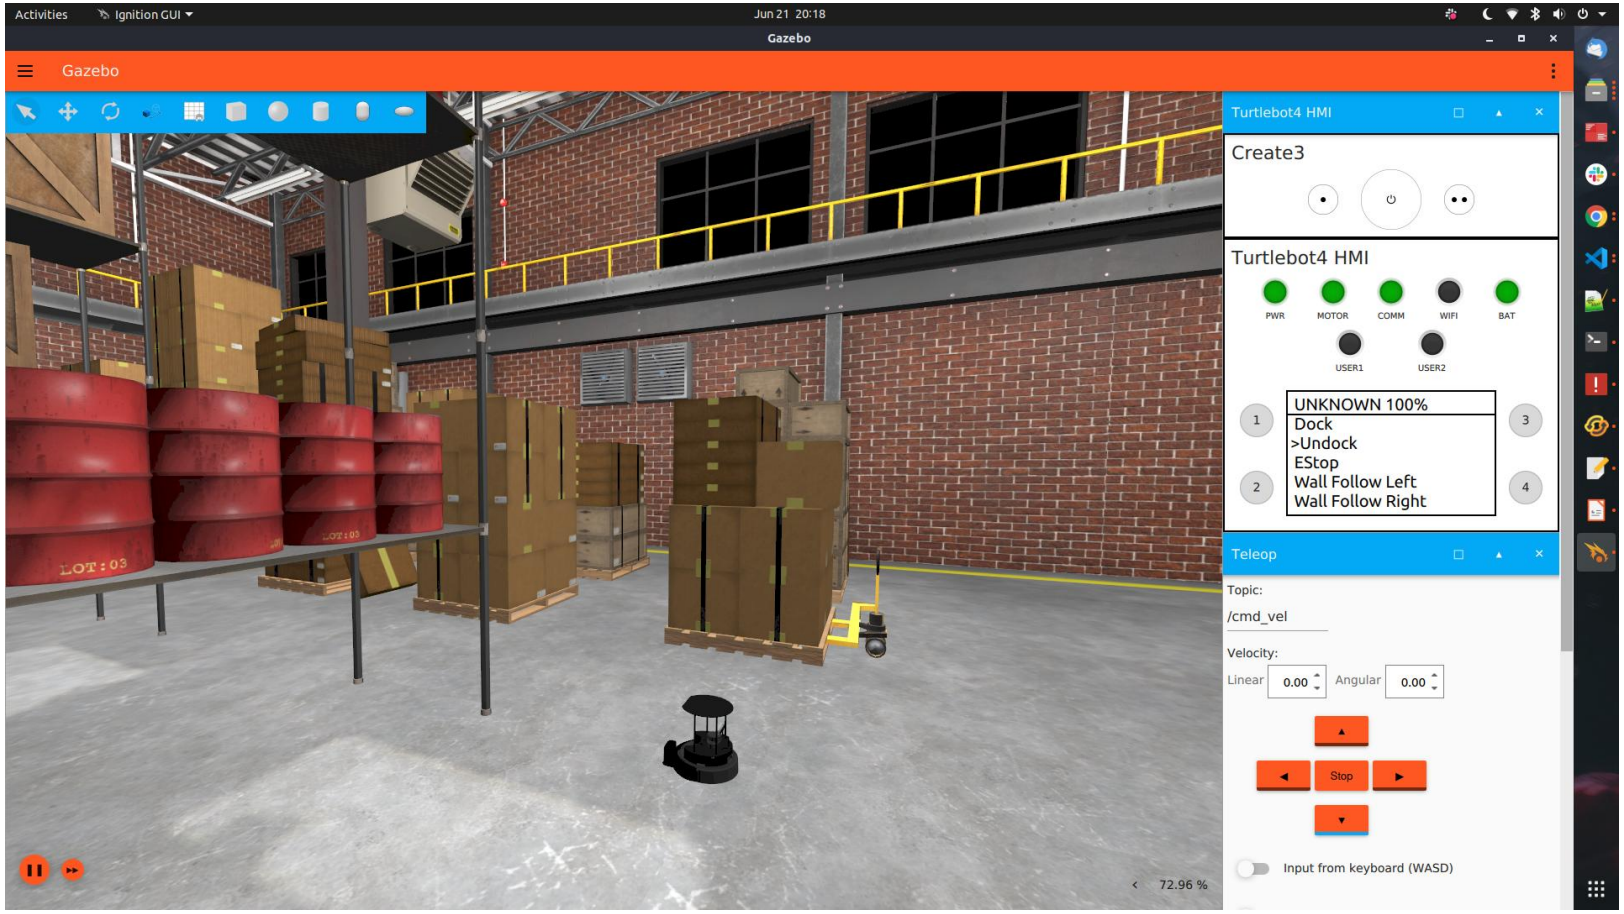
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
https://gazebosim.org/home

3D Simulation

Gazebo, Open Source



https://raw.githubusercontent.com/turtlebot/TurtleBot4Lessons/main/media/tb4.png



https://github.com/turtlebot/TurtleBot4Lessons/blob/main/units/Unit01-ROS-2-Basics/L02-Gazebo-World/U01-L02-Empty-World.md

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

3D Simulation

Habitat-Lab, Open Source

Simulation von Innenräumen

- Navigation („Gehe in die Küche“)
- Anweisungen folgen („Drehe dich nach rechts, gehe durch die Tür, …“)
- Beantwortung von Fragen
  („Welche Farbe hat die Haustür?“)





3D Simulation

ThreeDWorld, Open Source

“TDW is a 3D virtual world simulation platform, utilizing state-of-the-art video game engine technology”

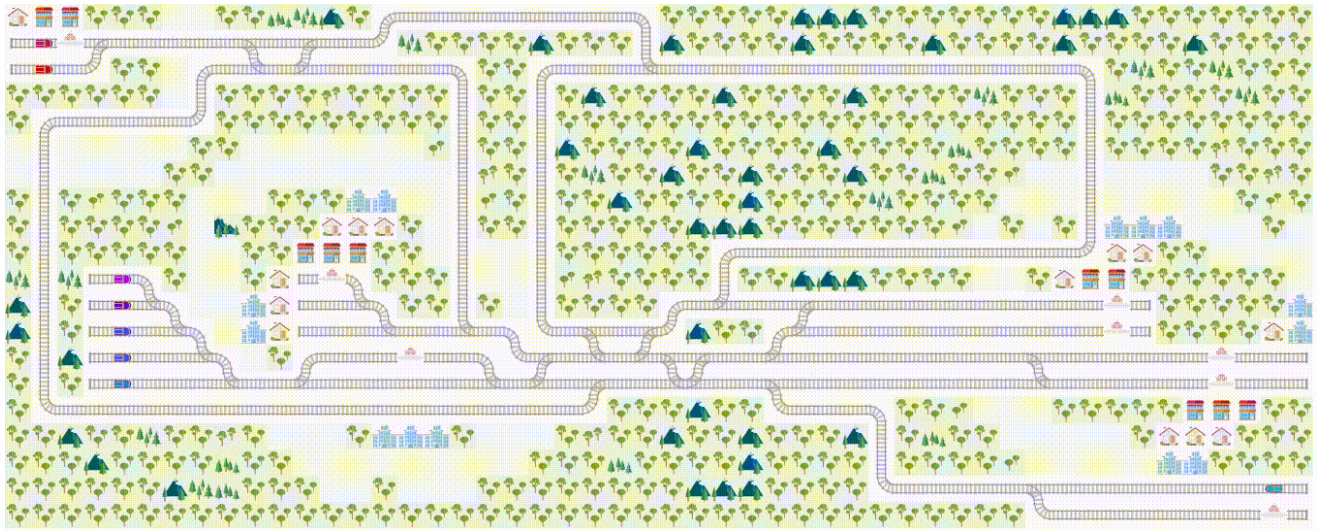
https://threedworld.org/



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Weitere Simulationen

- EnergyPlus, „EnergyPlus™ is a whole building energy simulation program that engineers, architects, and researchers use to model both energy consumption - for heating, cooling, ventilation, lighting and plug and process loads - and water use in buildings.“, Quelle: https://energyplus.net/
- Flatland, How to efficiently manage dense traffic on complex railway networks?, https://flatland.aicrowd.com/intro.html



Von der Simulation in die Realität

Sim2Real, sim-to-real

Sim2real bezieht sich auf den Prozess der Übertragung einer in einer simulierten Umgebung erlernten Strategie oder eines Modells auf eine reale Umgebung.

- Schließen des „reality gaps“ (Lücke zwischen Simulation und Realität)

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

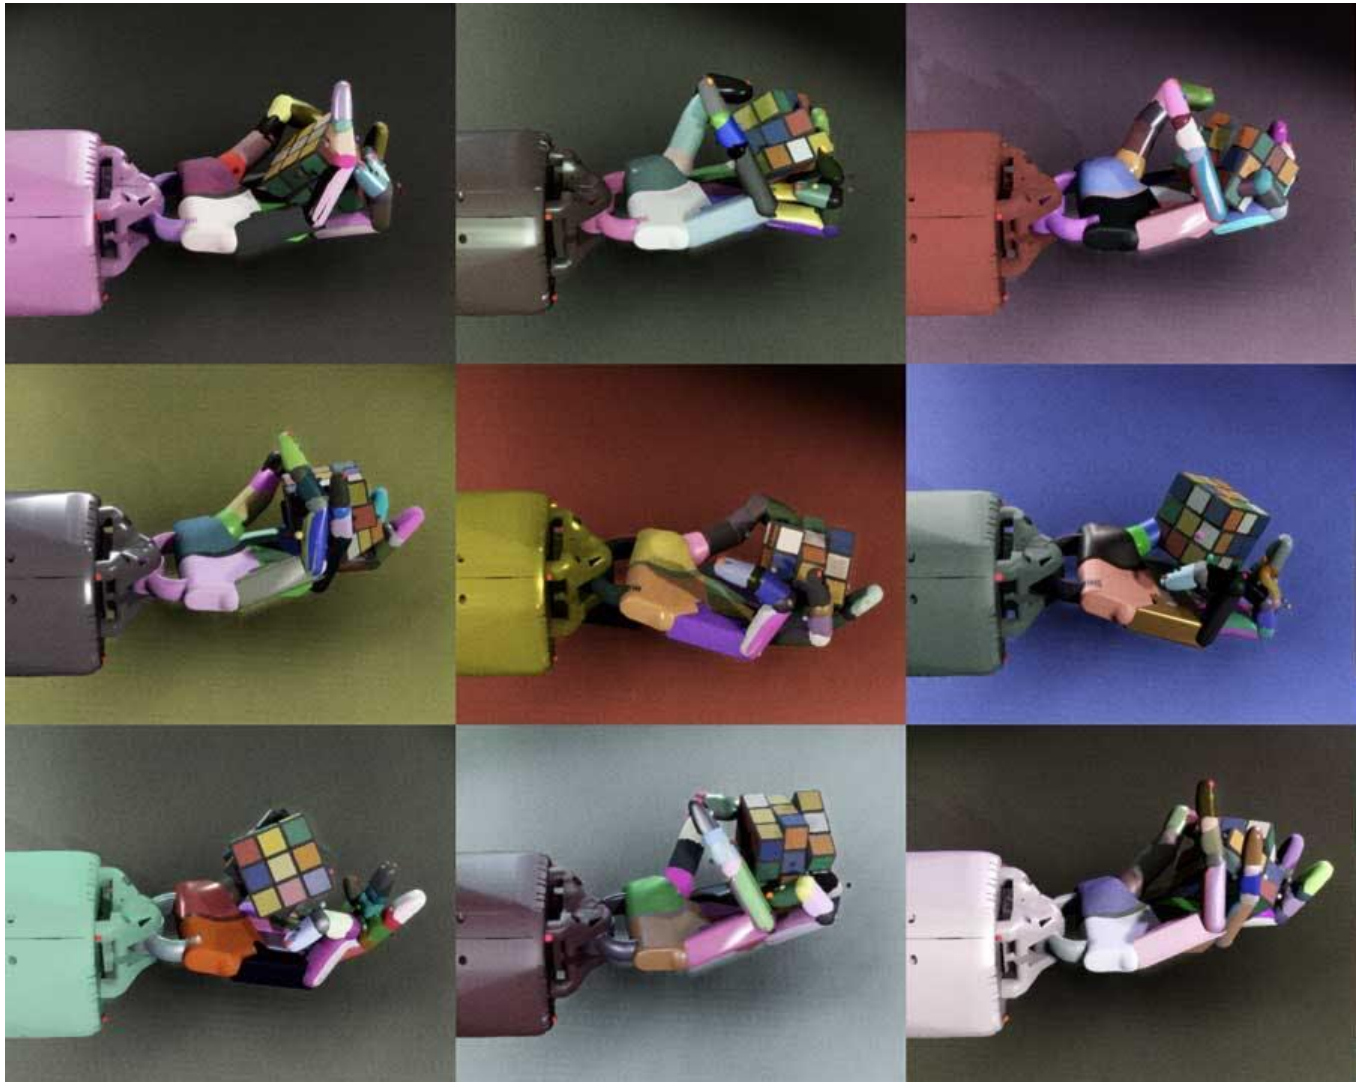
Simulation → Realität

Sim2Real, sim-to-real

Domain Randomization:

- Anwendung von zufälligen Transformationen auf ein Simulationsmodell, um die Generalisierung auf unbekannte Umgebungen zu verbessern.

- Training einer Roboterhand, um den Zauberwürfel (Rubik‘s Cube) zu lösen
- Simulation verschieden aussehender Roboterhände, damit KI lernt, dass Aussehen der Hand keine Rolle spielt

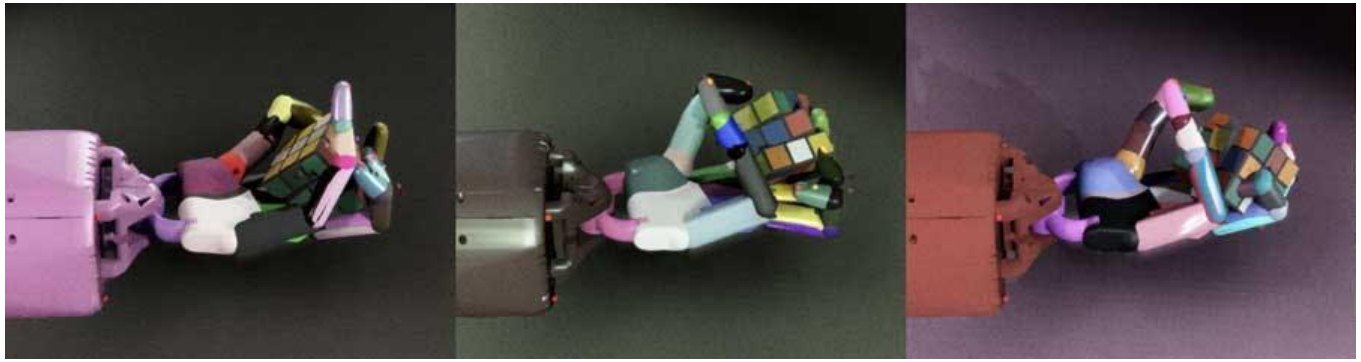


https://openai.com/research/solving-rubiks-cube

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Simulation → Realität

Sim2Real, sim-to-real



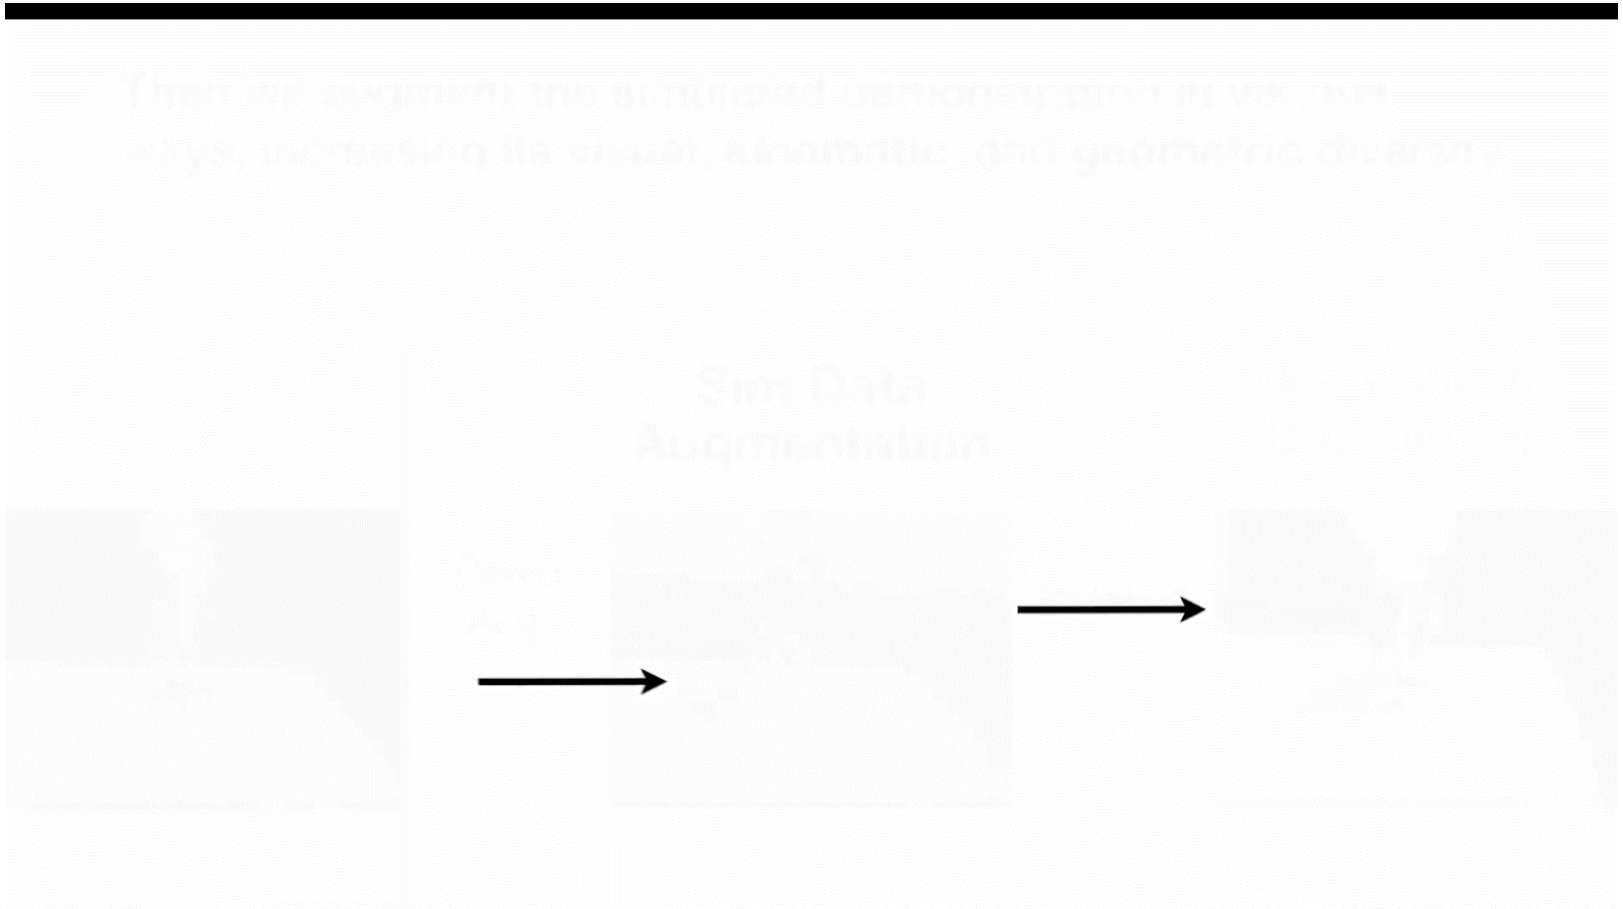
Domain Randomization:

- Randomisierung von visuellen Merkmalen, aber auch von physikalischen Parametern (Reibung, Masse, Größe von Objekten, …)
- Ziel:
  „Die Hauptidee hinter diesen Methoden ist das Lernen in einer großen Anzahl von simulierten Umgebungen mit dem Ziel, ein robustes Modell oder eine robuste Strategie zu erlernen, die die physische Welt als eine weitere Variation "sieht" und ohne jegliche Anpassung übertragen wird.“
  [Quelle: K. Dimitropoulos et al., A Brief Survey of Sim2Real Methods for Robot Learning, 2022]

https://openai.com/research/solving-rubiks-cube

Simulation → Realität

Sim2Real, sim-to-real



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Simulation → Realität

Sim2Real, sim-to-real

Werden Modelle/Strategien immer besser in der realen Welt funktionieren, wenn die Simulationen immer besser/realistischer werden?

- Scheinbar nicht
- “Our results show that, contrary to expectation, adding fidelity does not help with learning; performance is poor due to slow simulation speed (preventing large-scale learning) and overfitting to inaccuracies in simulation physics.” aus: J. Truong et al., Rethinking Sim2Real: Lower Fidelity Simulation Leads to Higher Sim2Real Transfer in Navigation, 2022
- Übersetzung: “Unsere Ergebnisse zeigen, dass die Erhöhung der Genauigkeit entgegen den Erwartungen nicht zum Lernen beiträgt; die Leistung ist aufgrund der langsamen Simulationsgeschwindigkeit (die ein Lernen in großem Maßstab verhindert) und der Überanpassung an Ungenauigkeiten in der Simulationsphysik schlecht.”

Simulation → Realität

Sim2Real, sim-to-real



Simulation → Realität

Sim2Real, sim-to-real



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
https://robogen-ai.github.io/
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Simulation → Realität

Sim2Real, sim-to-real

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
https://robogen-ai.github.io/
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Erstellung von Simulationsmodellen aus einer realen Umgebung

Gaussian Splatting



Quelle: https://mv-dust3rp.github.io/
MV-DUSt3R+: Single-Stage Scene Reconstruction from Sparse Views In 2 Seconds

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Erstellung von Simulationsmodellen aus einer realen Umgebung
Gaussian Splatting





https://superspl.at/editor

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Quelle: N. Struckmeyer: Entwicklung eines Partikelfilters zur Lokalisierung mobiler Roboter mithilfe von 3D-Gaussian-Splatting, Bachelorthesis, 2026

Übung – Erstellen eines Modells der Umgebung

- Entwicklung eines humanoiden Roboters, der beim Golf dem Golfspieler immer den richtigen Schläger anreicht.
- Was ist die Umgebung?

- Wie können wir diese modellieren?

- Trainingsdaten evtl. mit einem 3D Golf Computerspiel aufnehmen

Inhalt

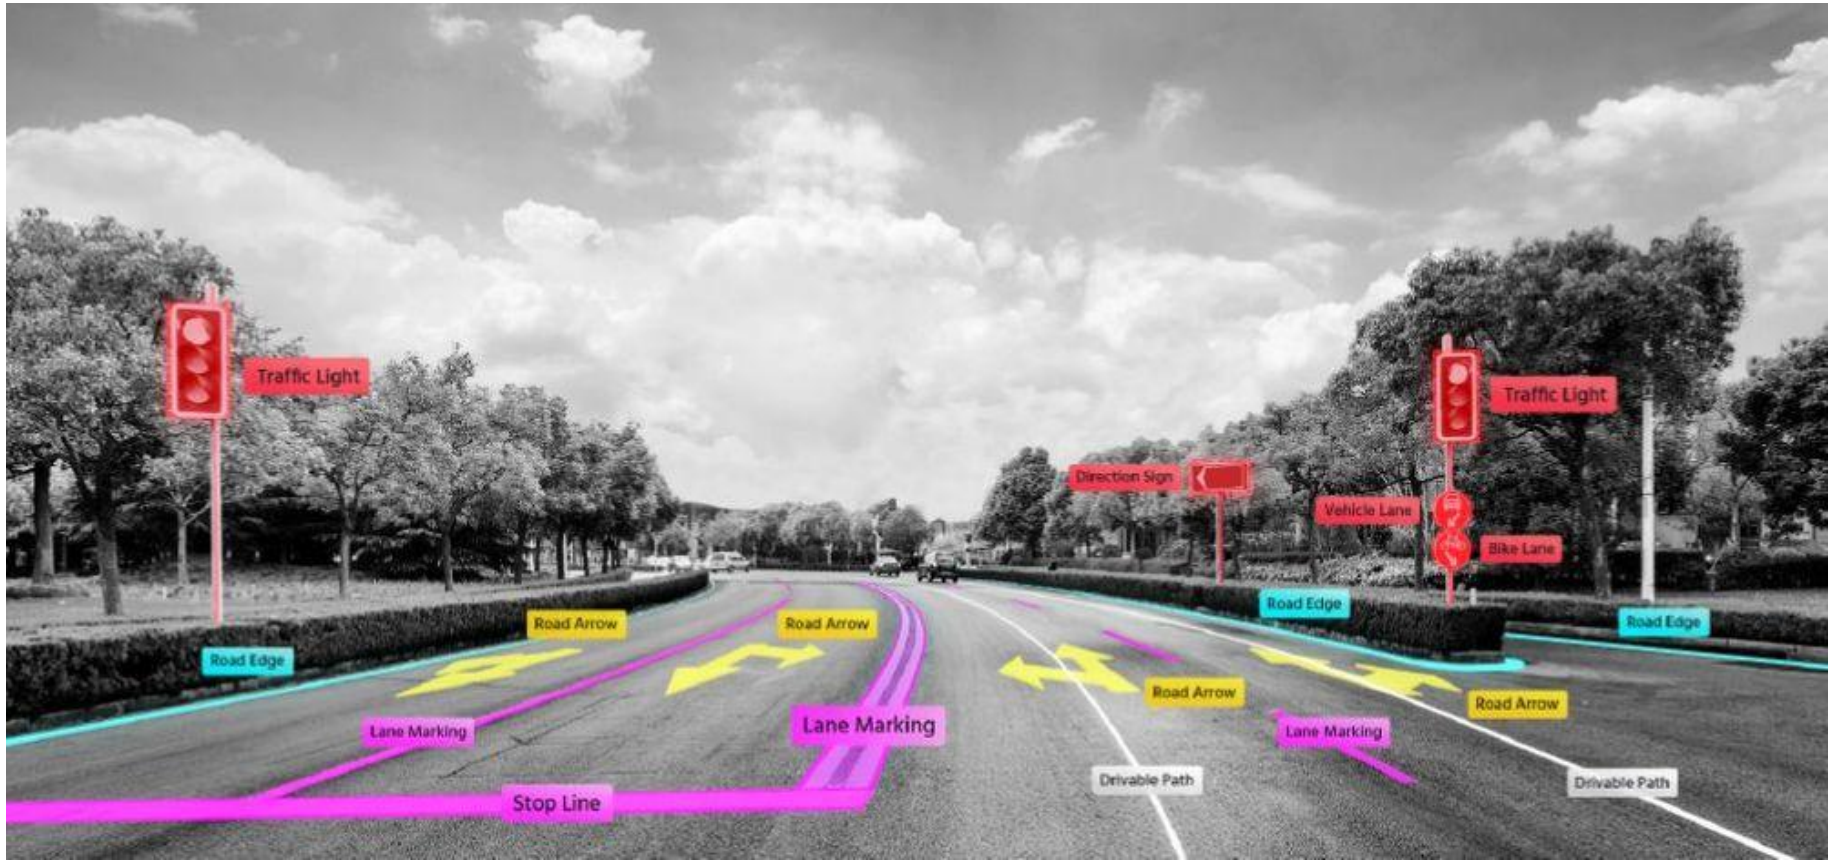
Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - Spracherkennung
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - World Models
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- **Statische Modelle der Umgebung (Karte)**
  - **SLAM – Simultaneous Localization and Mapping**
  - Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)

HD Karte für autonomes Fahren

High Definition map





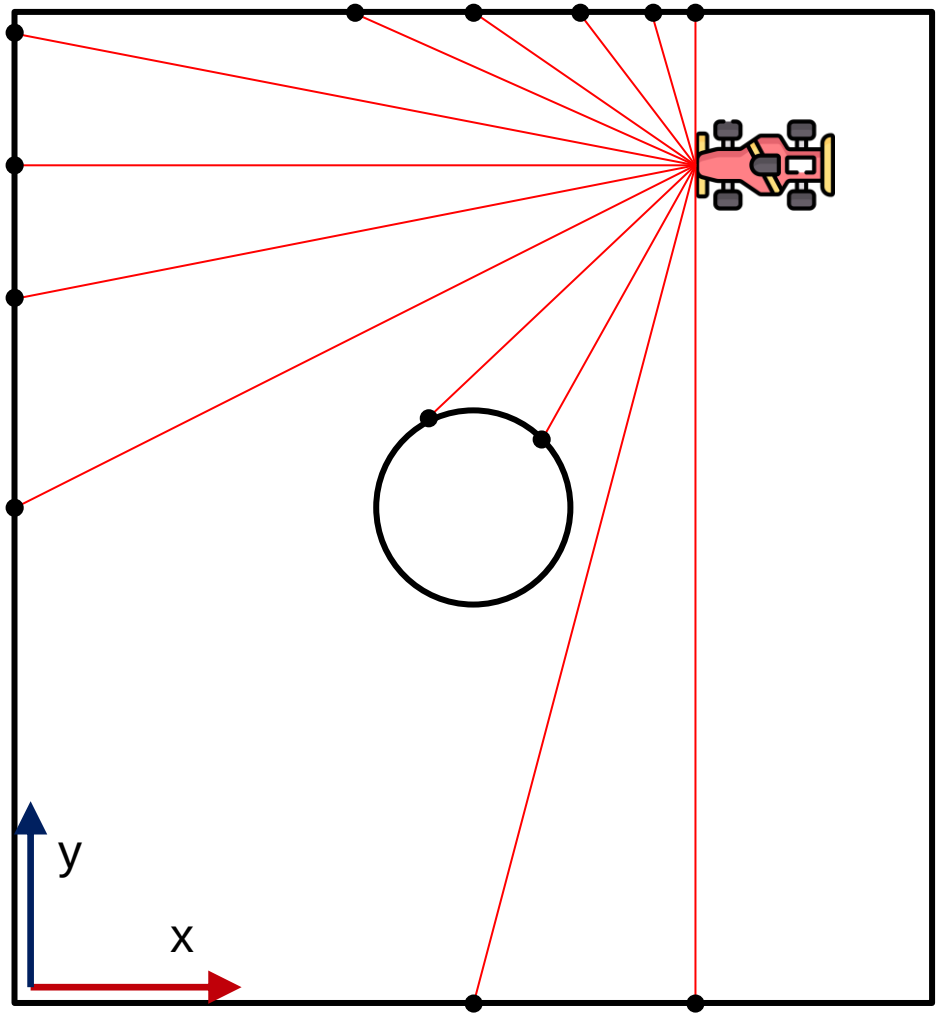
https://www.mobileye.com/blog/av-maps-vs-hd-maps/
https://paperswithcode.com/task/lane-detection

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

SLAM - Simultaneous Localization and Mapping

Wenn Sie keine Karte der Umgebung haben…

- Erstellung einer Karte der Umgebung durch ein autonom fahrendes System (bspw. Roboter)
- Problem:
  - Roboter weiß selbst nicht wo er sich befindet

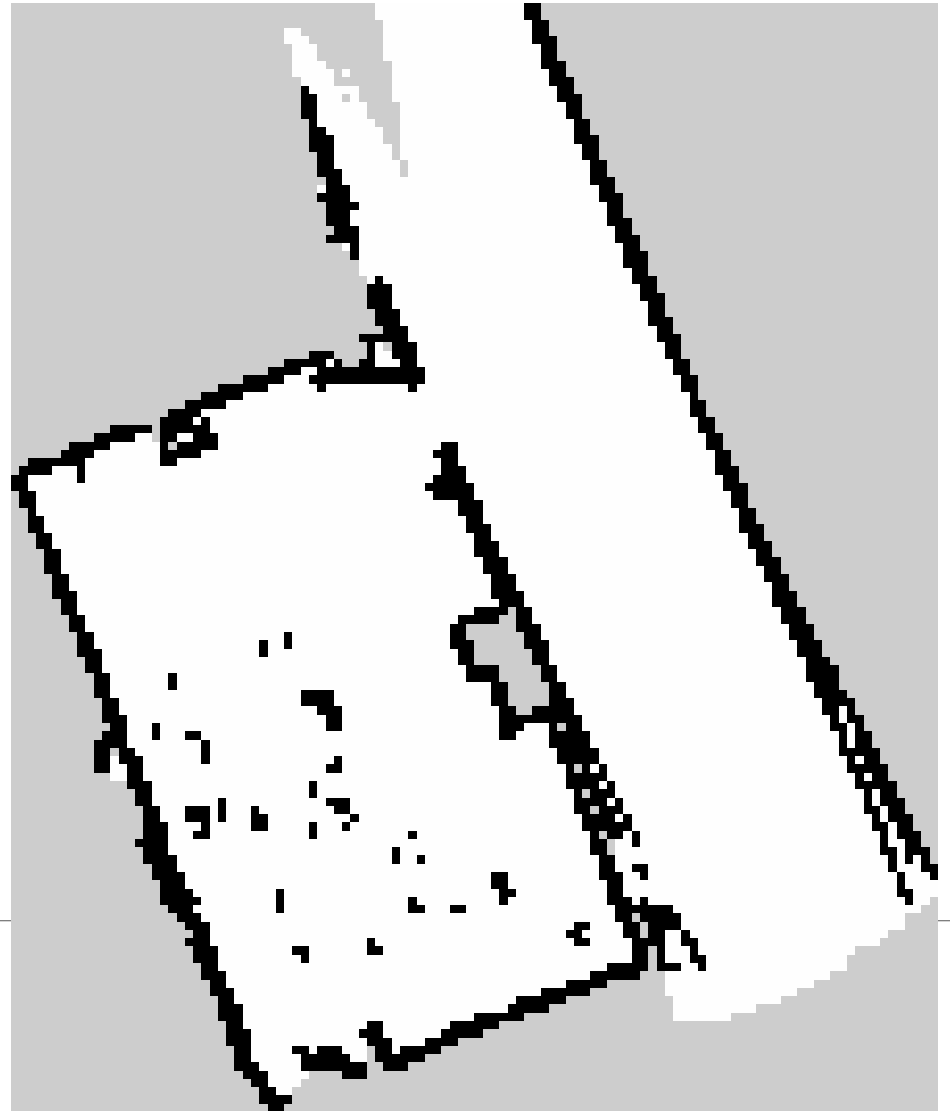


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Bildquelle: R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

SLAM - Simultaneous Localization and Mapping

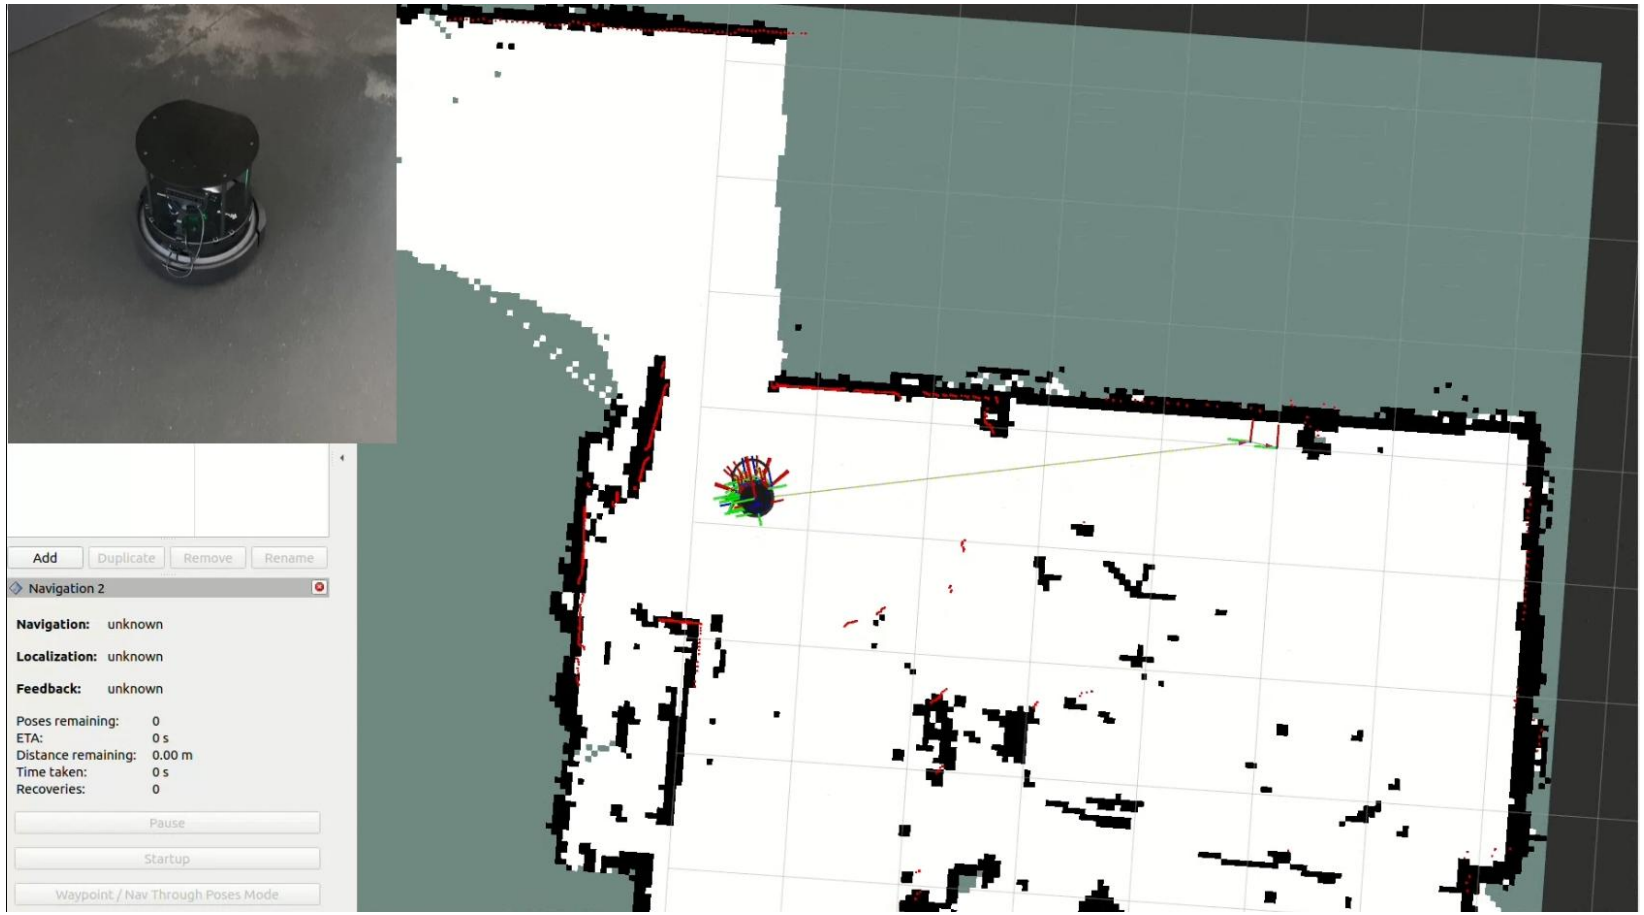
Karte des Raumes 1.242 mit Teil des Flures
erstellt durch Turtlebot mit SLAM



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

SLAM - Simultaneous Localization and Mapping

Karte des Flures vor Raum 1.242 erstellt durch Turtlebot mit SLAM

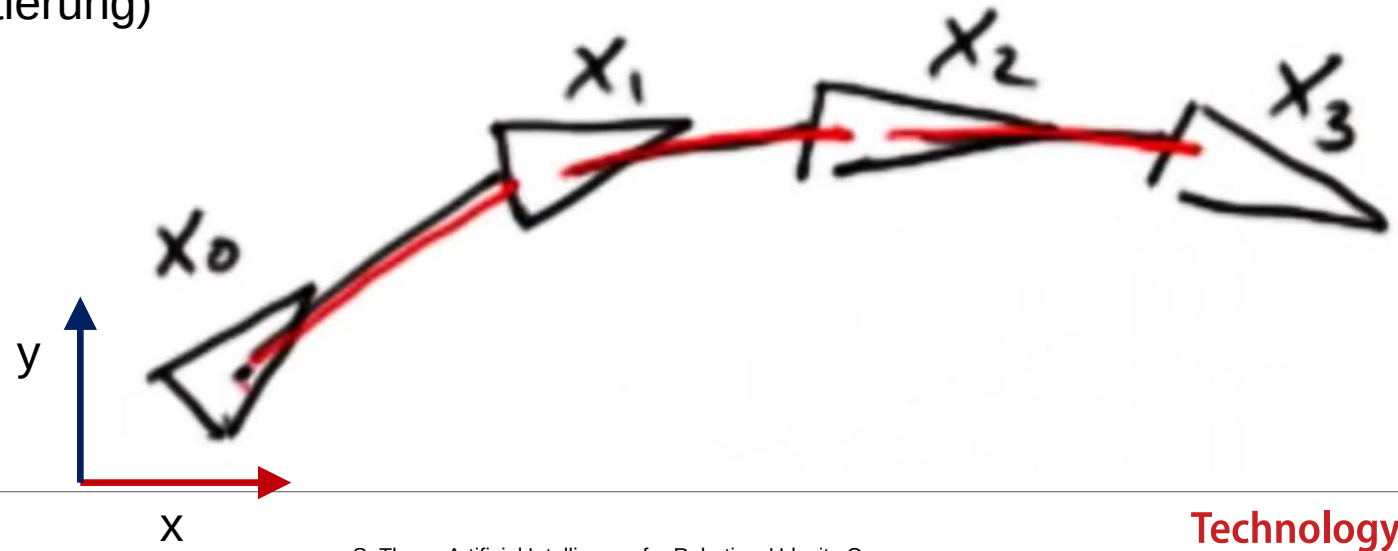


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

SLAM - Simultaneous Localization and Mapping

Wenn Sie keine Karte der Umgebung haben…

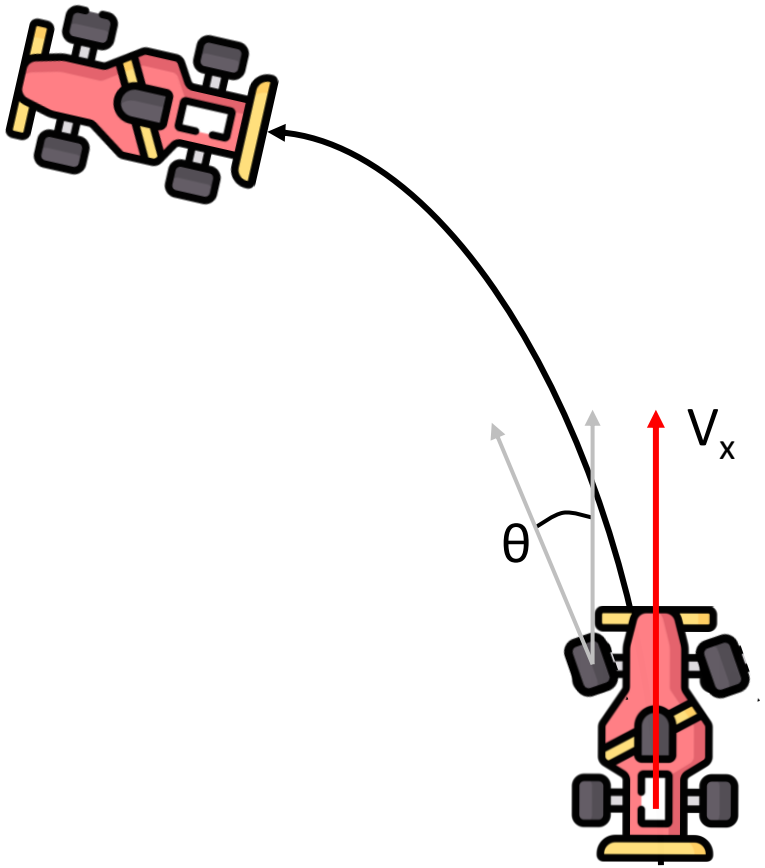
- Erstellung einer Karte der Umgebung durch ein autonom fahrendes System (bspw. Roboter)
- Problem:
  - Roboter weiß selbst nicht wo er sich befindet
- Roboter hat Sensoren mit denen er seine Bewegung messen kann. Bspw.:
  - Odometer (misst lineare Geschwindigkeit)
  - Inertialmesssystem (misst Orientierung)



S. Thrun, Artificial Intelligence for Robotics, Udacity Course, https://www.udacity.com/course/artificial-intelligence-for-robotics--cs373

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Dead Reckoning (Koppelnavigation)



Berechnung der aktuellen Position eines fahrenden Roboters auf der Grundlage einer zuvor ermittelten Position.

Mit Hilfe eines grundlegenden Kinematikmodells kann die relative Position des Fahrzeugs anhand von Messungen

- der Fahrgeschwindigkeit in Längsrichtung und
- des aktuellen Lenkwinkels

bestimmt werden.

Problem: Bestimmte Position wird mit der Zeit immer ungenauer.

SLAM - Simultaneous Localization and Mapping

Graph SLAM

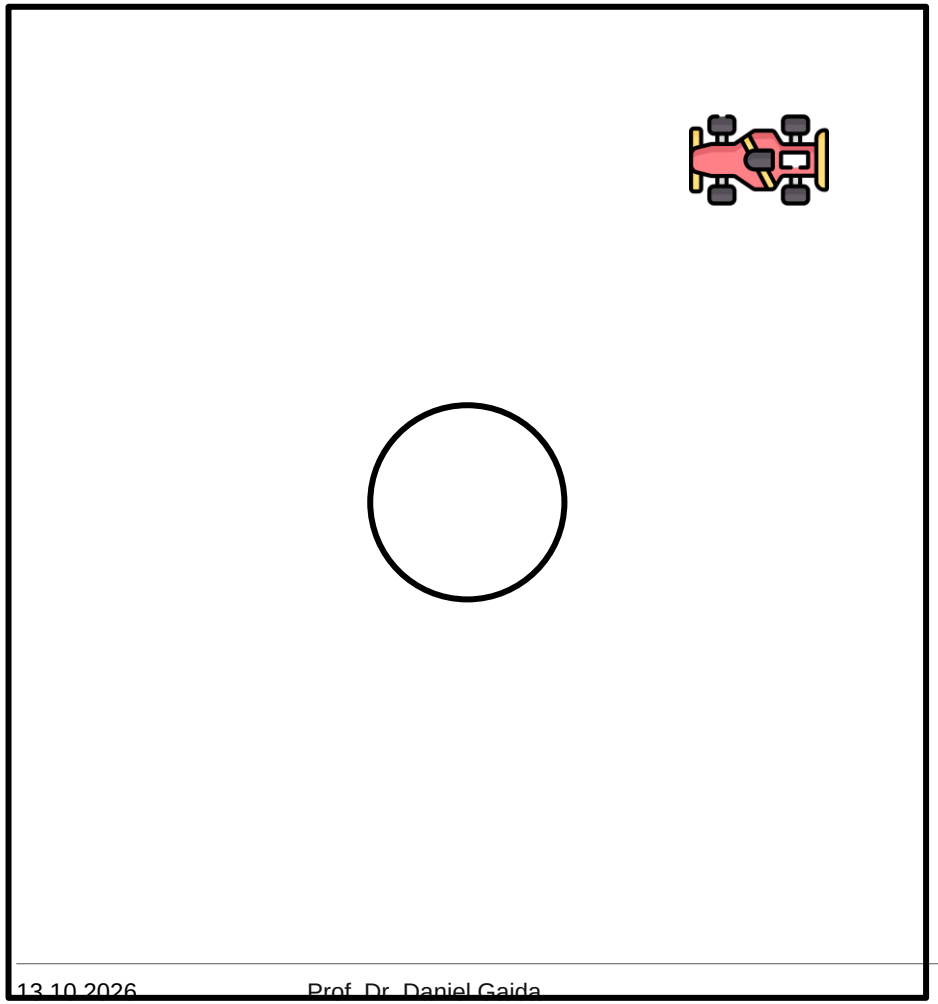
- Landmark – Fixpunkt, dessen Position bekannt ist



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

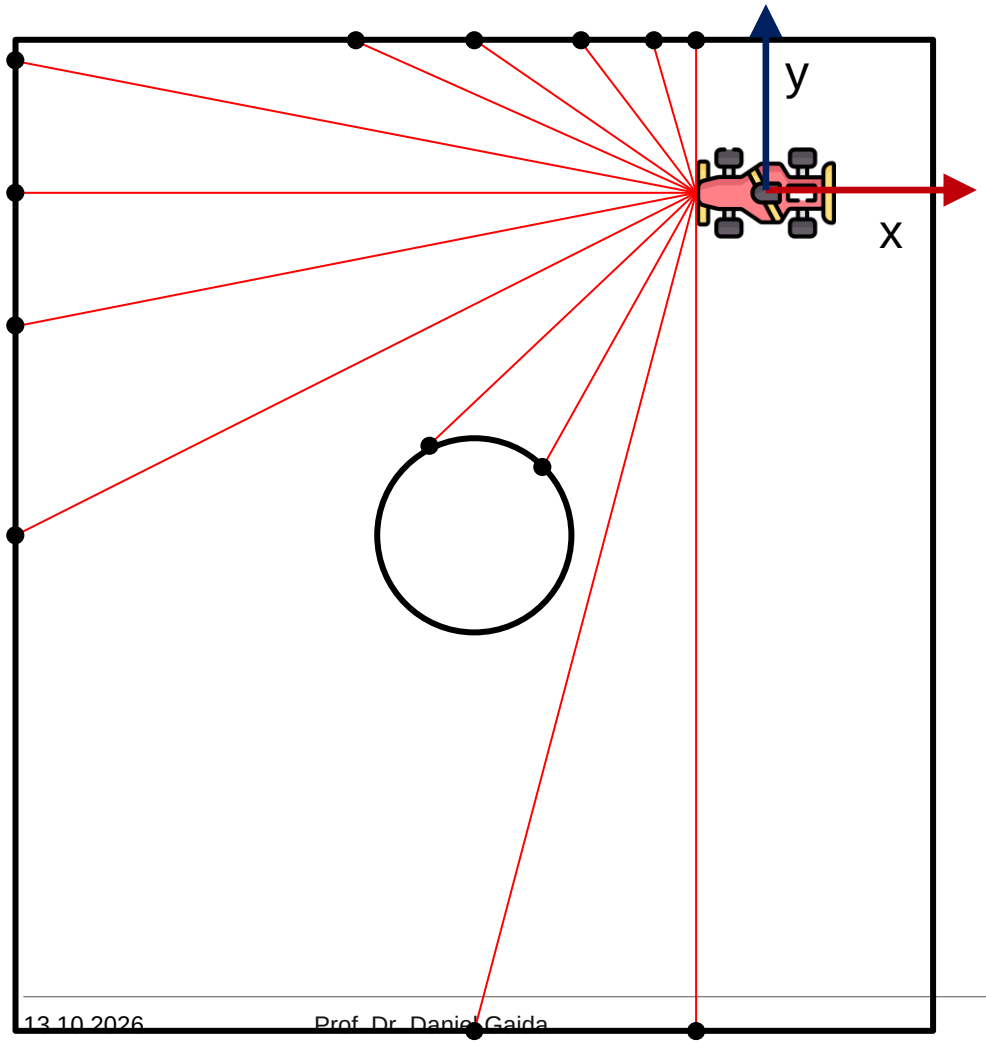
S. Thrun, Artificial Intelligence for Robotics, Udacity Course, https://www.udacity.com/course/artificial-intelligence-for-robotics--cs373

Sensing the environment



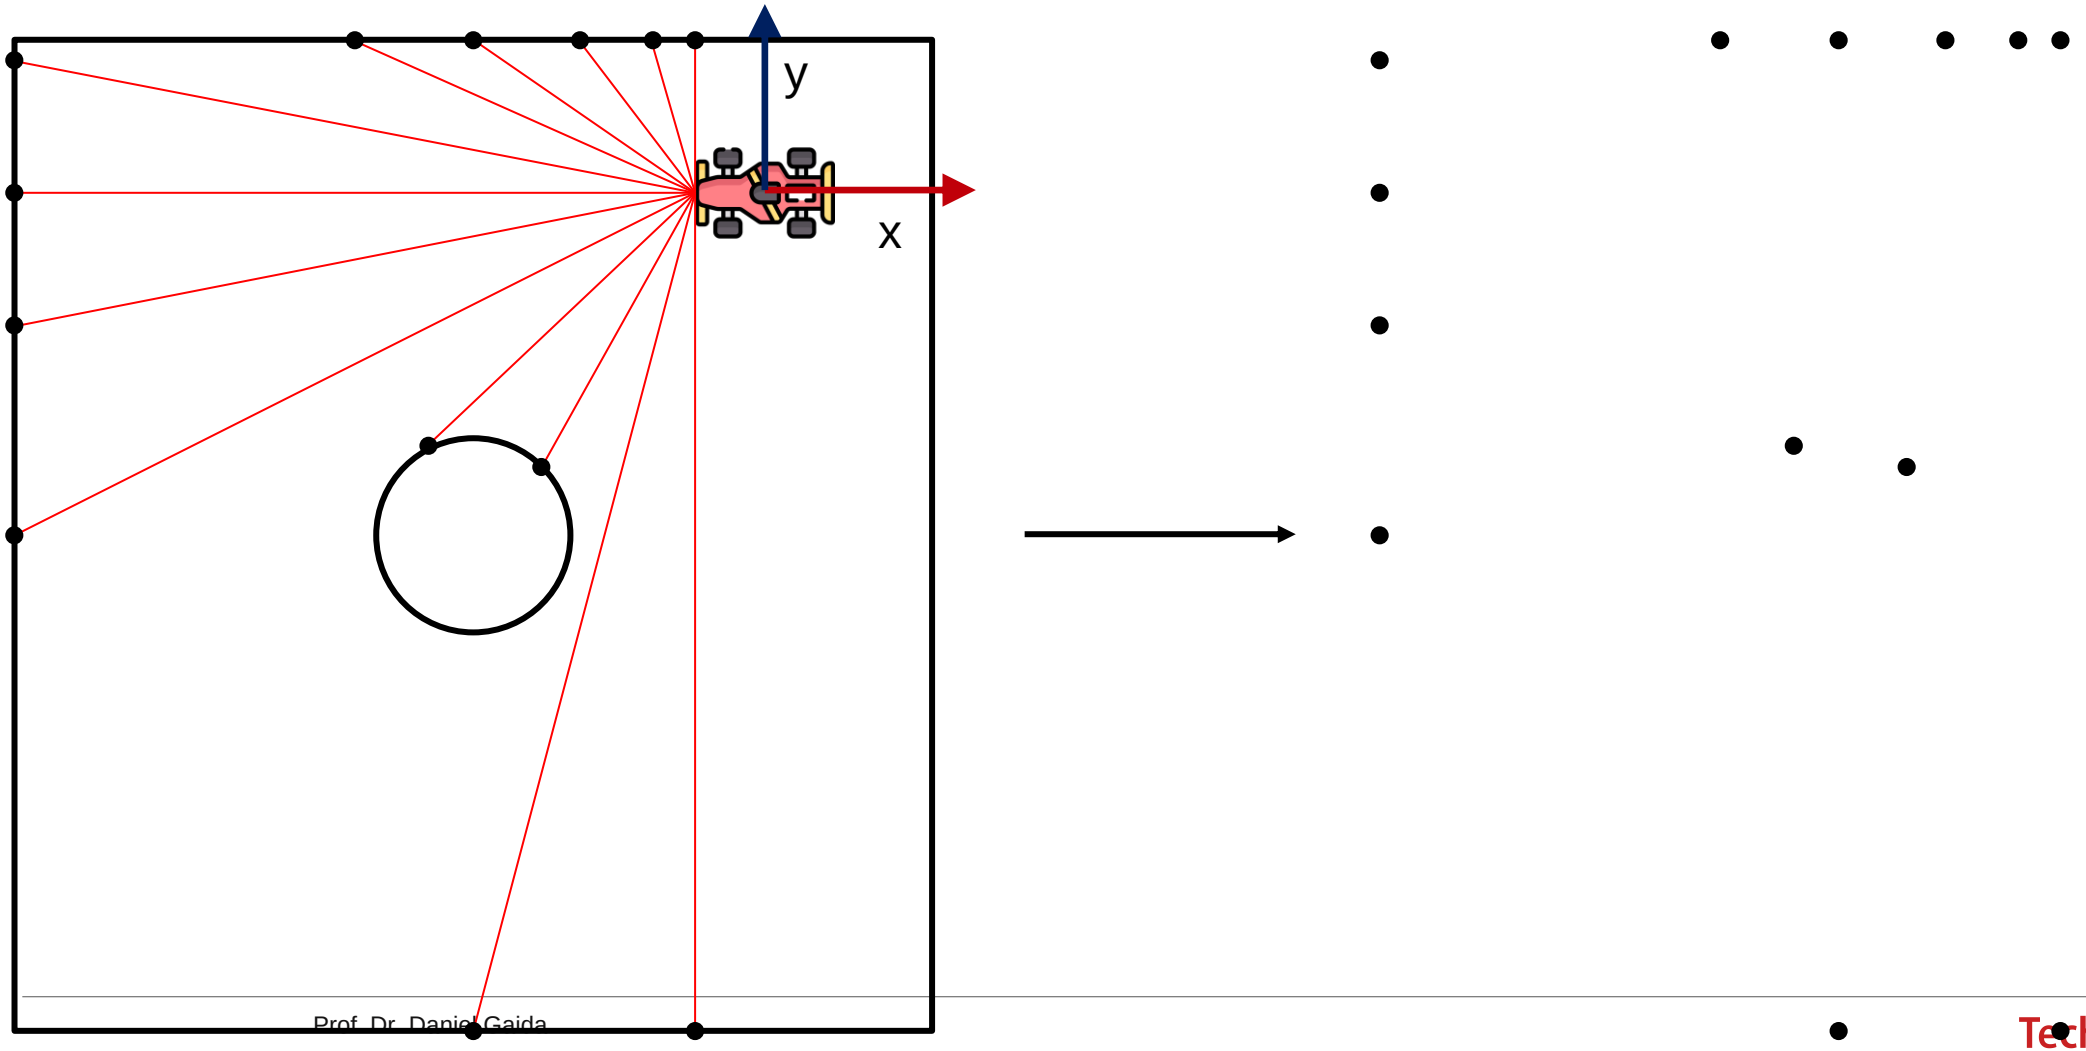
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Sensing the environment



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Sensing the environment



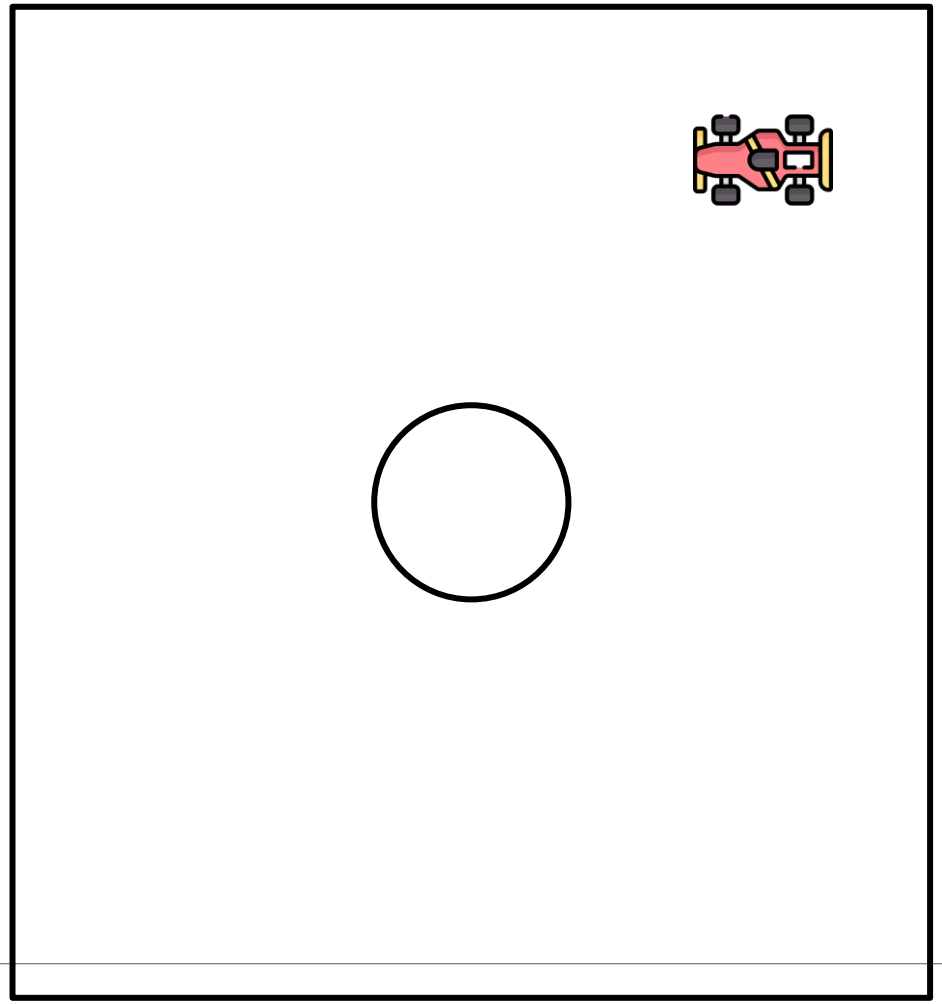
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Alright, let’s try to make a map.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

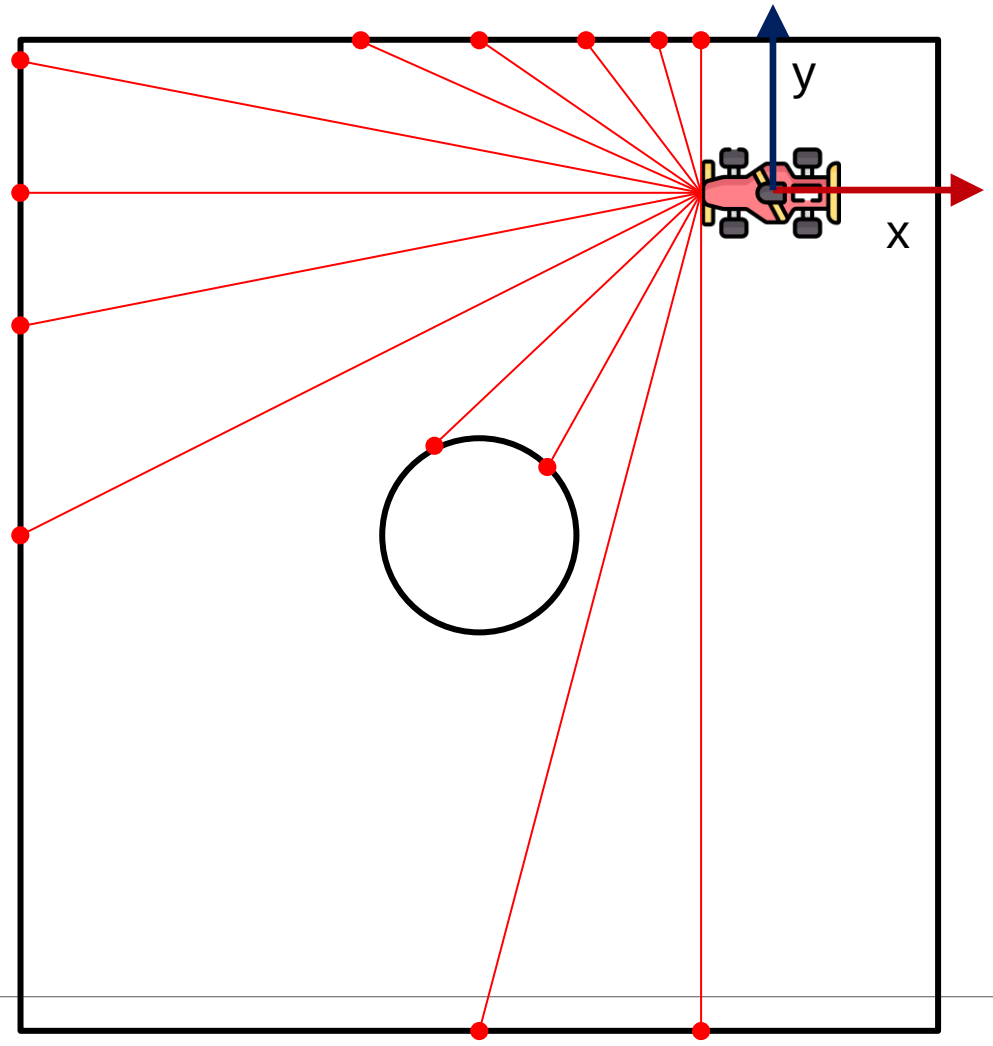
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

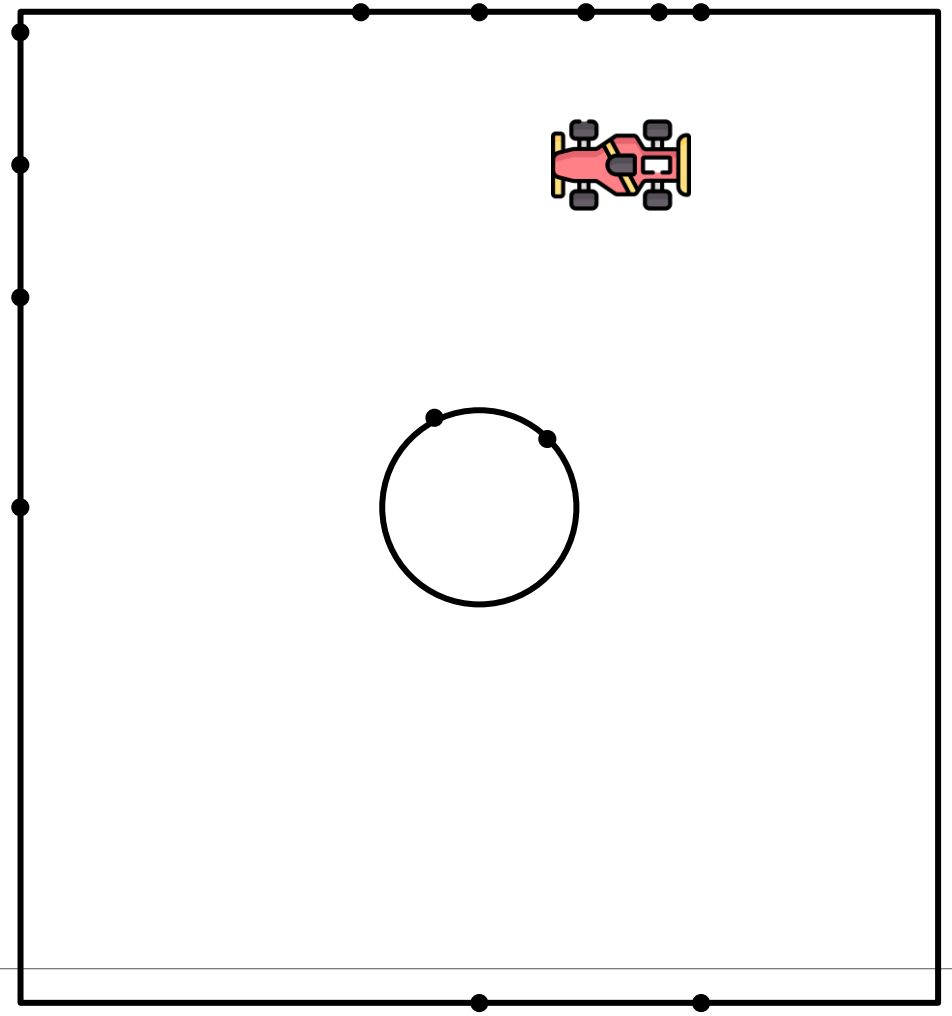
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

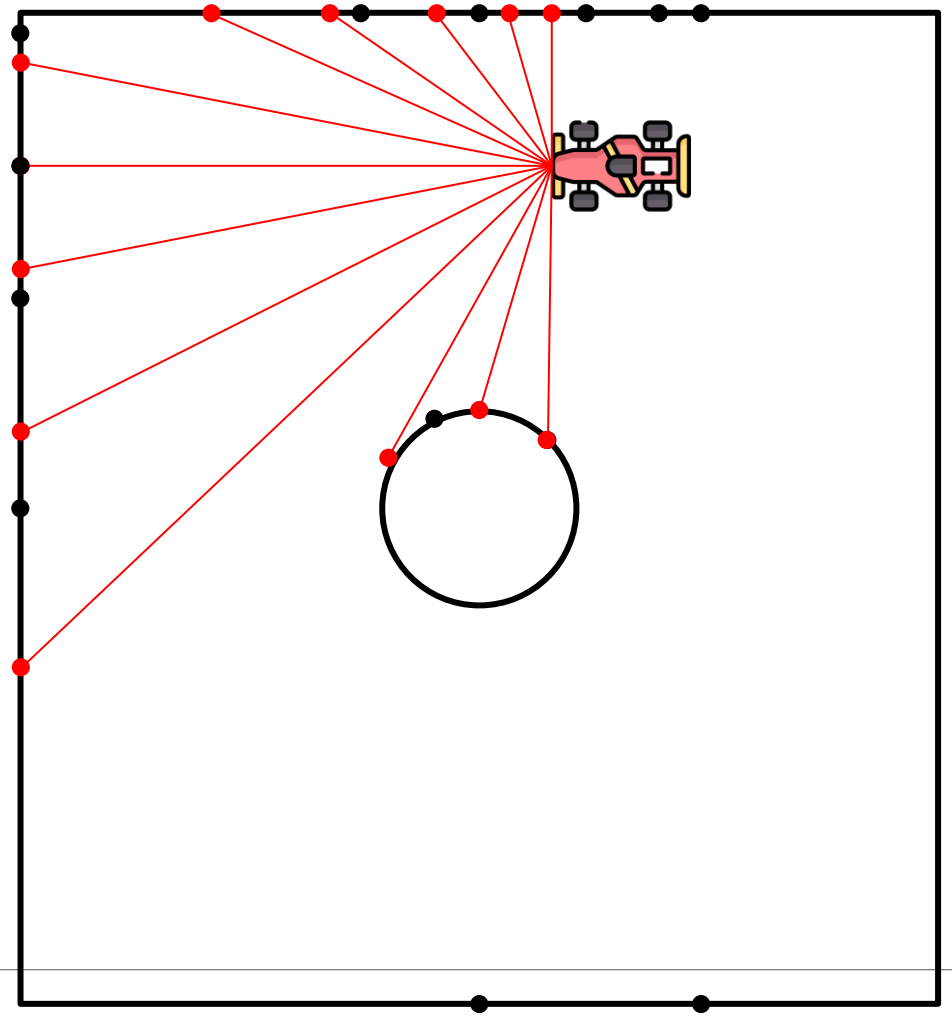
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

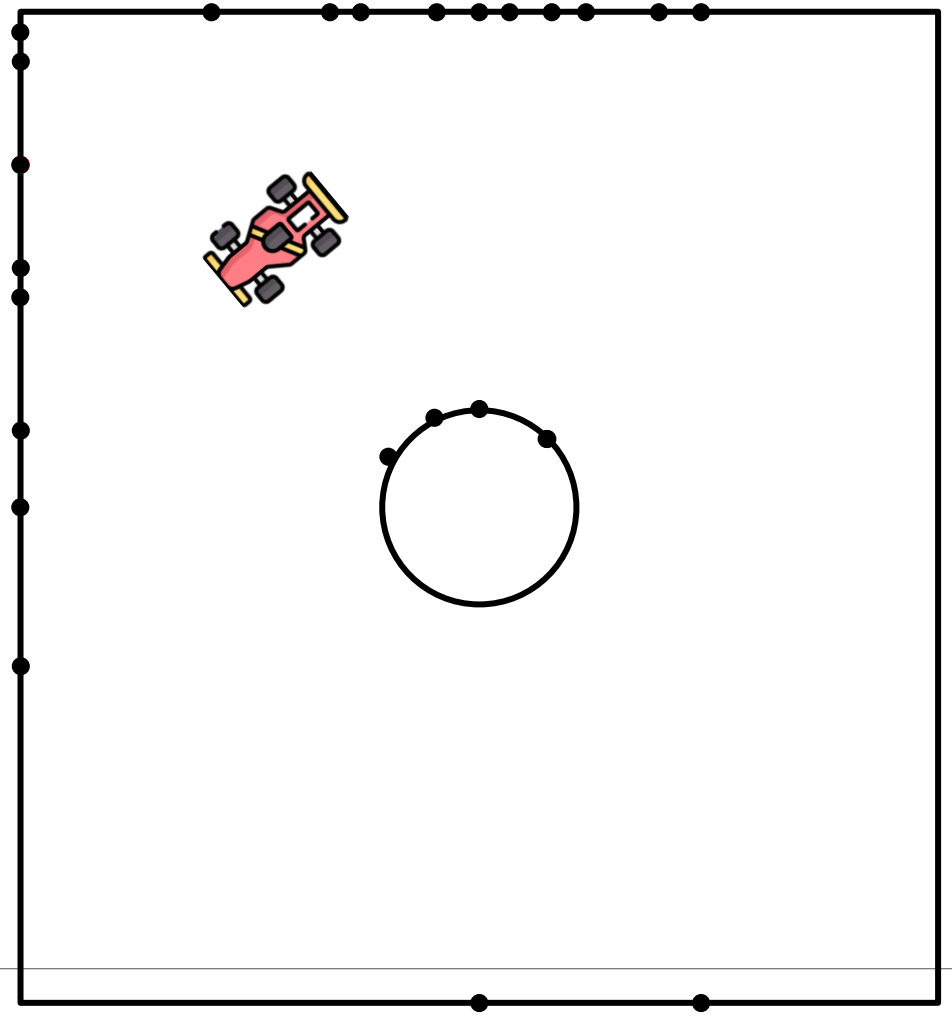
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

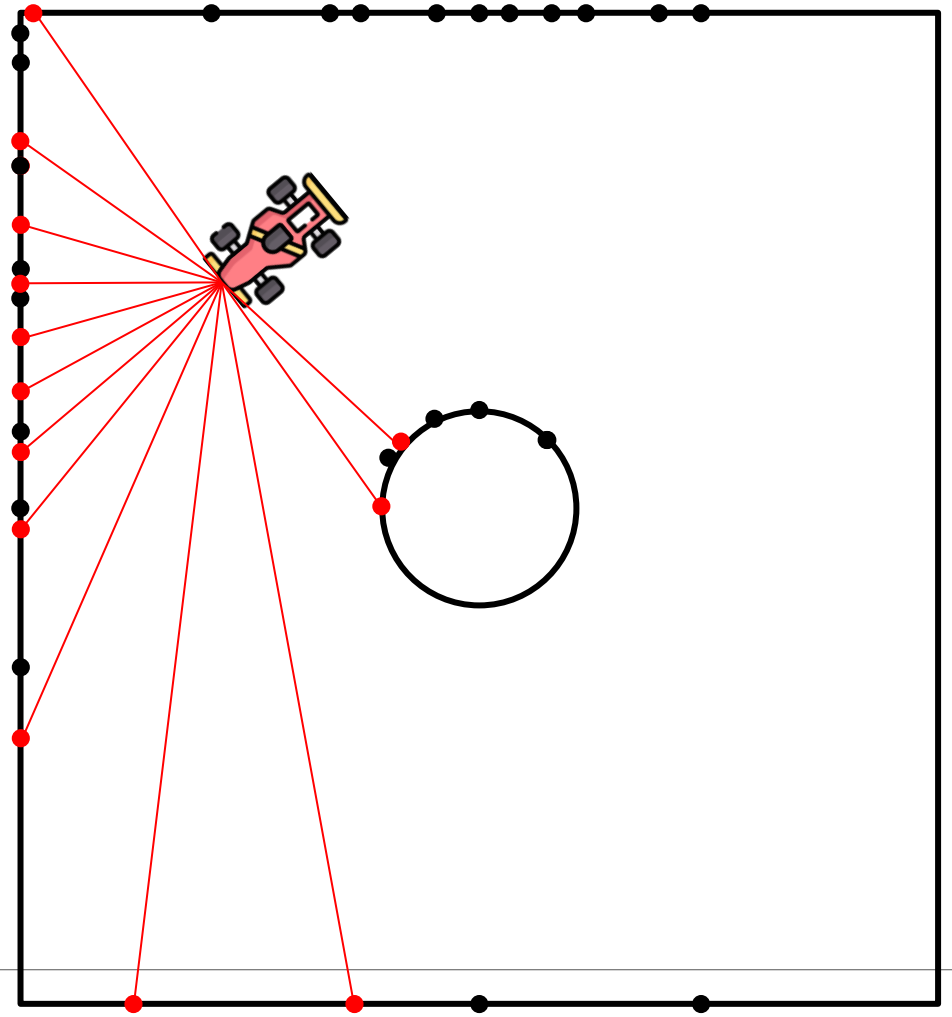
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

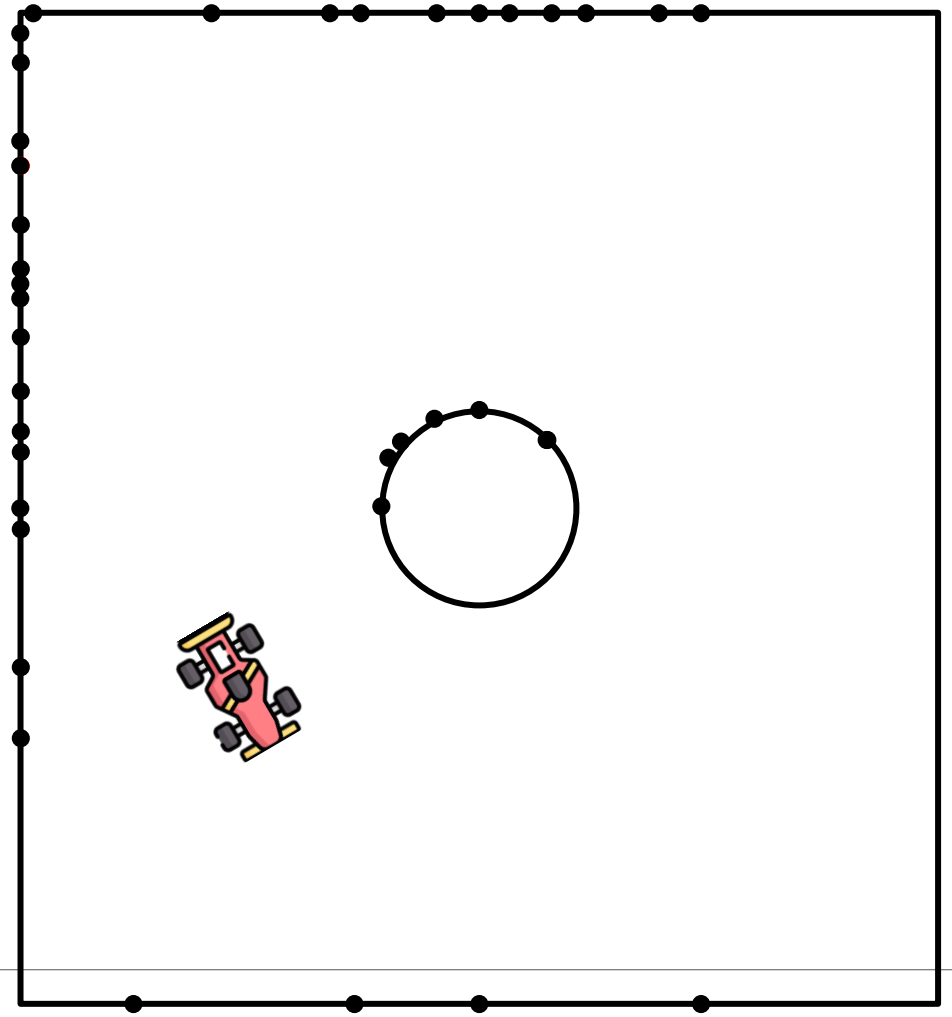
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

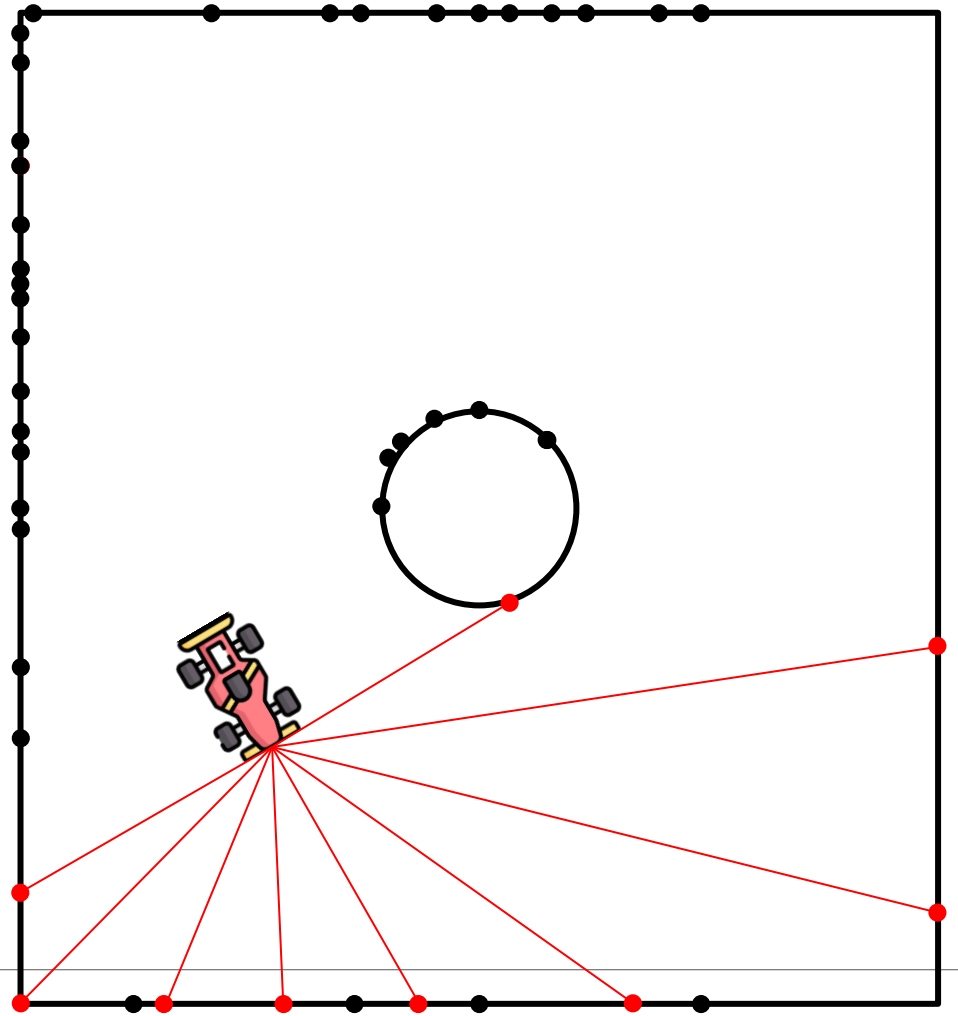
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

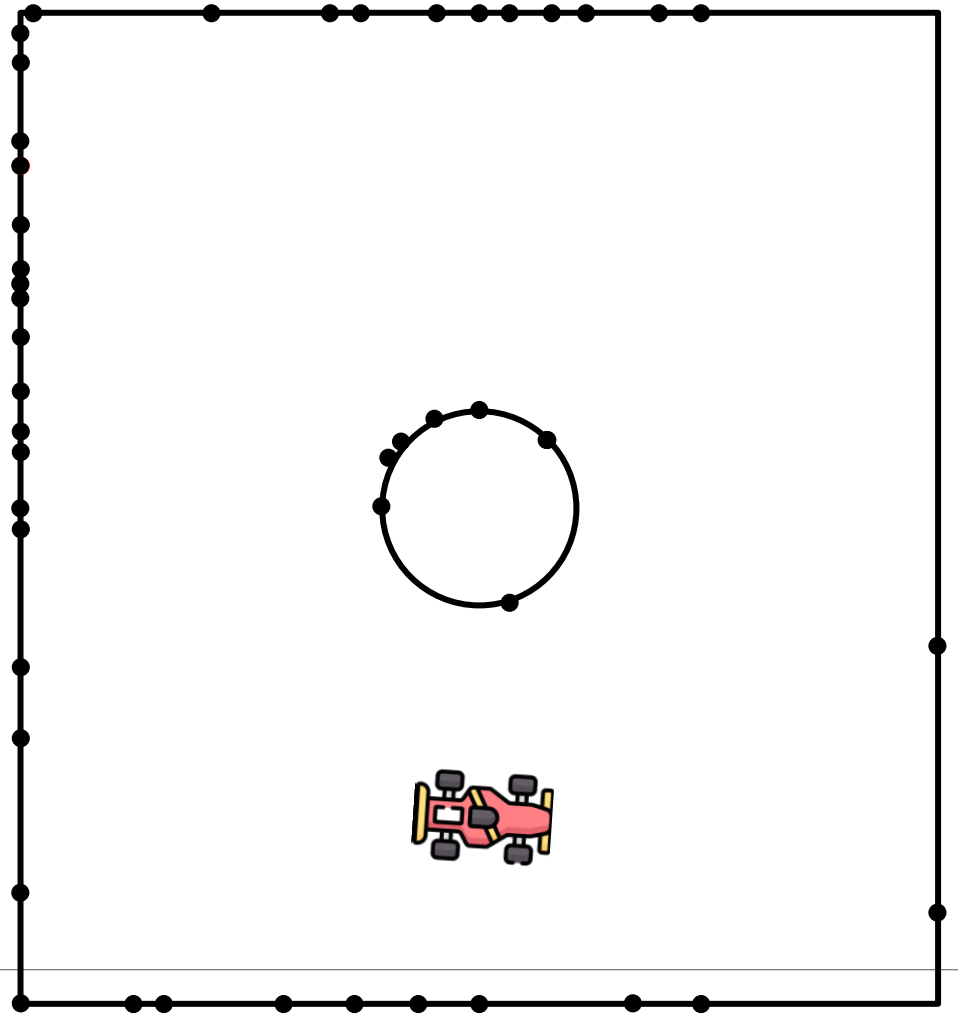
Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Technology Arts Sciences TH Köln

In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

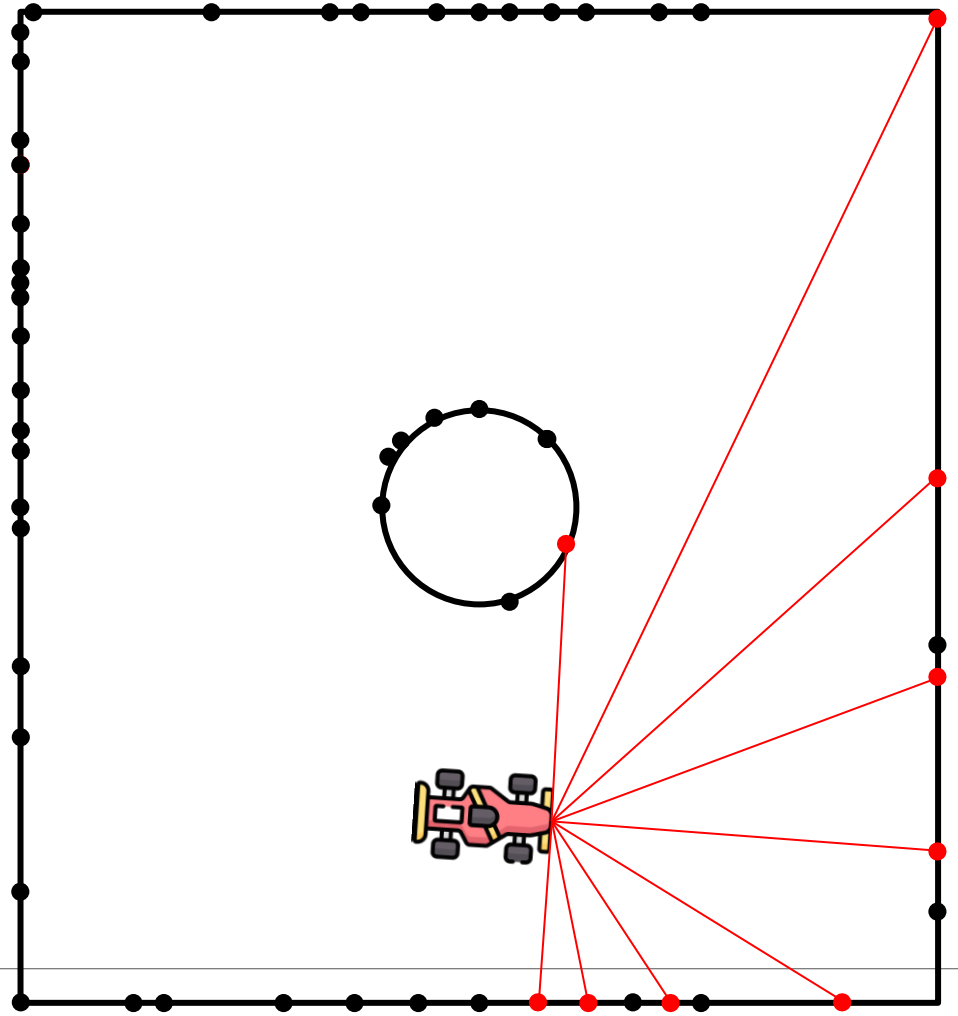
Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Technology Arts Sciences TH Köln

In an ideal world…



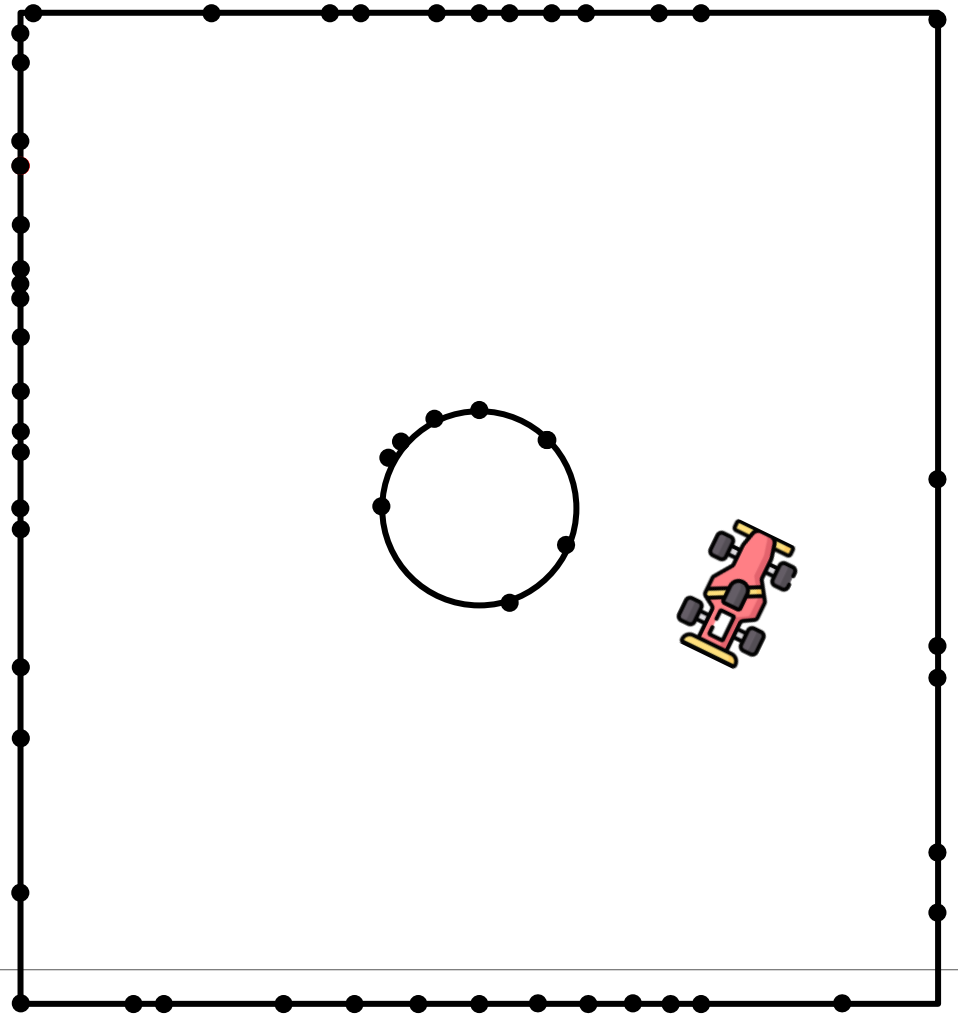
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

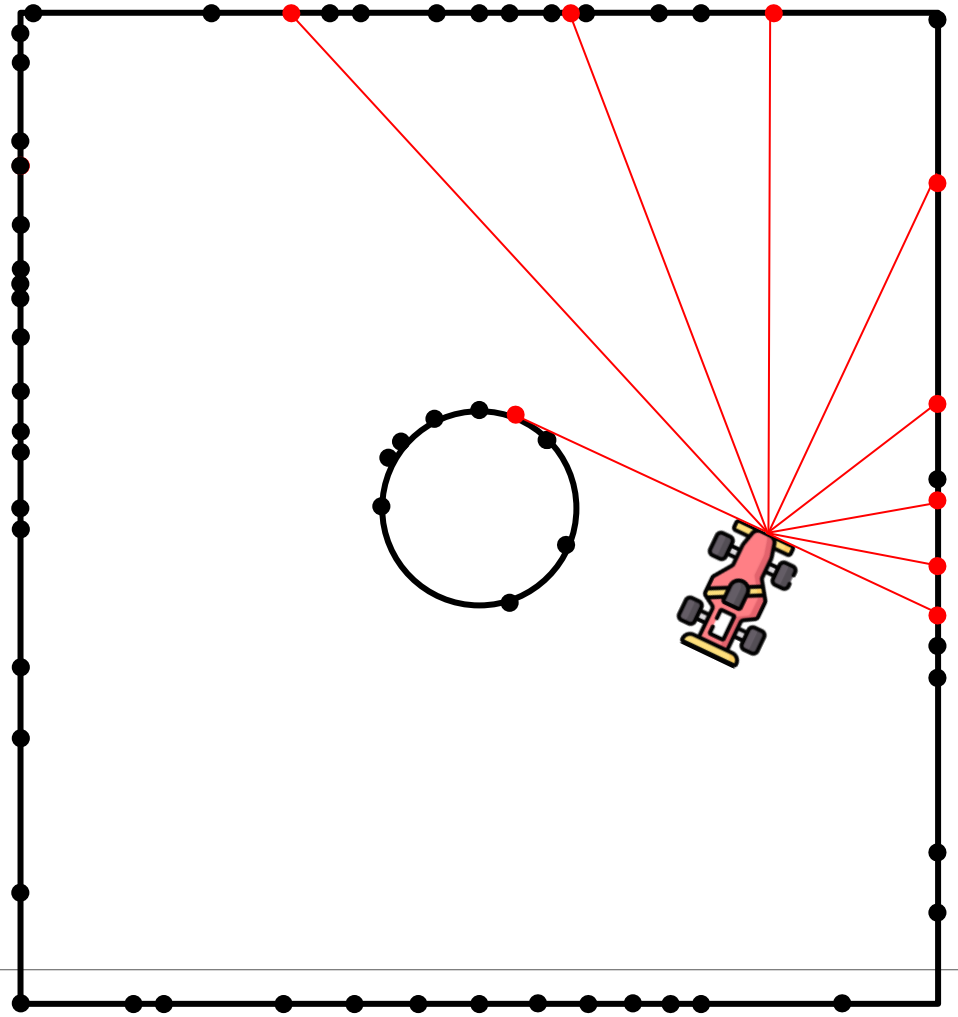
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

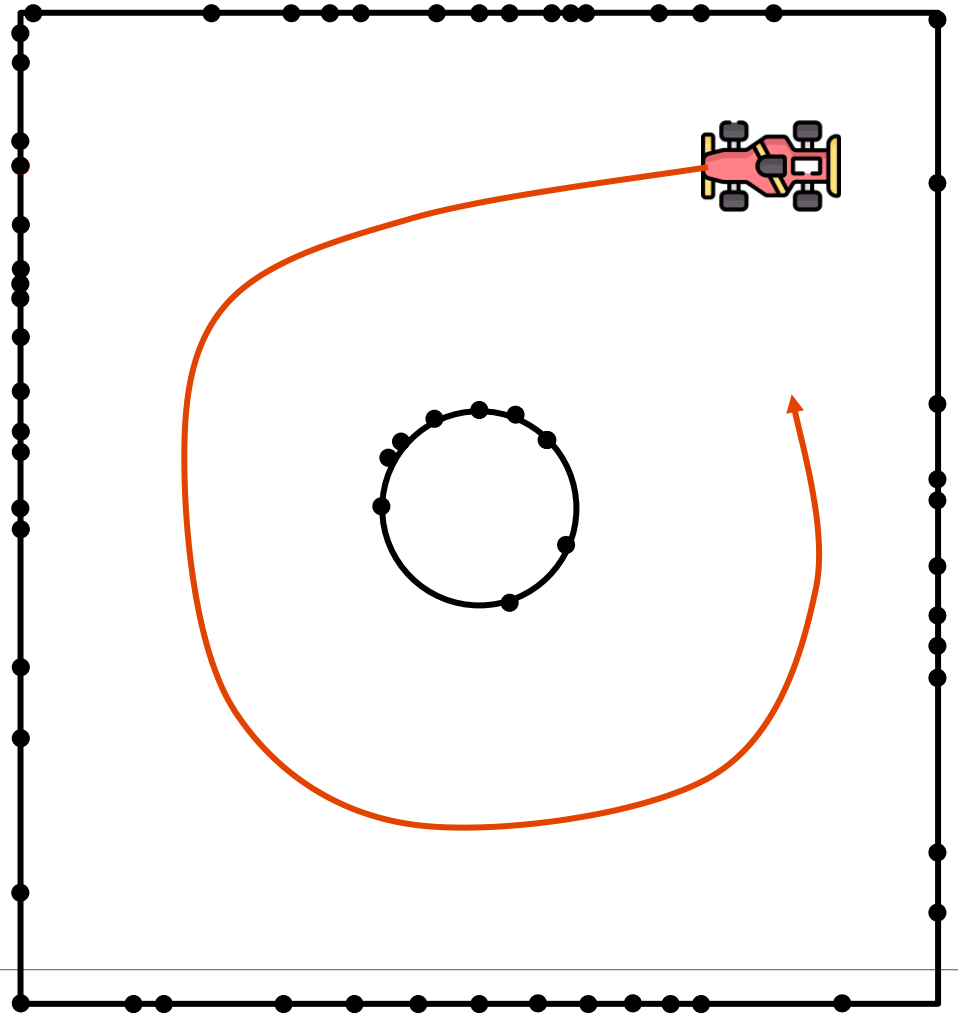
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

In an ideal world…



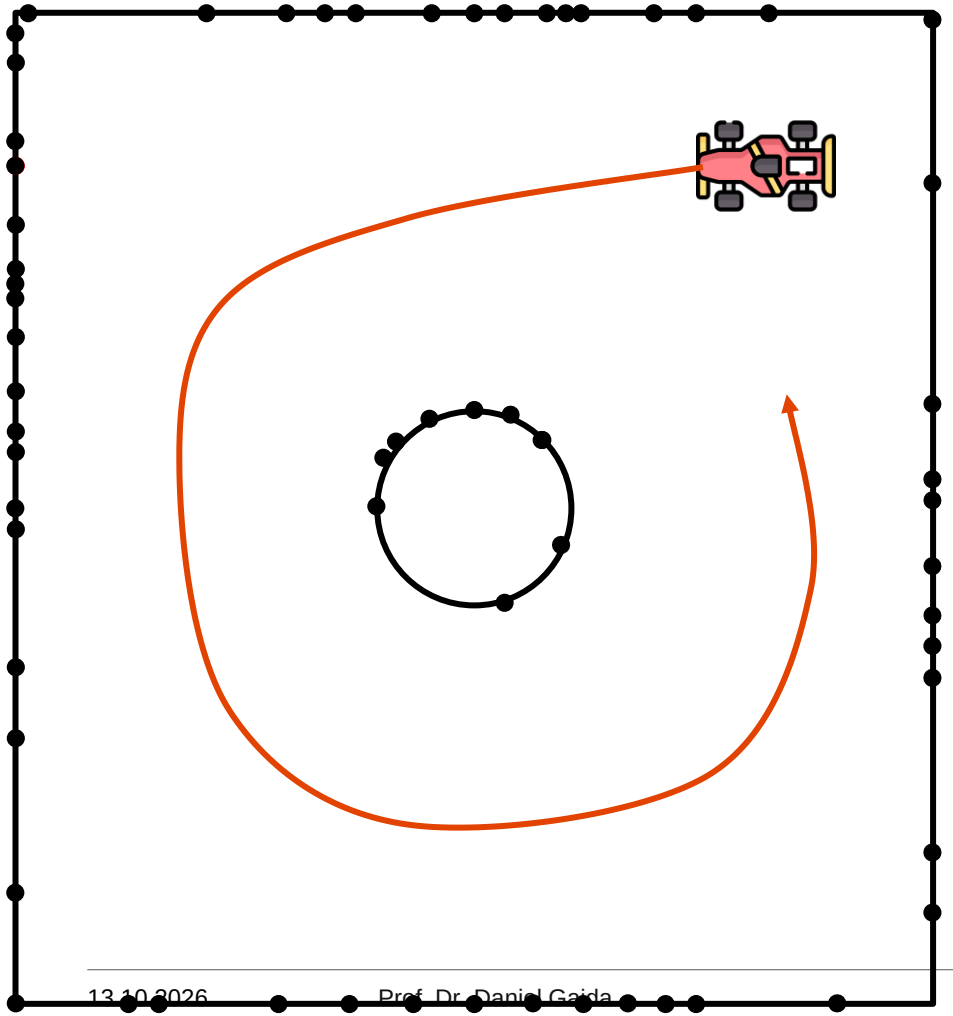
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

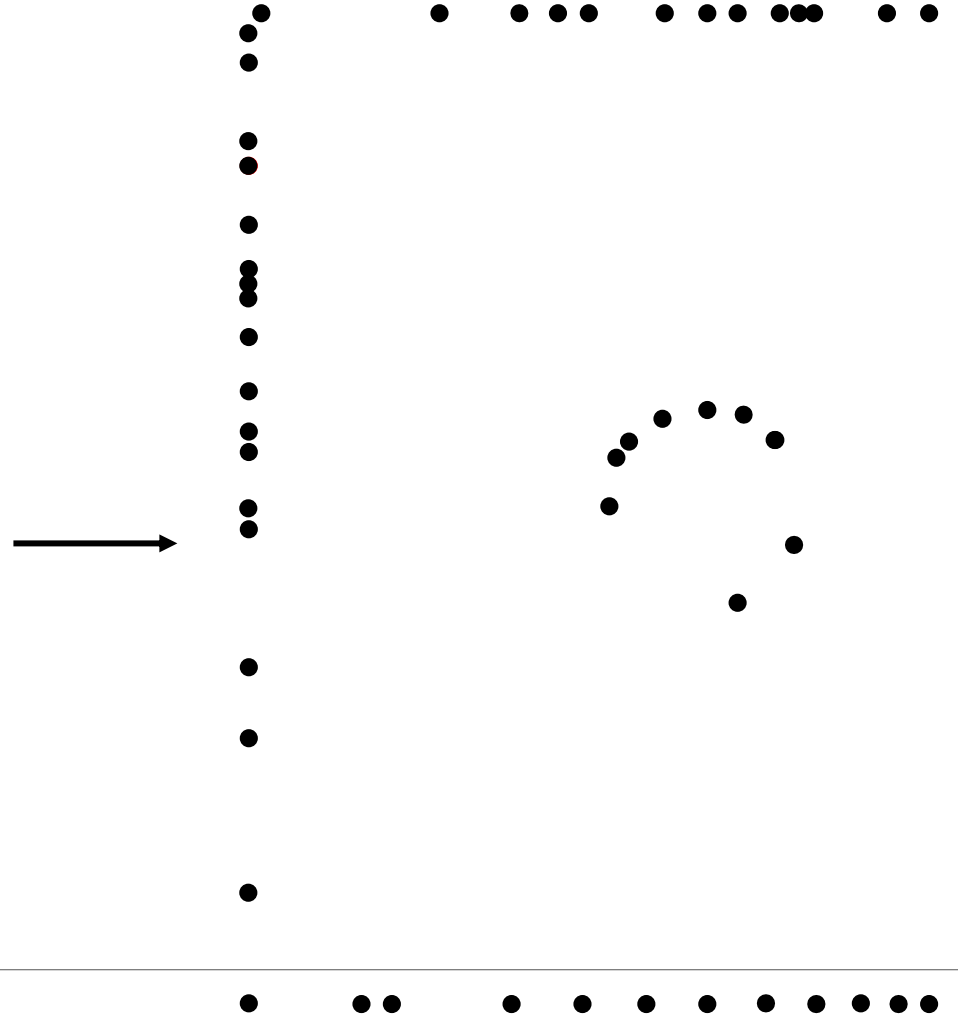
Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

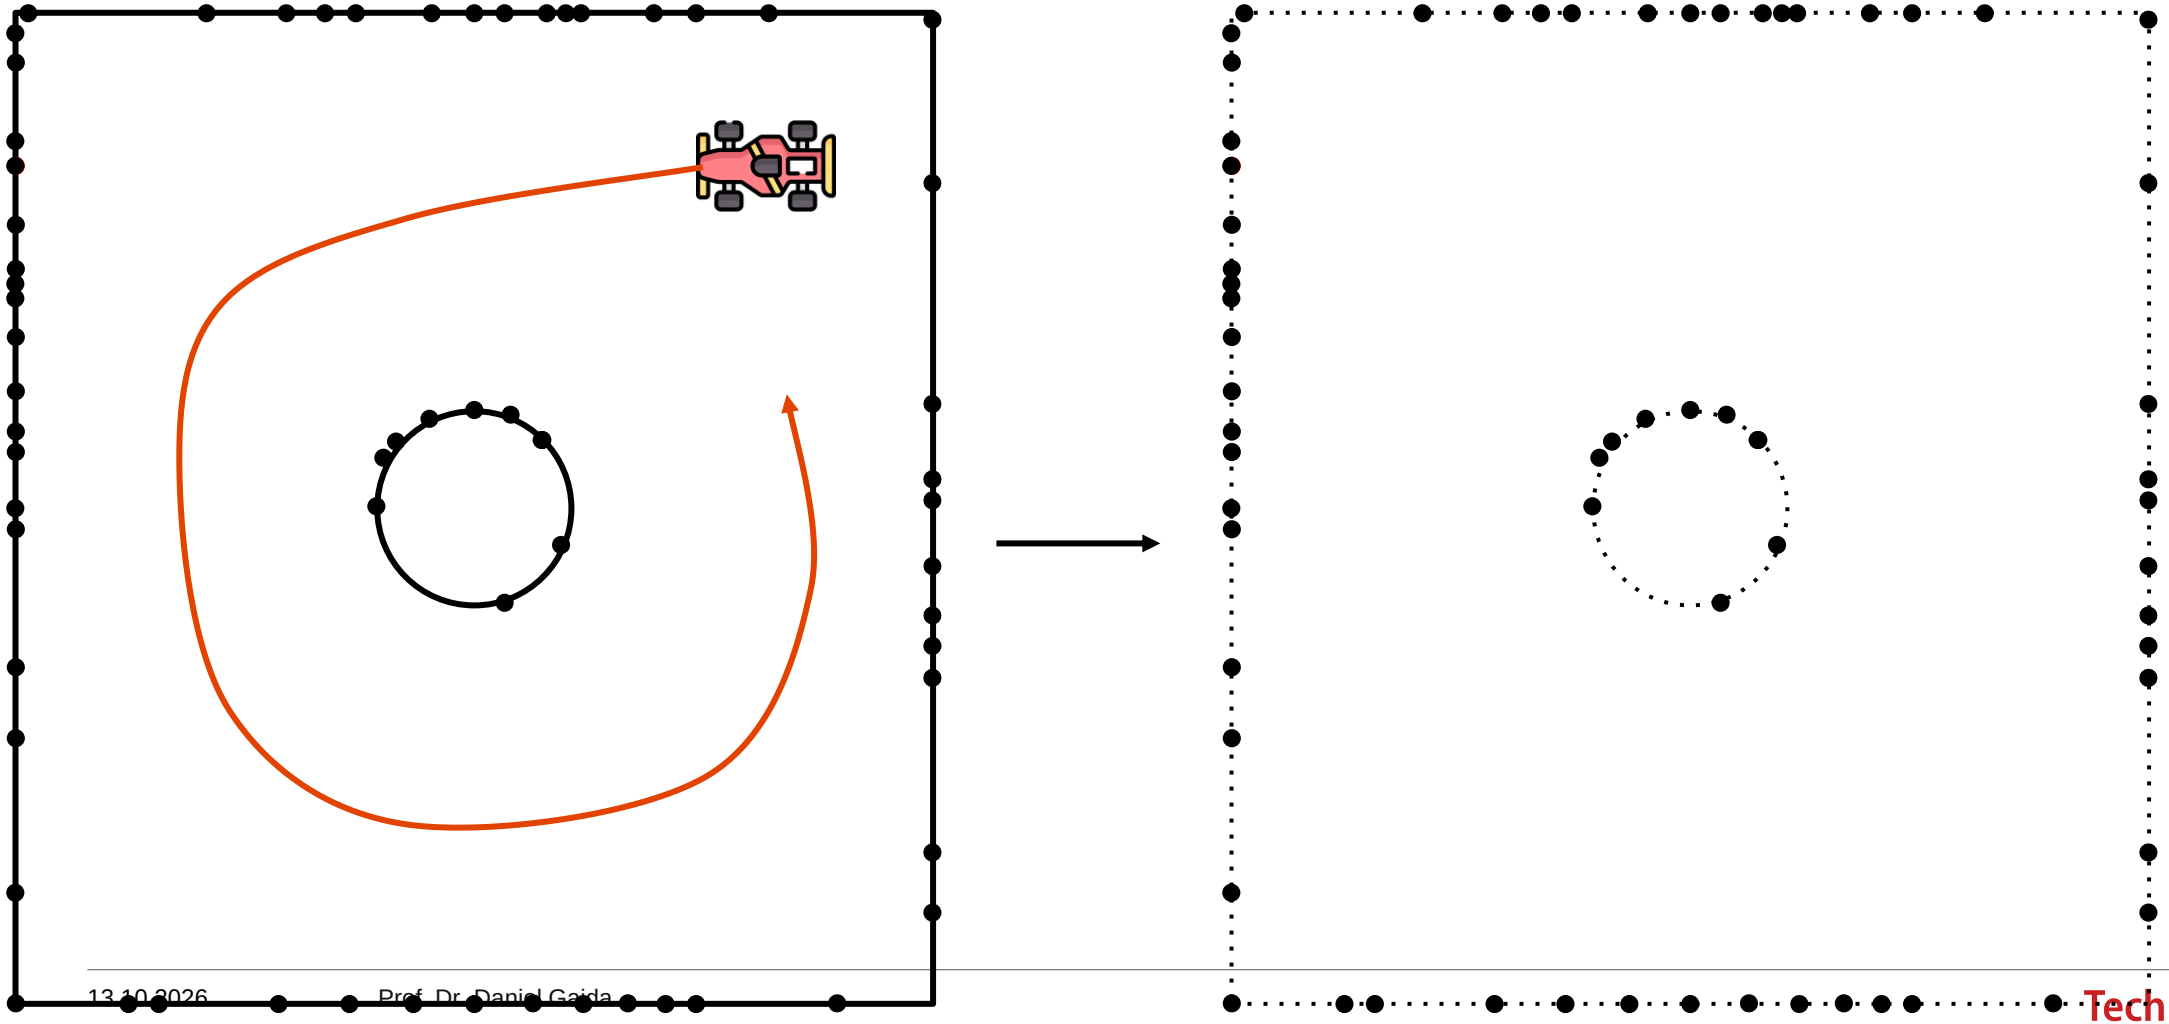
In an ideal world…





R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

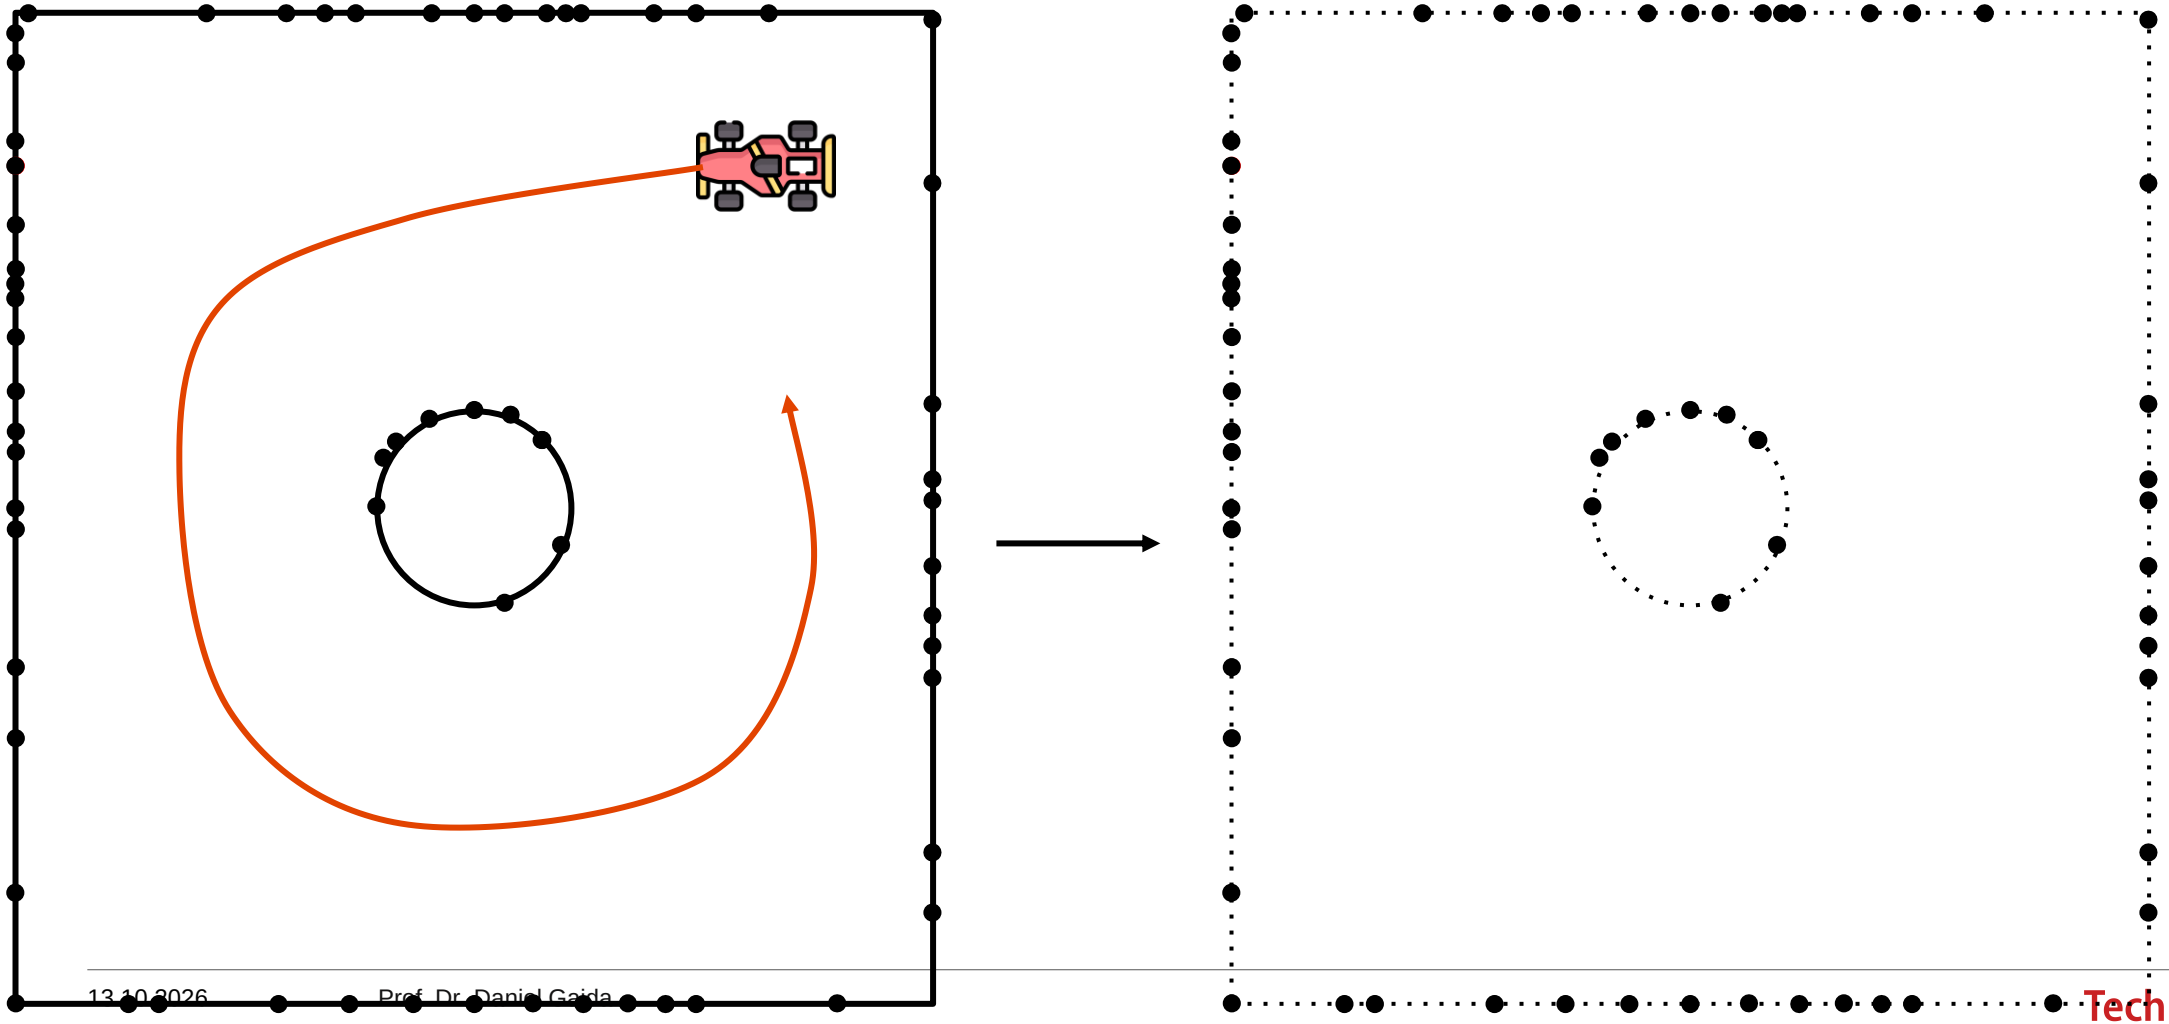
In an ideal world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

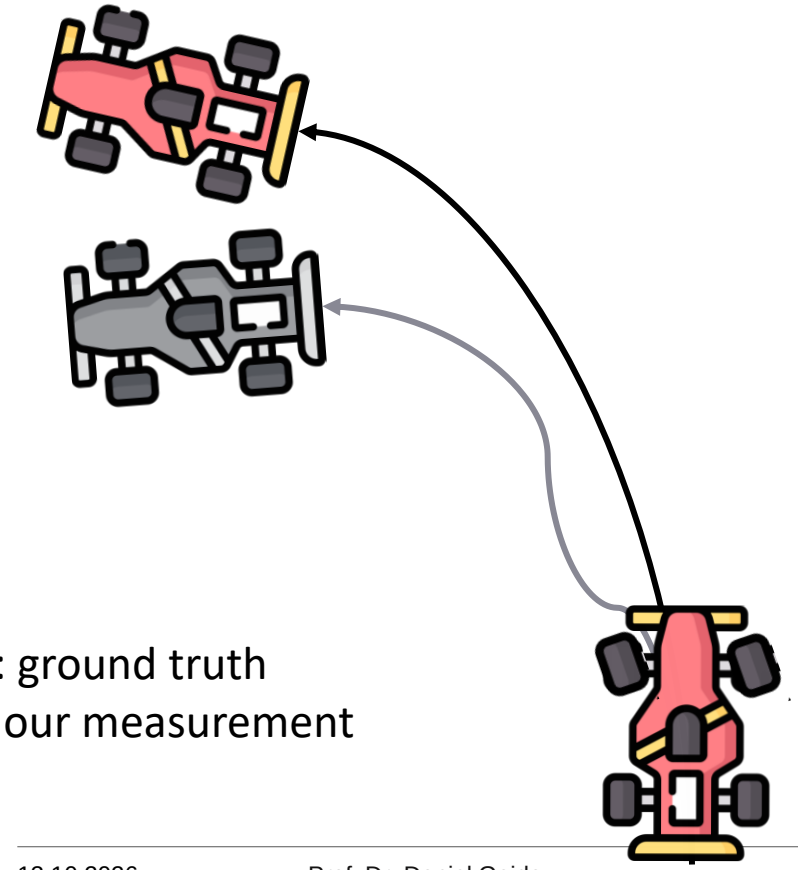
Wie lokalisieren wir uns in dieser Umgebung?

Partikelfilter: Vergleich Lidar-Messung mit Karte

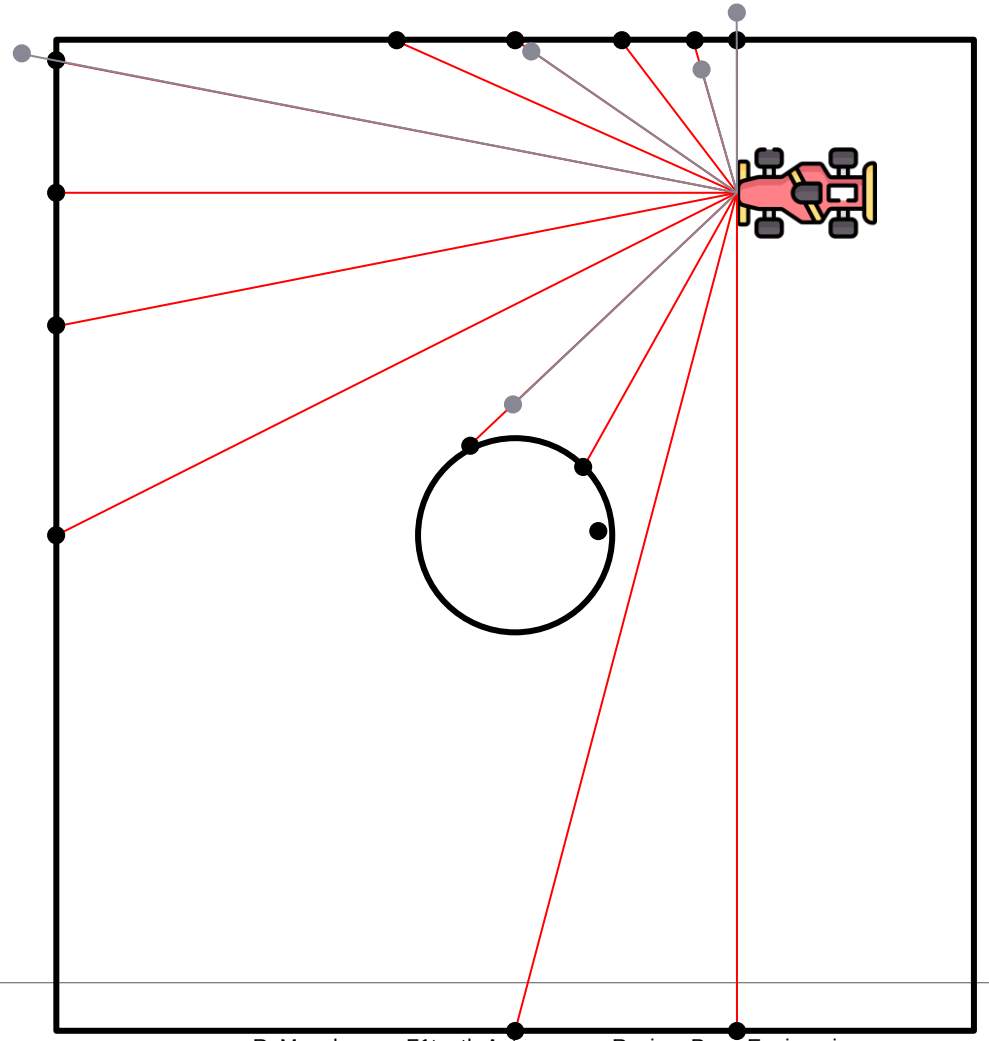


R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

But in the real world…



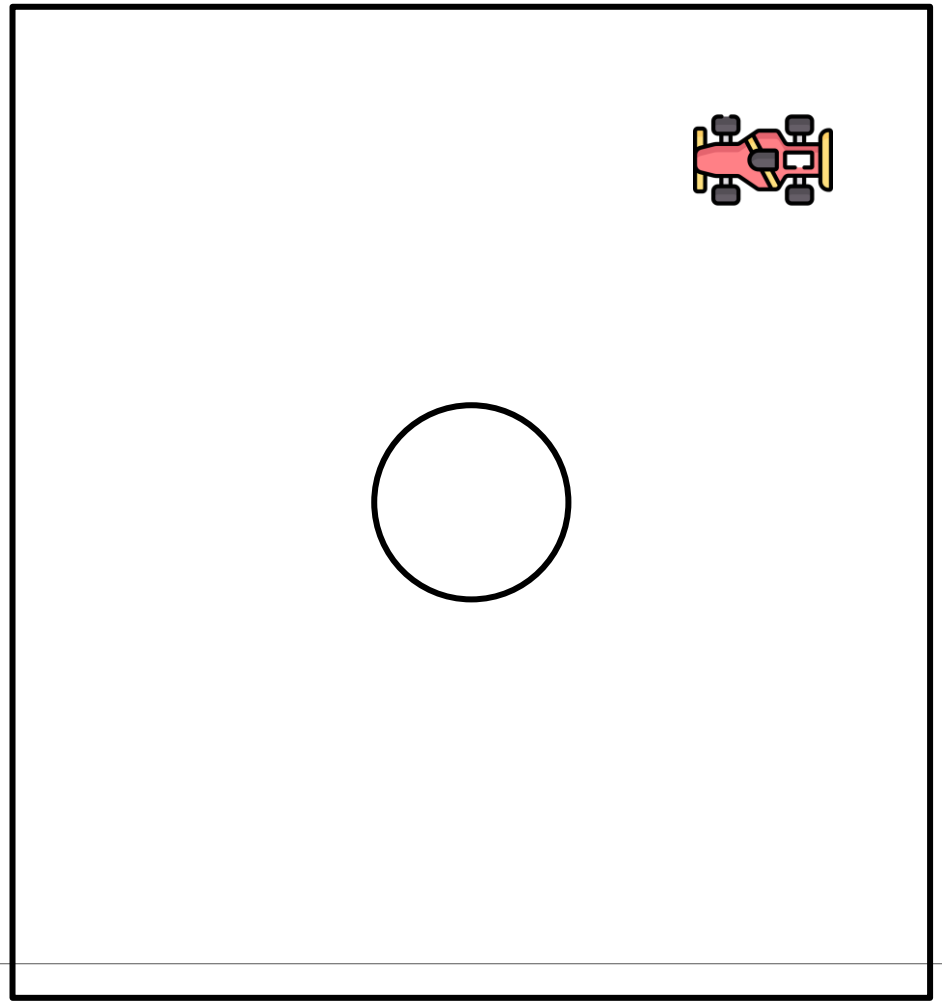
Color: ground truth
Gray: our measurement



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

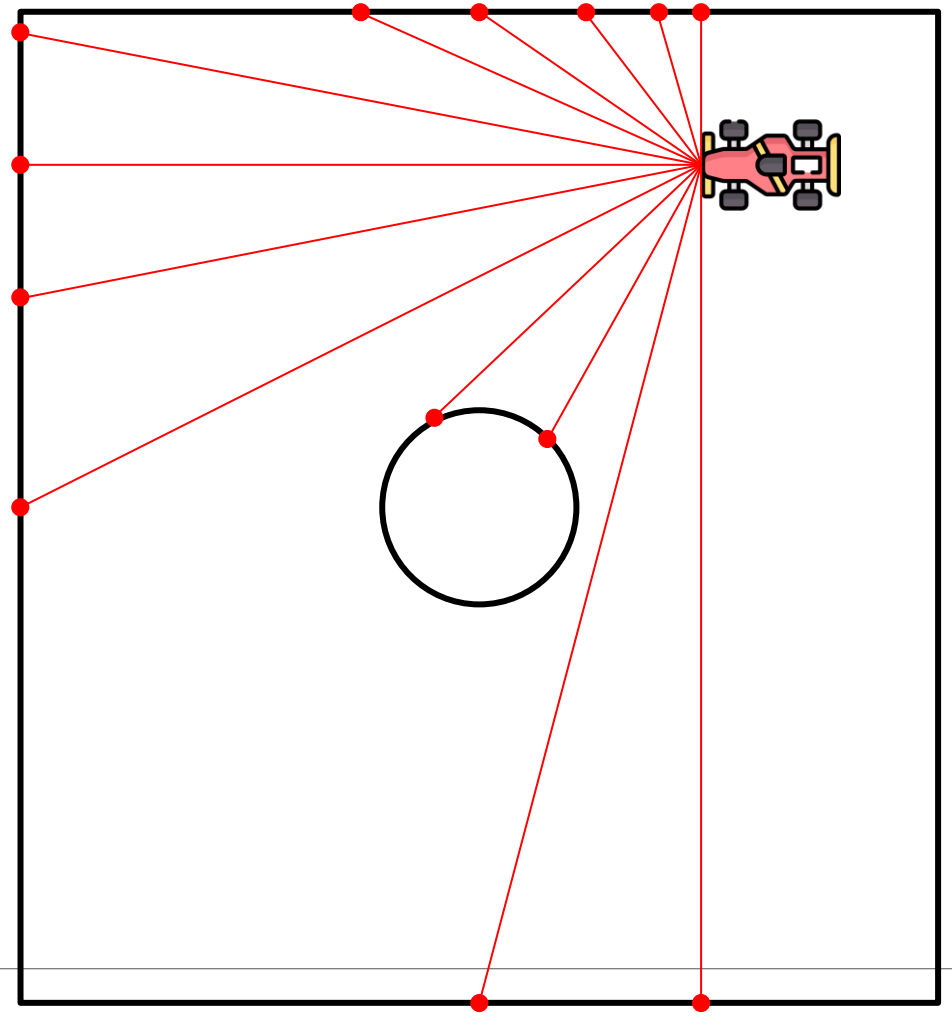
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

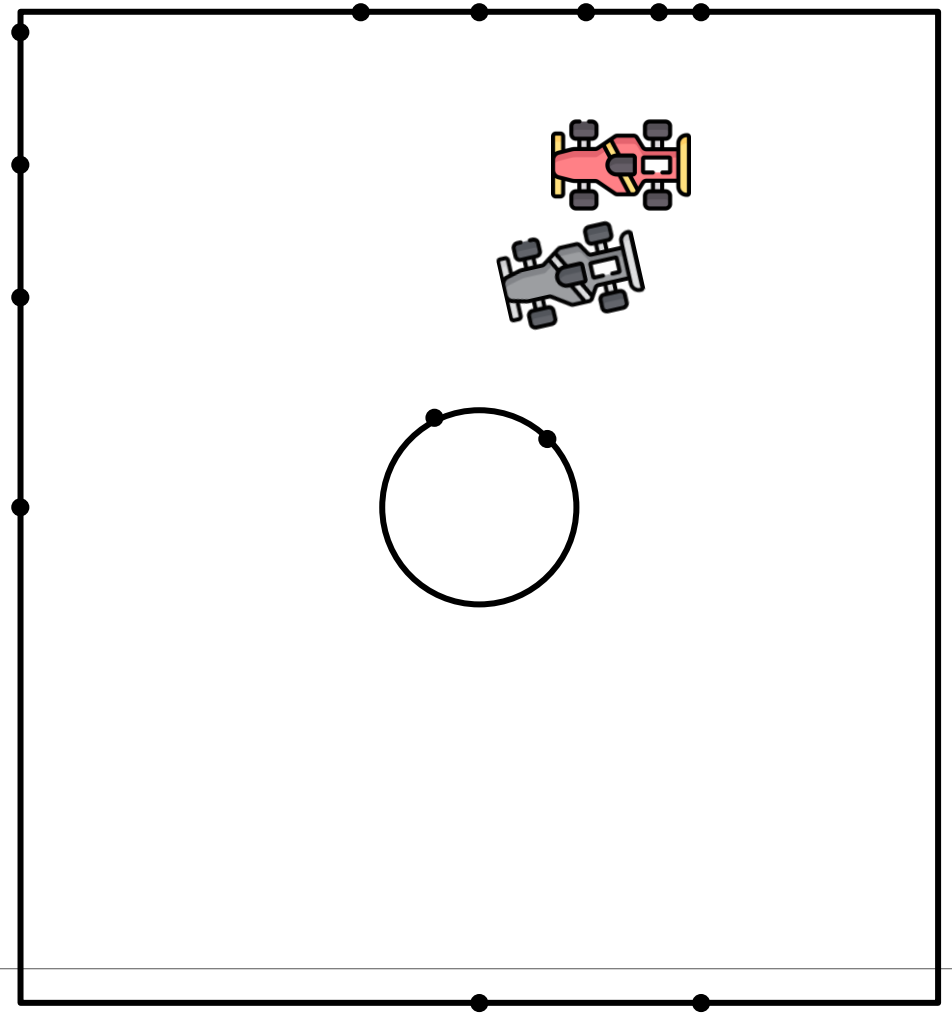
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

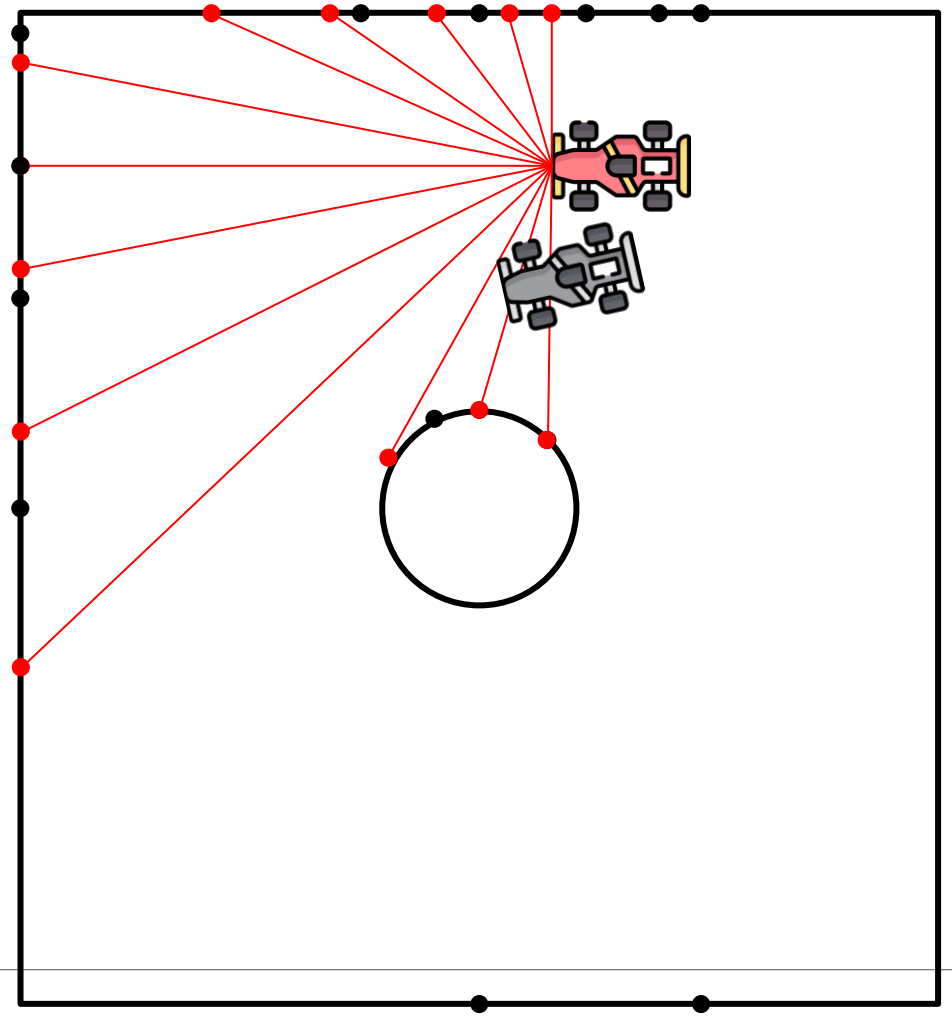
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

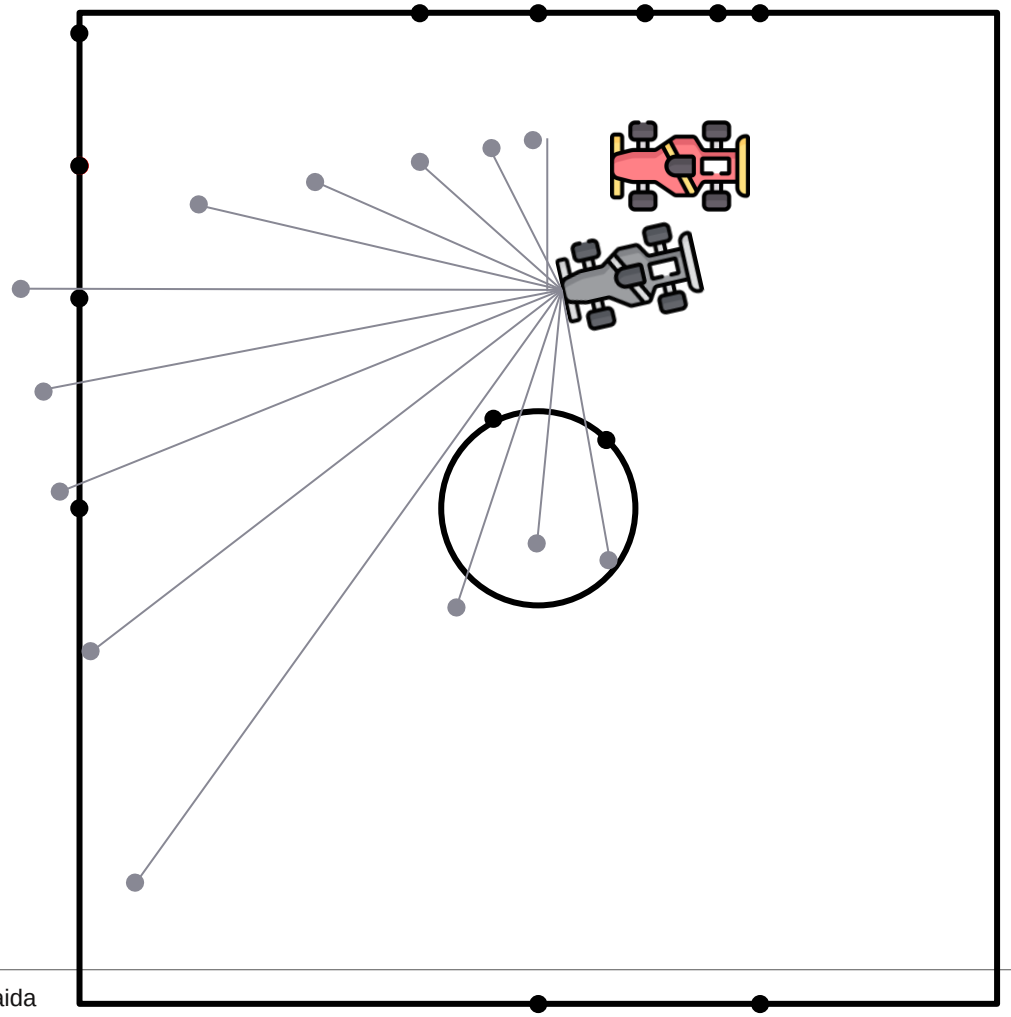
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

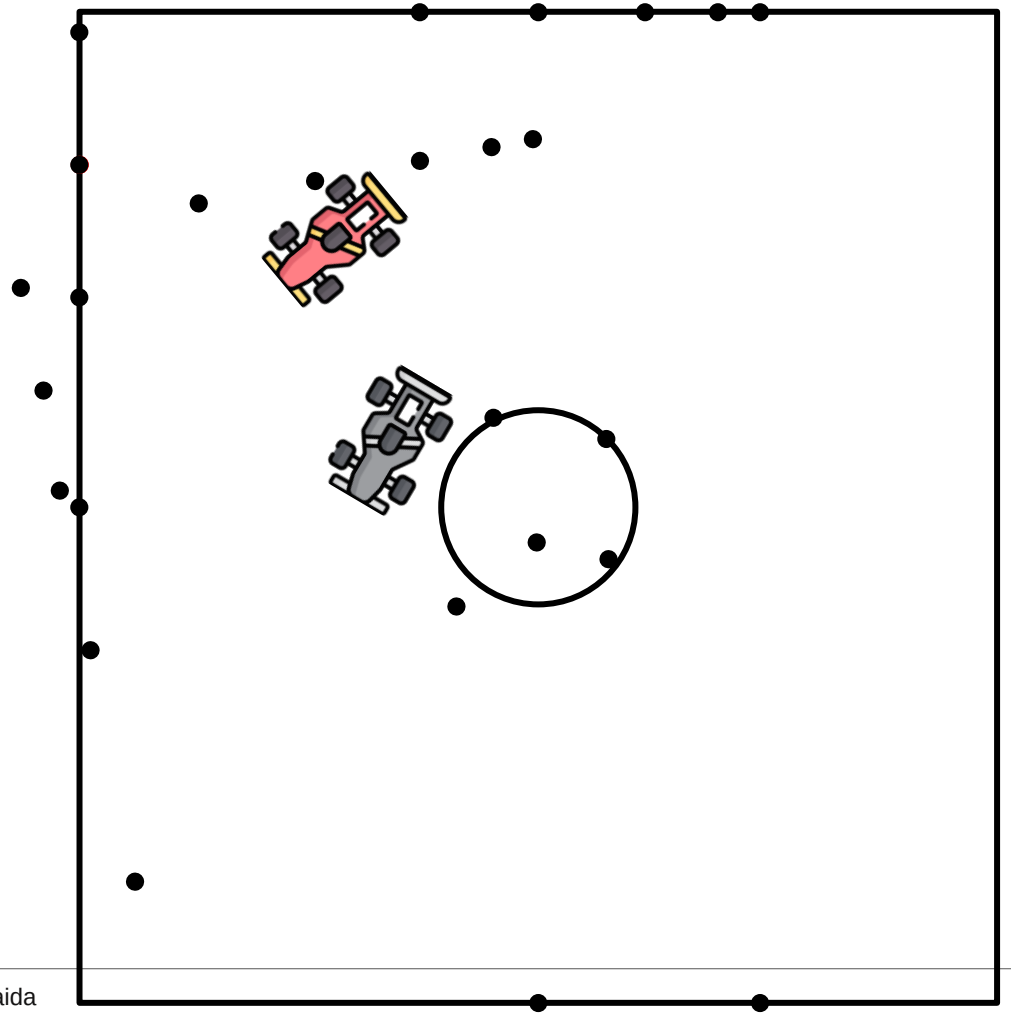
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

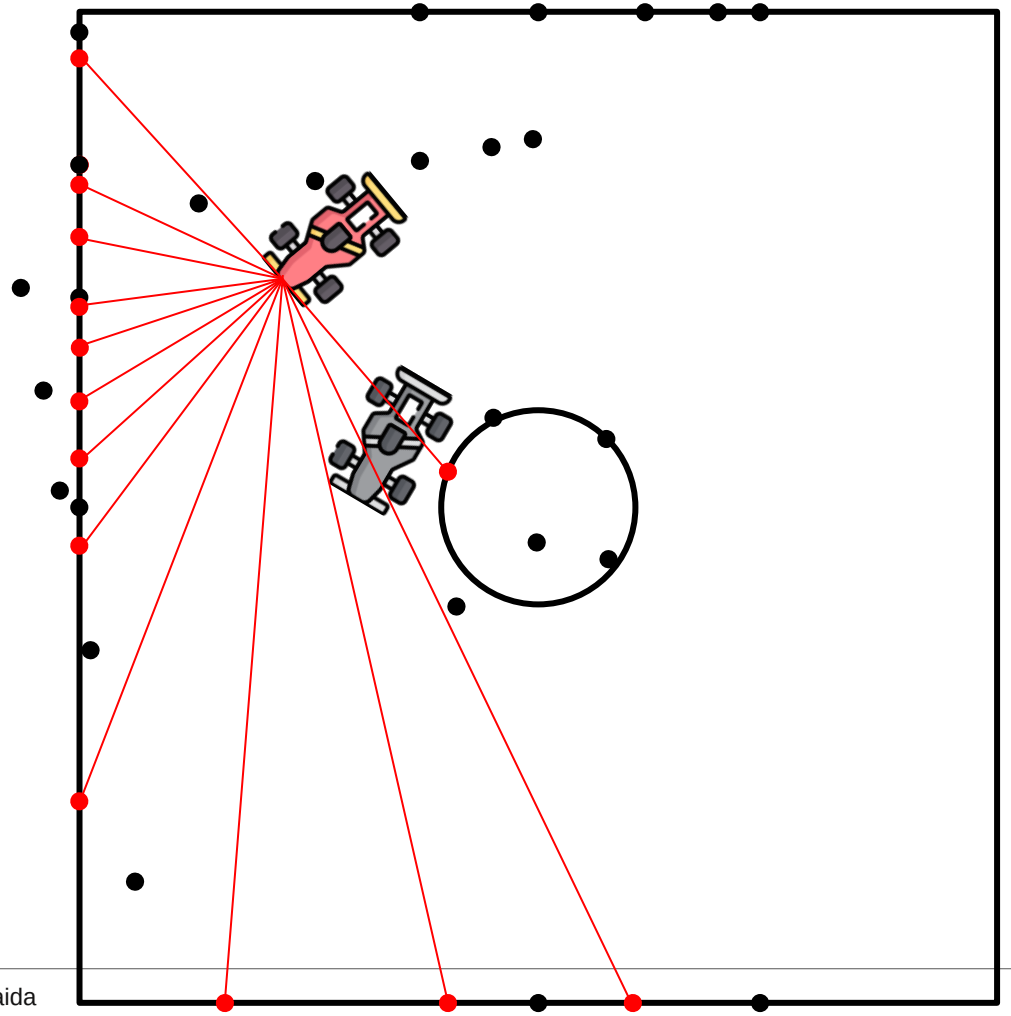
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

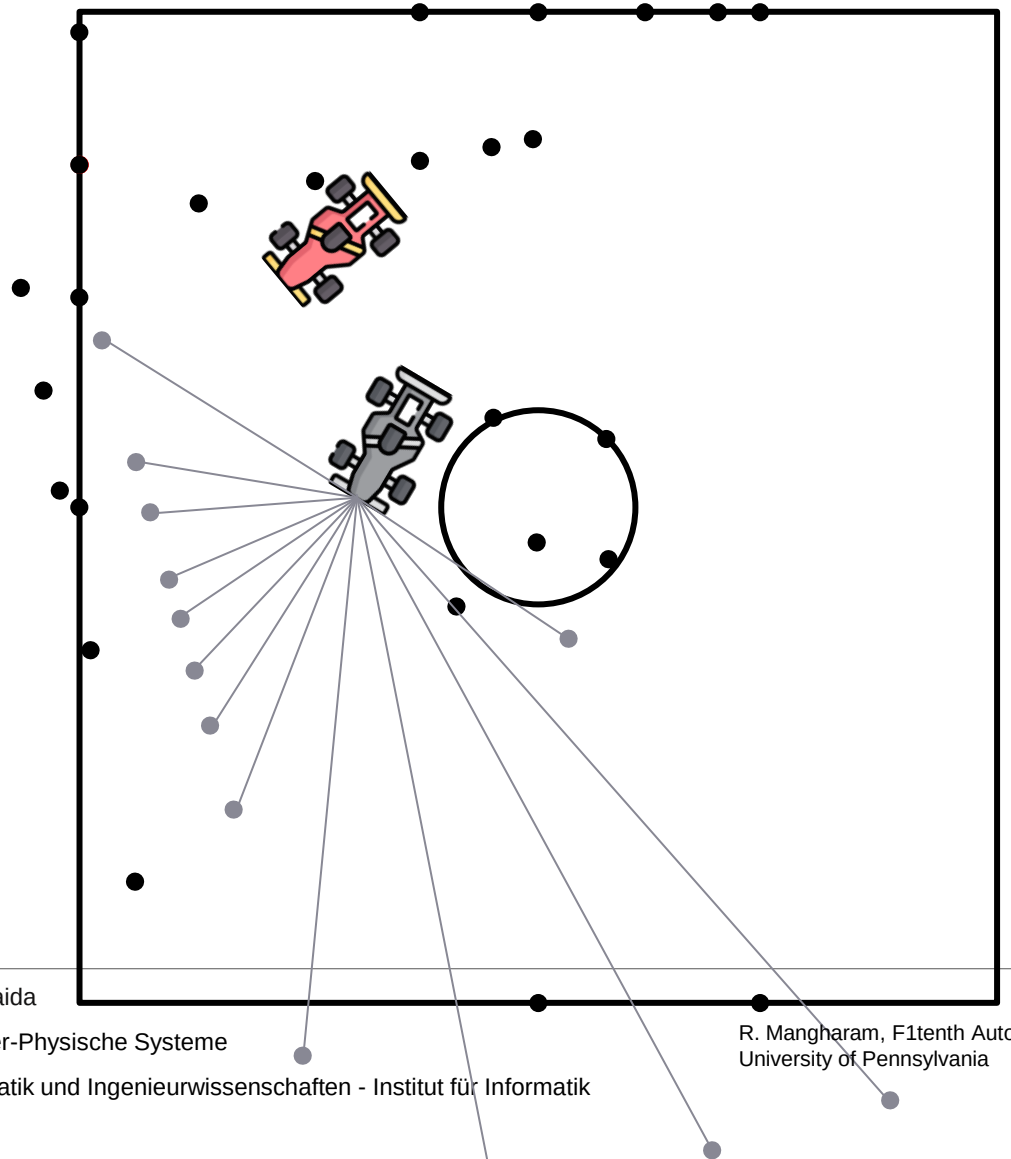
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

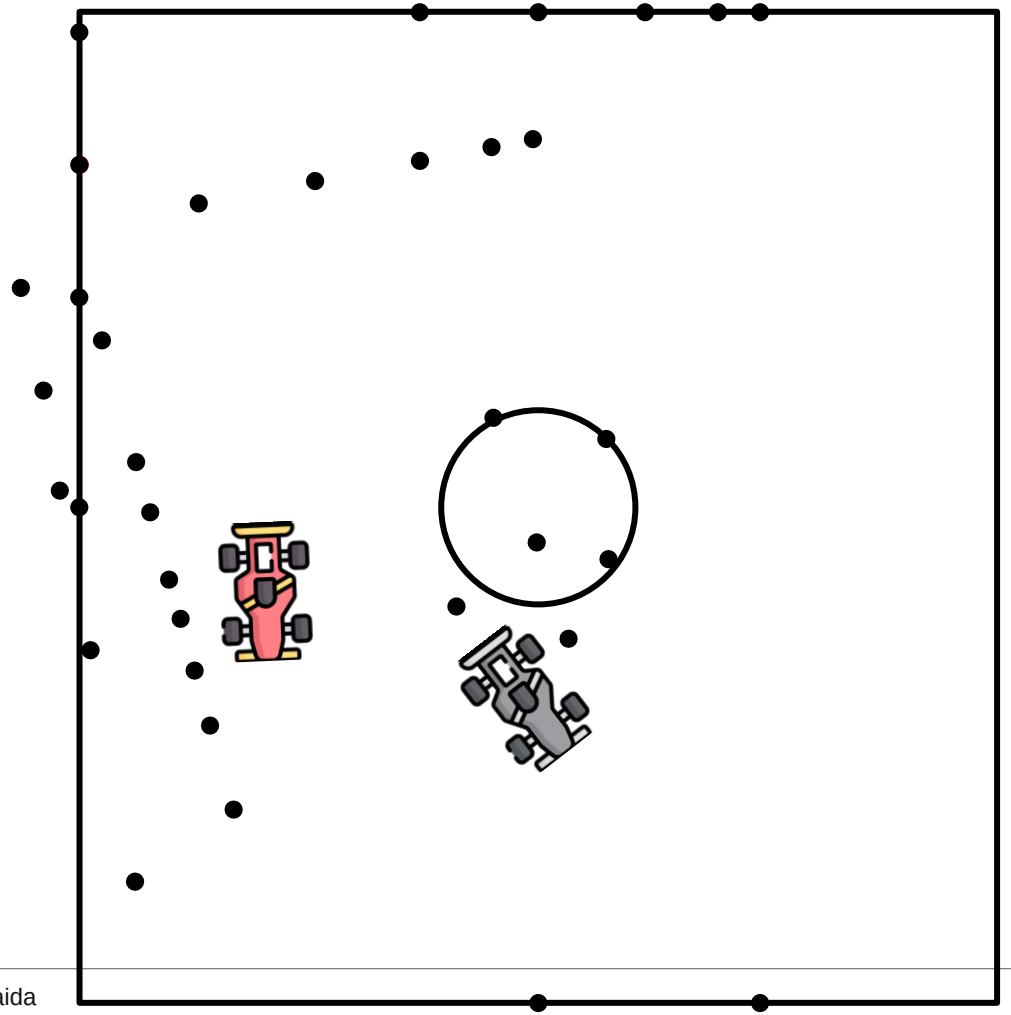
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

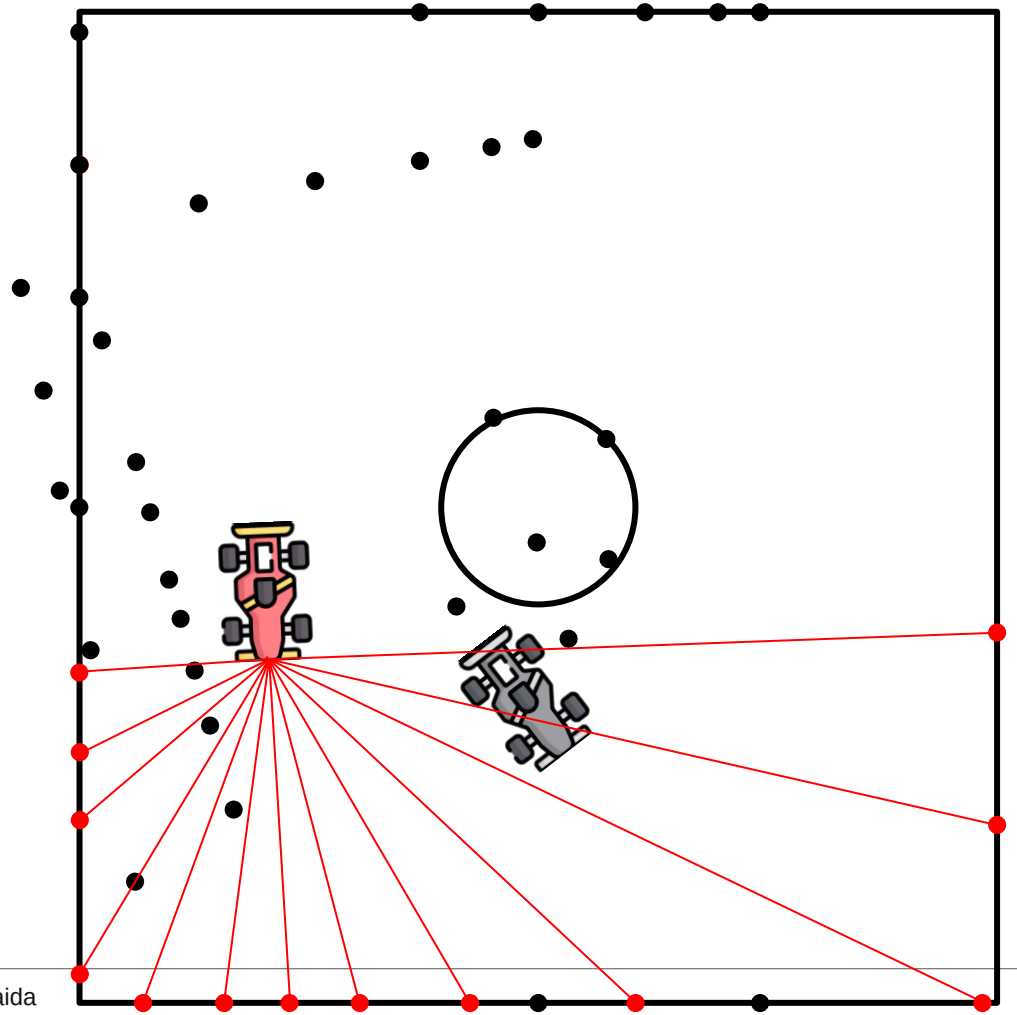
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

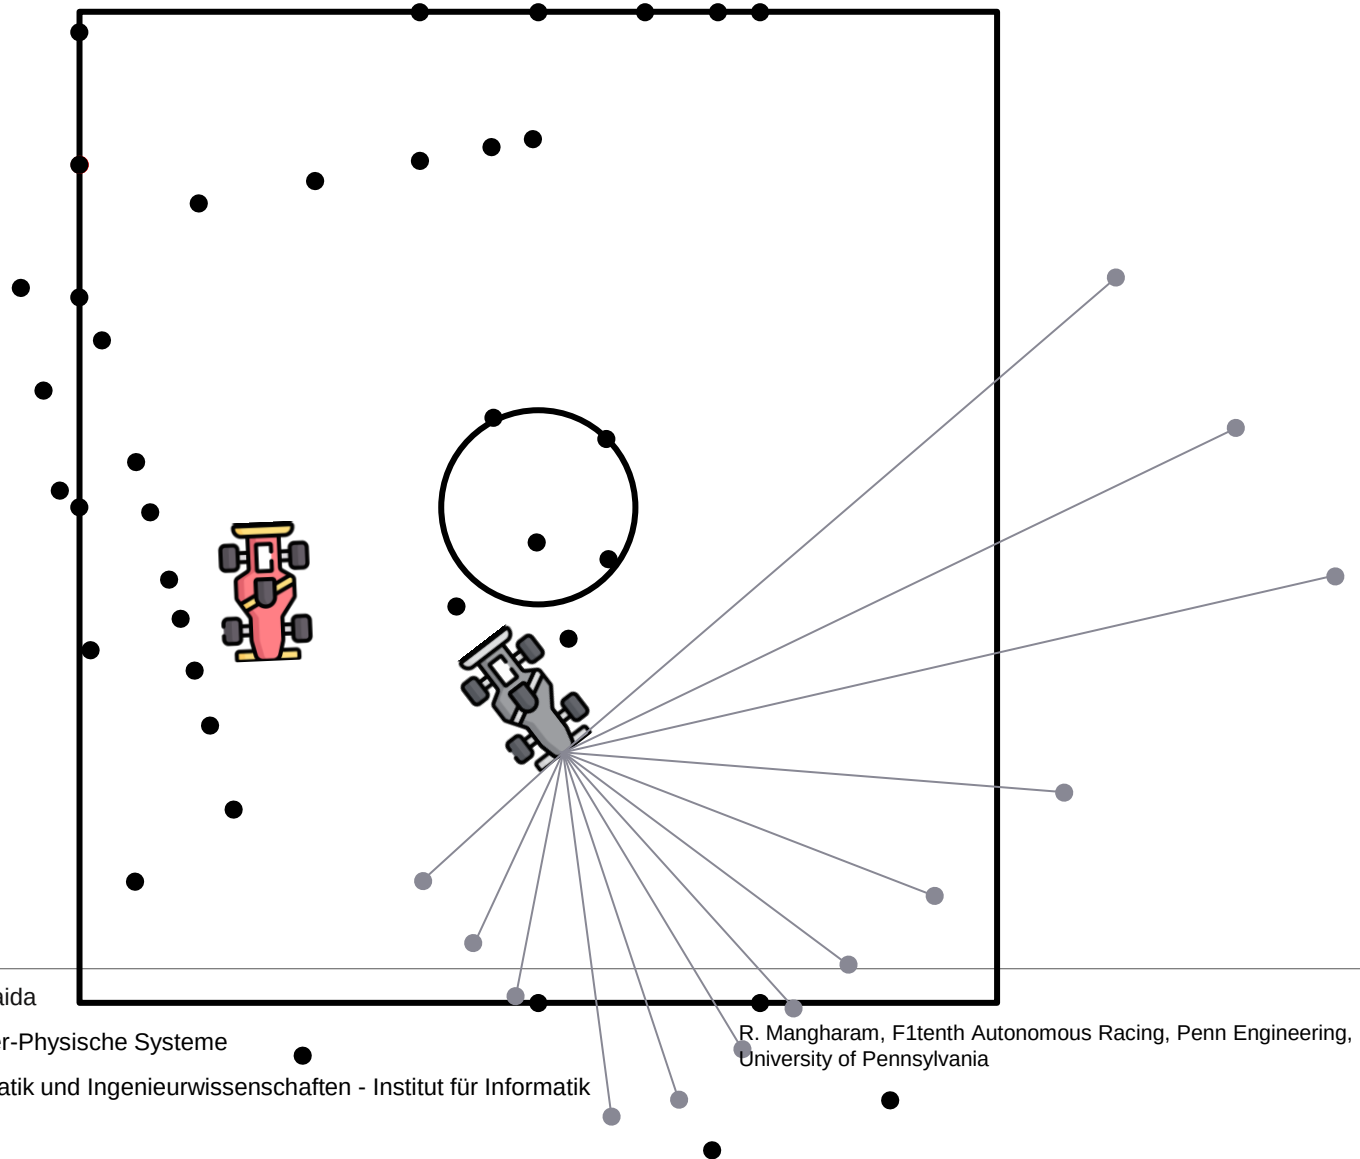
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



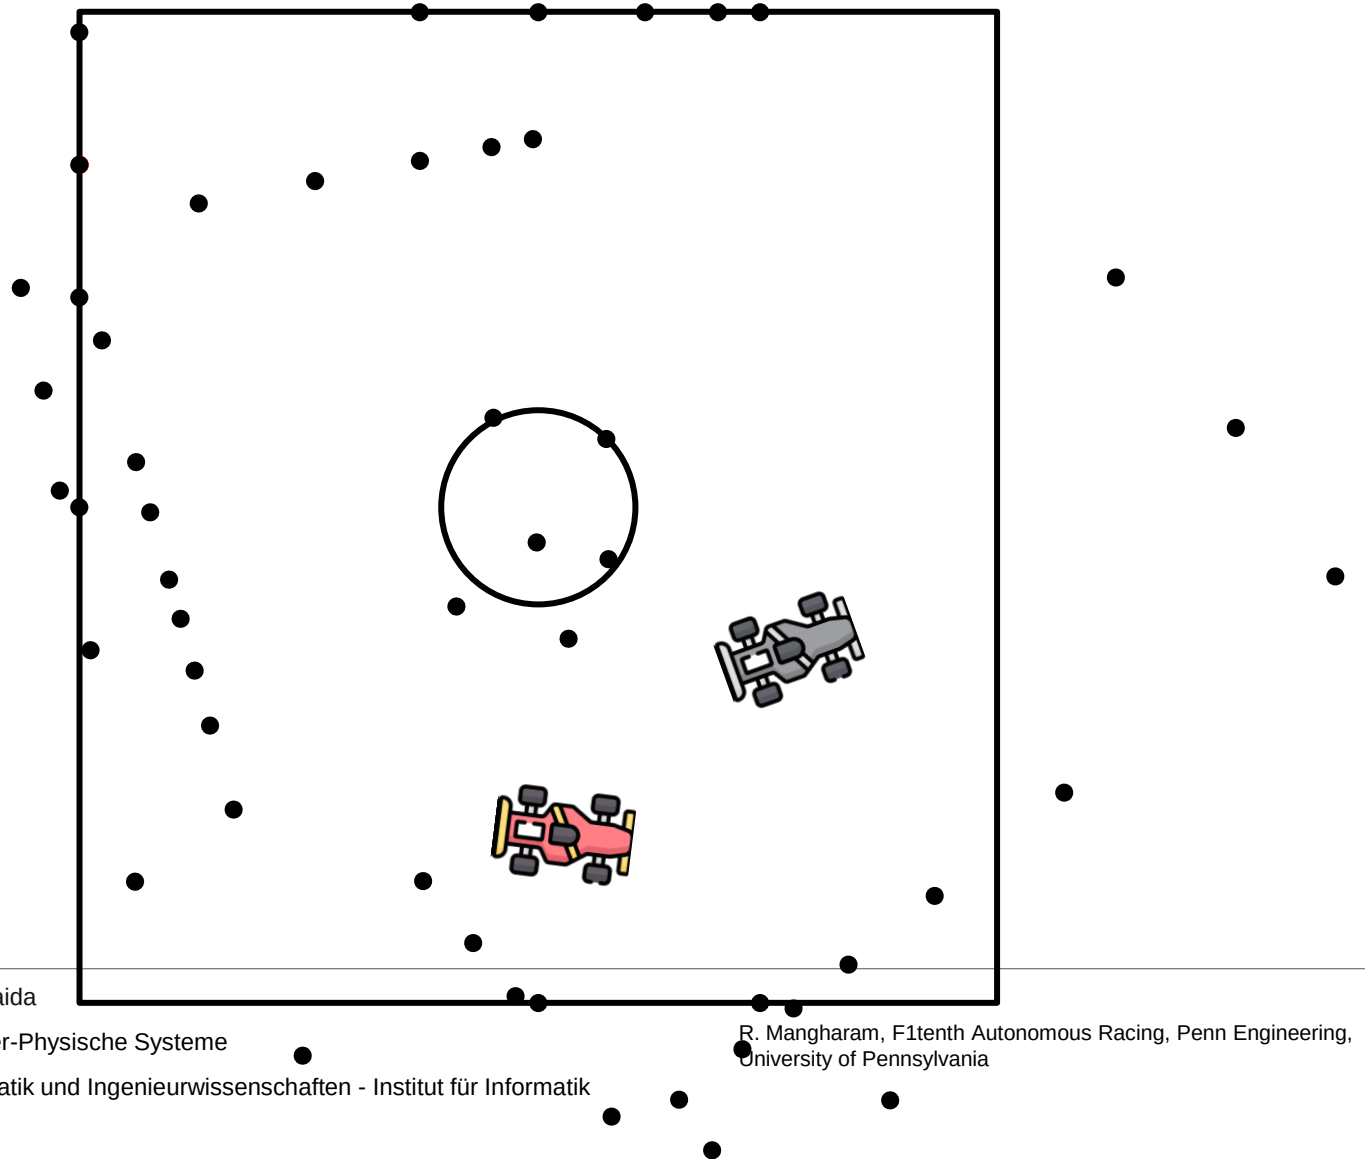
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



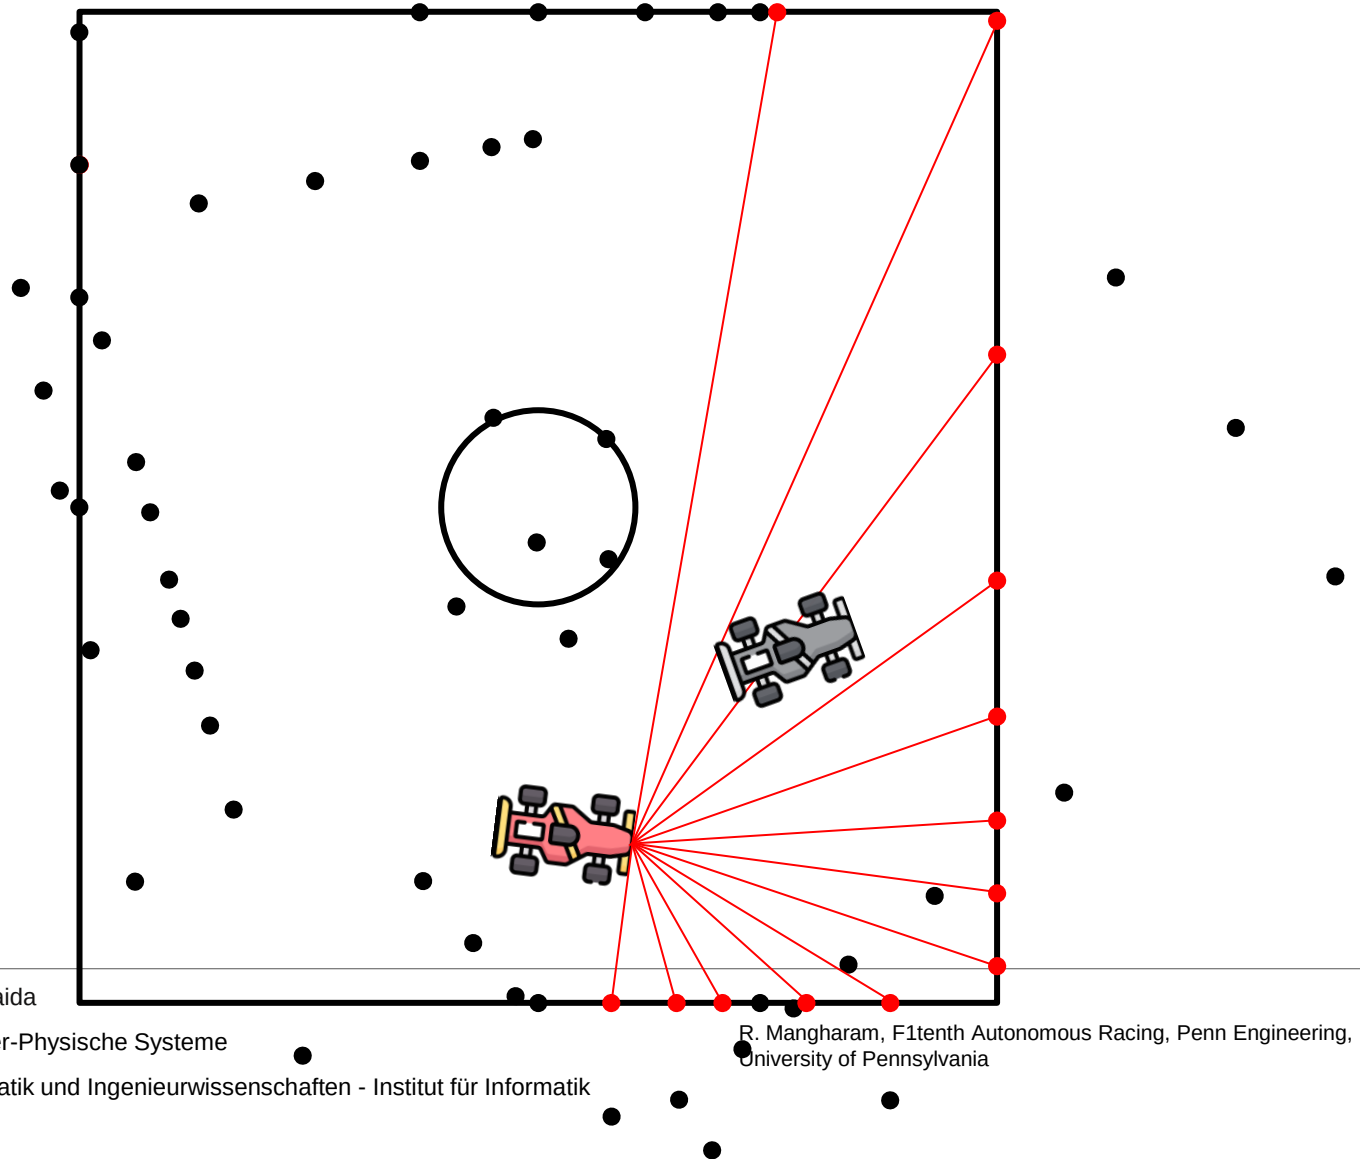
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



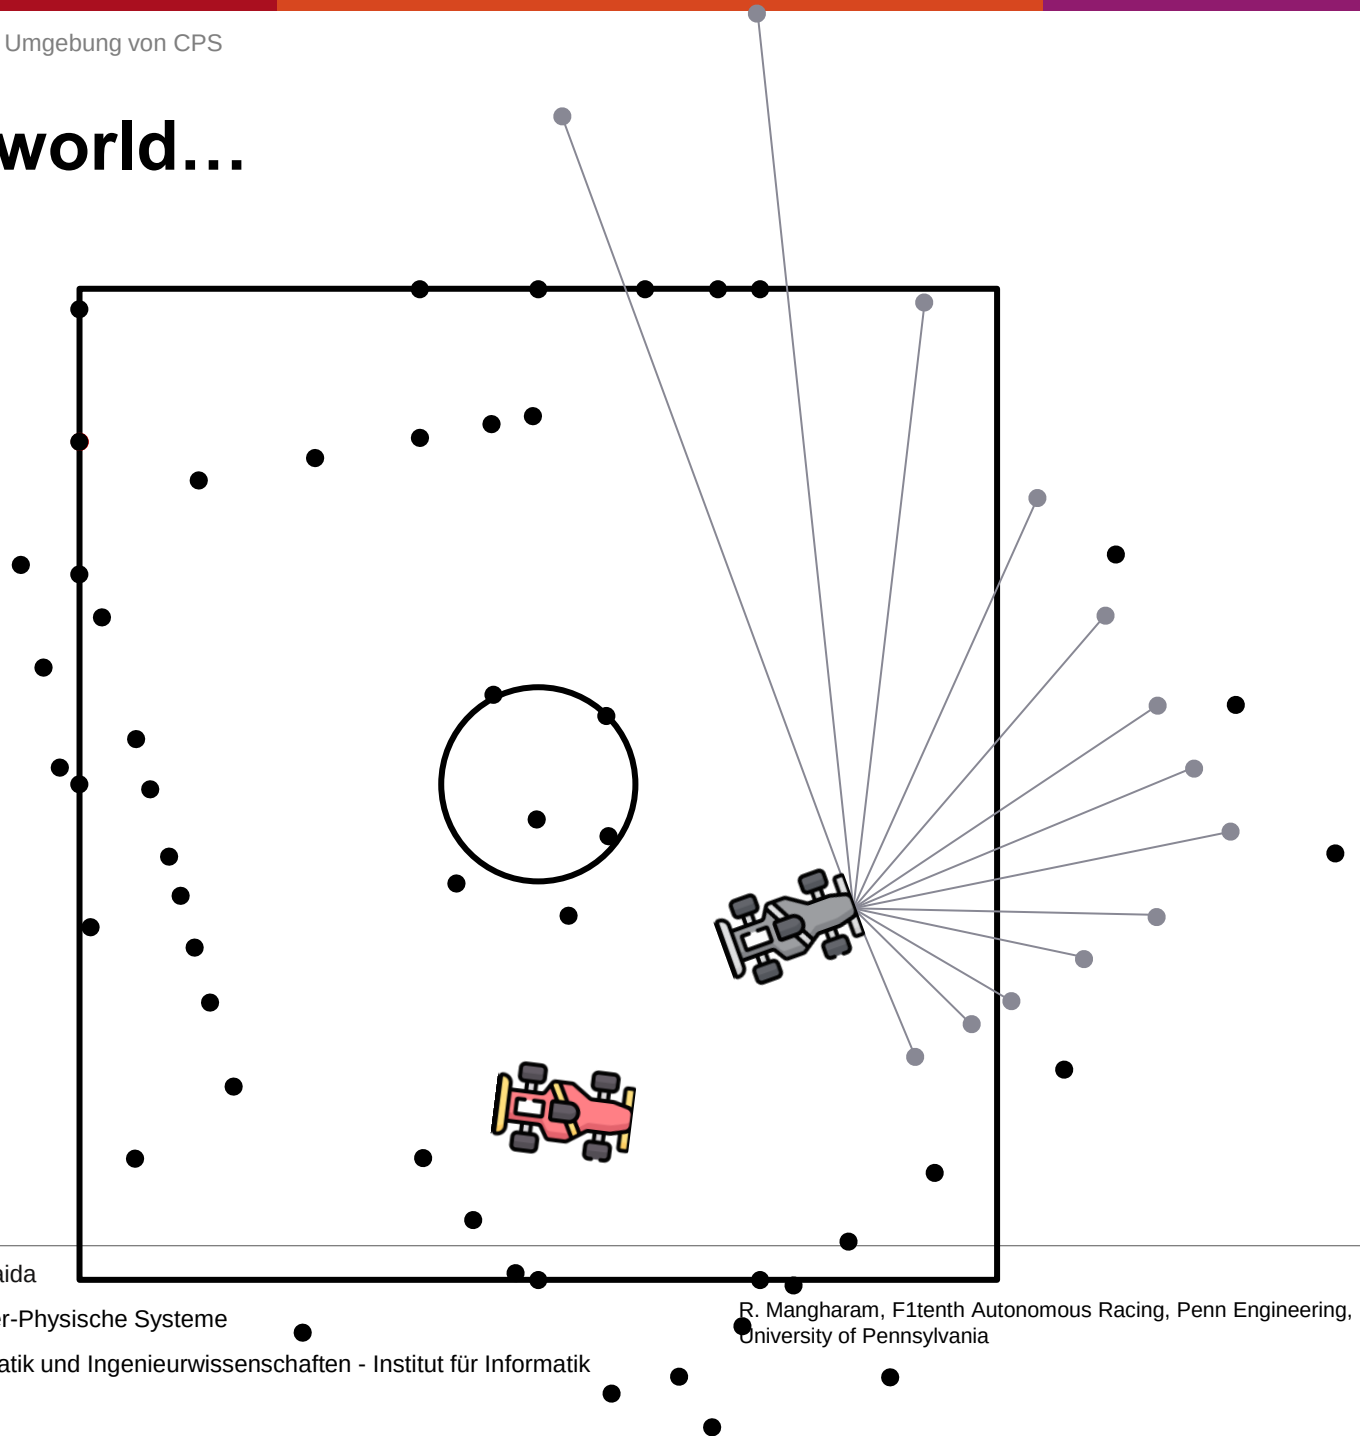
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



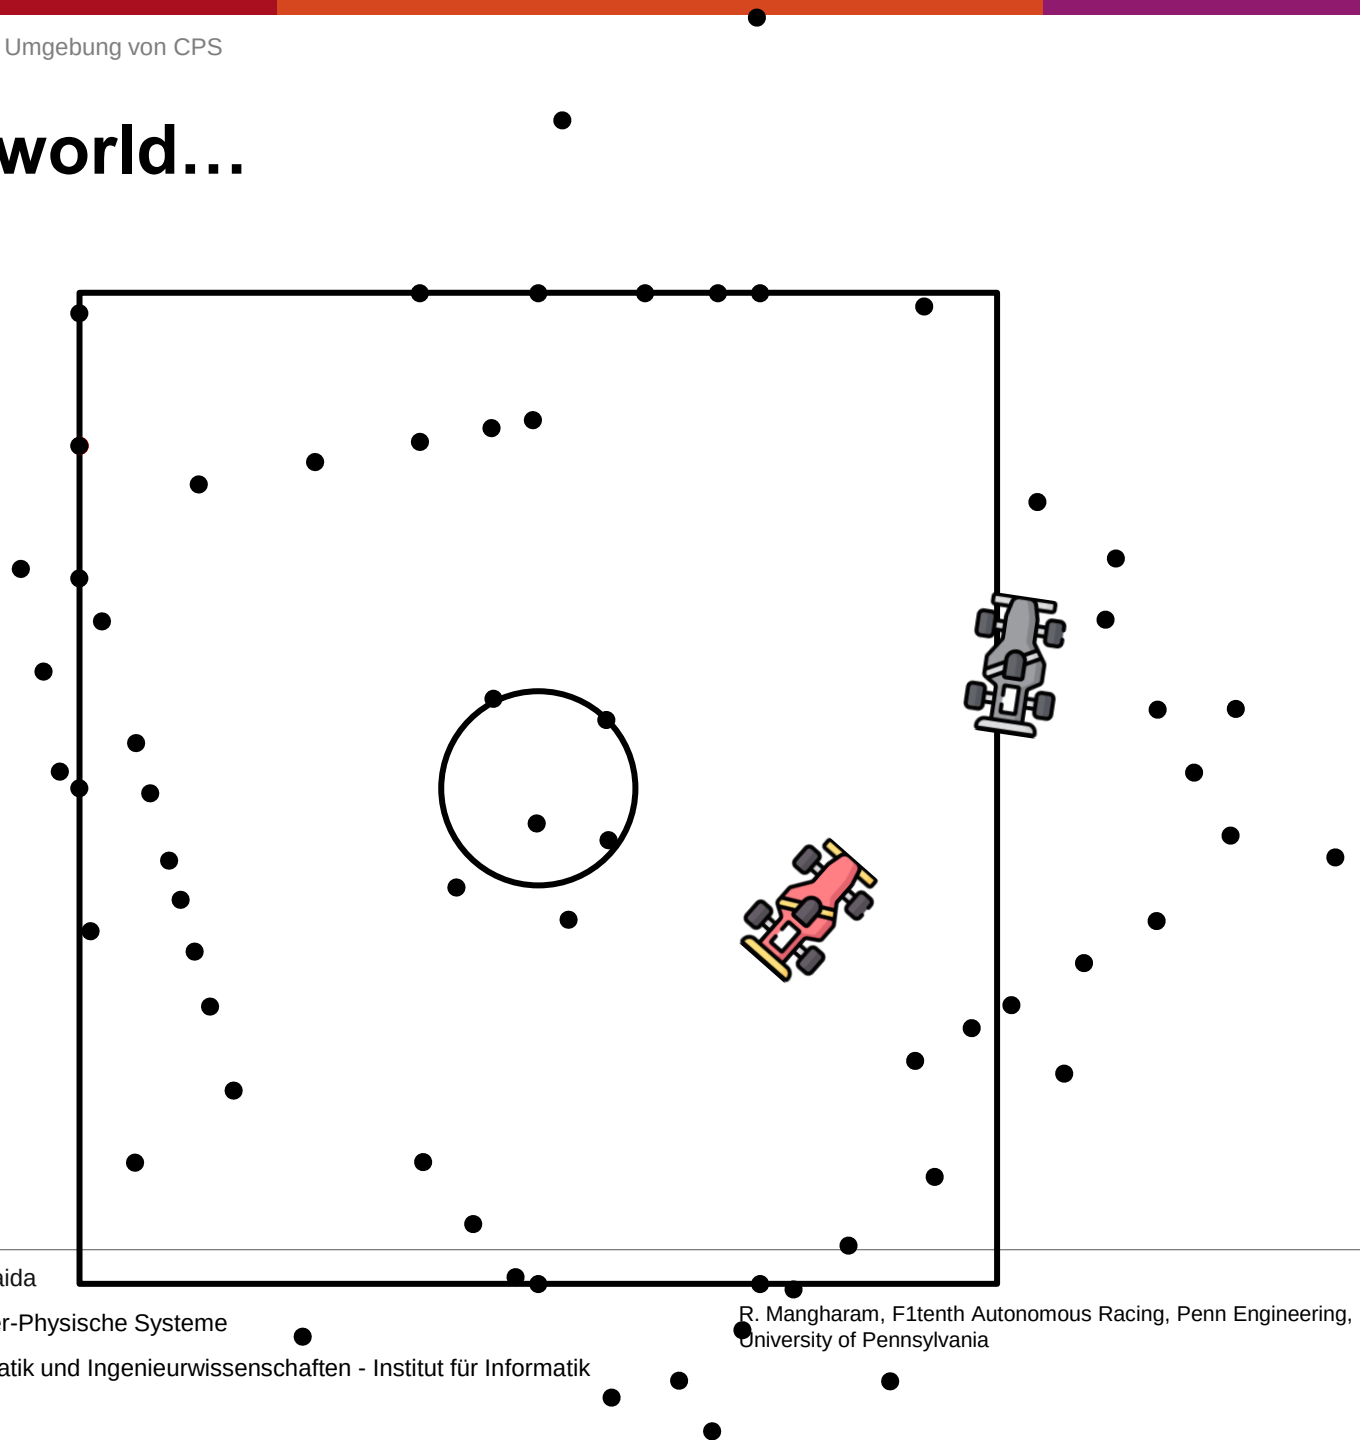
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



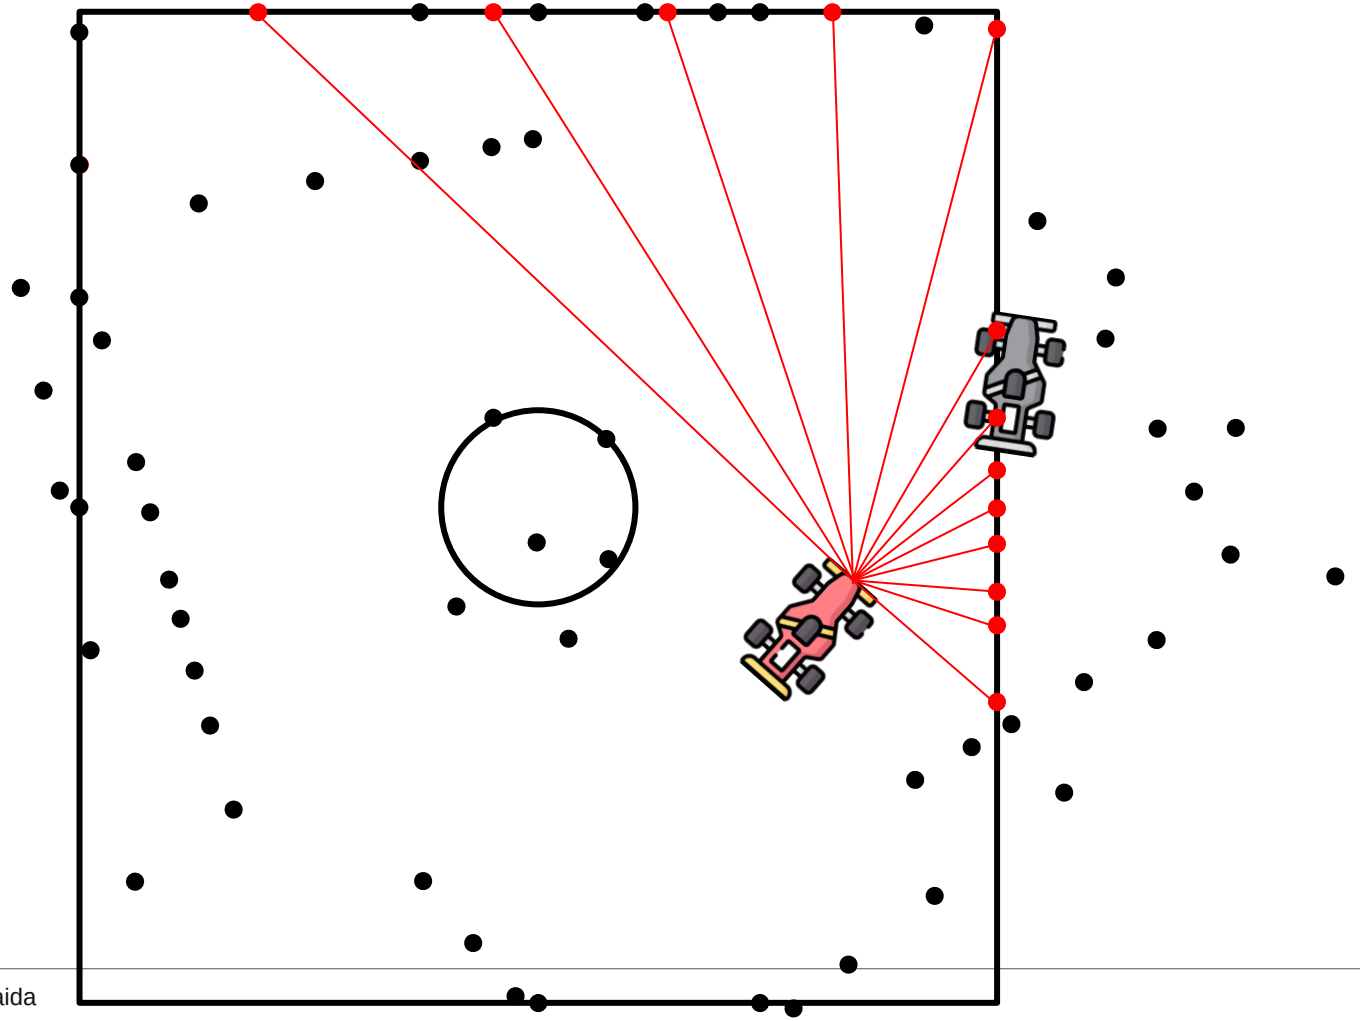
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



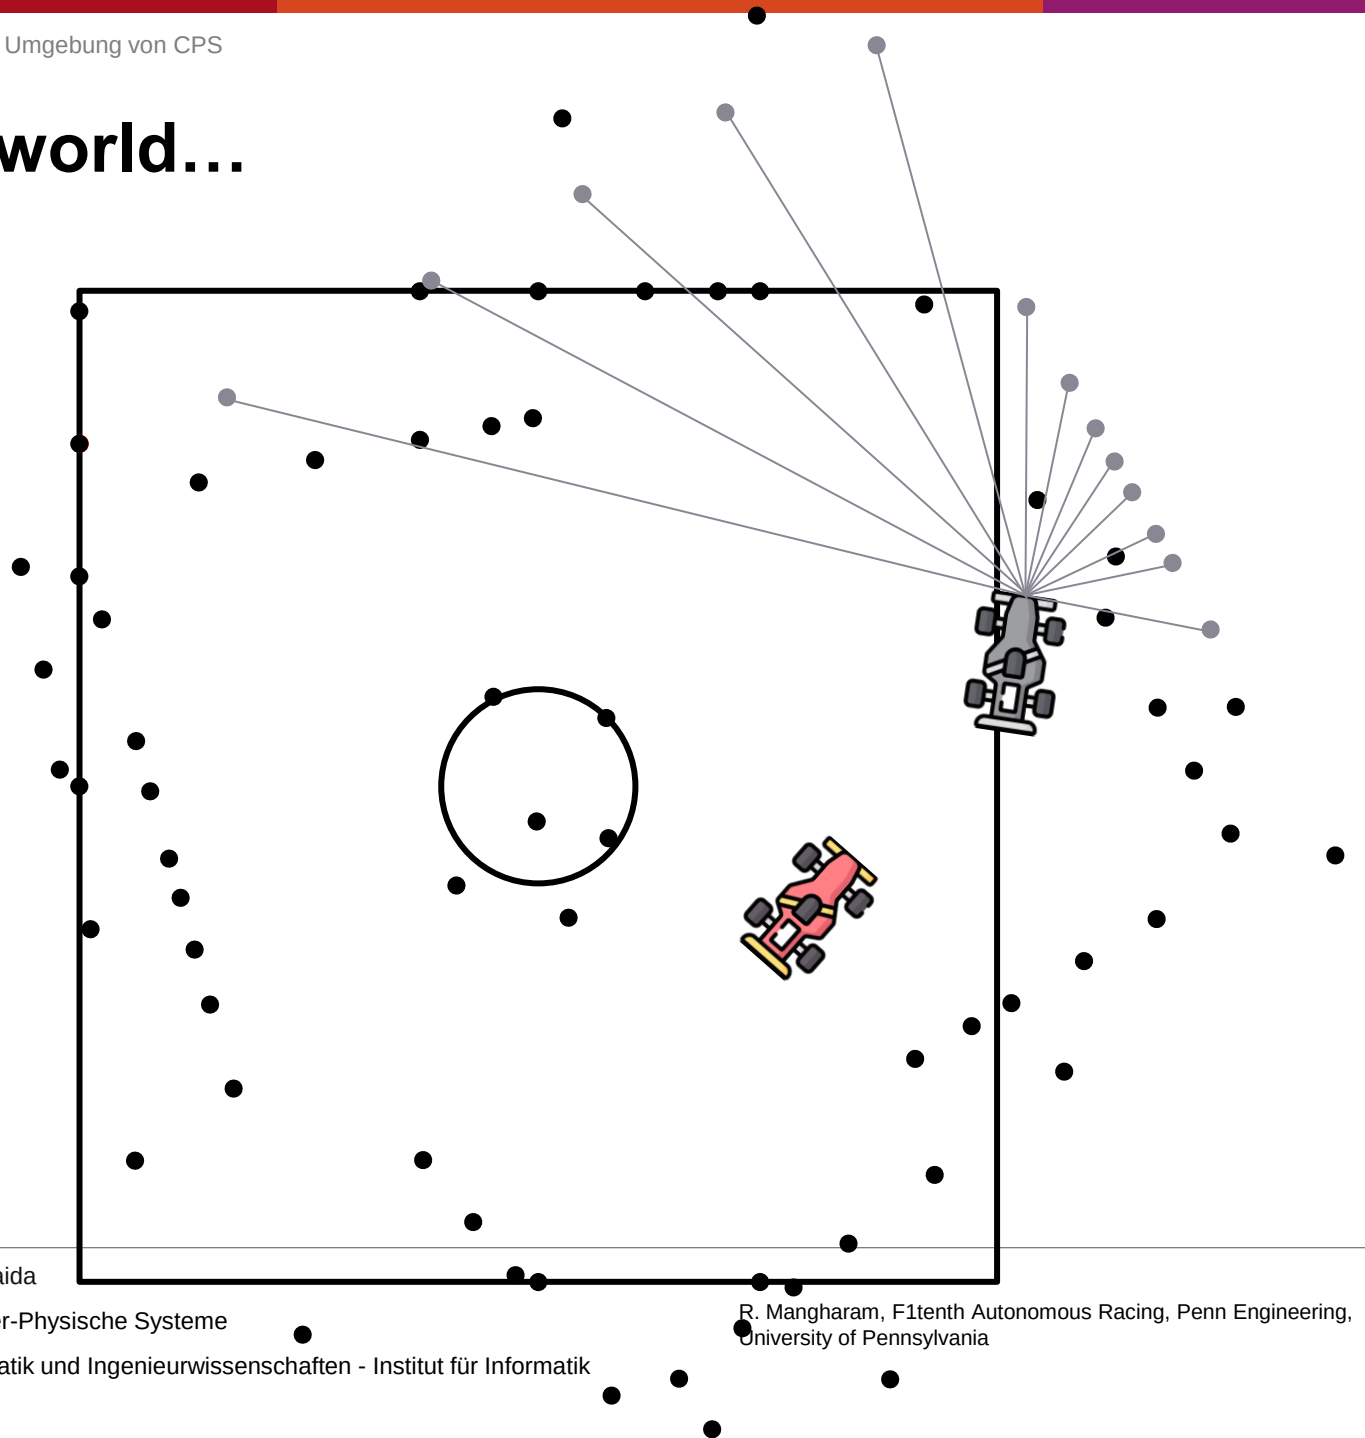
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



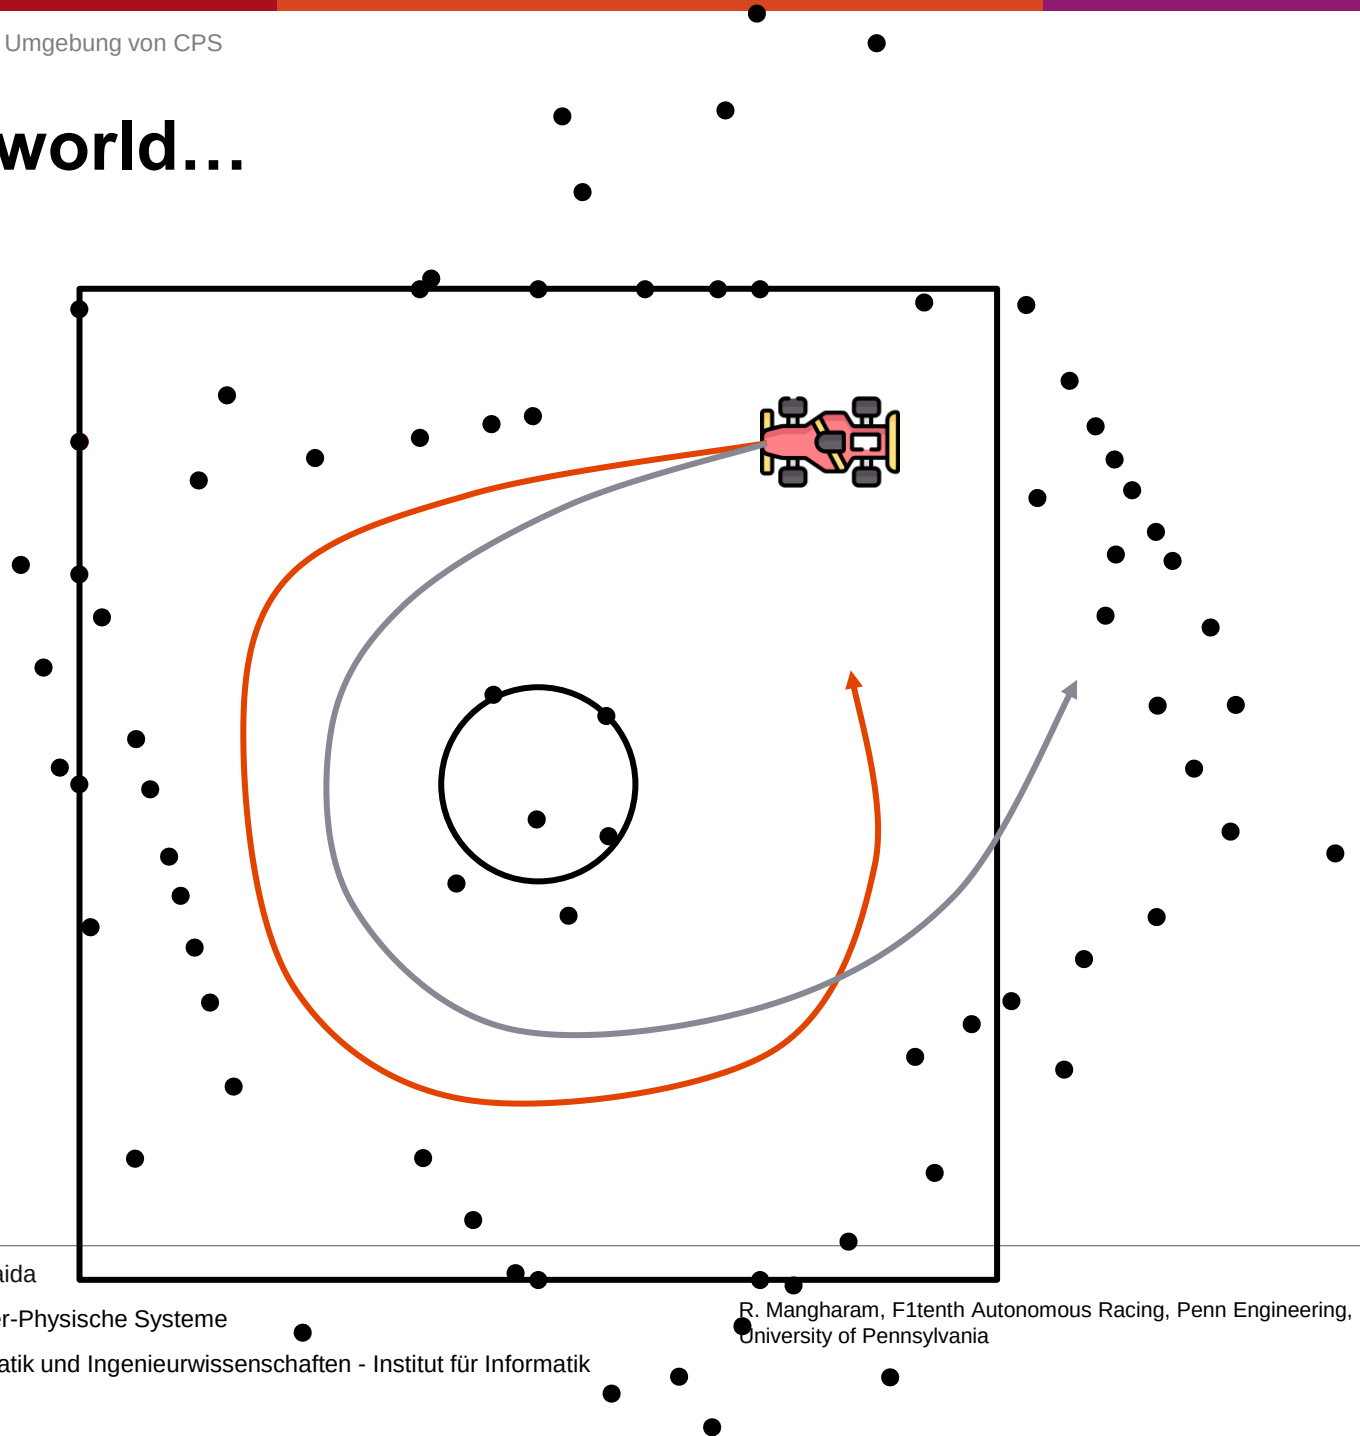
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



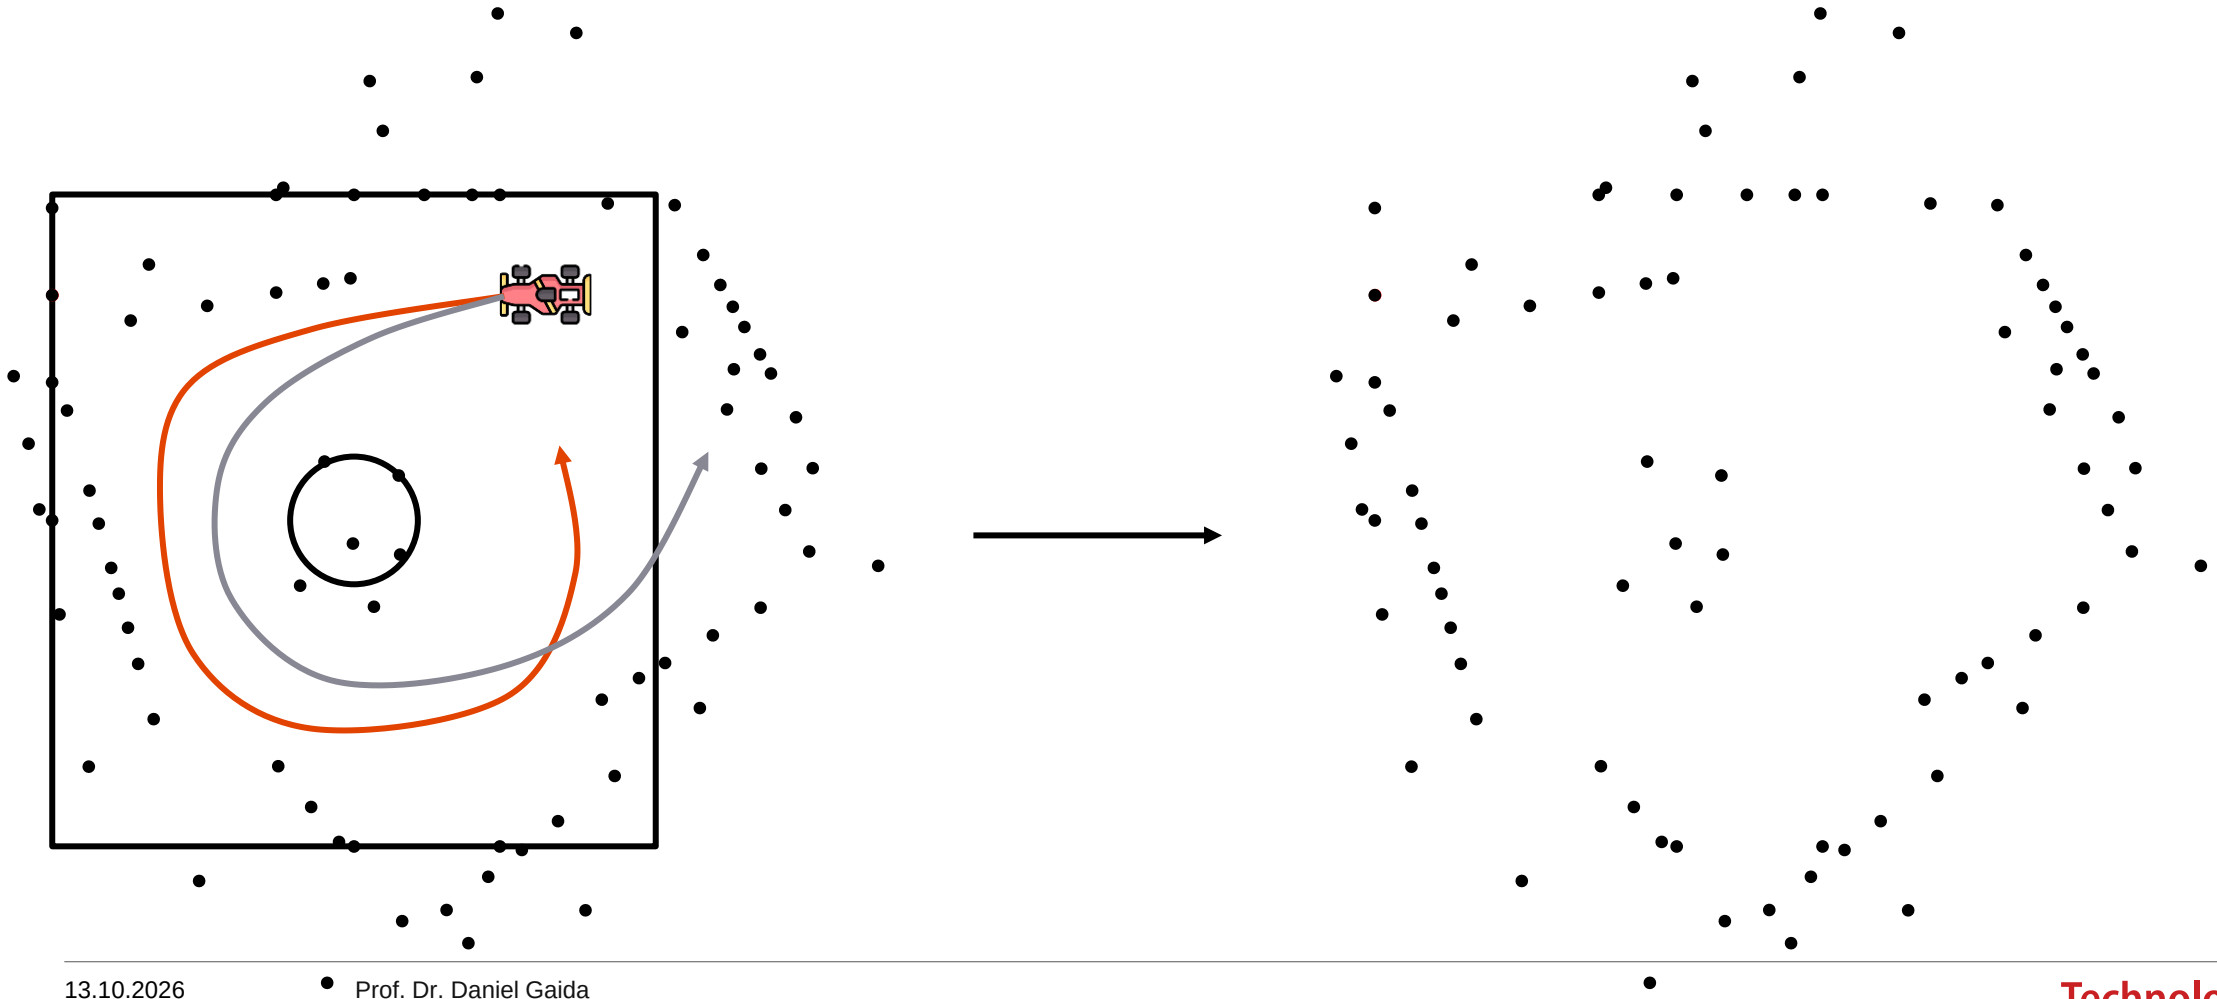
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

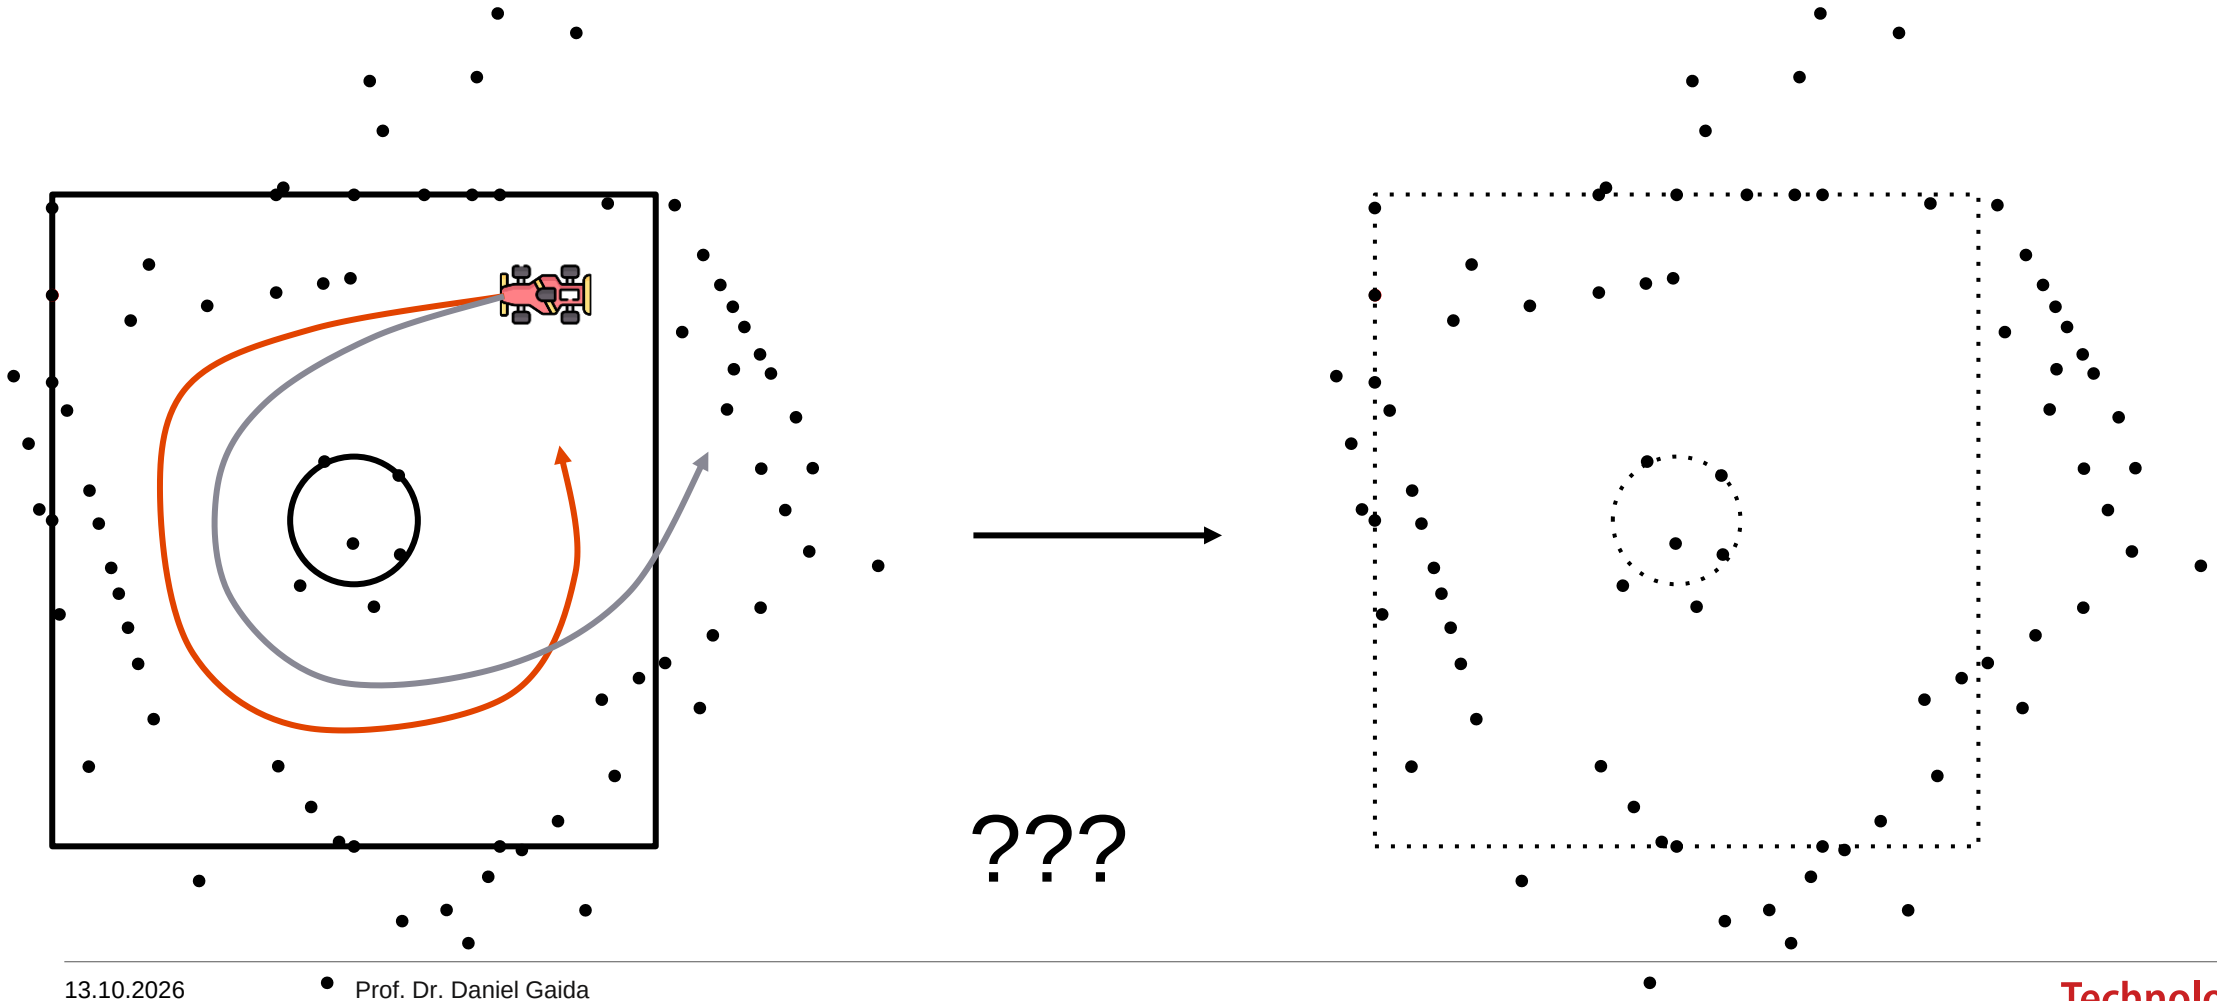
But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

But in the real world…



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

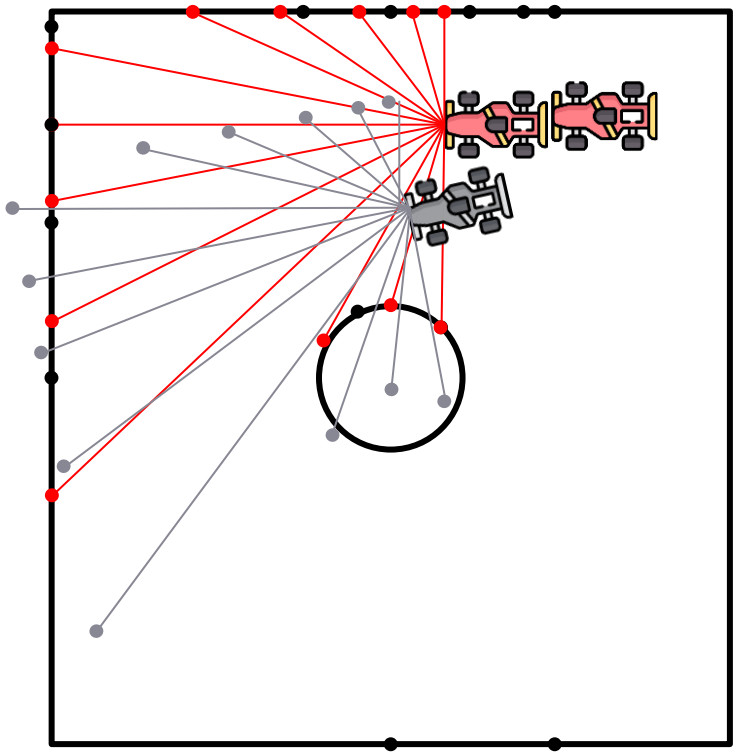
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

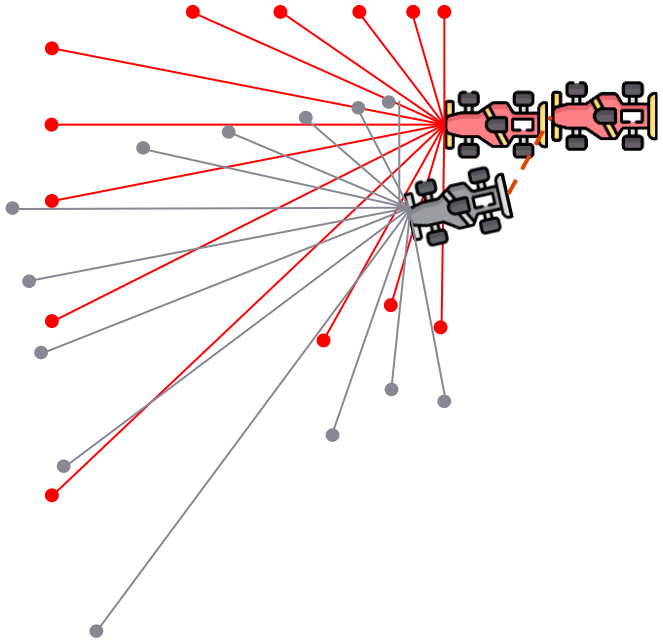
SLAM overview

Generally 2 different approaches:

- Filtering-based
  - Use Extended Kalman Filter or Particle Filter for state estimation and build the map based on that estimation
  - Examples are GMapping, HectorSLAM
- Graph-based
  - Use pose graphs to store constraints between pose estimations
  - Use optimization for loop-closure to correct for pose estimations
  - Examples are KartoSLAM and Cartographer
  - We'll be using slam_toolbox, also graph-based

Pose Graphs: Edge Constraints

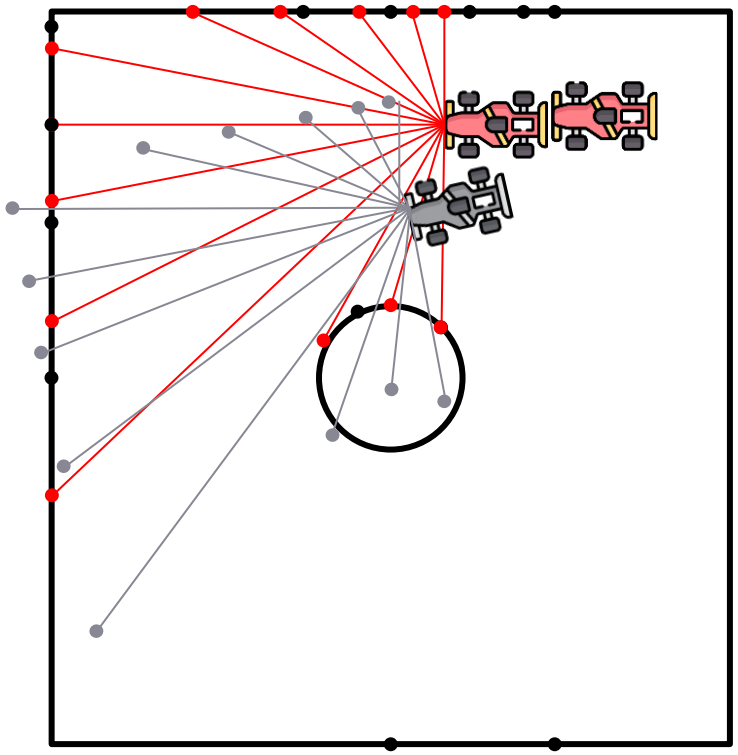


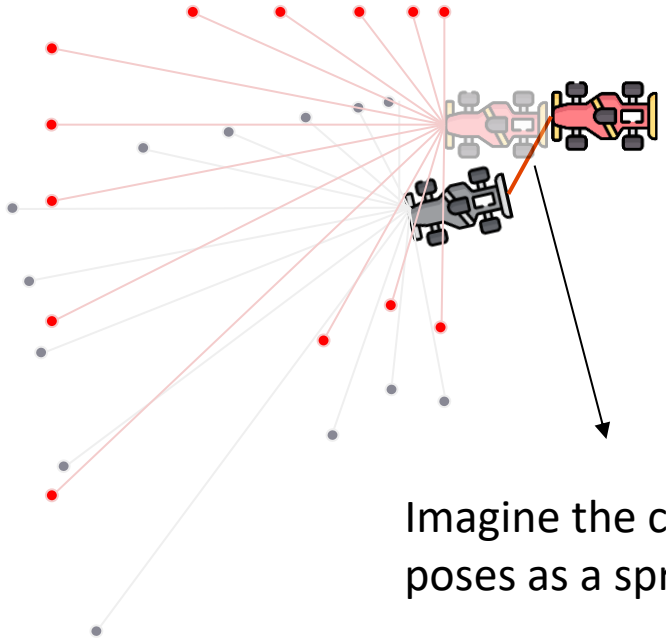


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Pose Graphs: Edge Constraints



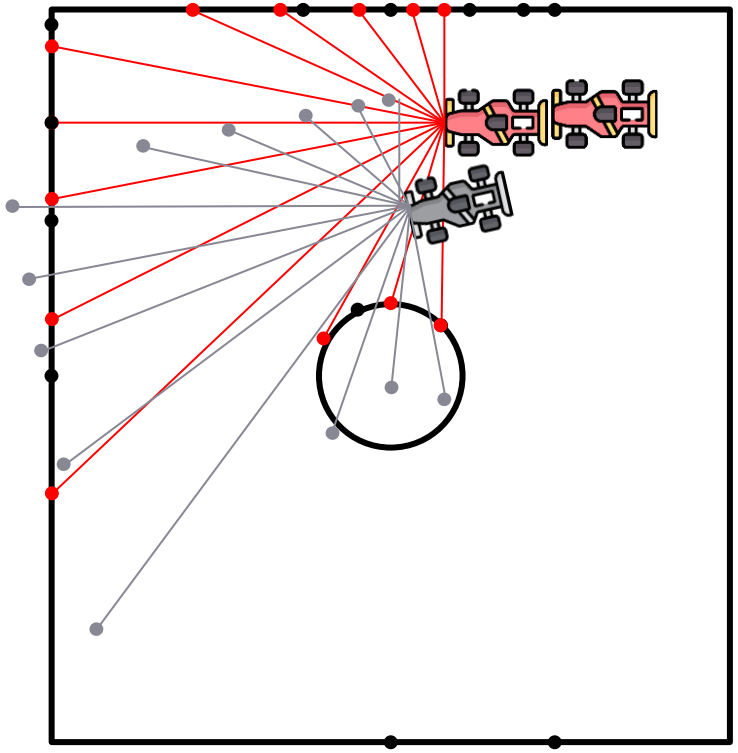


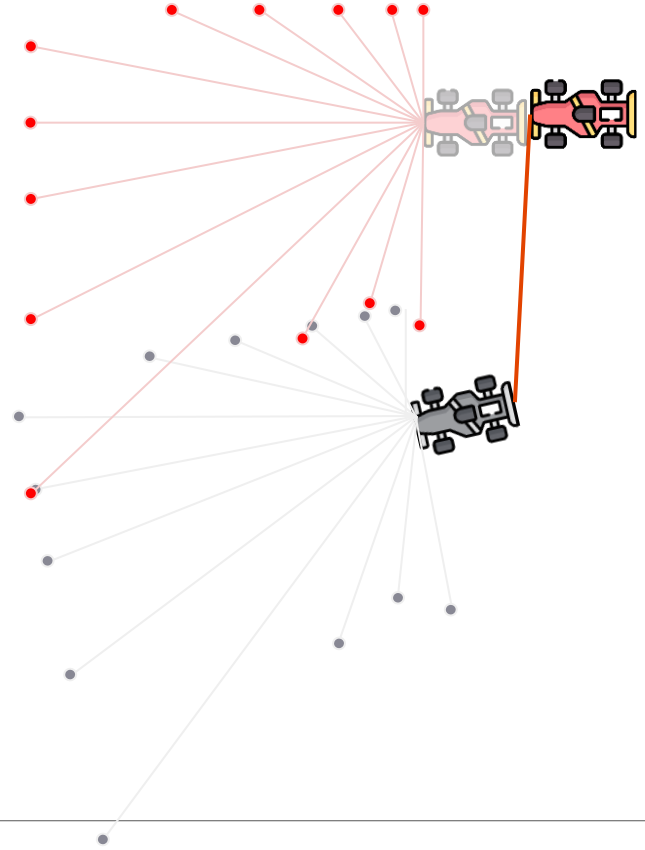
Imagine the constraint between poses as a spring.

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Pose Graphs: Edge Constraints

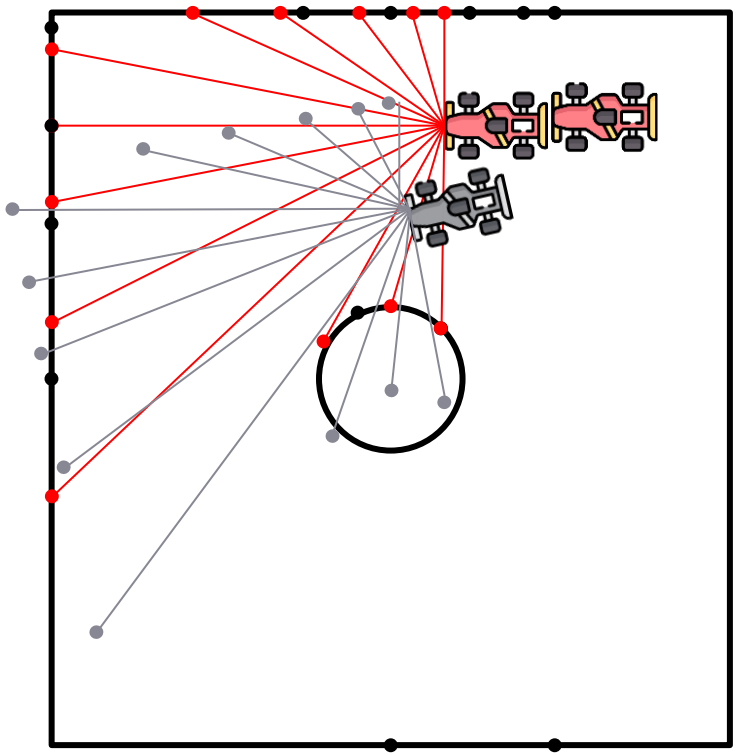


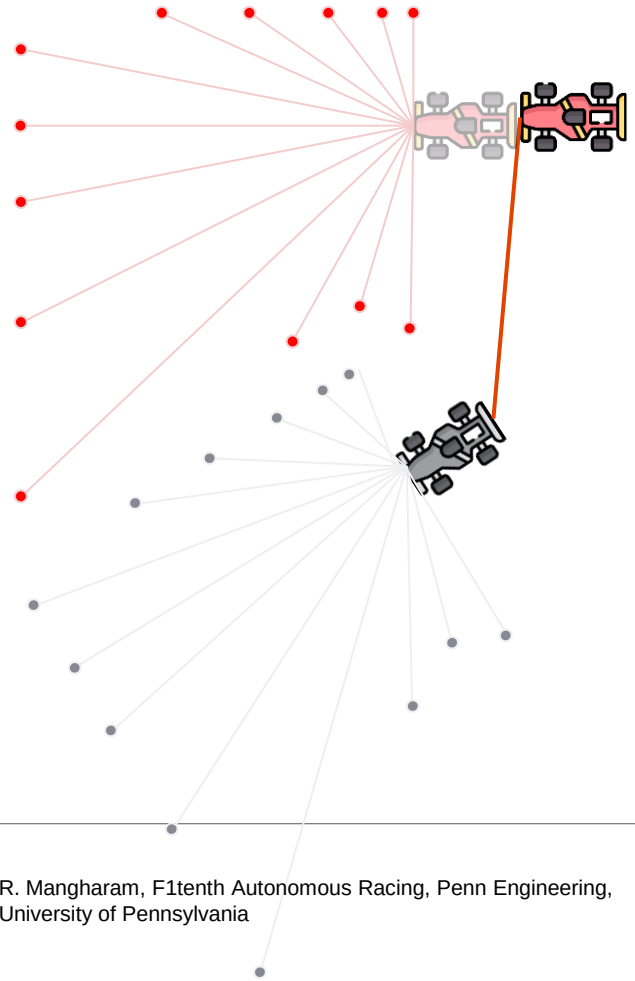


R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Pose Graphs: Edge Constraints

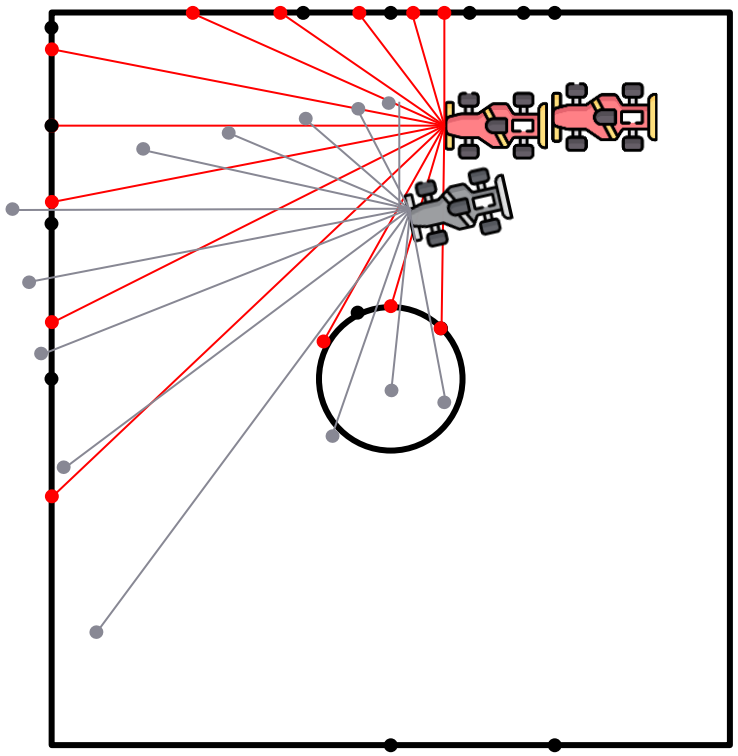


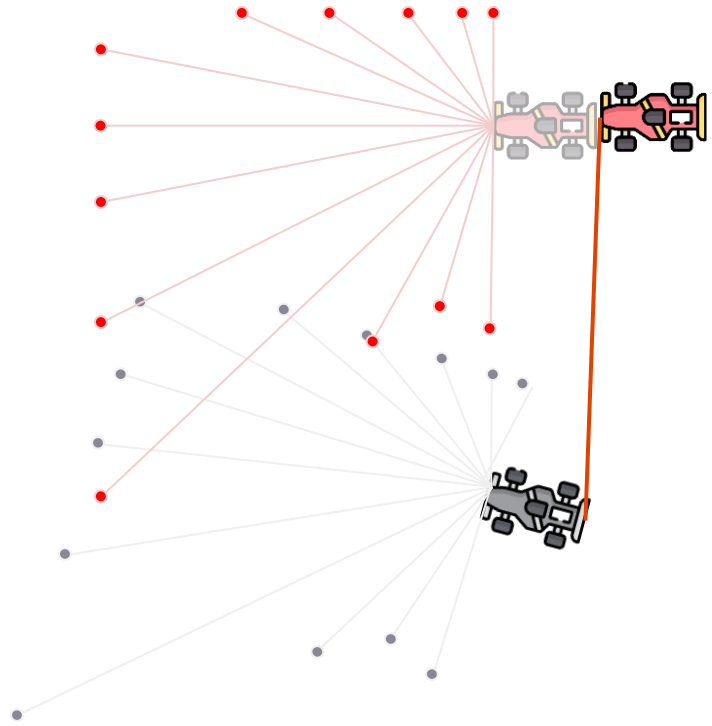


R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Pose Graphs: Edge Constraints

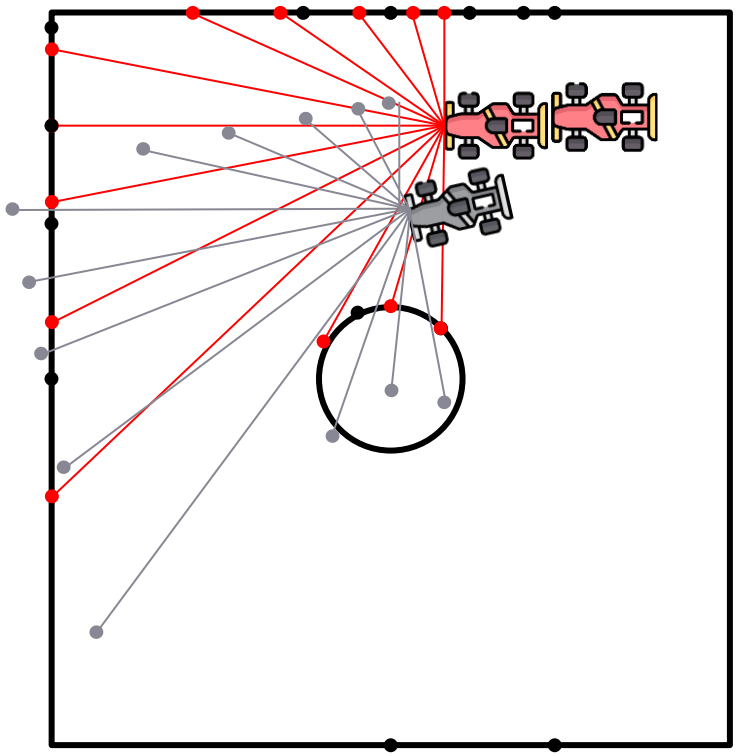


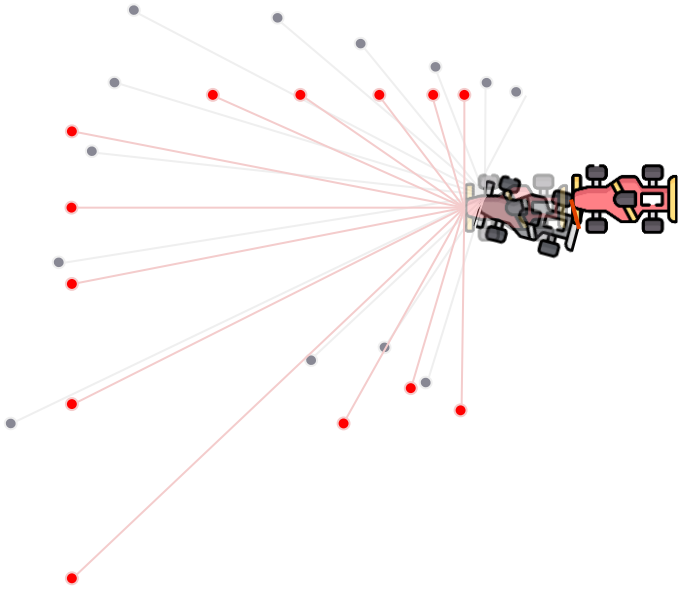


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Pose Graphs: Edge Constraints

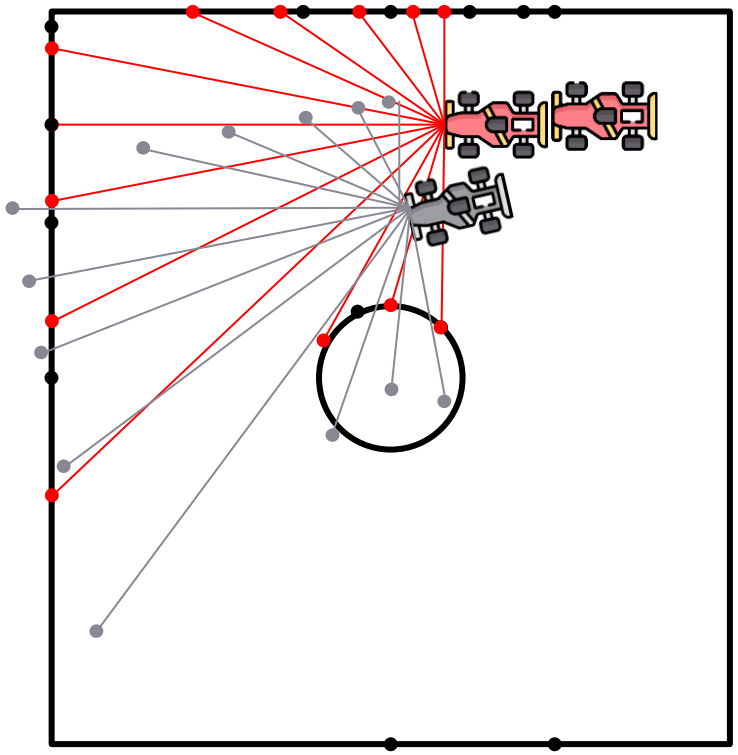


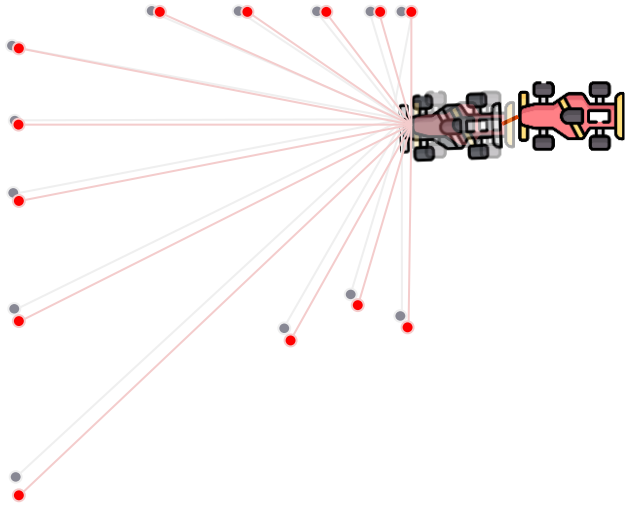


Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Pose Graphs: Edge Constraints

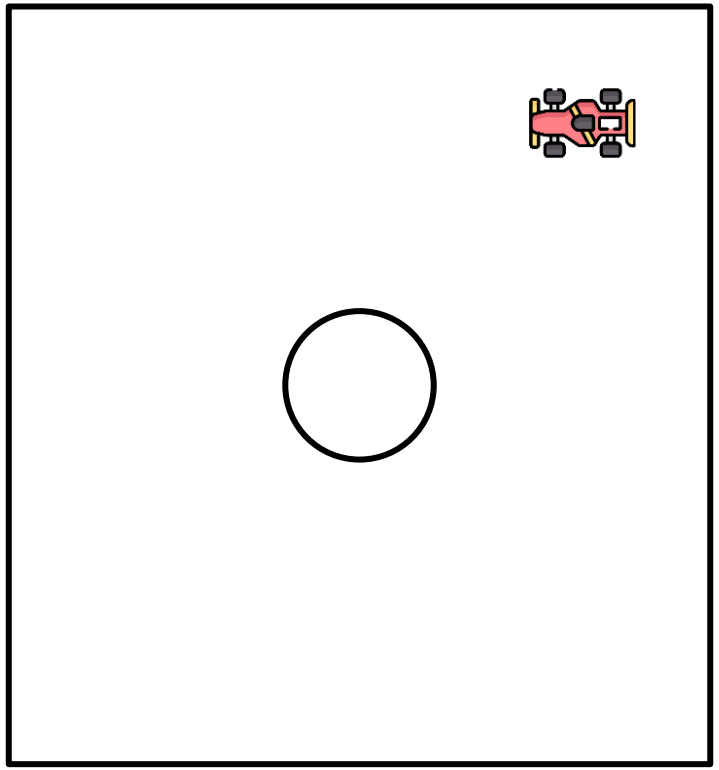




Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

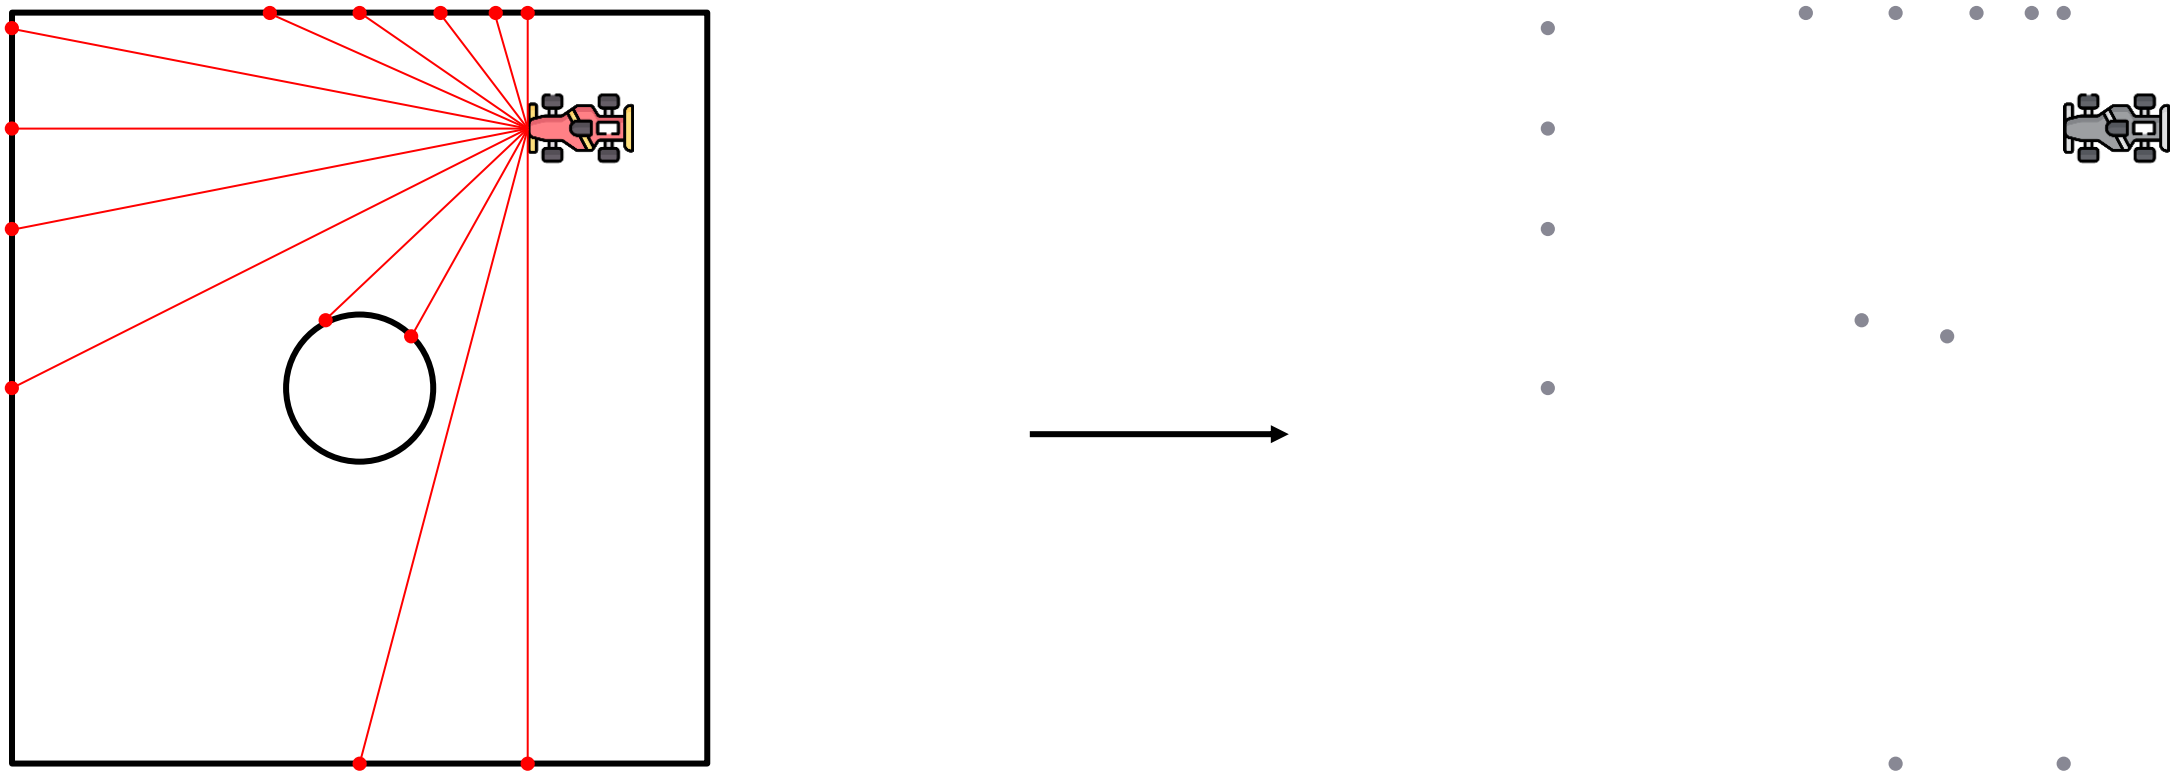
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

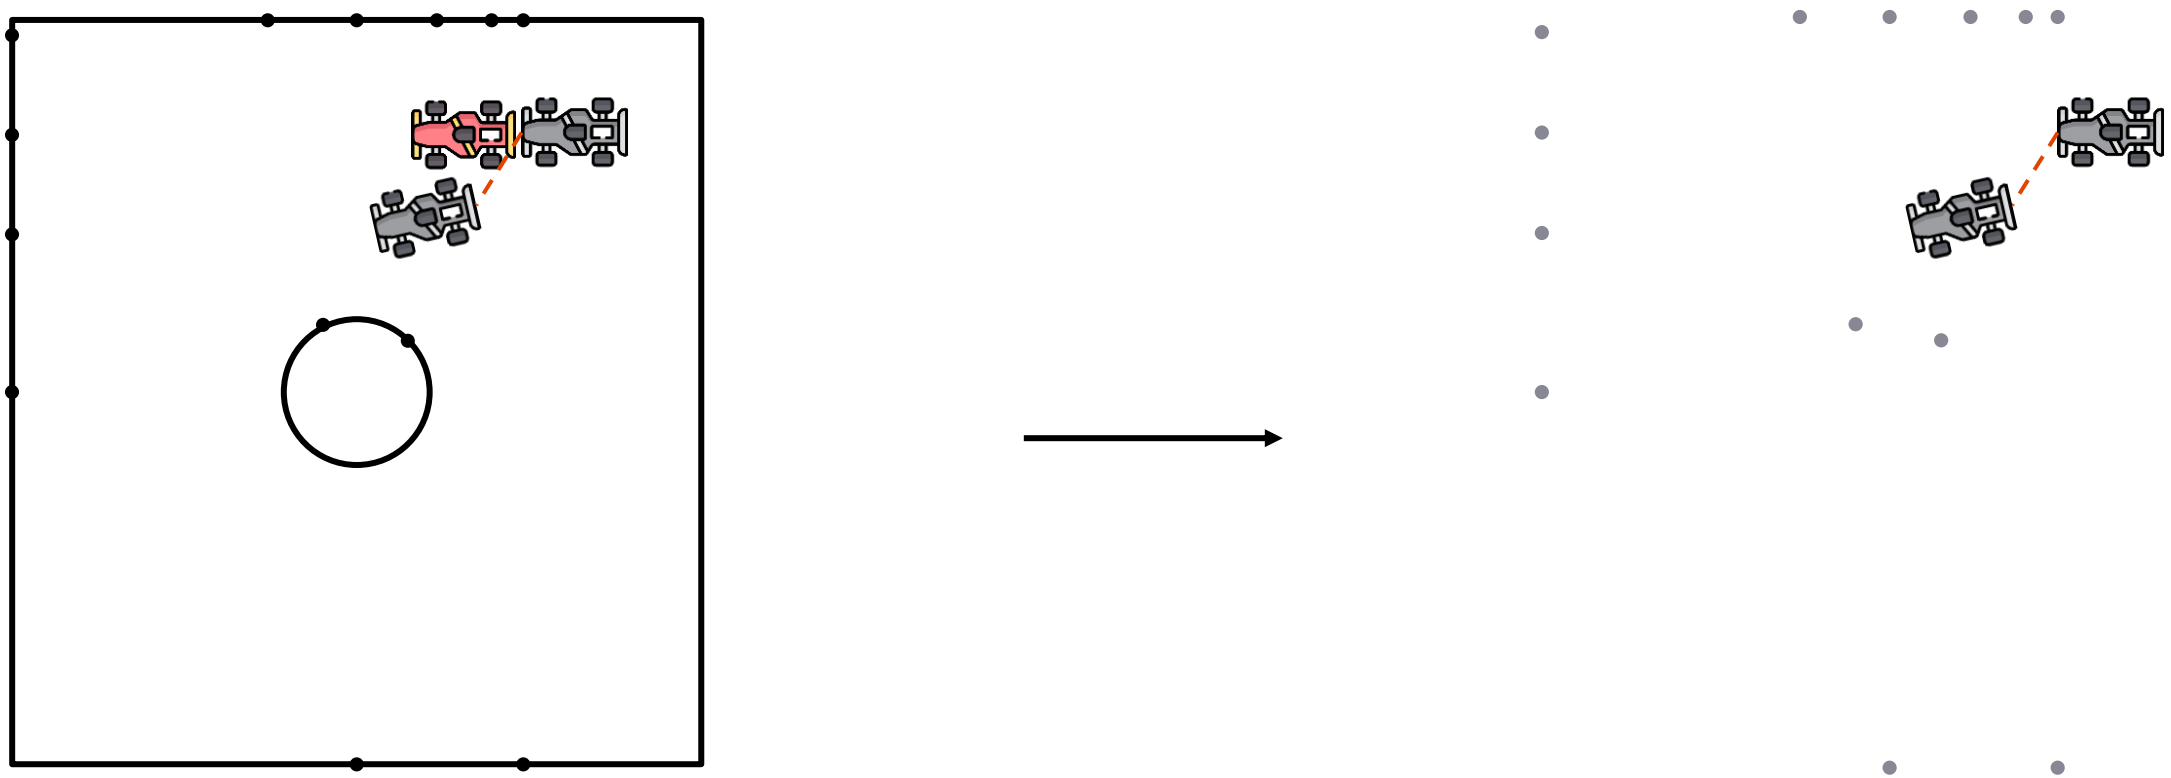
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

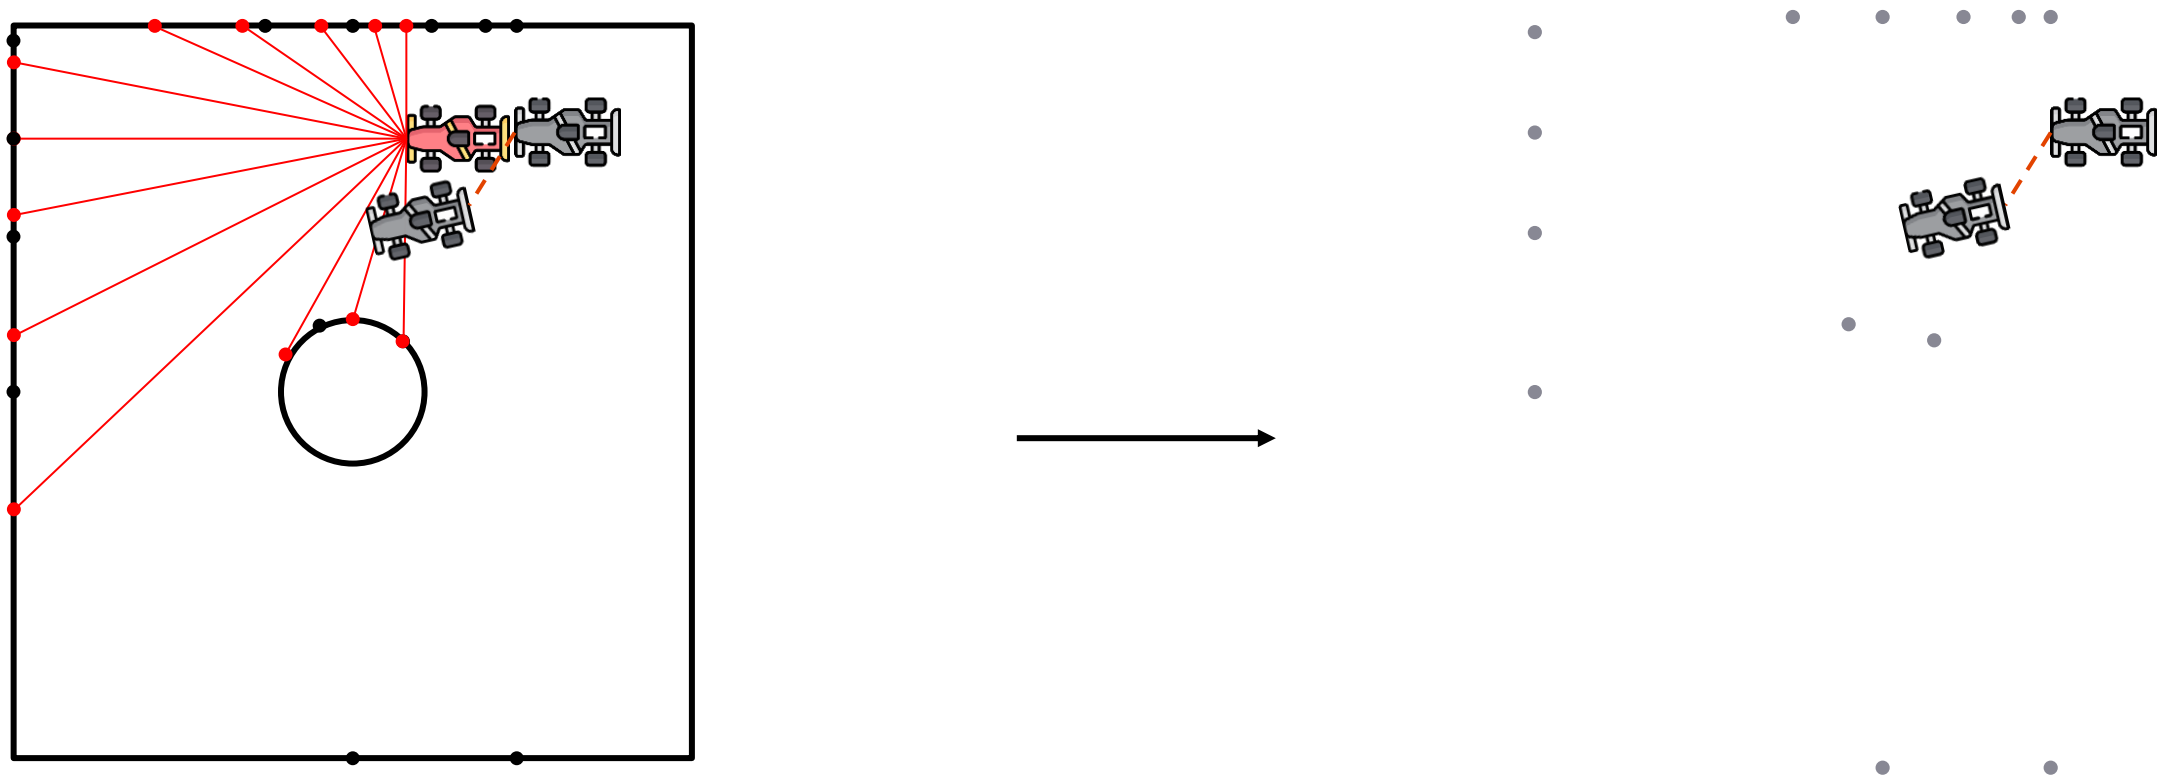
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

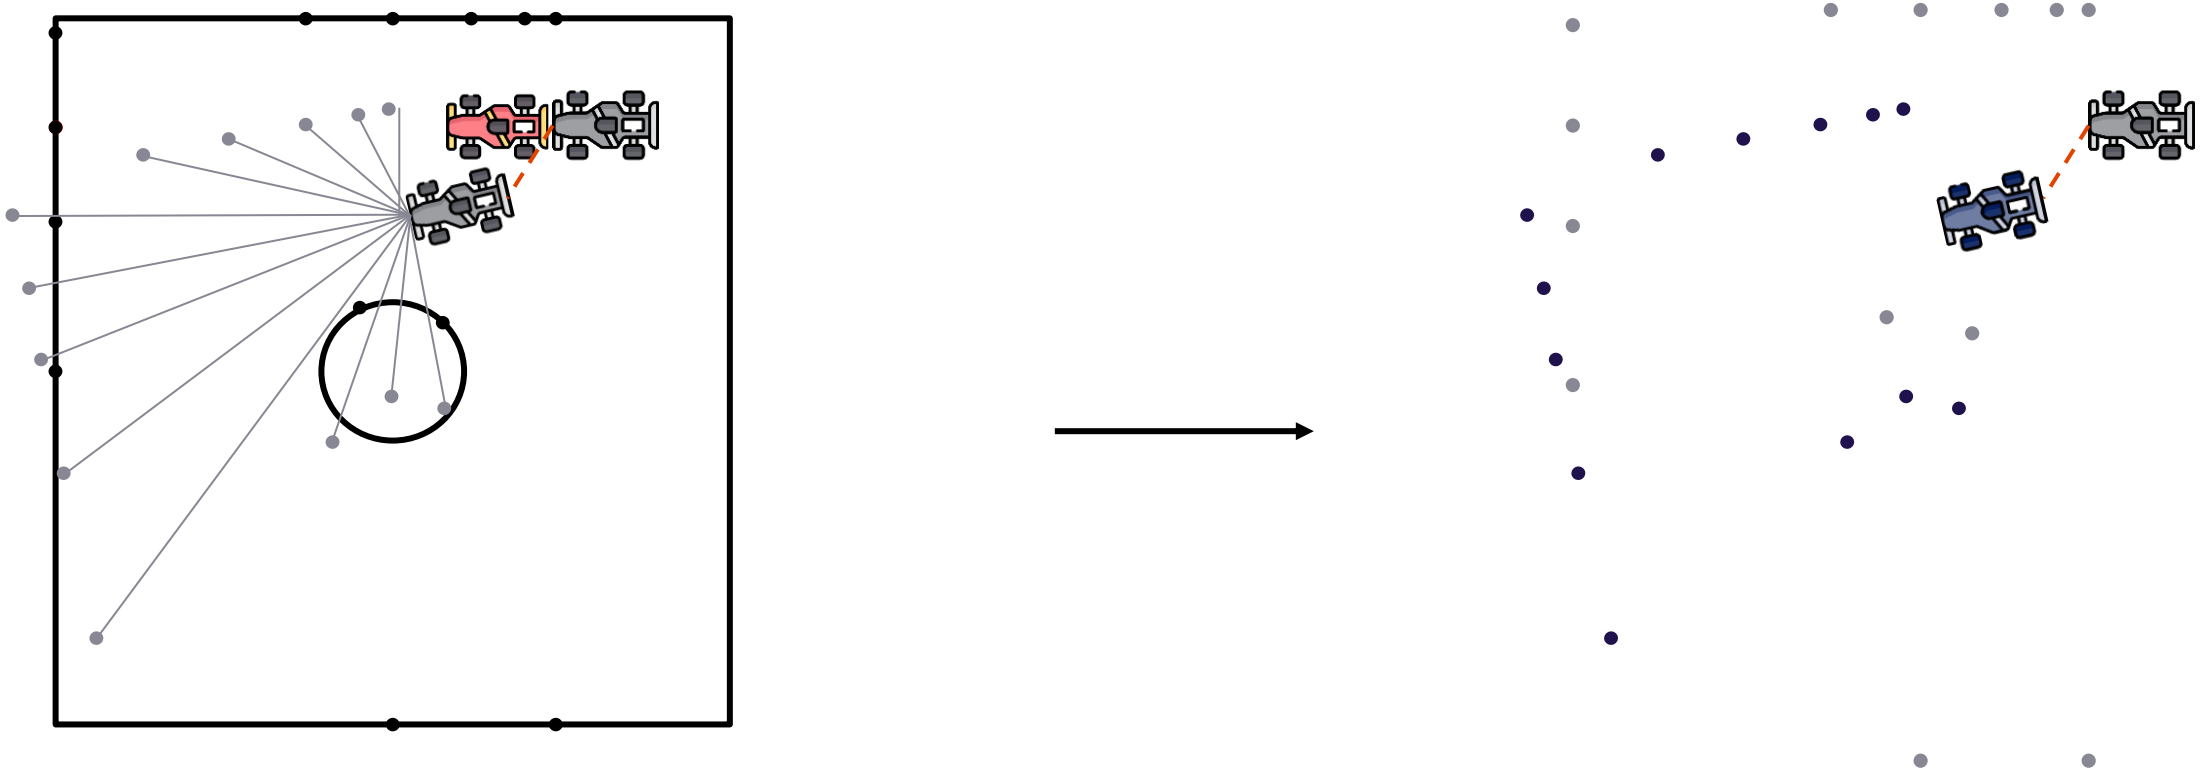
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

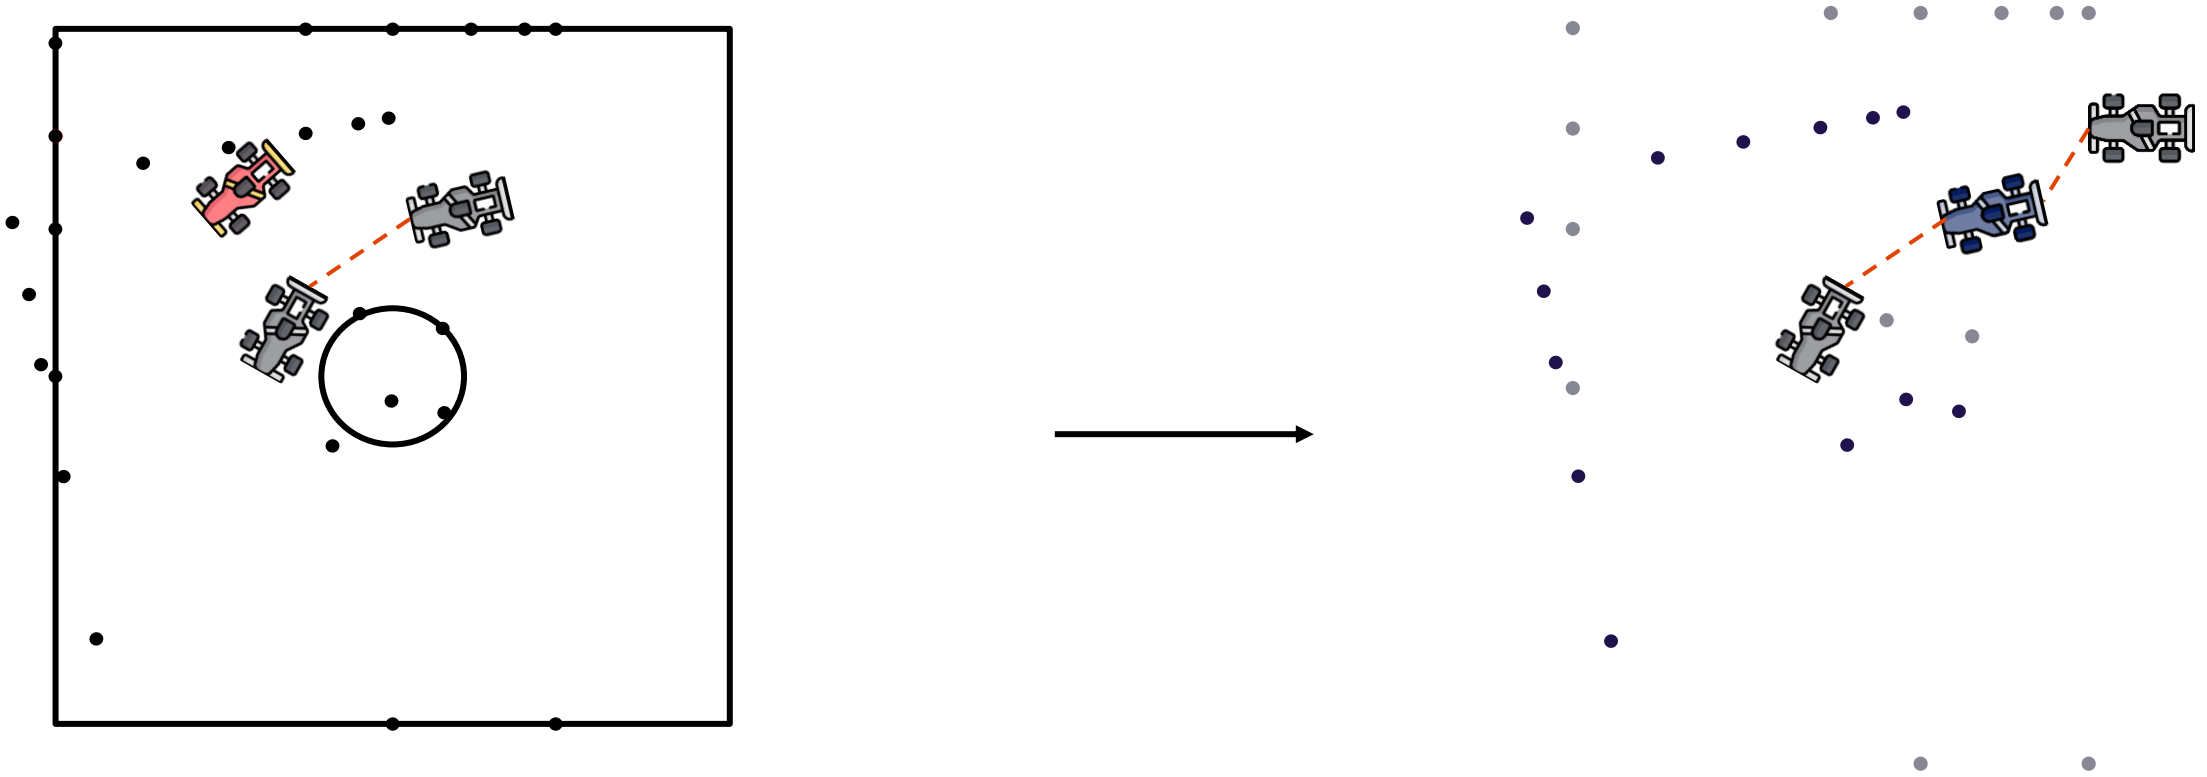
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

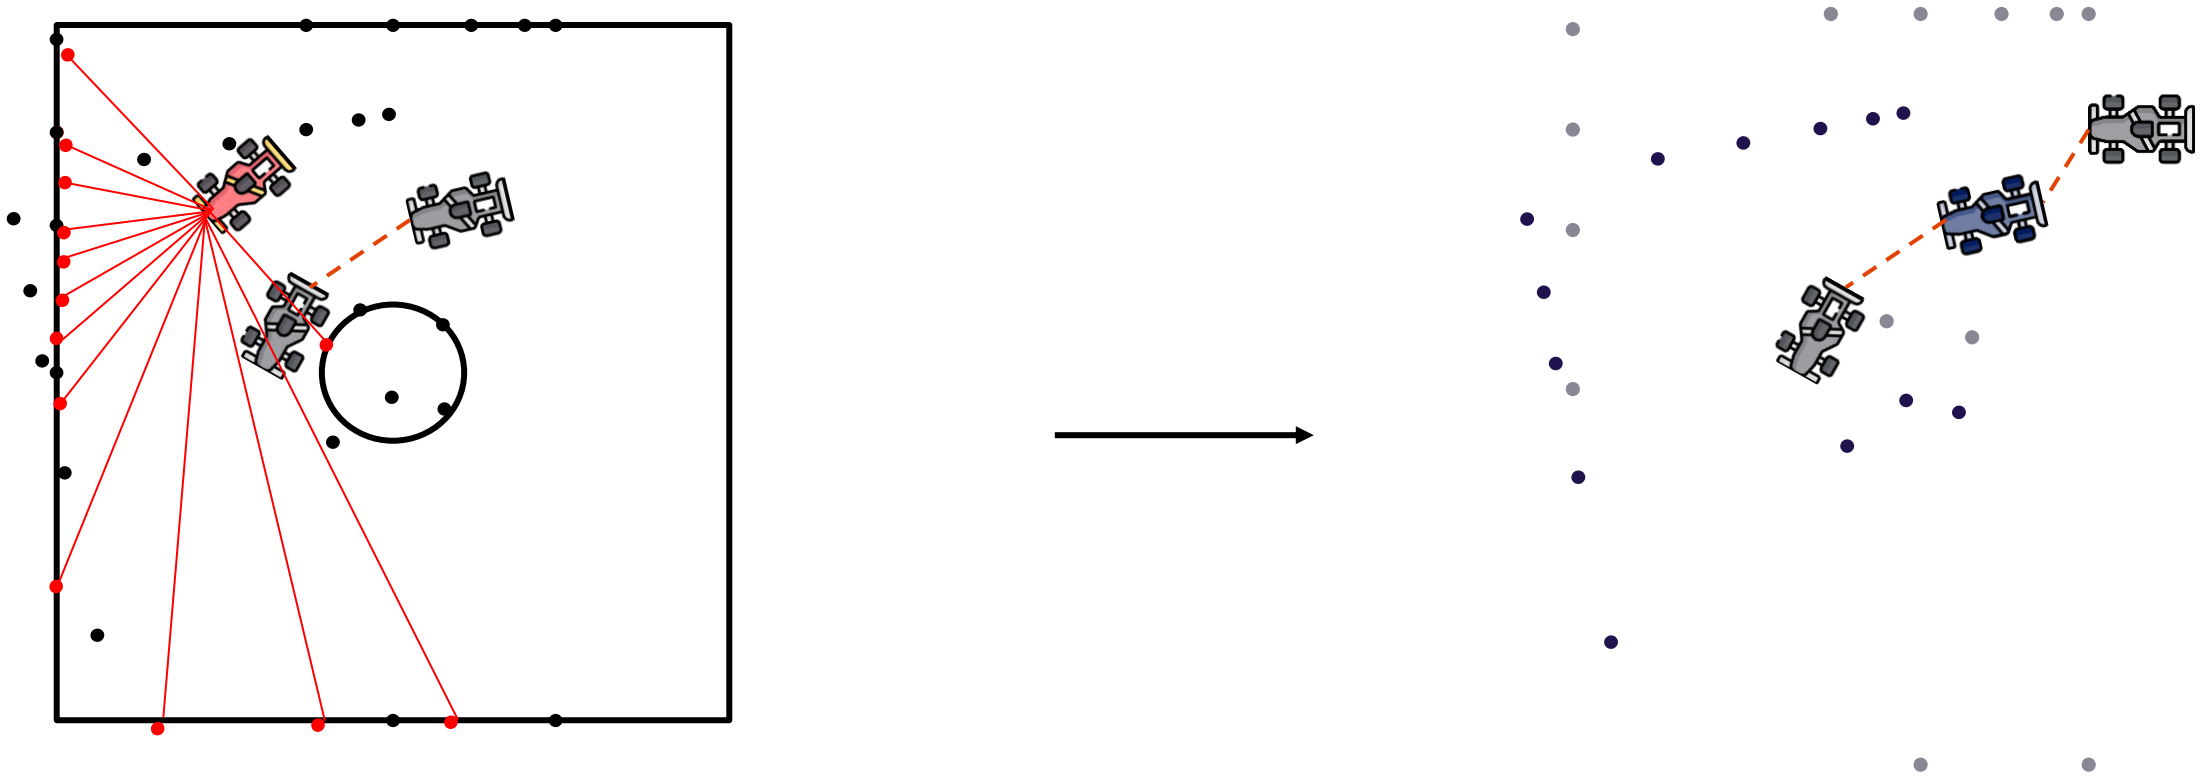
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

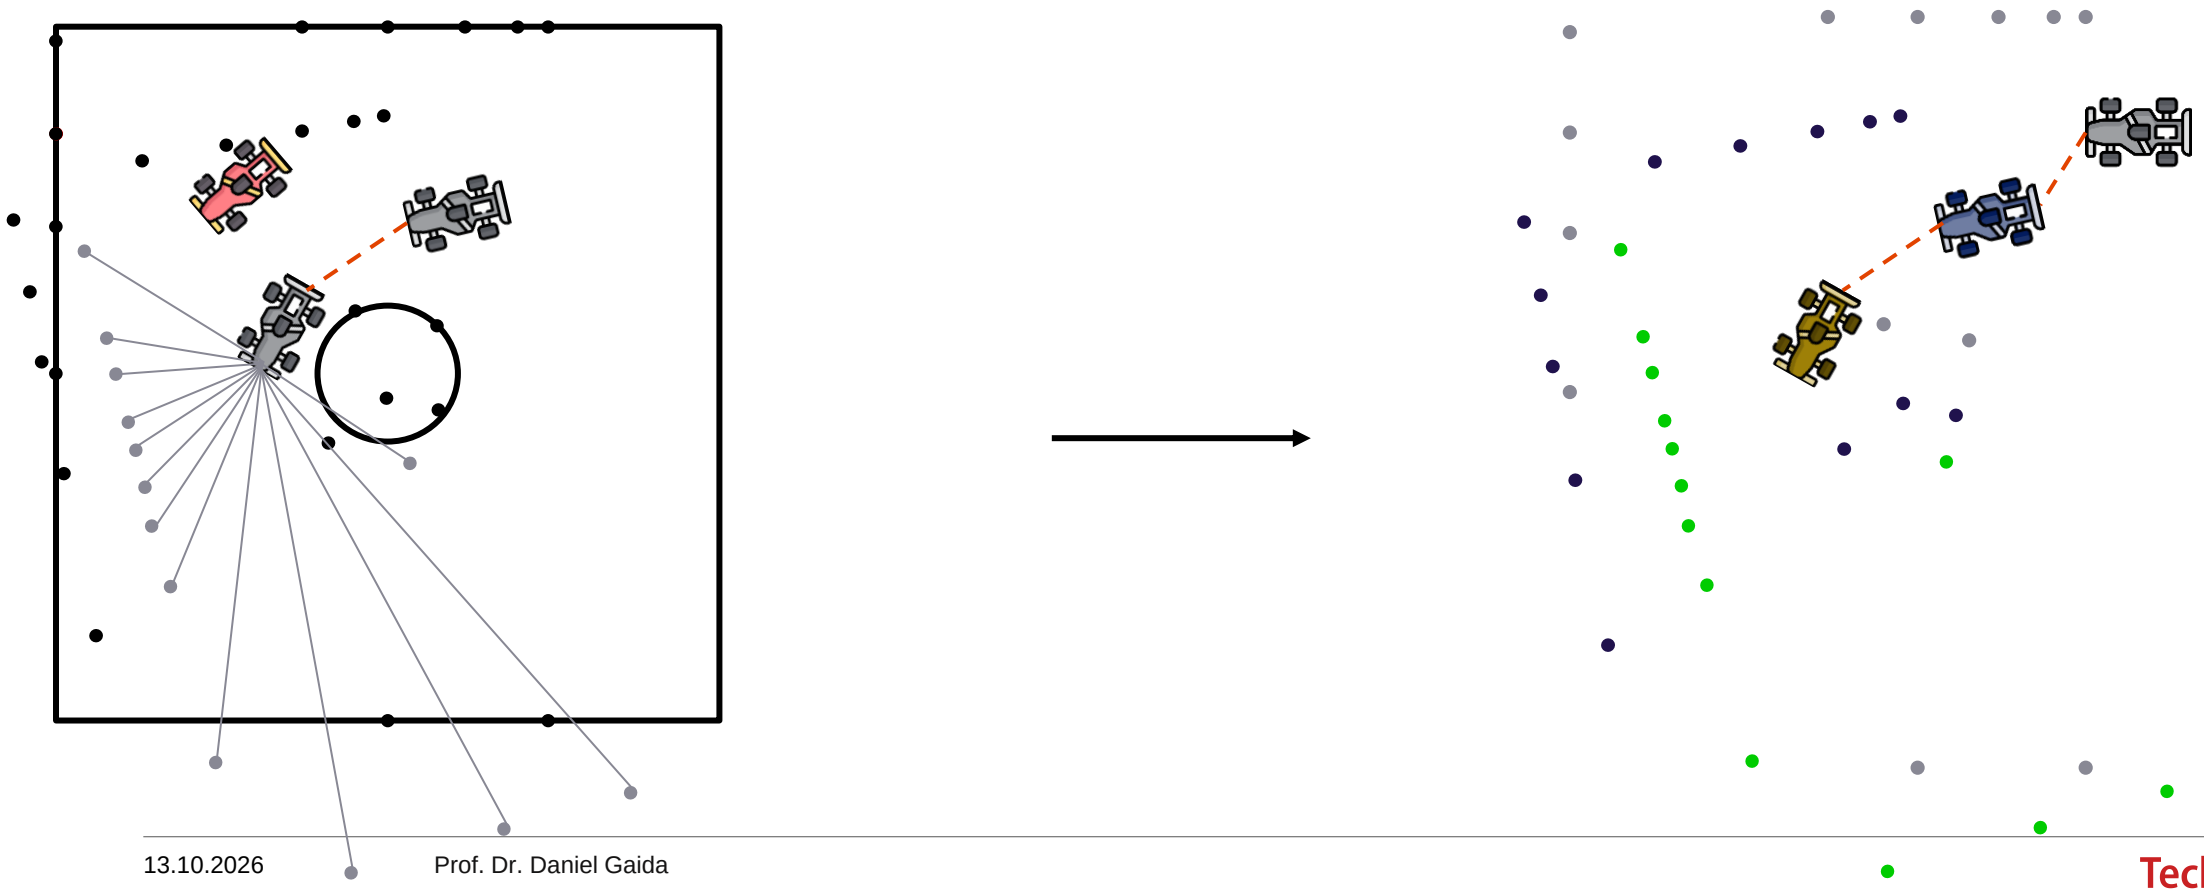
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

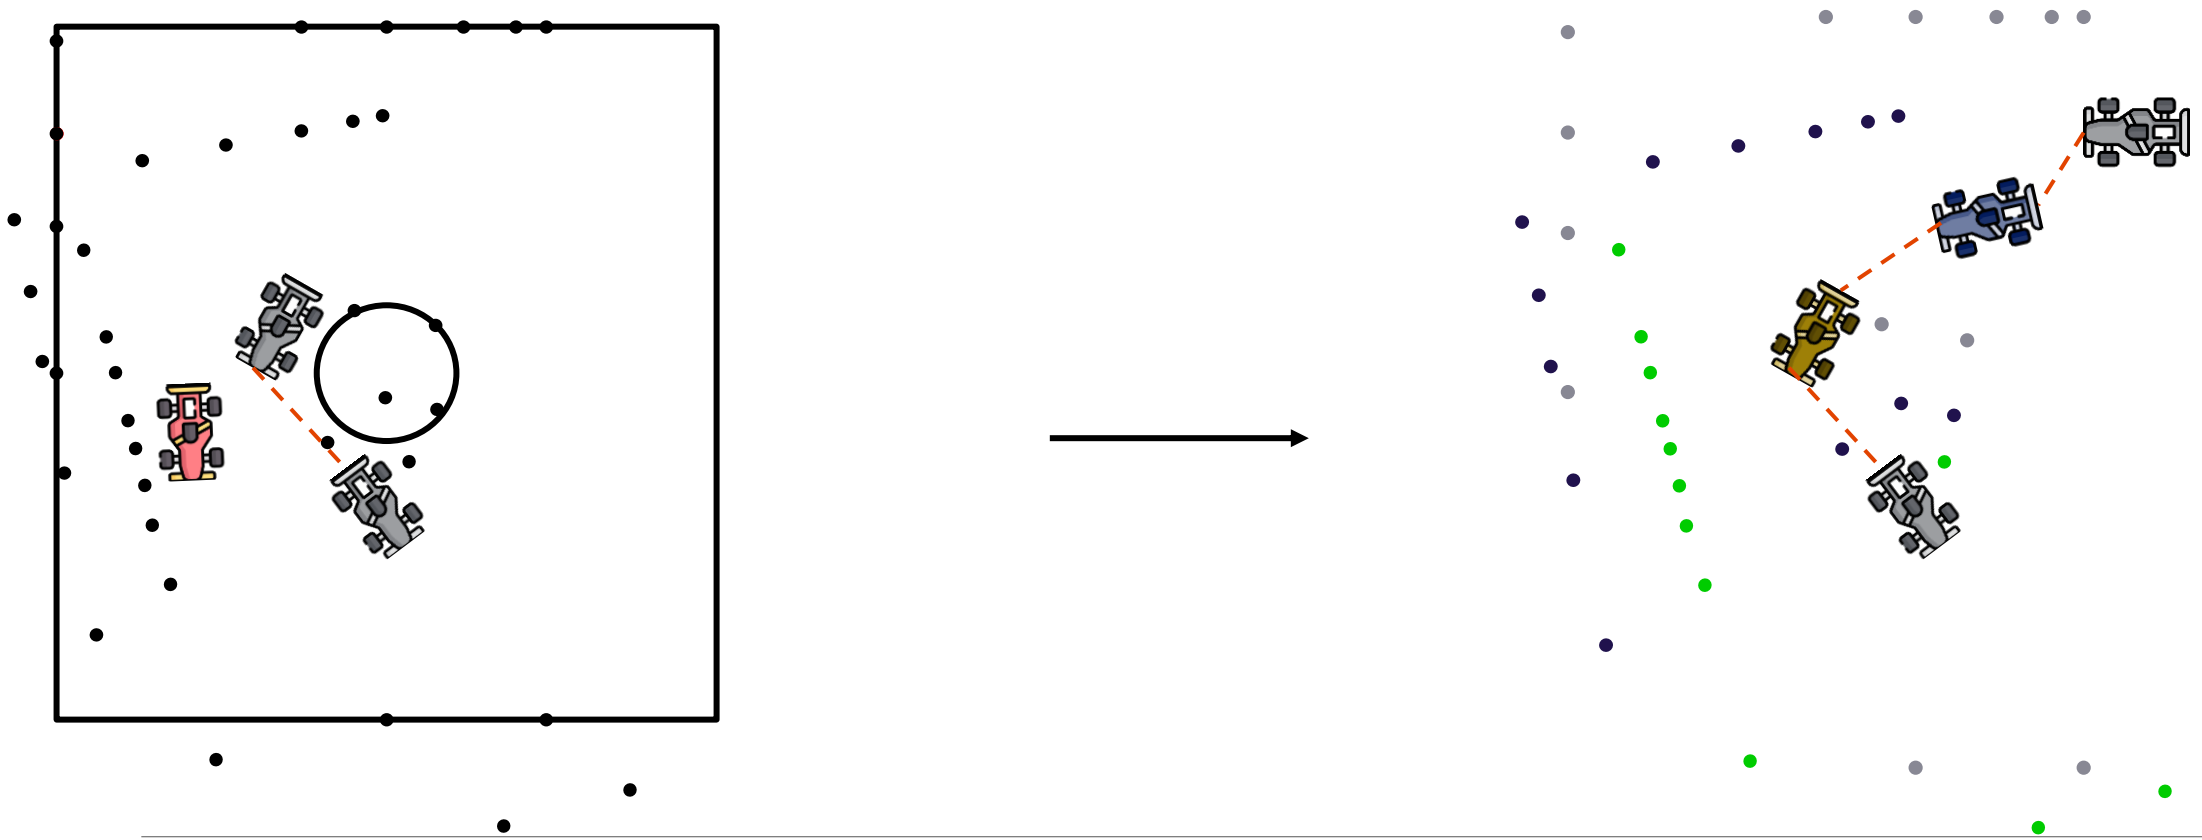
Pose Graphs



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

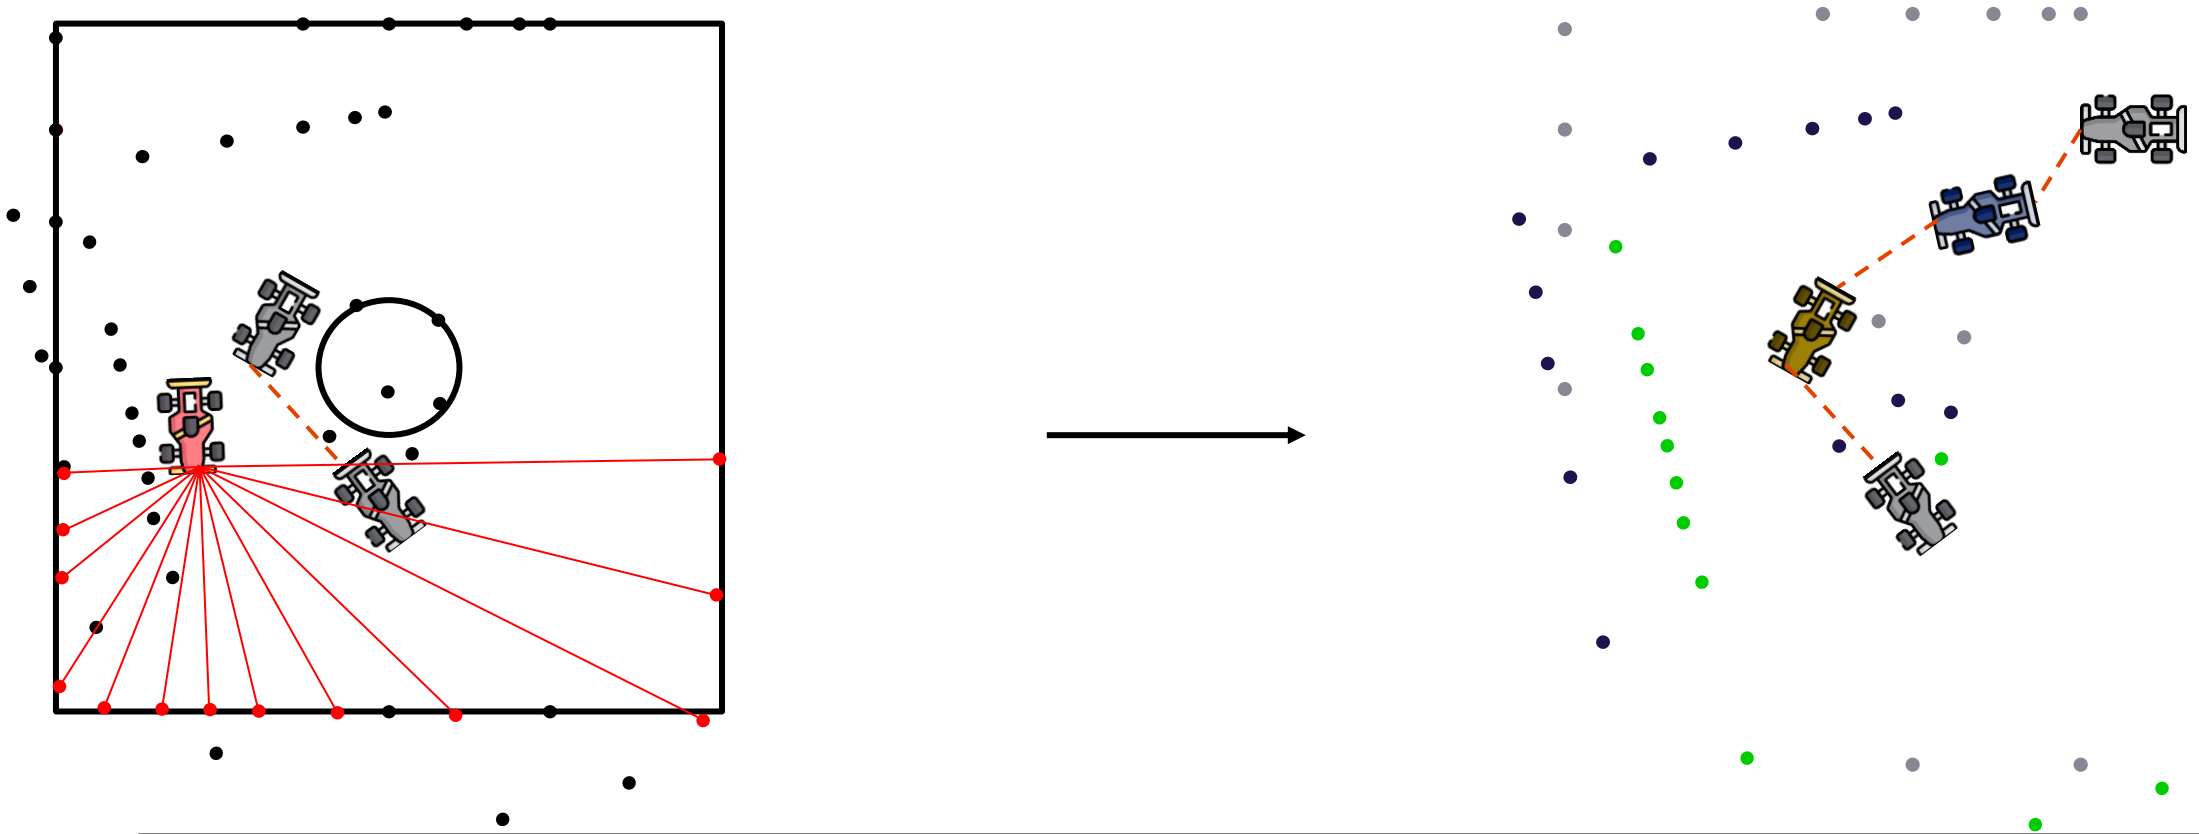
Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

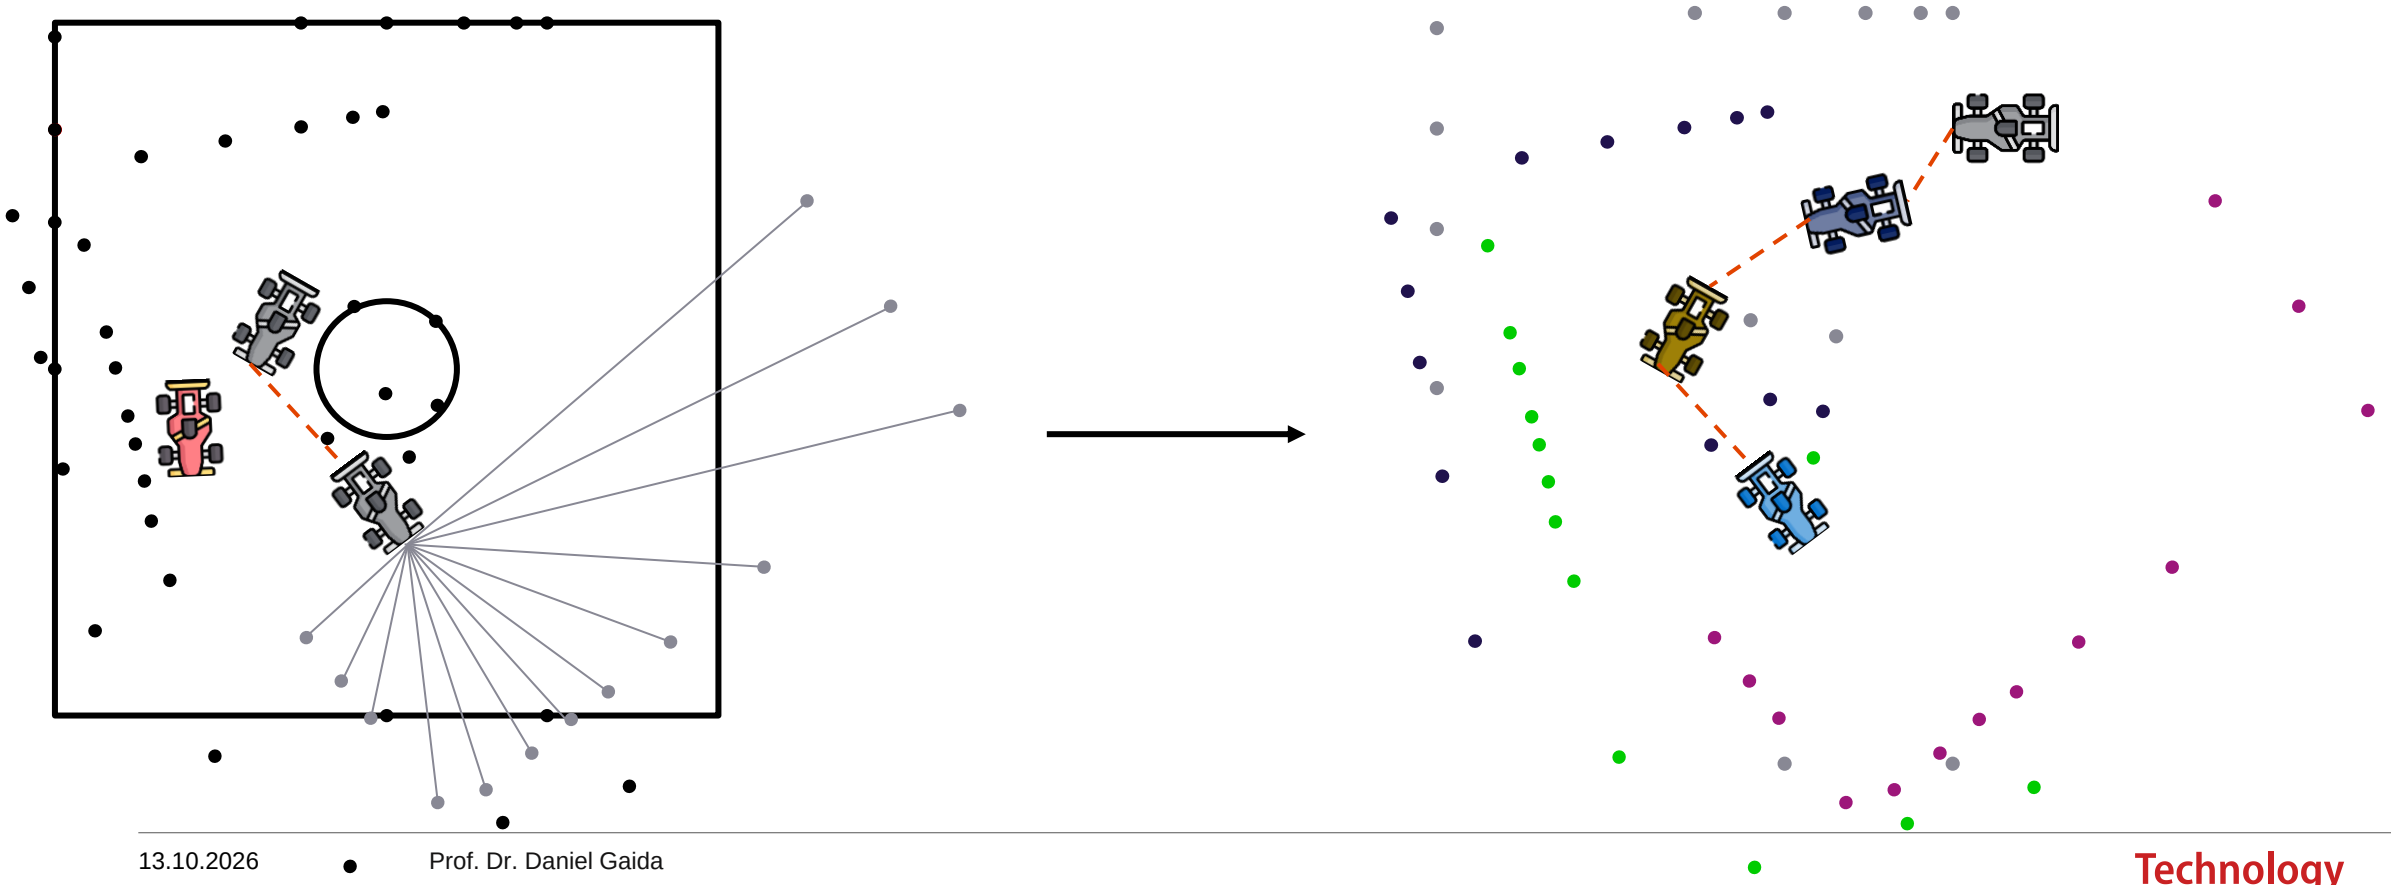
Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Pose Graphs



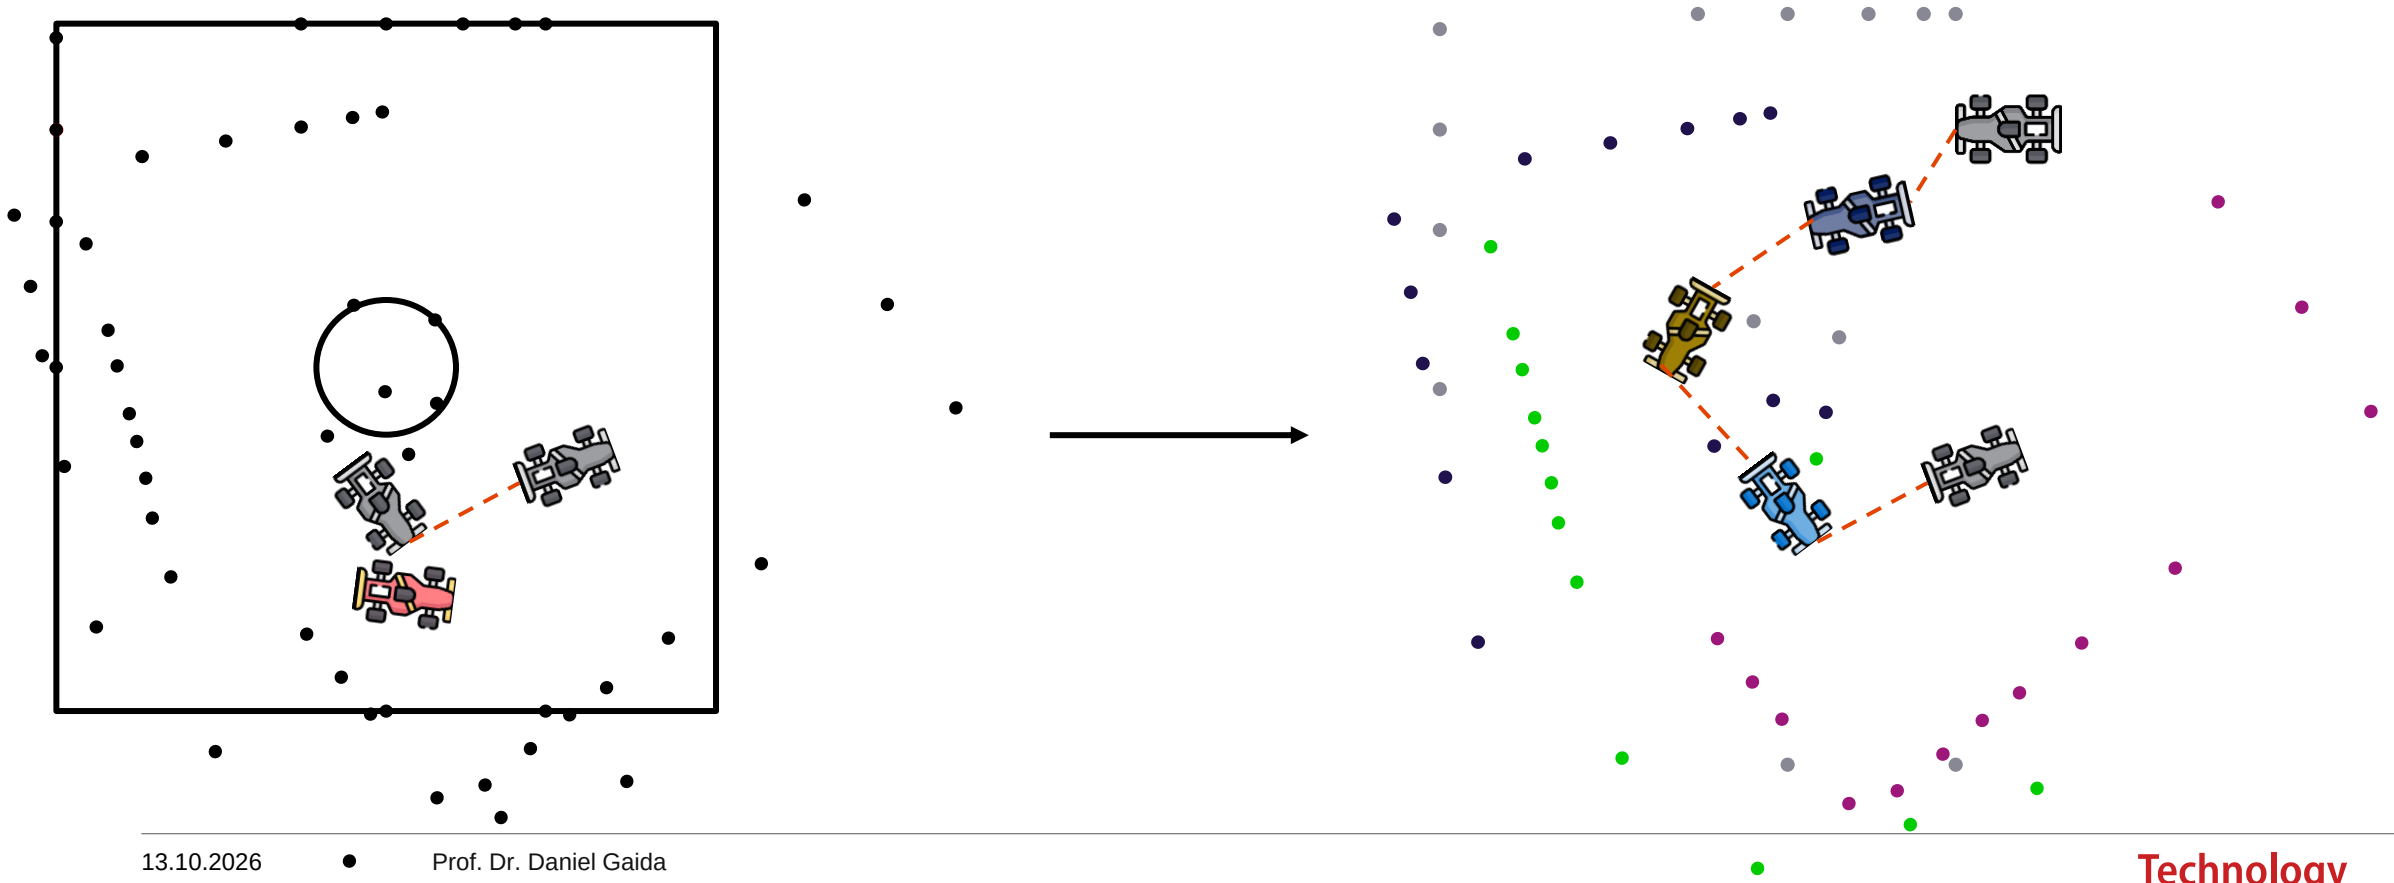
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida

Professor für Cyber-Physische Systeme

Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

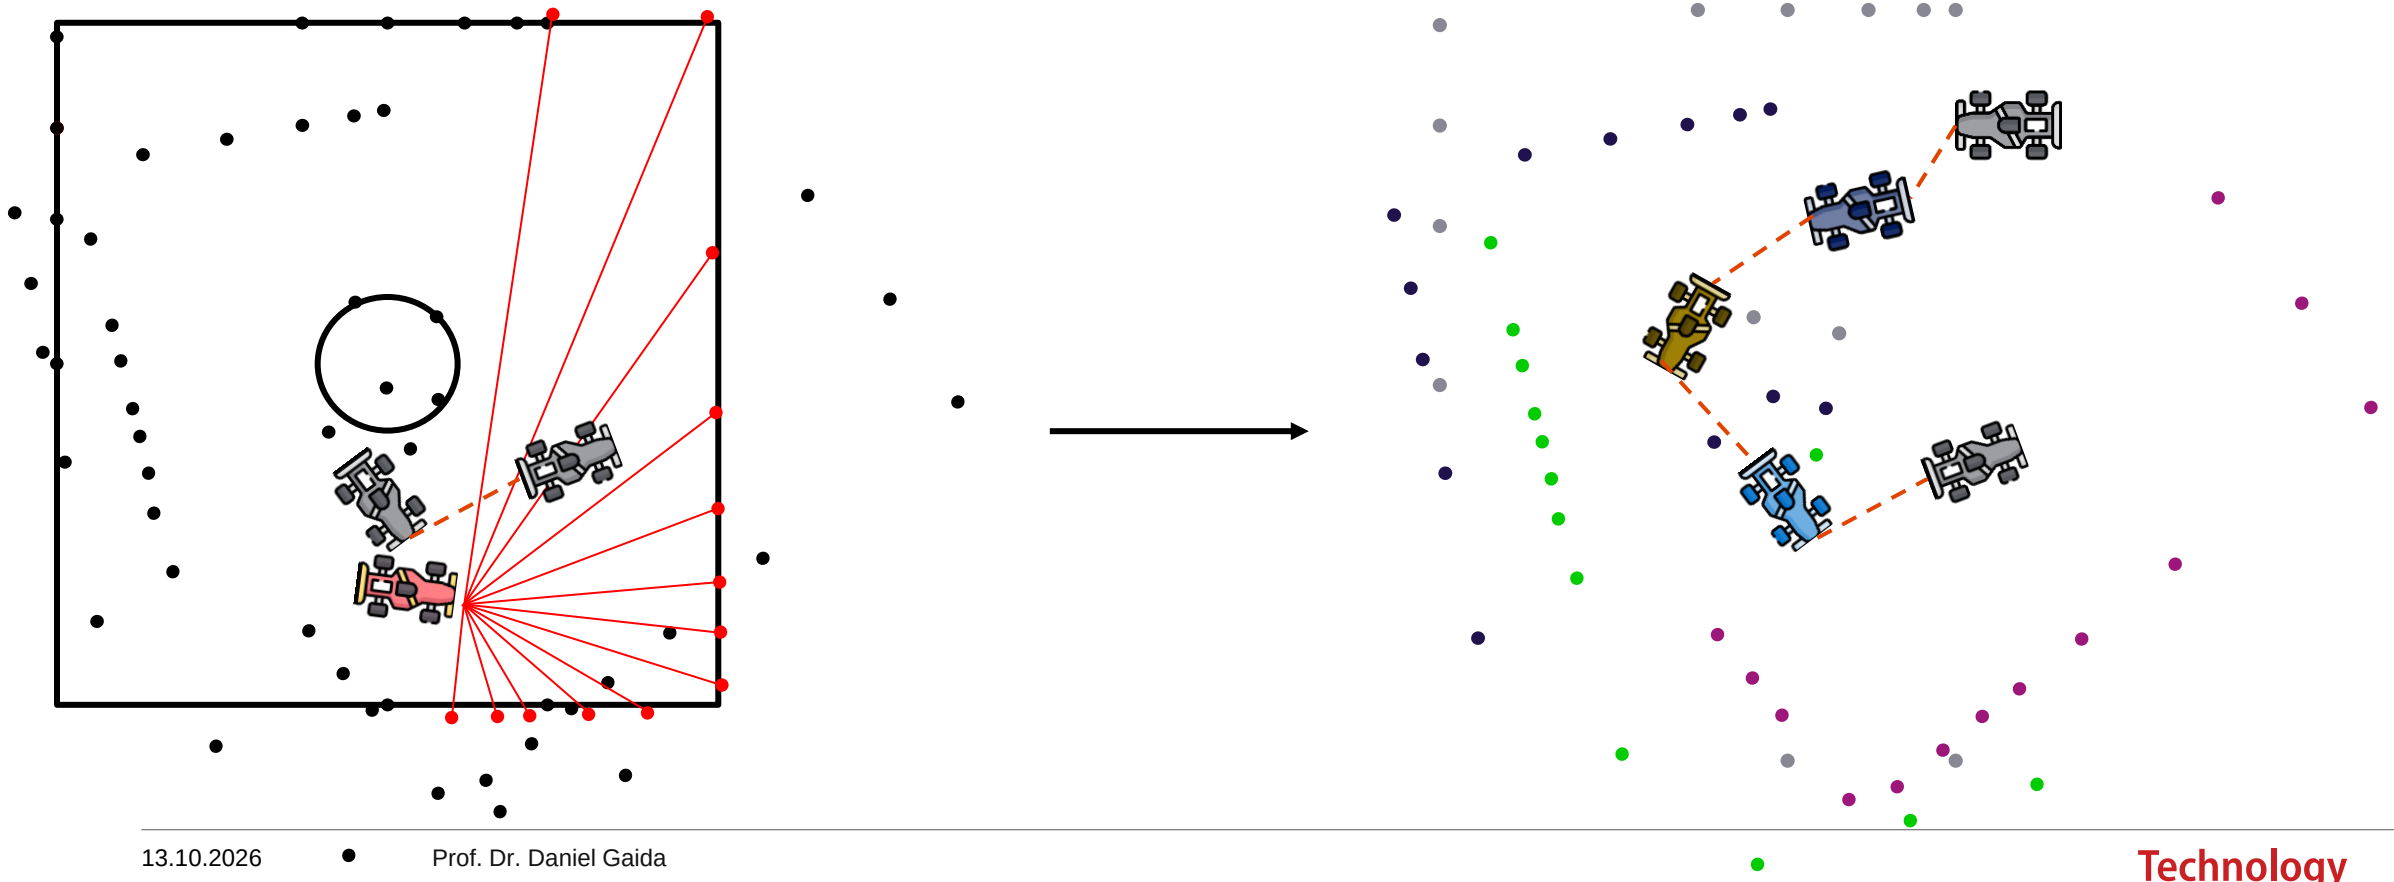
Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

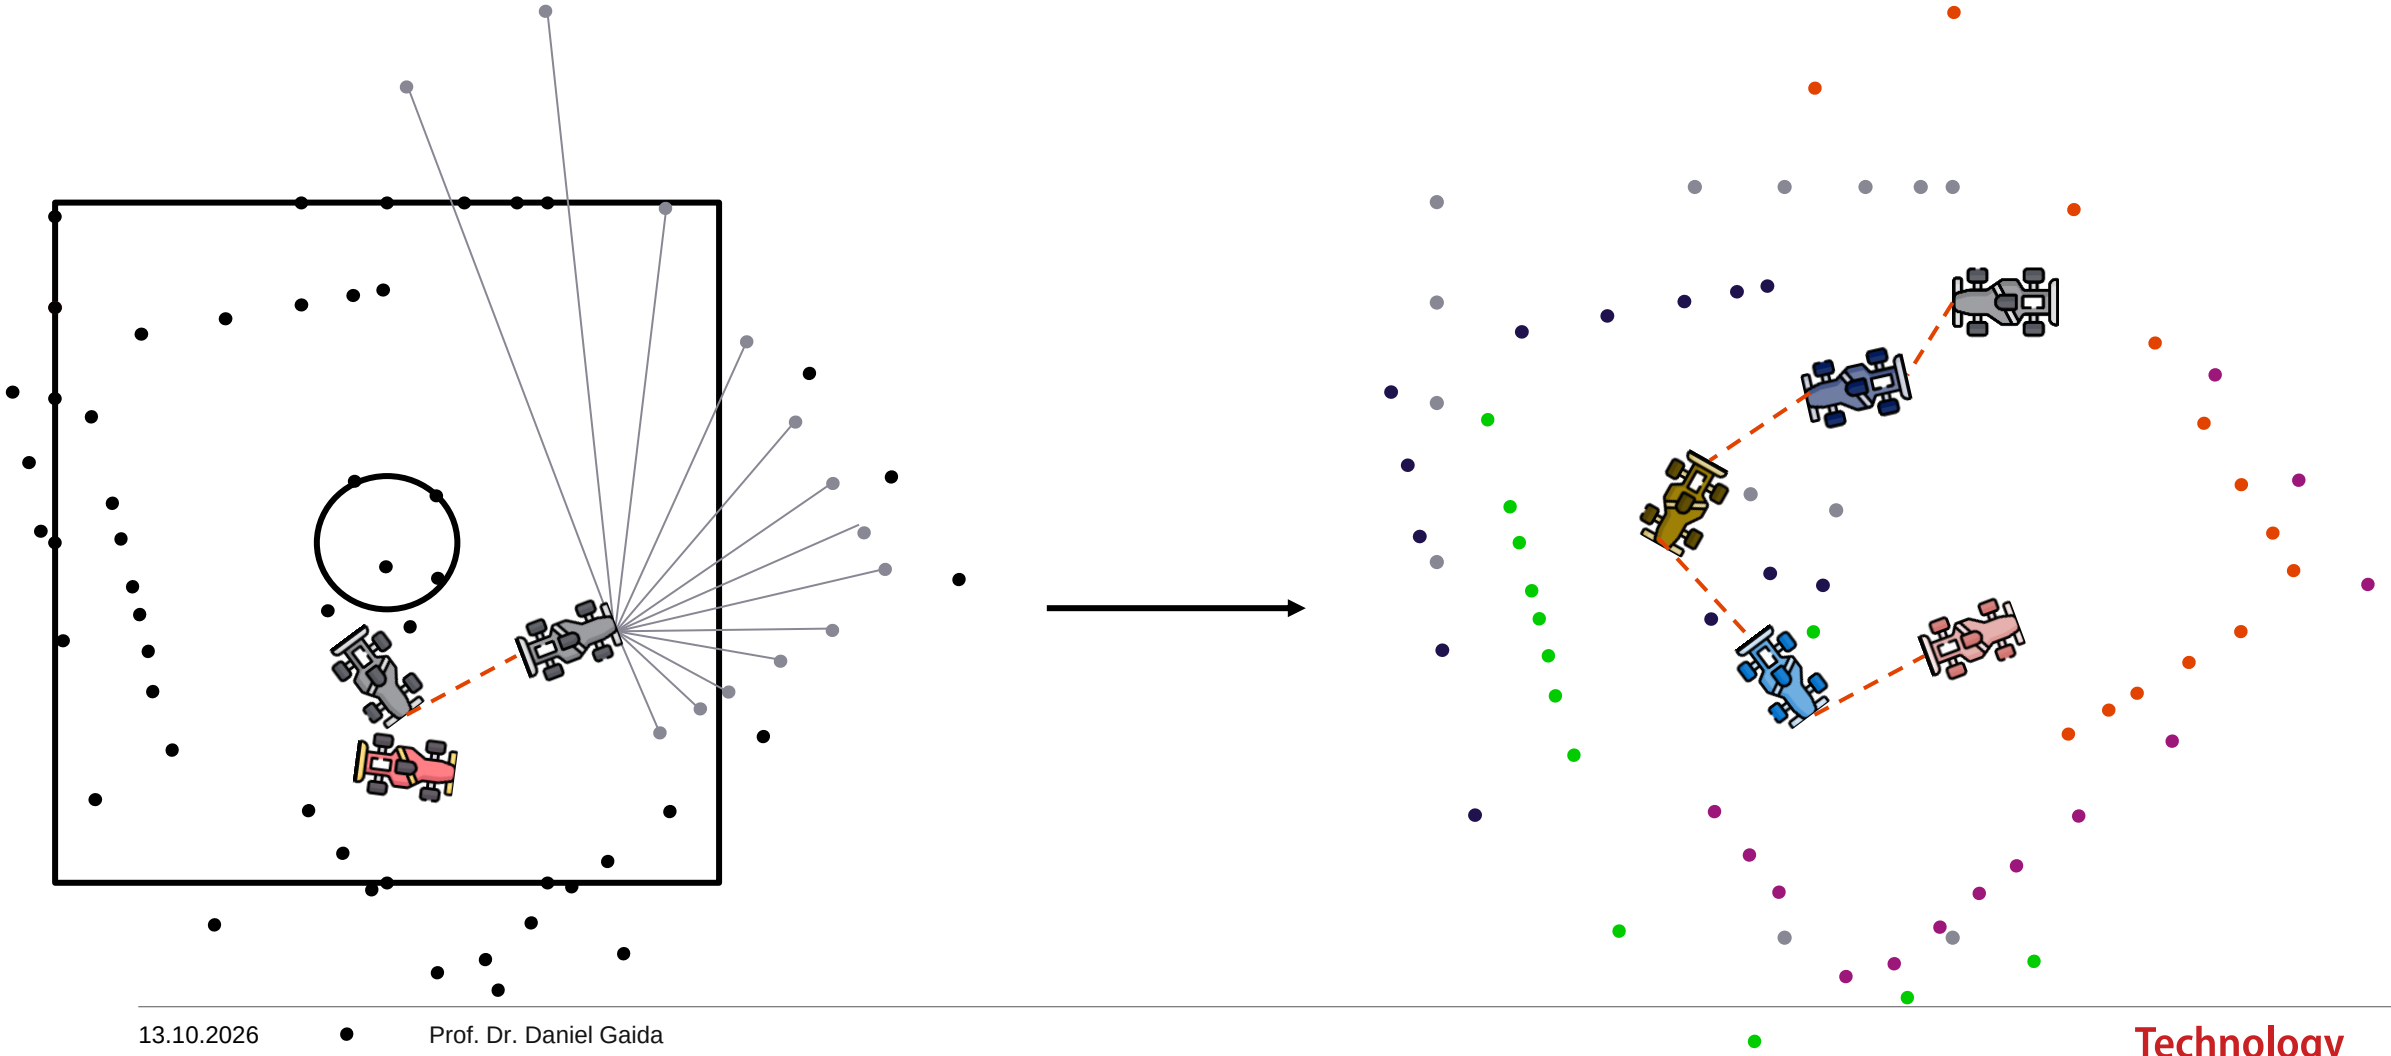
Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

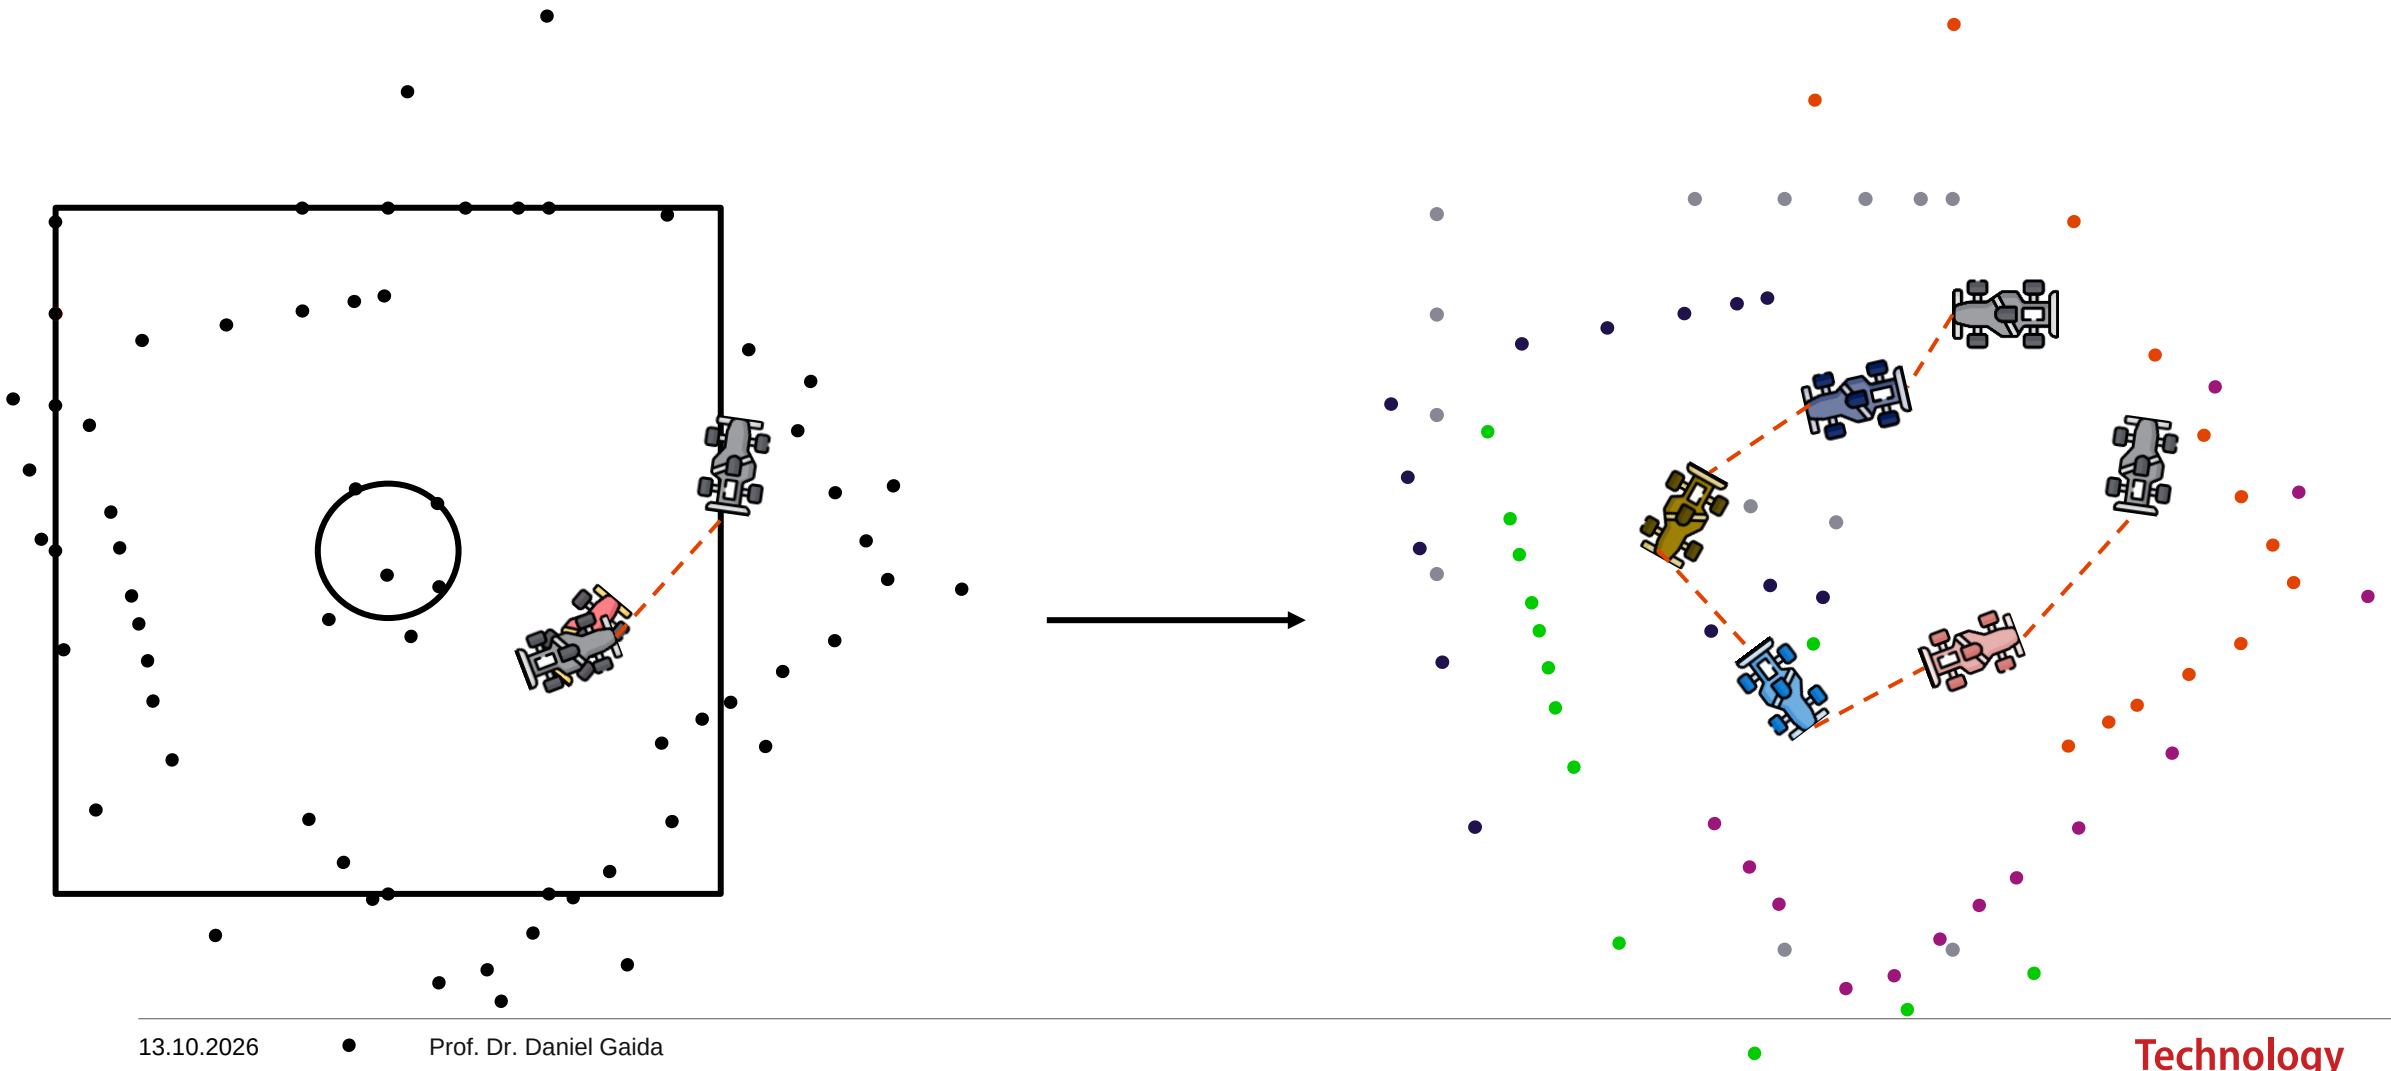
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

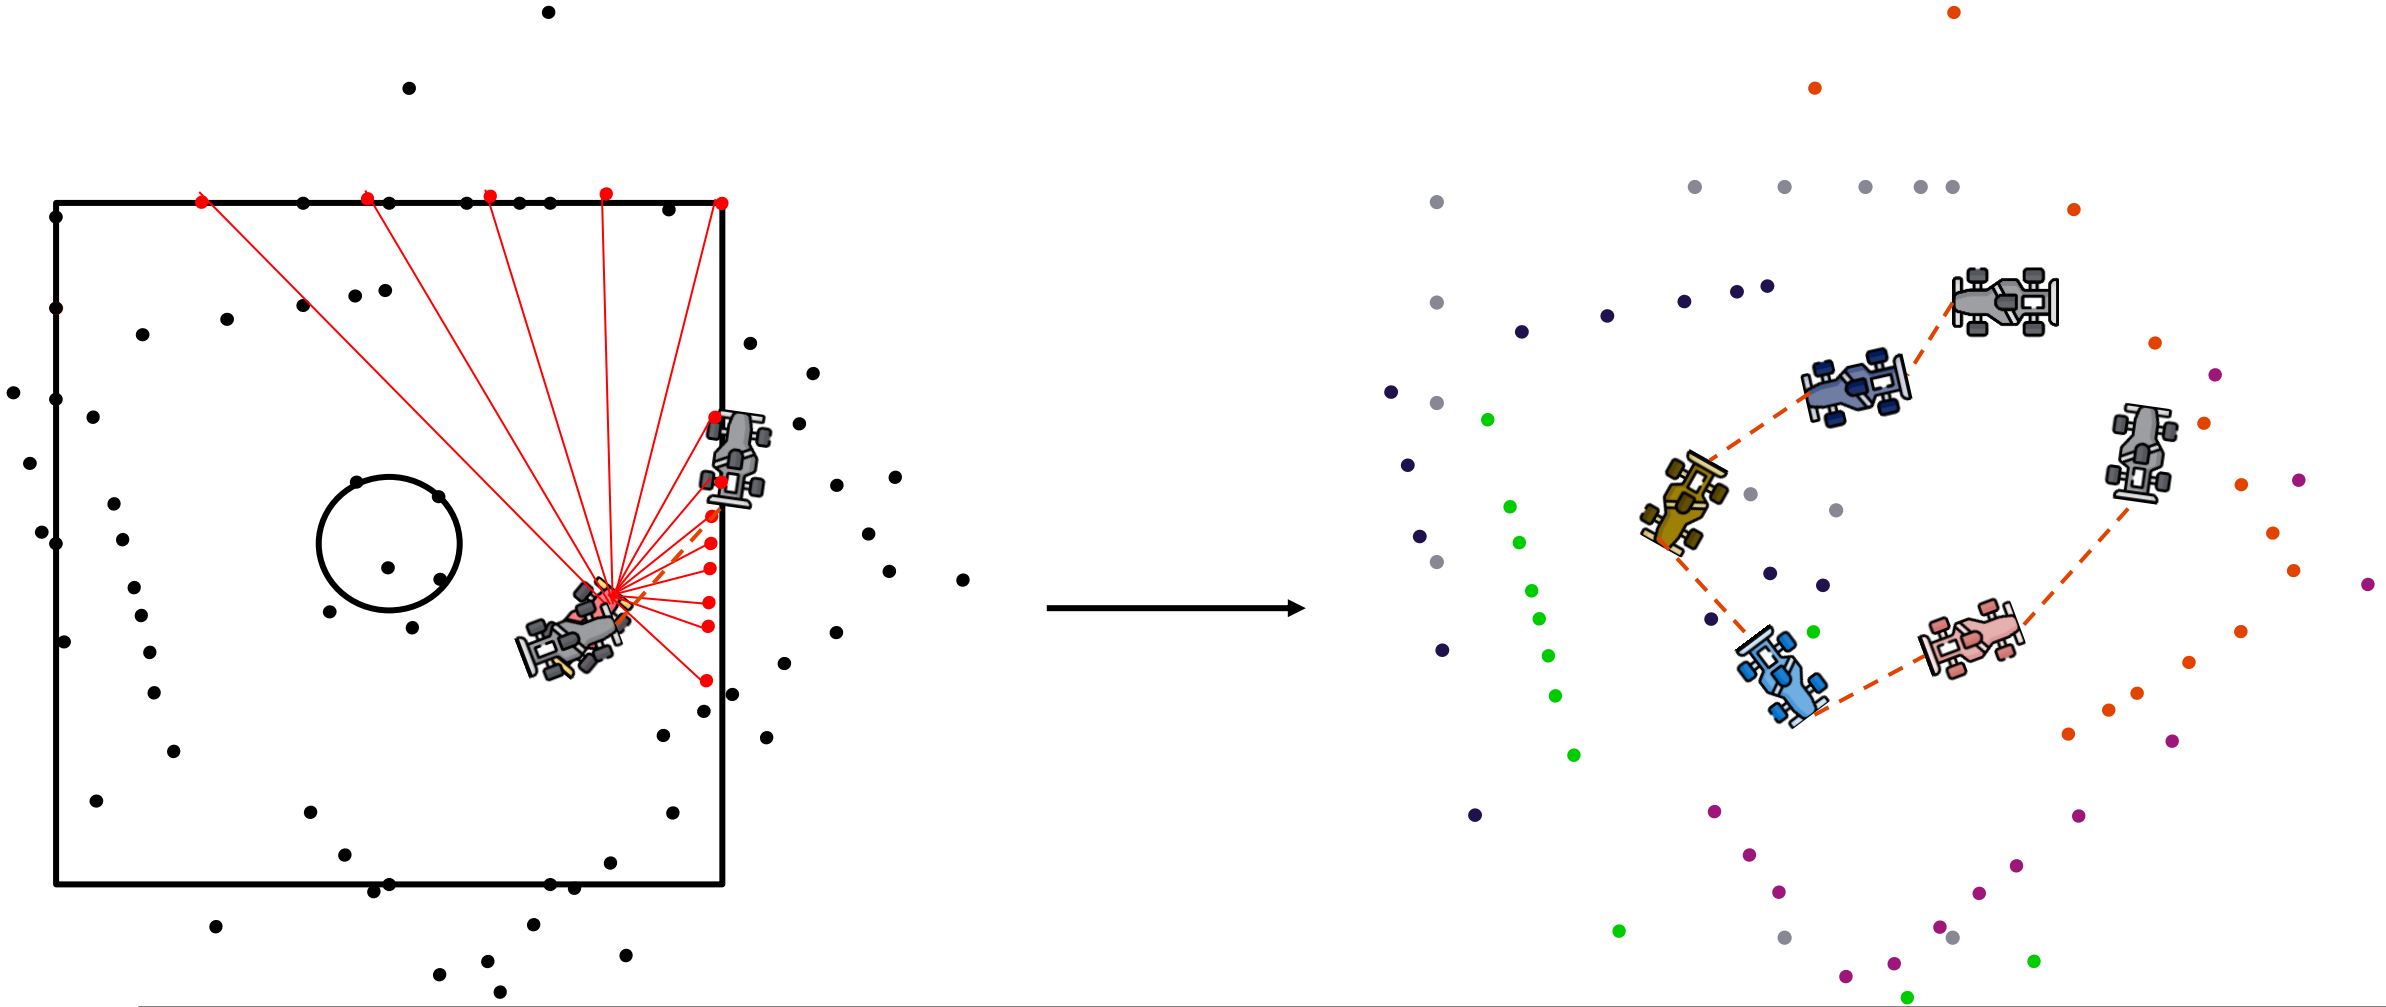
Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

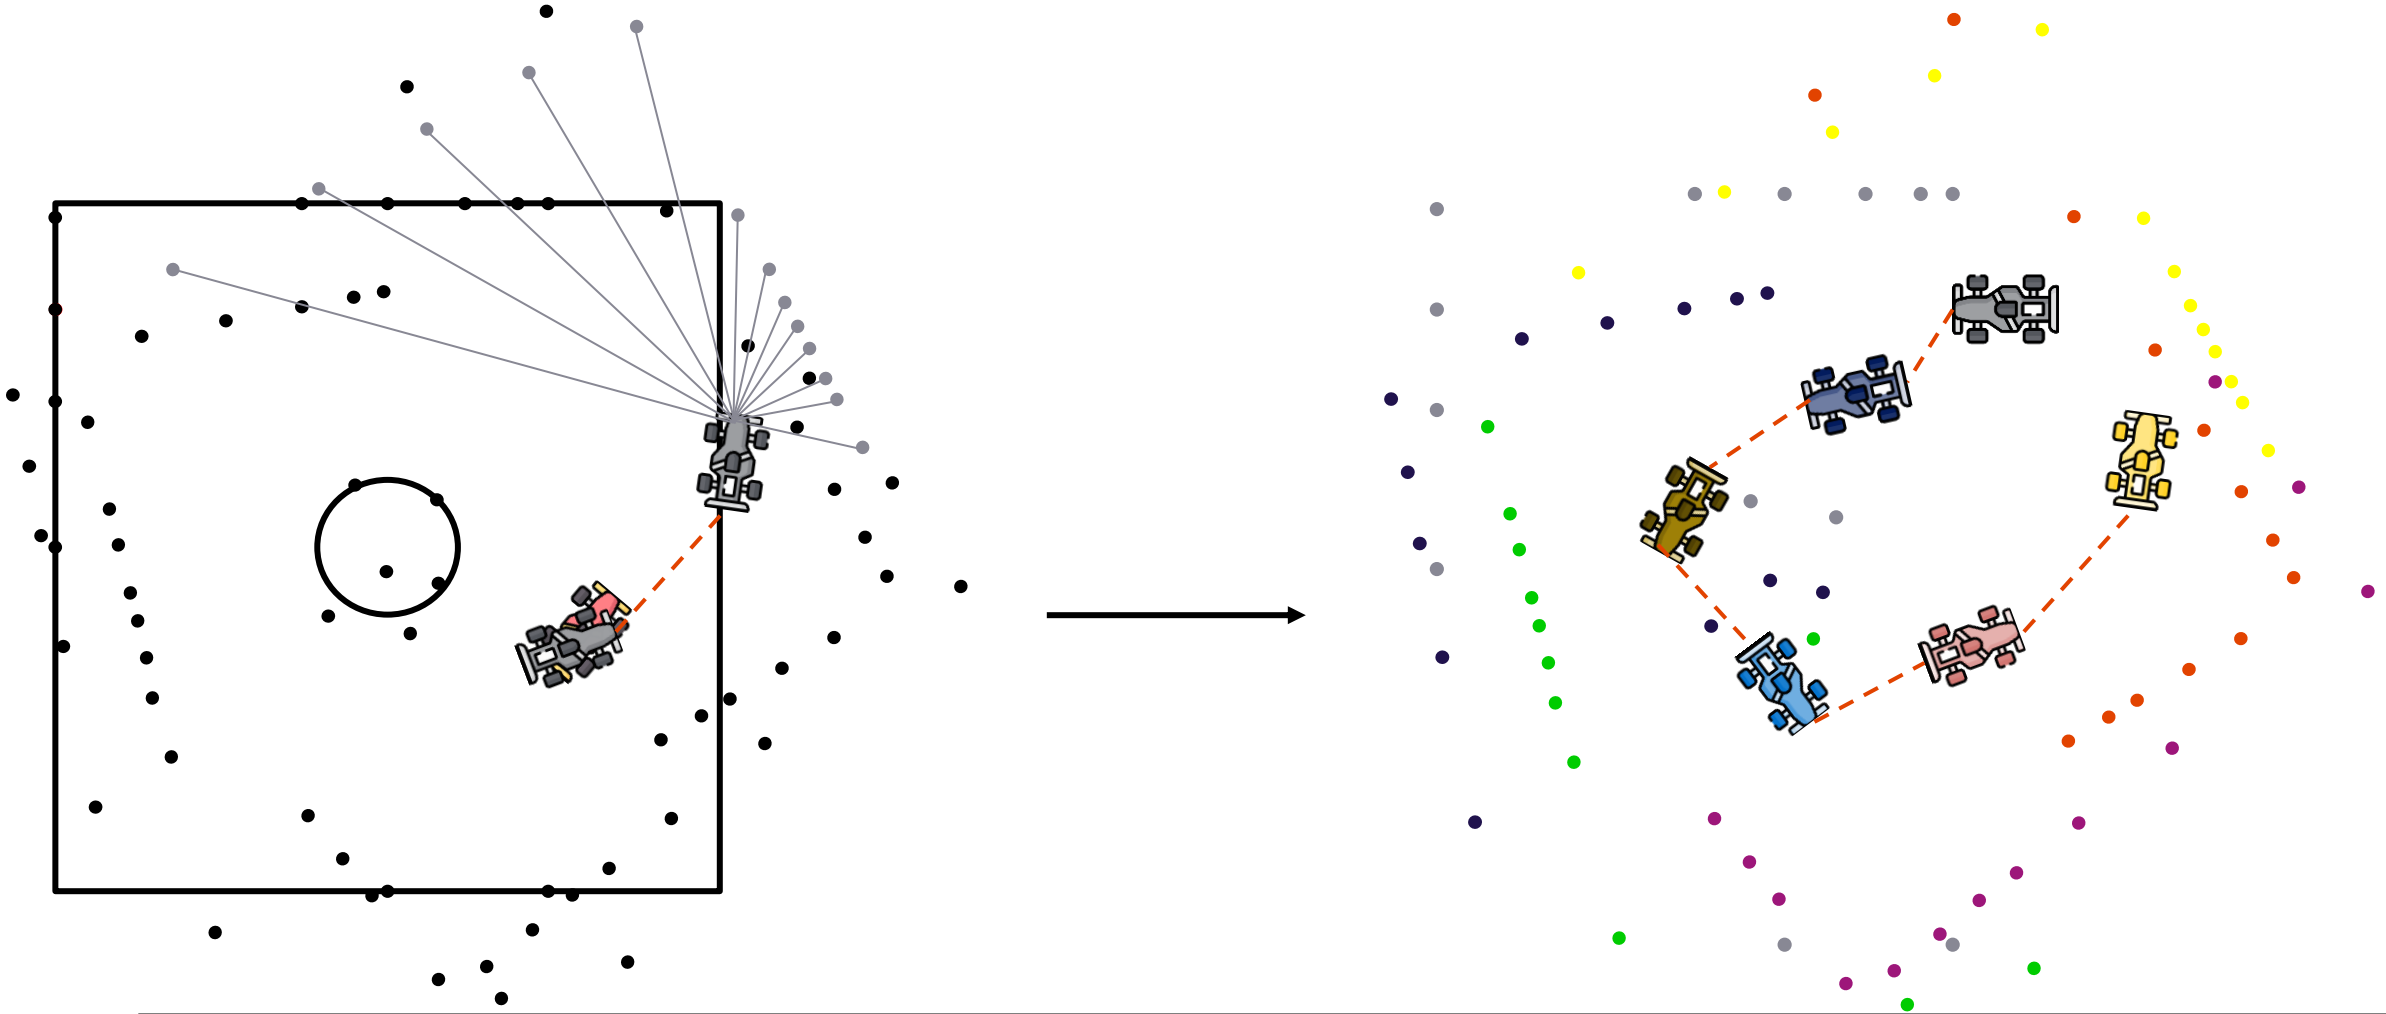
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

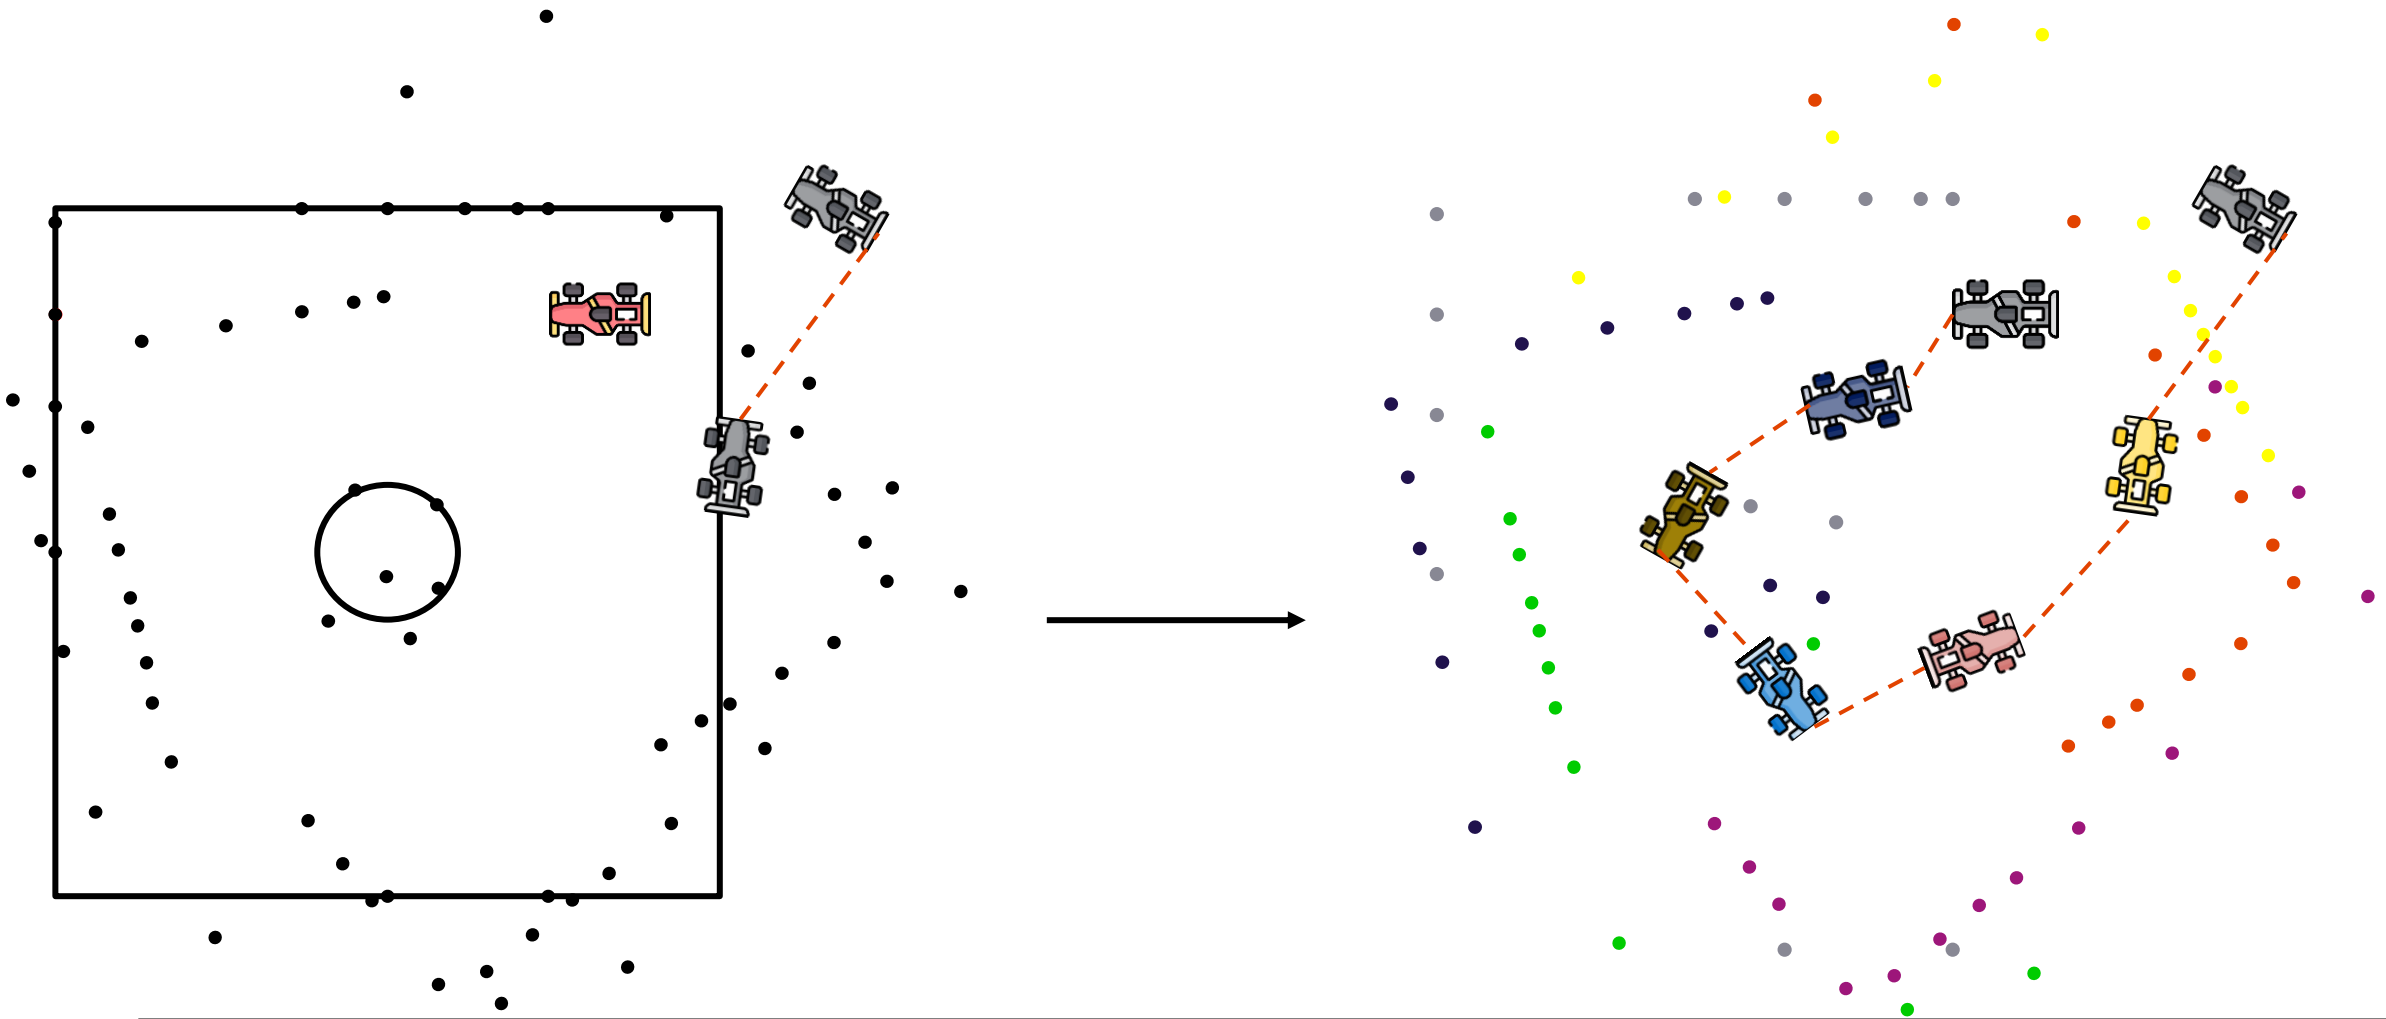
Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

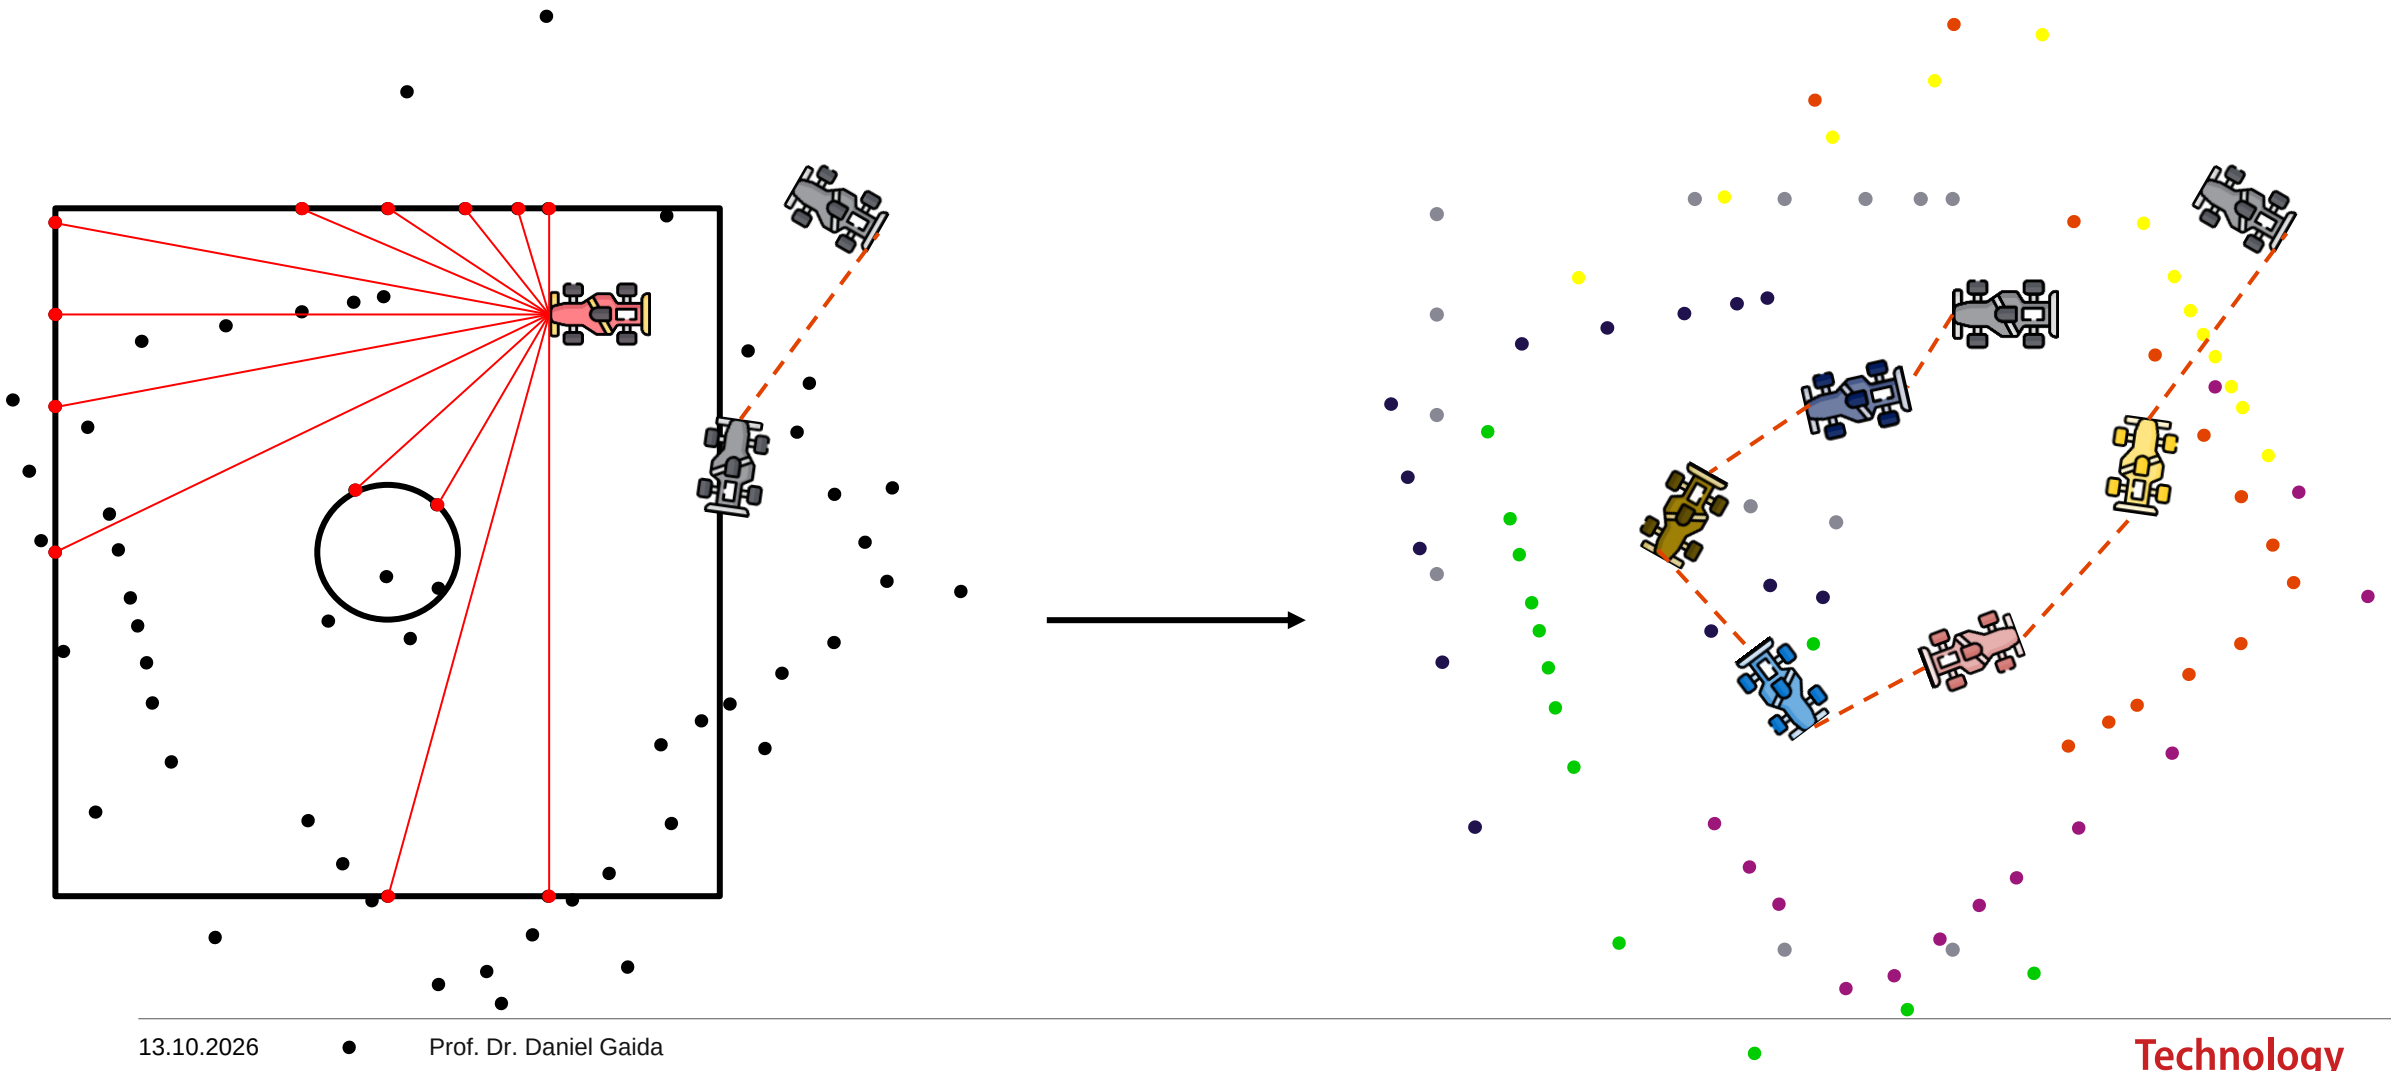
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Pose Graphs



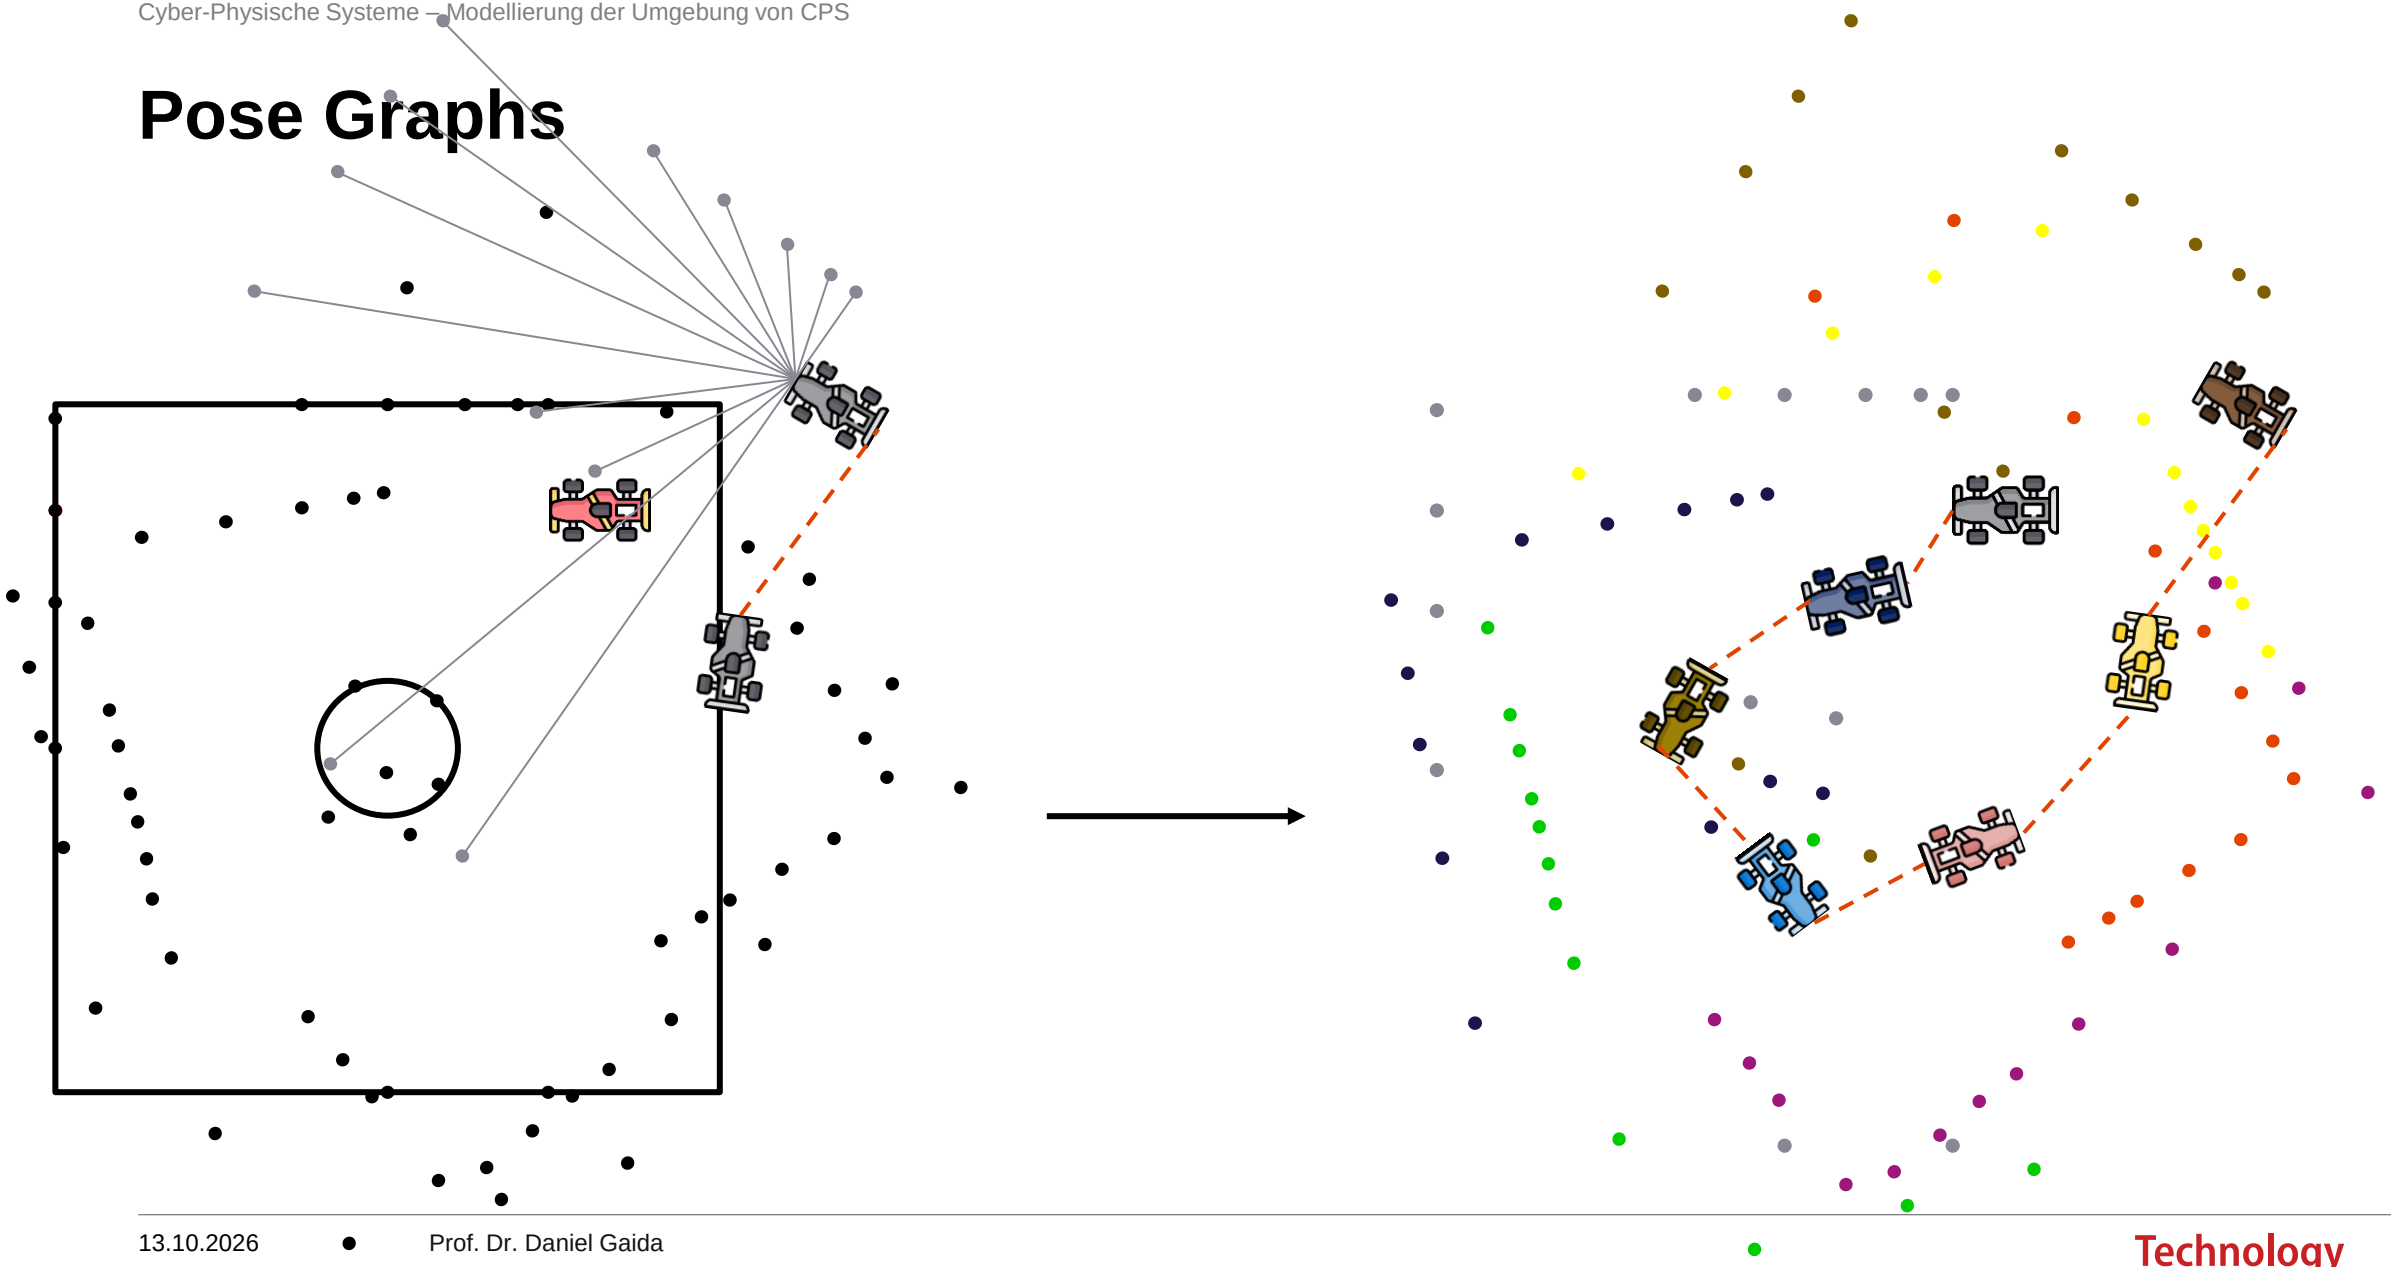
R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Pose Graphs



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Pose Graphs

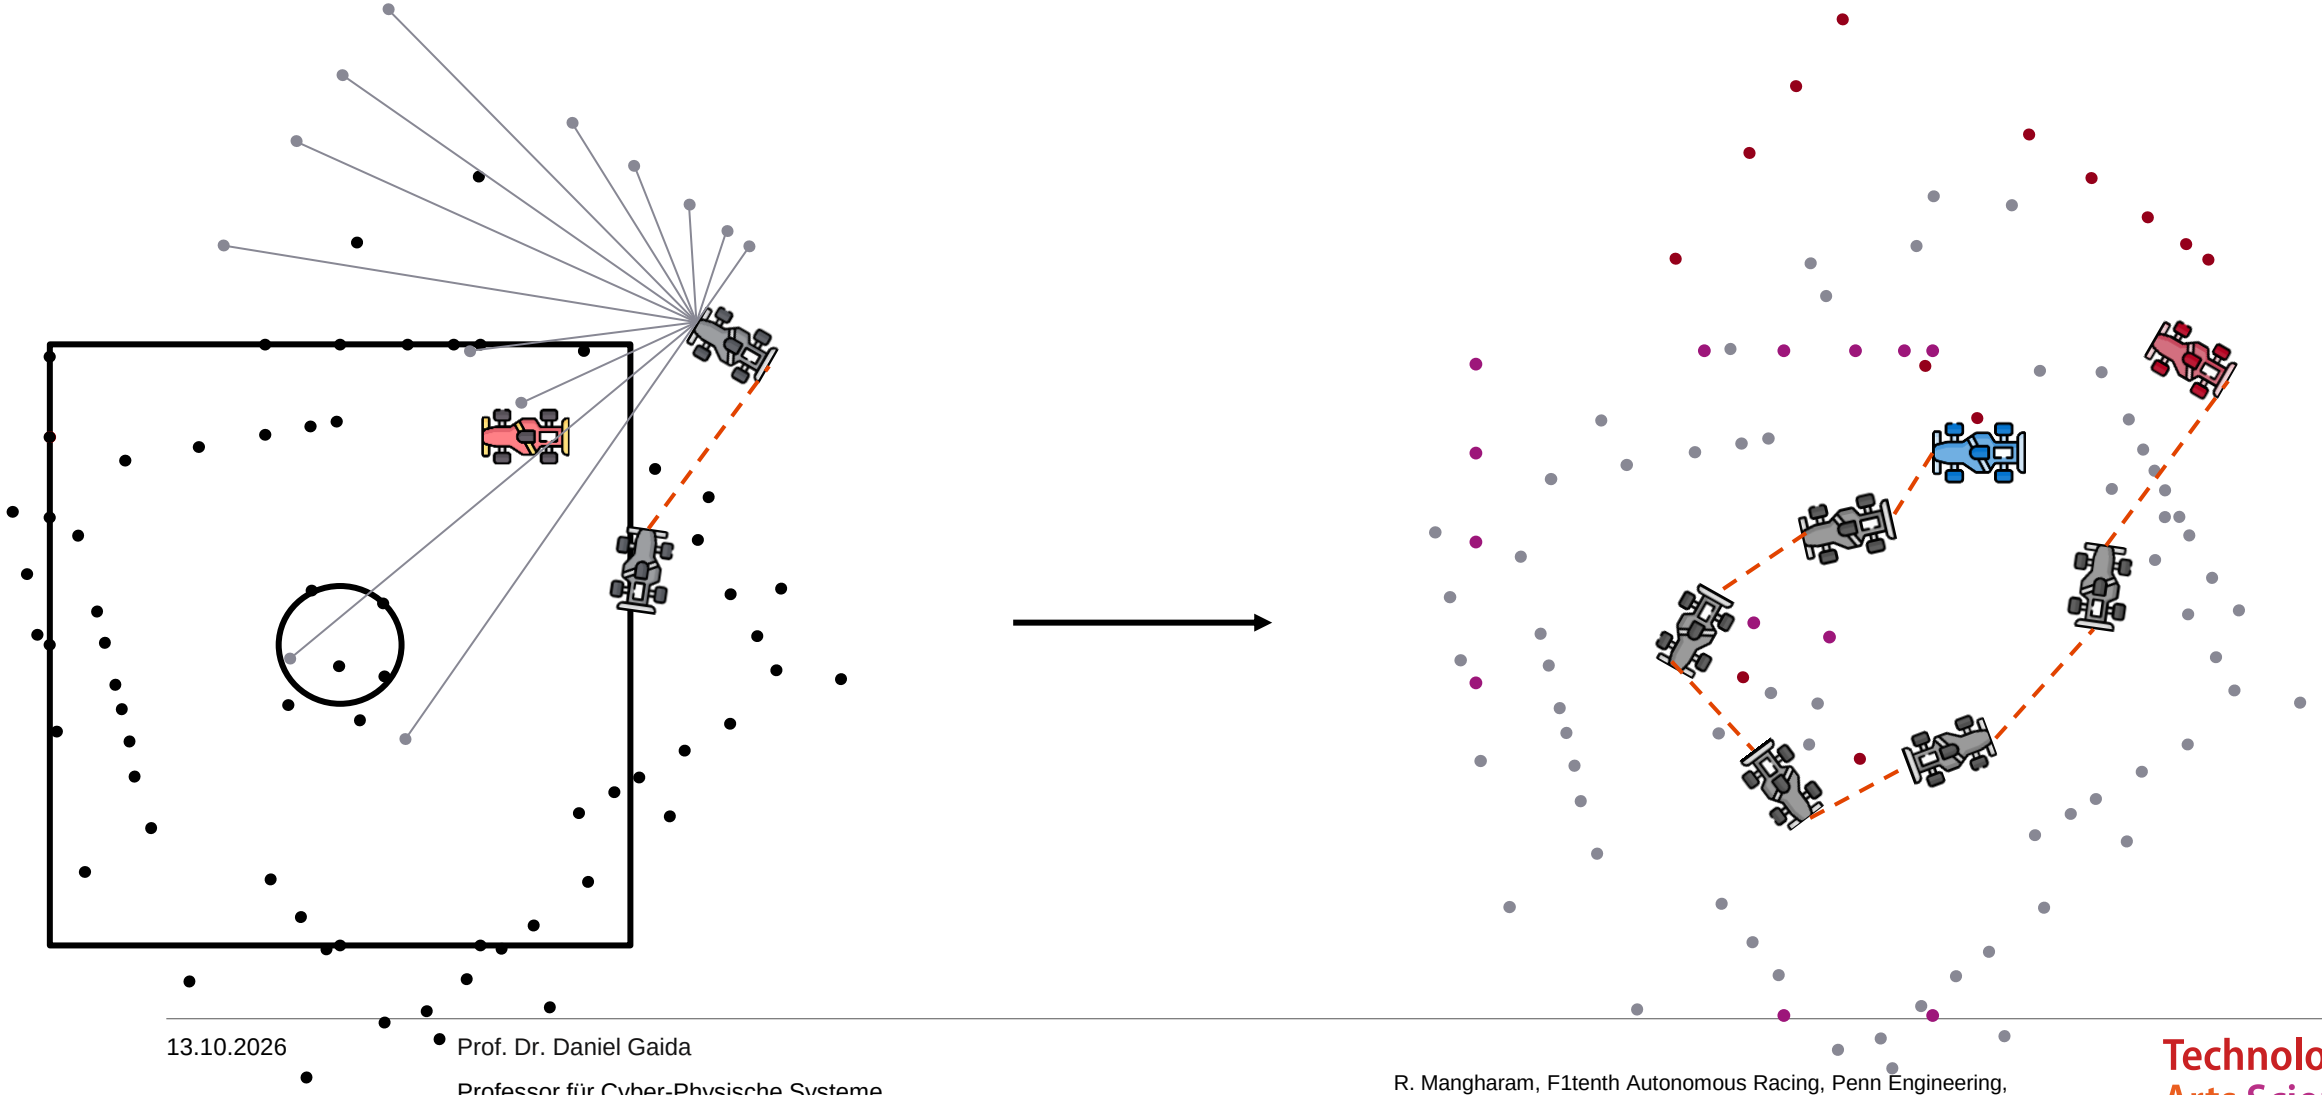


R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Technology
Arts Sciences
TH Köln

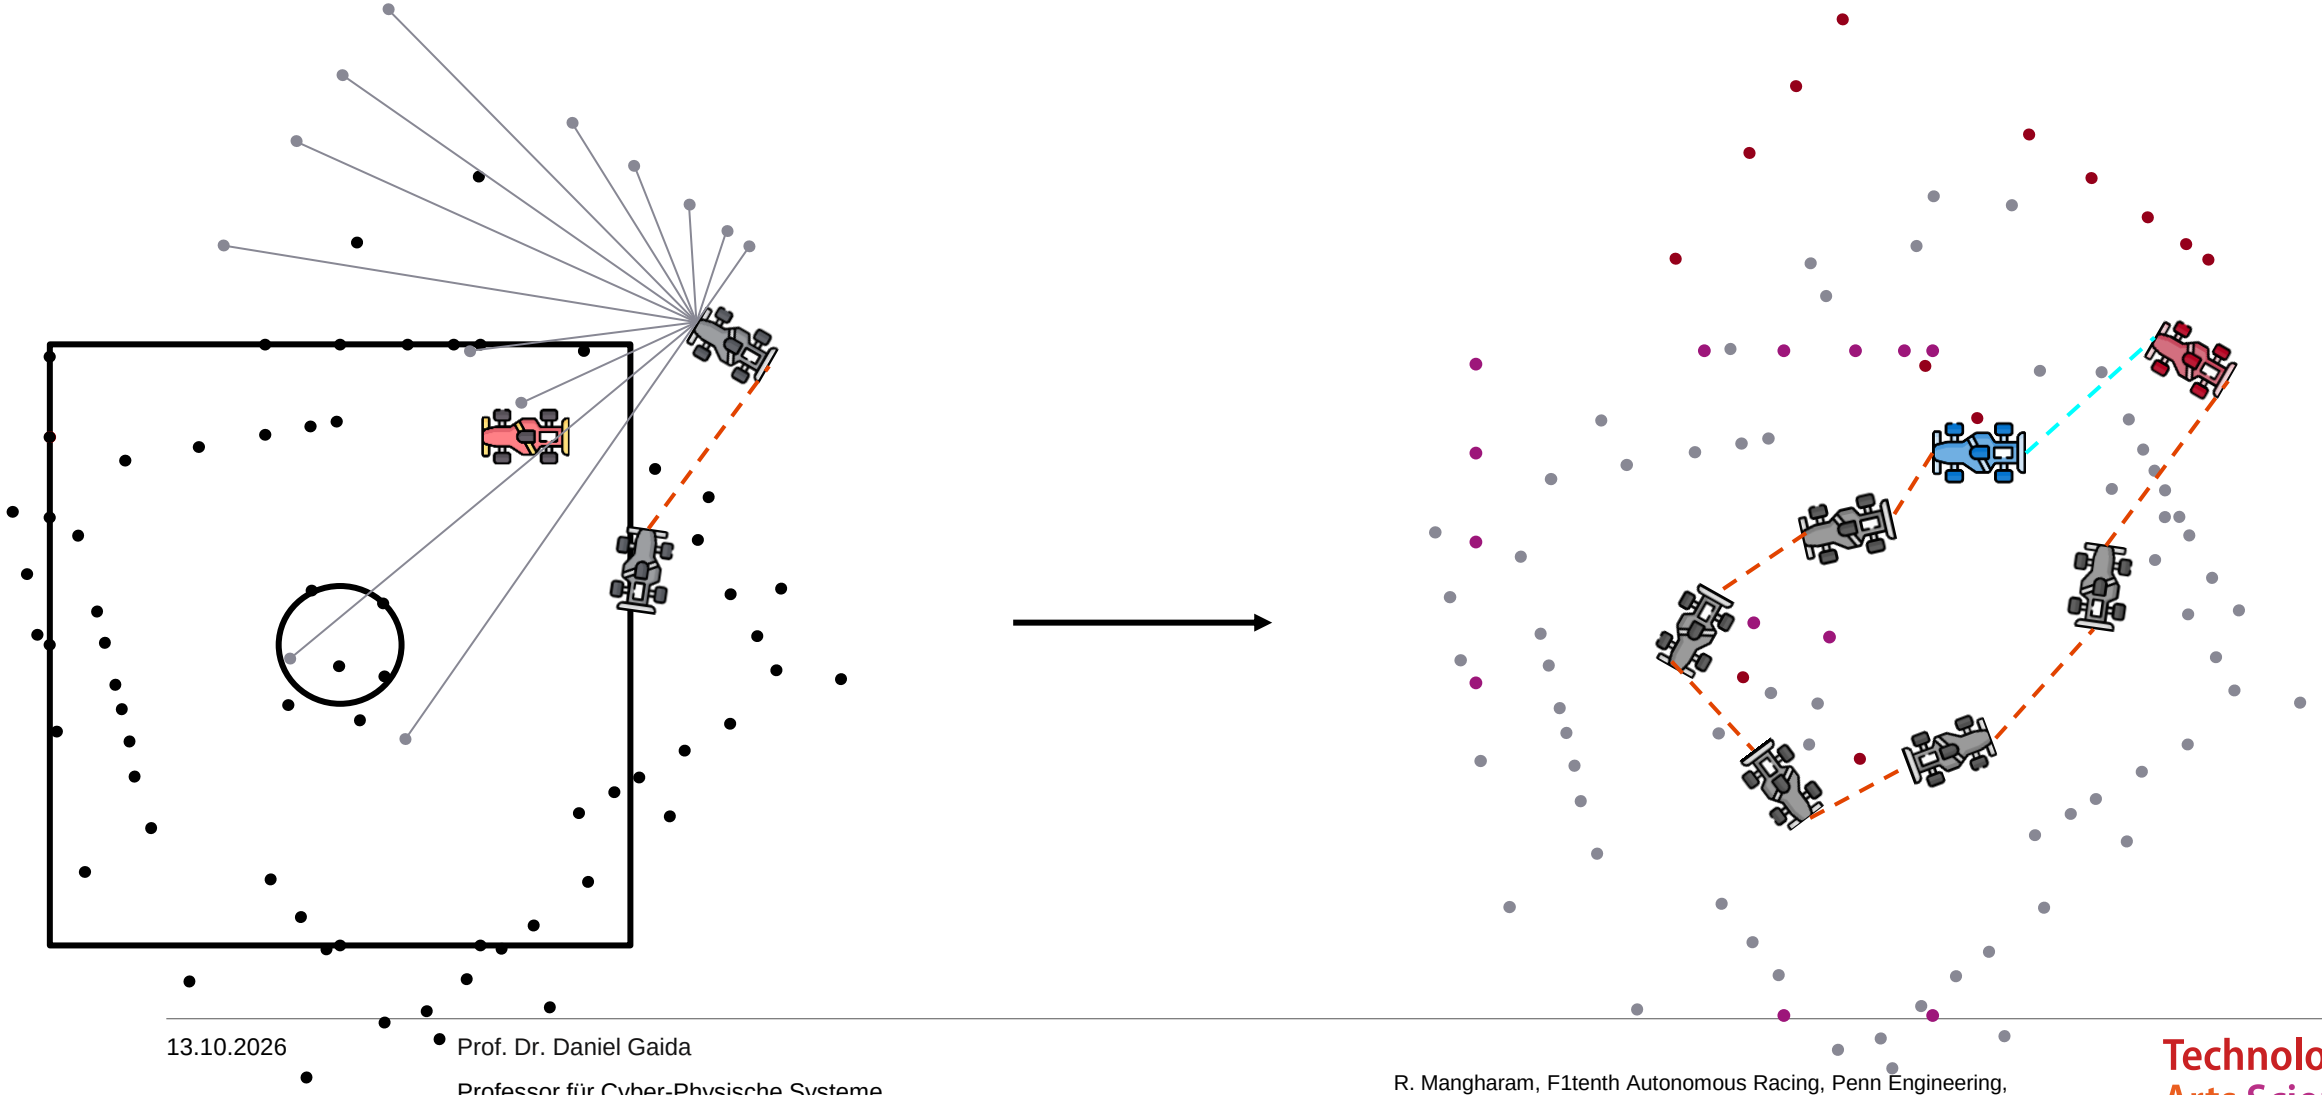
Pose Graph Optimization: Loop closure



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

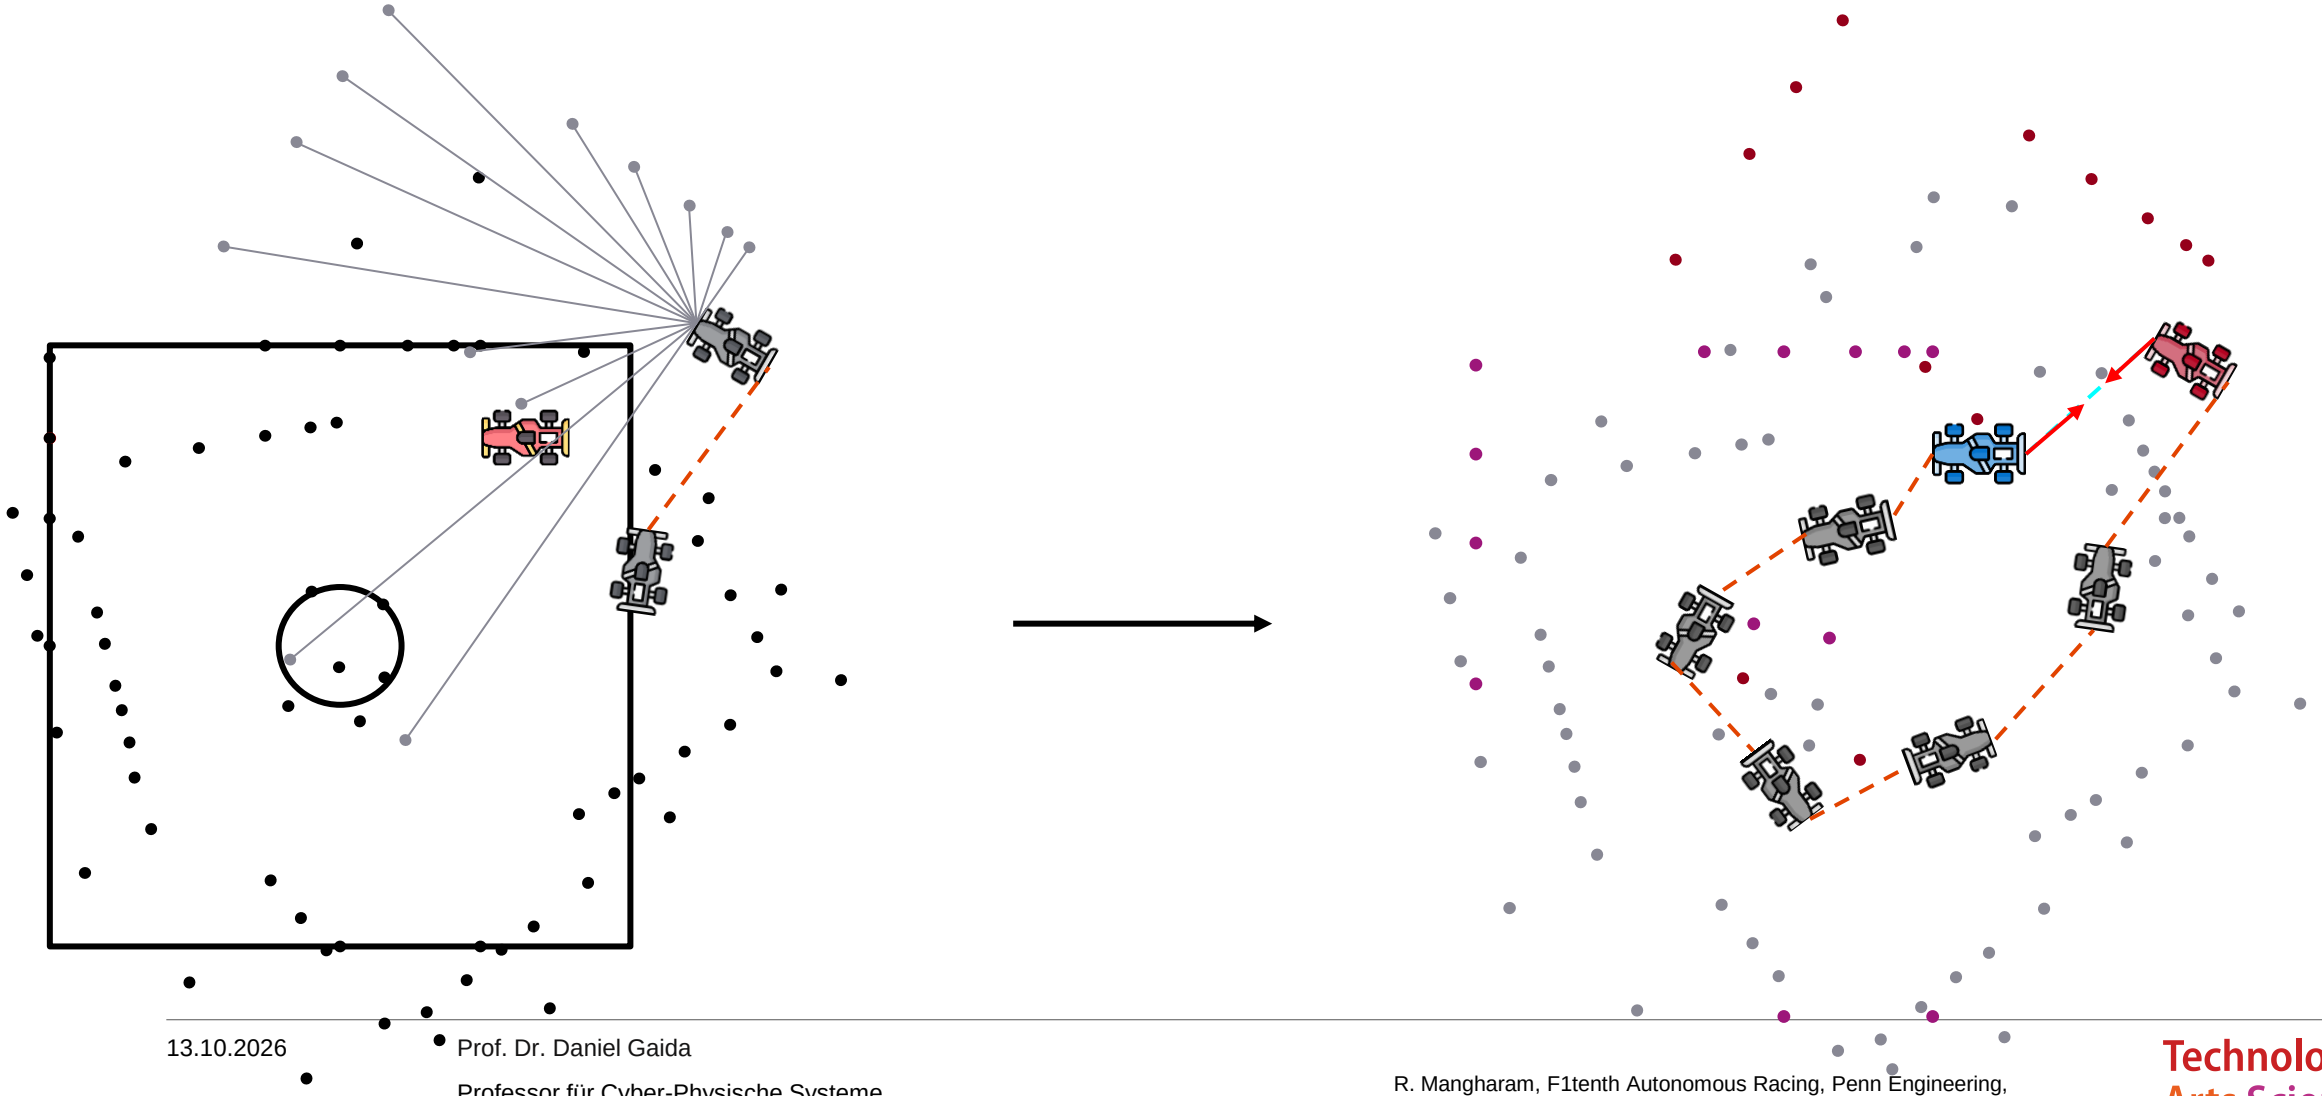
Pose Graph Optimization: Loop closure



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

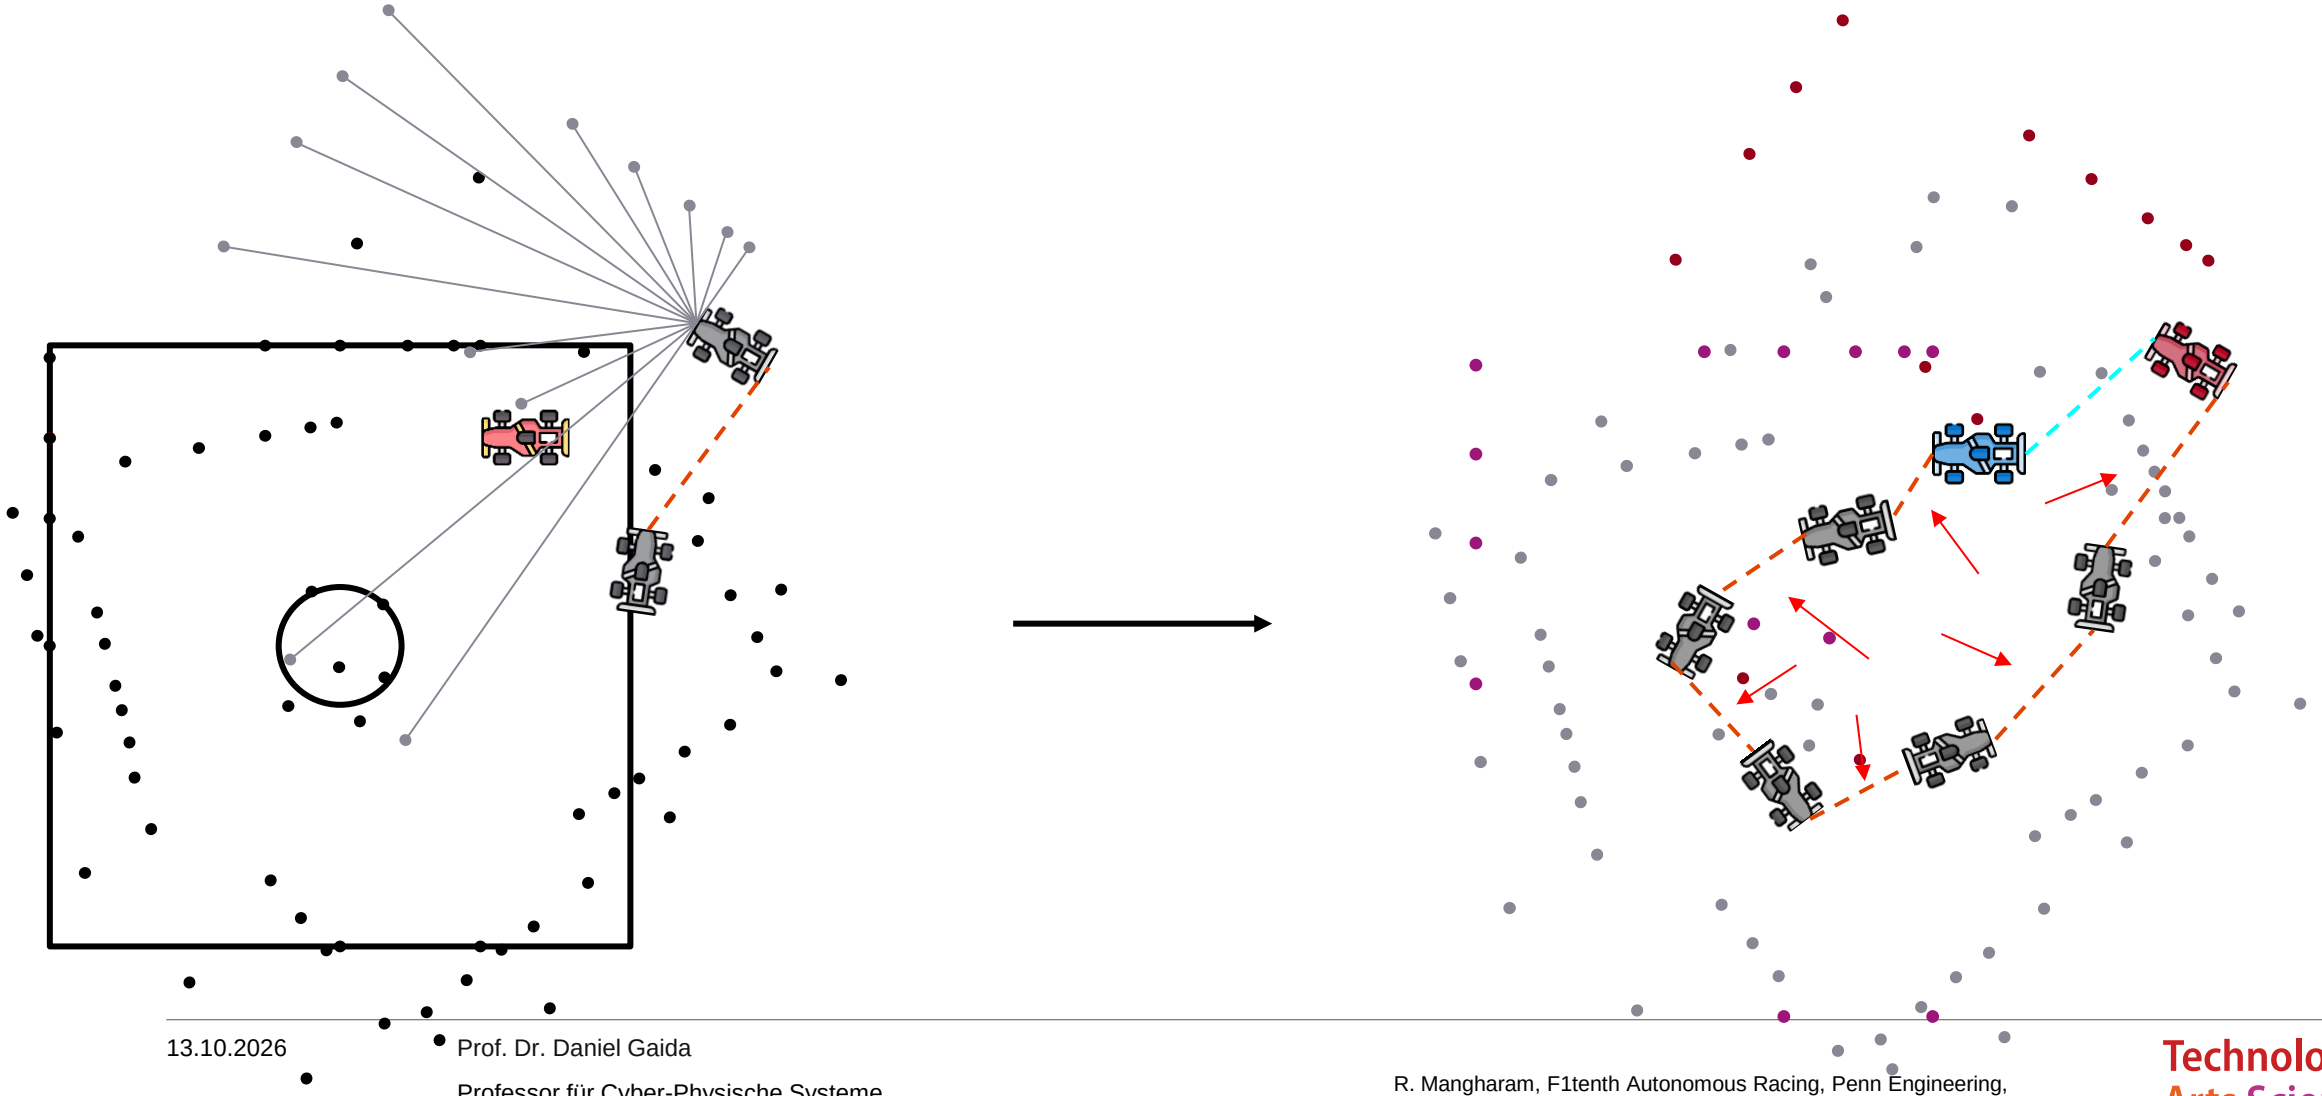
Pose Graph Optimization: Loop closure



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

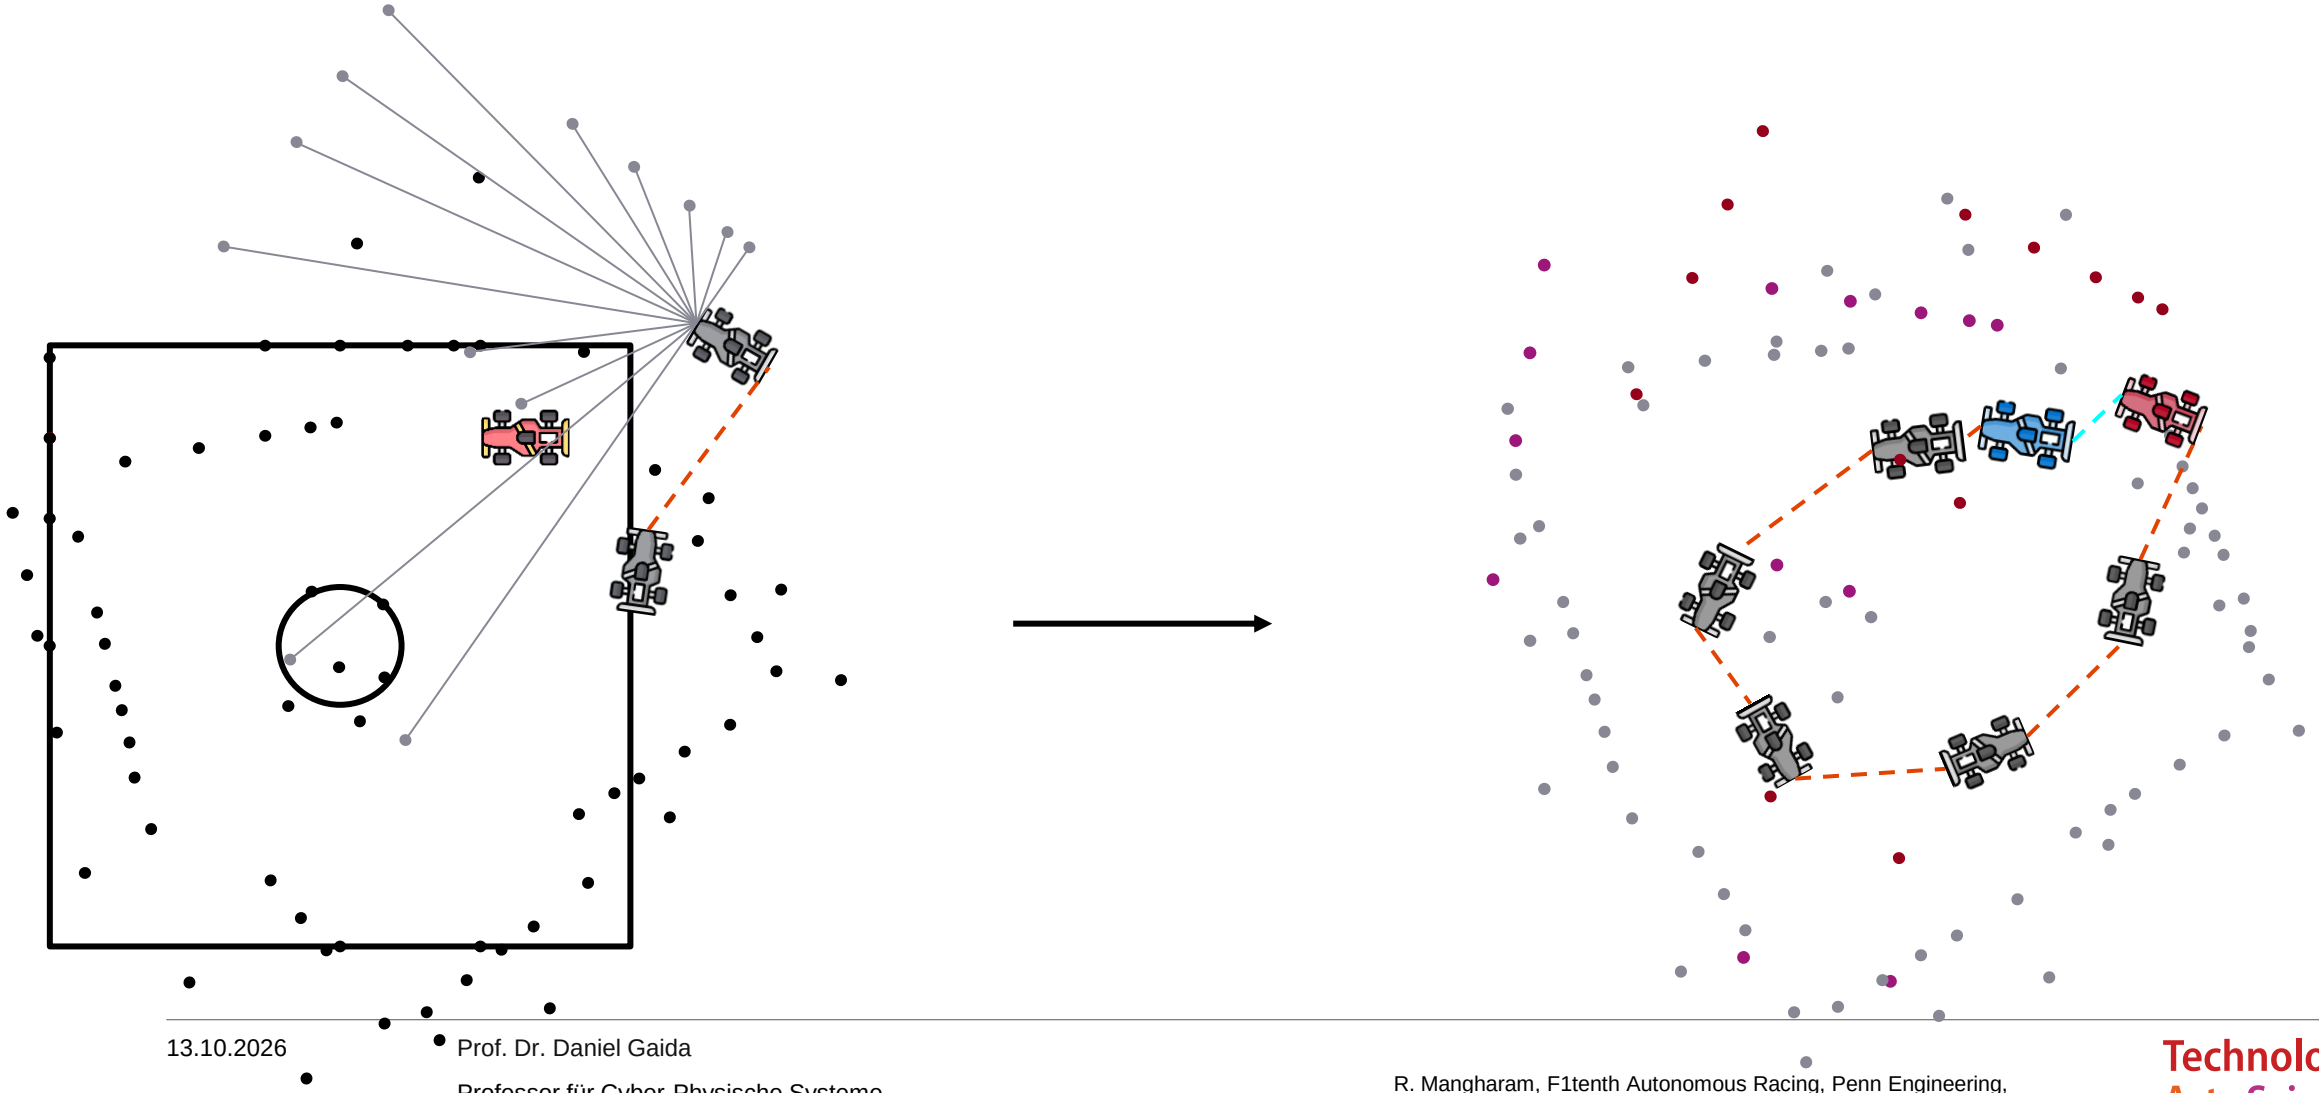
Pose Graph Optimization: Loop closure



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

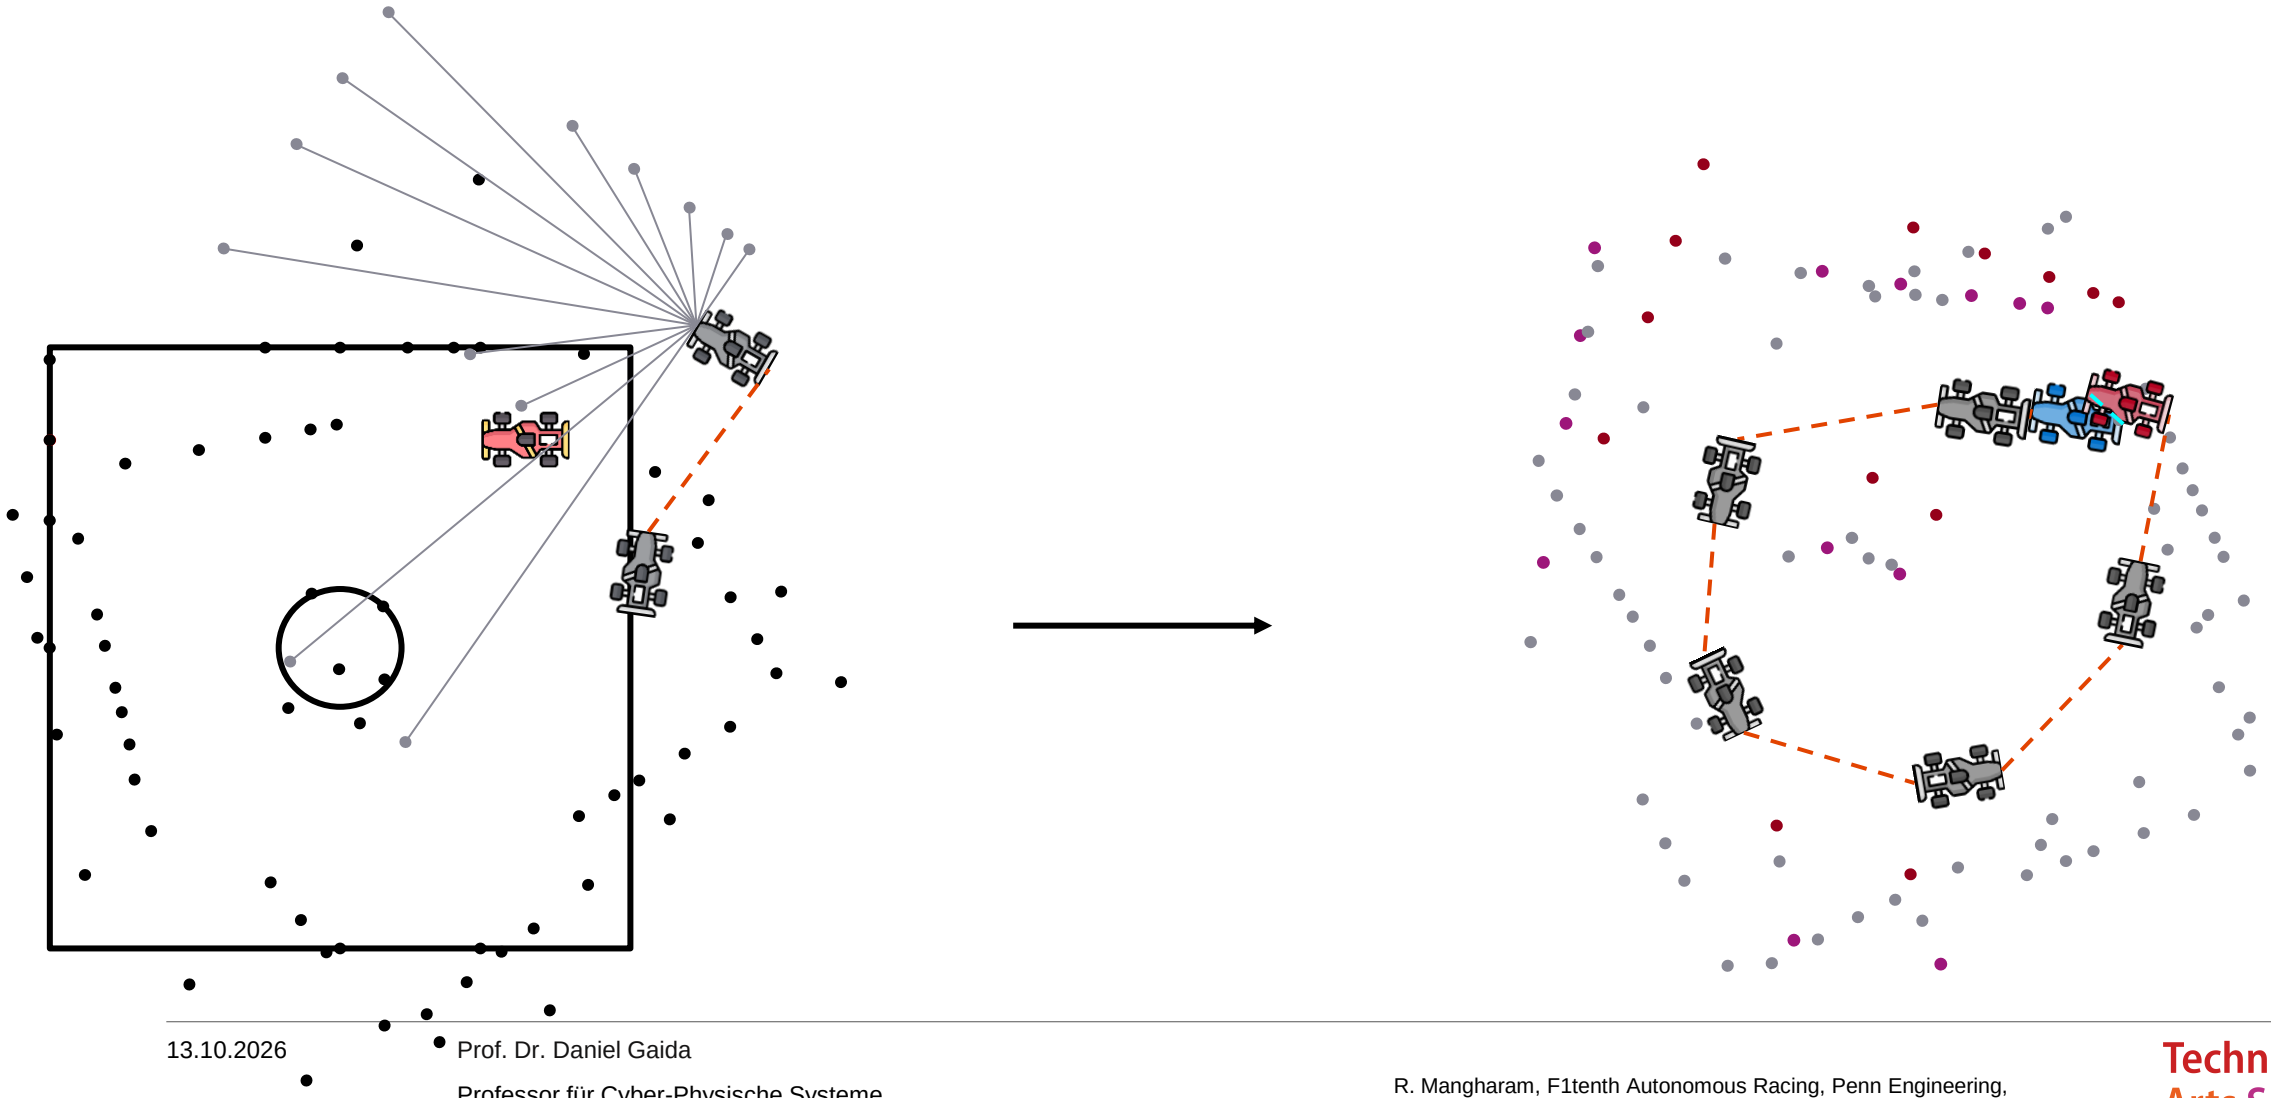
Pose Graph Optimization: Loop closure



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

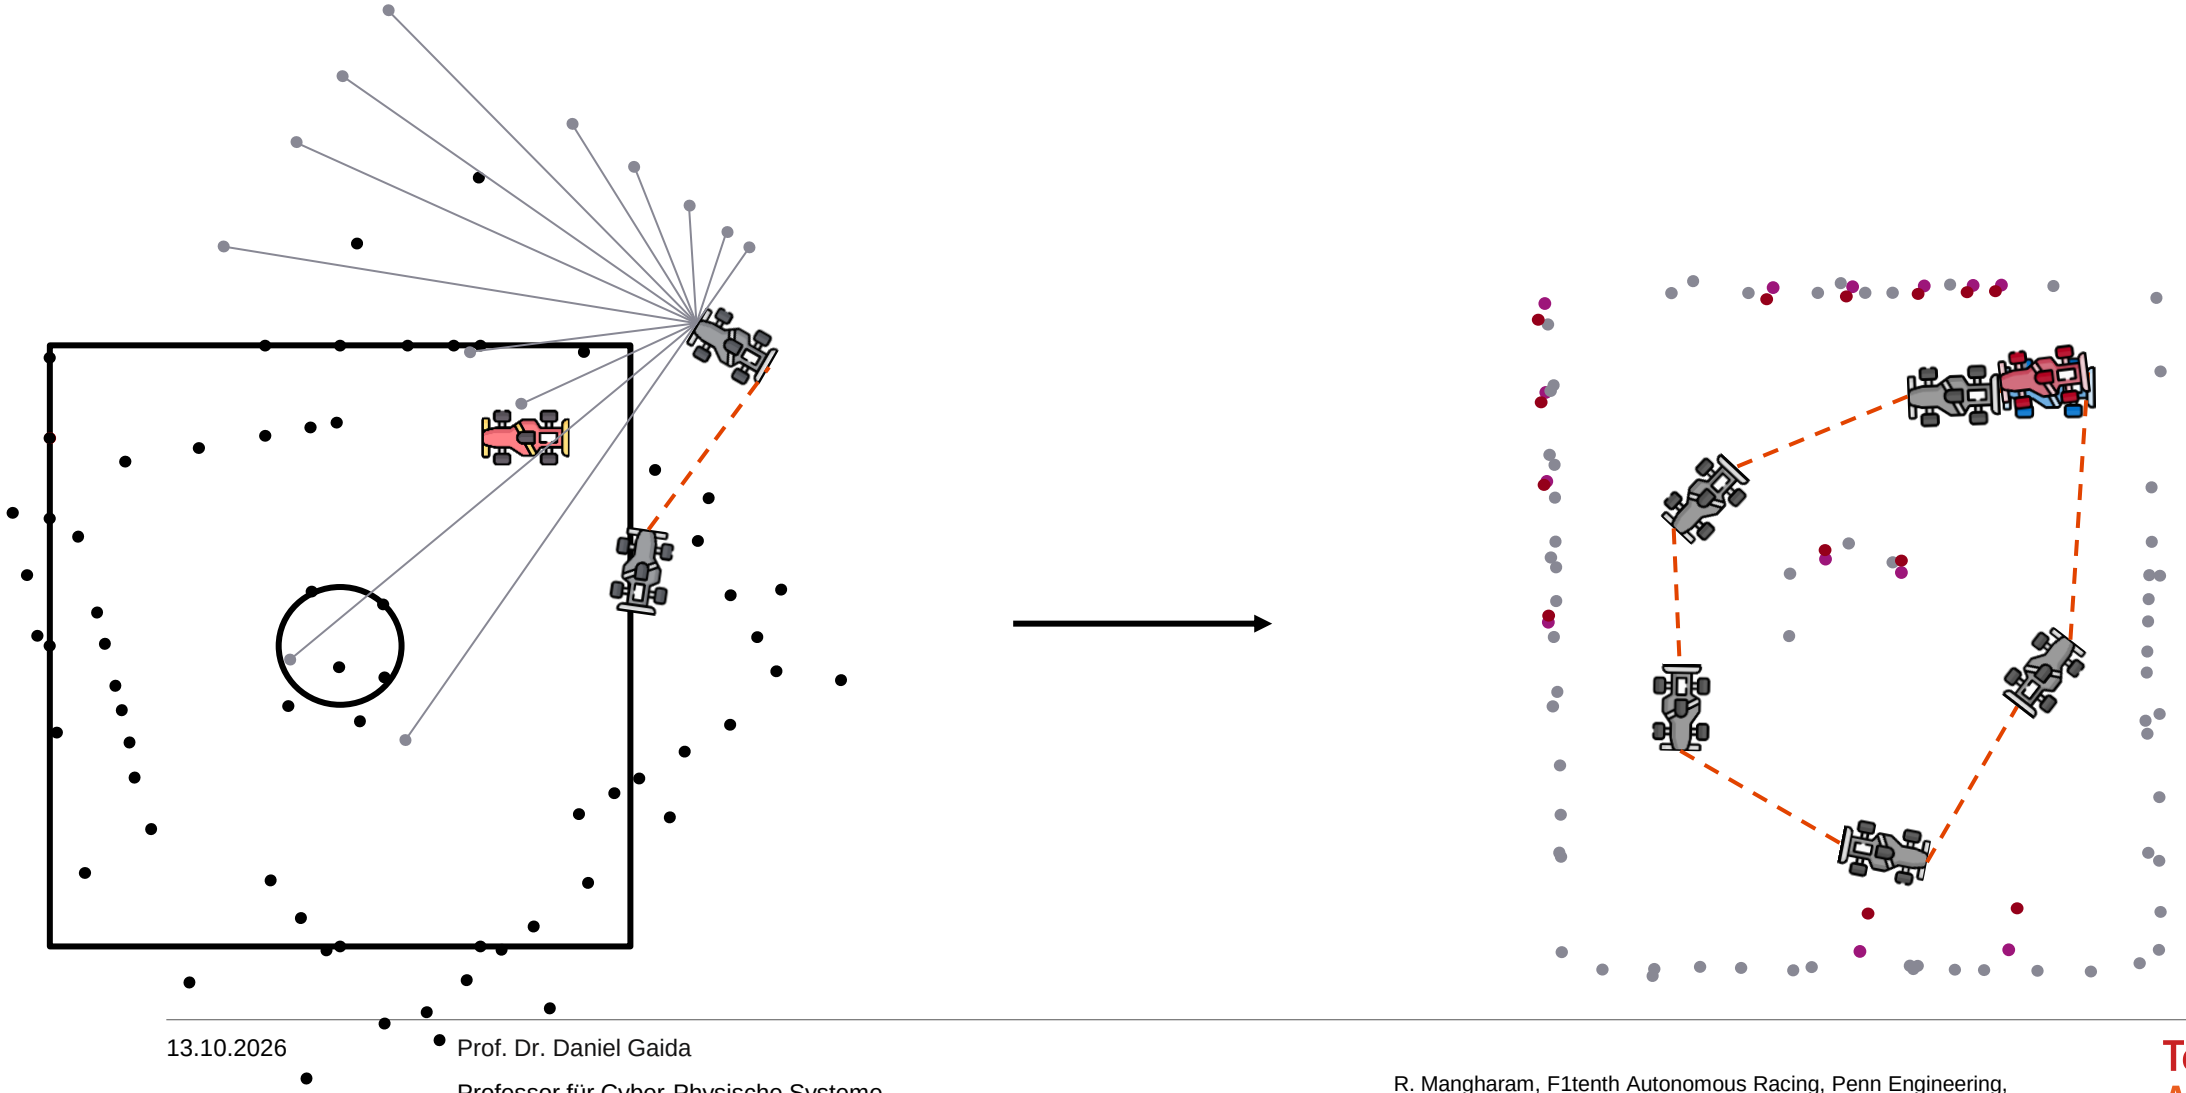
Pose Graph Optimization: Loop closure



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

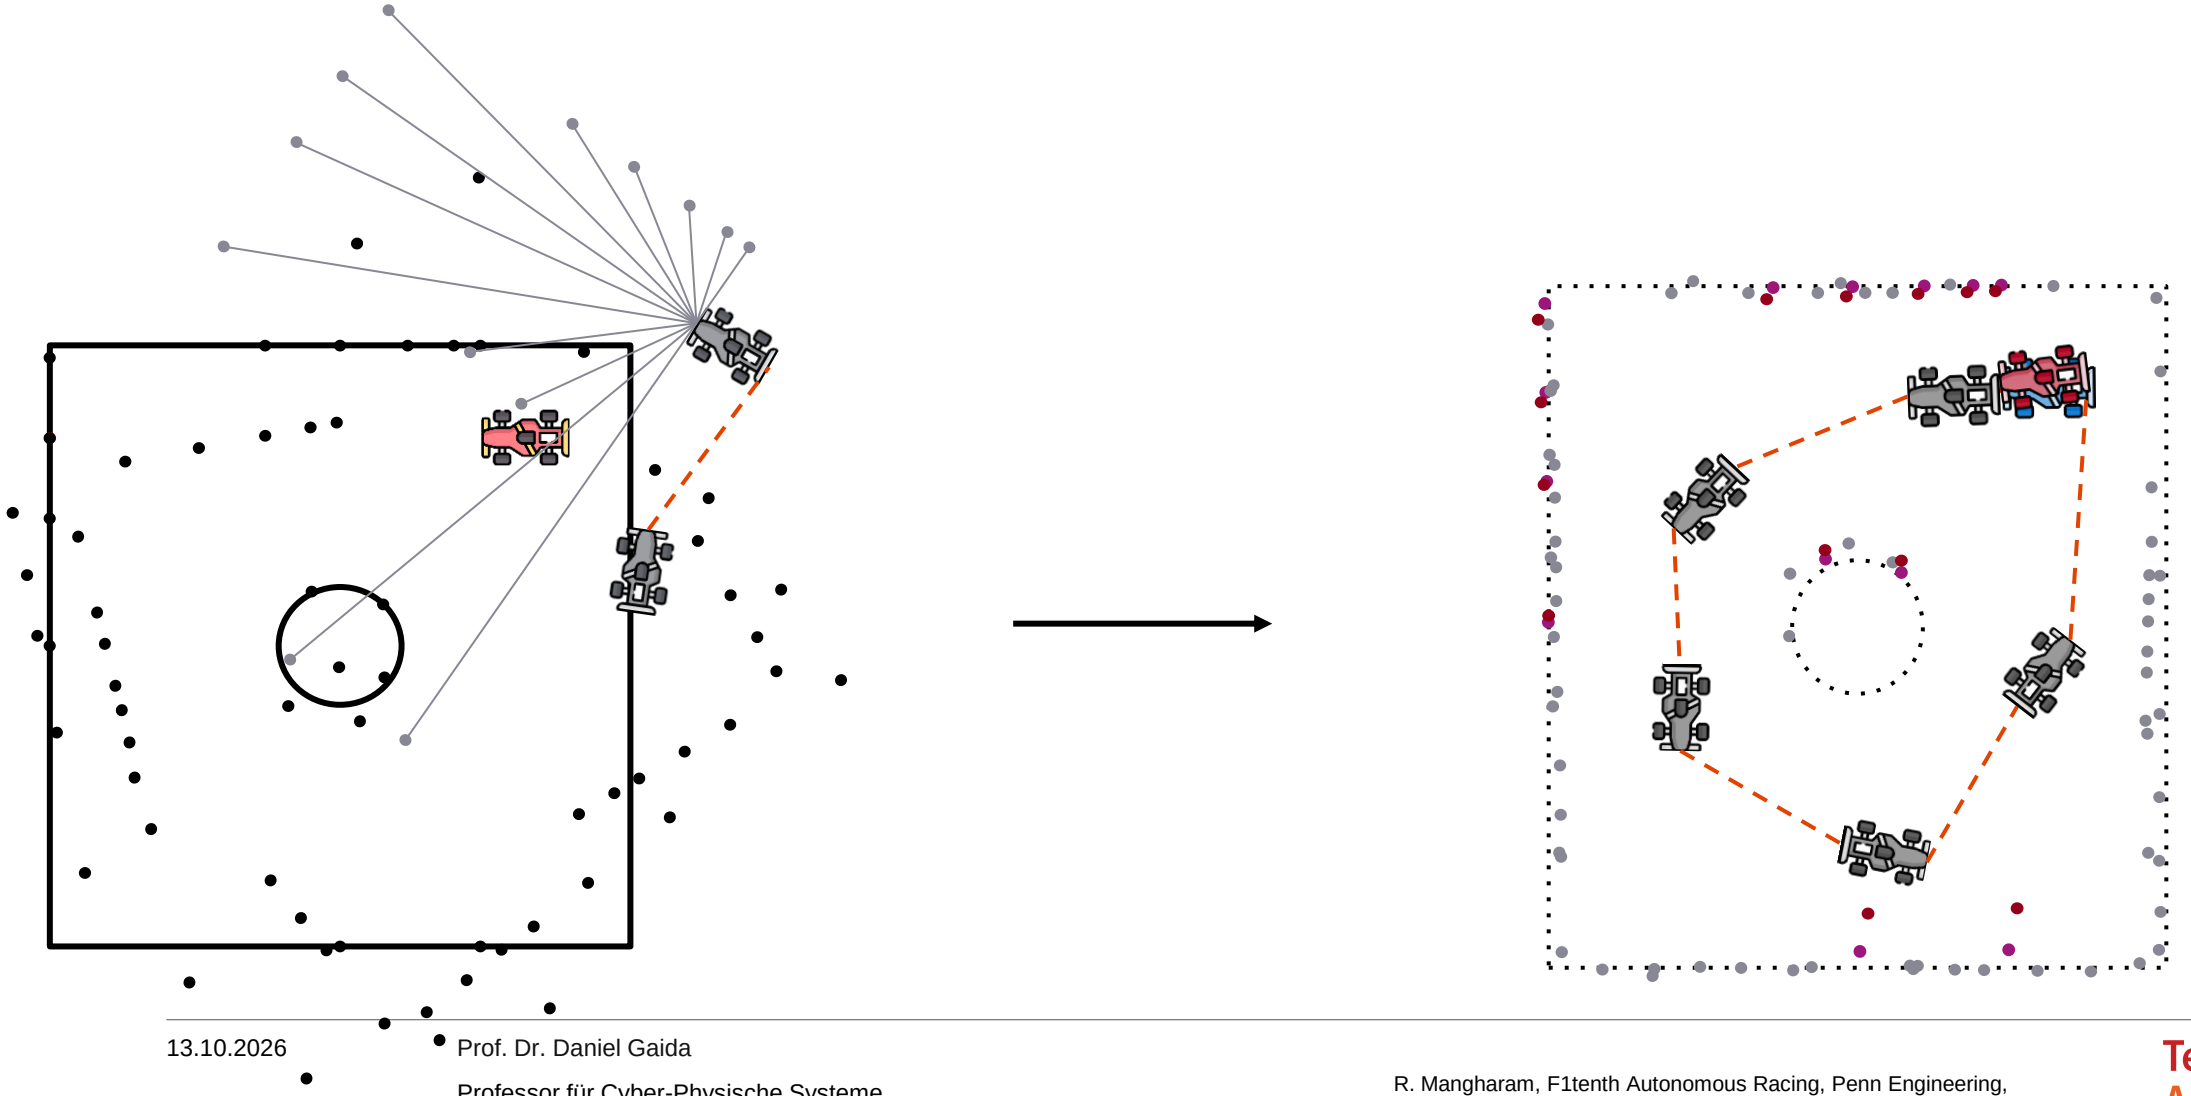
Pose Graph Optimization: Loop closure



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

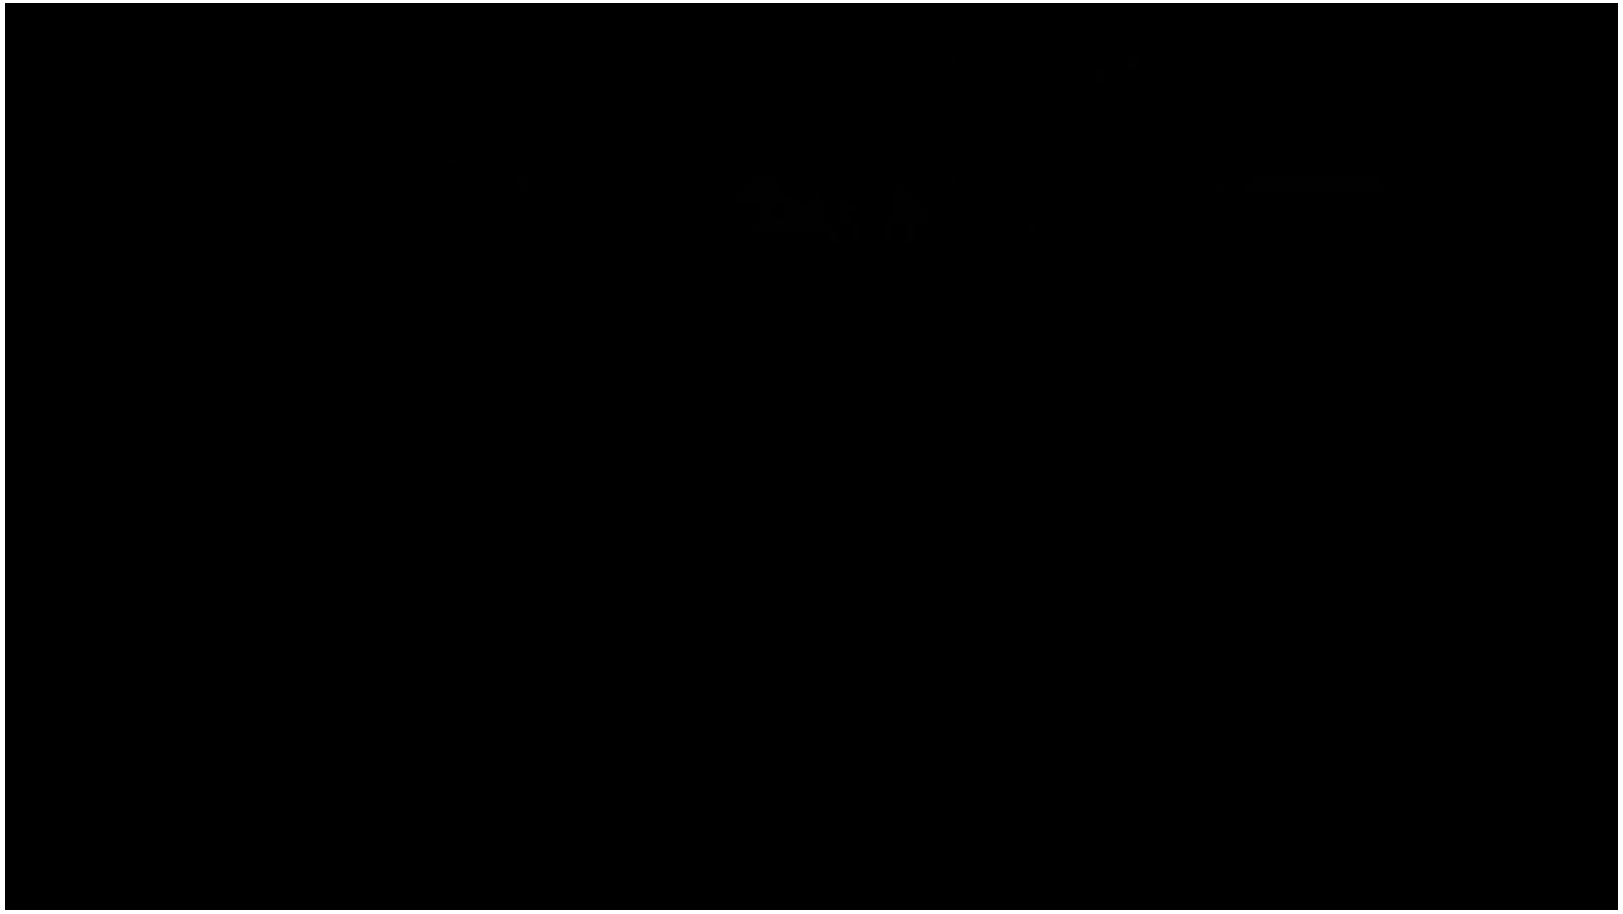
Pose Graph Optimization: Loop closure



R. Mangharam, F1tenth Autonomous Racing, Penn Engineering, University of Pennsylvania

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

SLAM - Simultaneous Localization and Mapping



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

S. Thrun, Artificial Intelligence for Robotics, Udacity Course, https://www.udacity.com/course/artificial-intelligence-for-robotics--cs373

SLAM - Zusammenfassung

Graph-basiertes SLAM ist sensorunabhängig. Es werden nur 2 Arten von Sensoren benötigt:

- Einen, der relative Transformationen zwischen Posen (Position + Orientierung) messen kann (IMS, Odometrie, Wheel-Encoder usw.). Dieser Sensor wird verwendet, um Beschränkungen zwischen den berechneten Posen zu erstellen.
- Ein Sensor, der die absolute Beobachtung der Umgebung messen kann. (LiDARs, Kameras, usw.). Dieser Sensor wird für das Schließen von Schleifen (Loop Closure) verwendet.

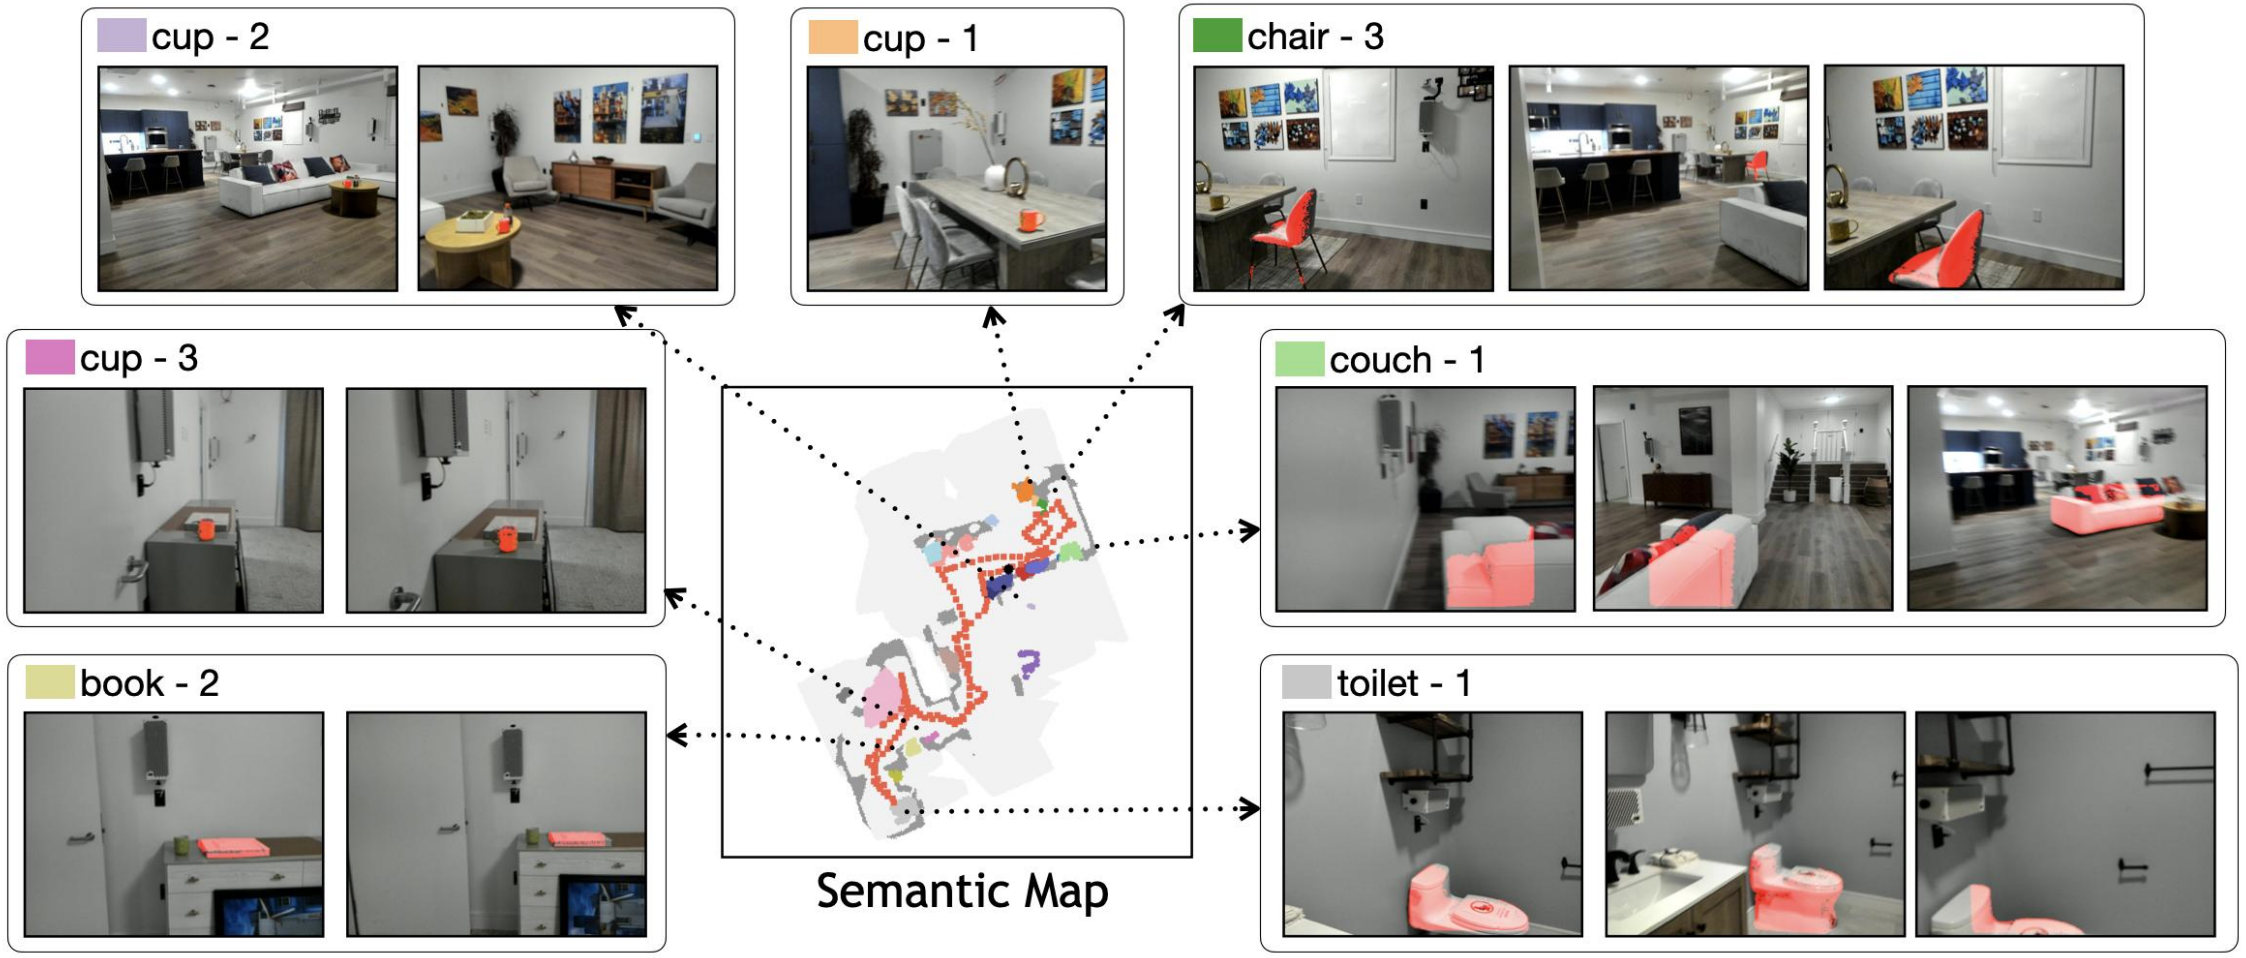
Inhalt

Modellierung der Umgebung von CPS:

- Modellierung mit KI/Deep Learning
  - Objektdetektion, -tracking, Bildsegmentierung, Greifpunkte
  - Warum ist die Modellierung der Umgebung mit nur einer Kamera schwierig?
  - Spracherkennung
  - Verhaltensmodellierung von Fußgängern, Fahrzeugen
  - World Models
- Lernen in virtuellen Umgebungen (in einer Simulation)
  - 3D Simulation
  - Von der Simulation in die Realität (Sim2real)
- **Statische Modelle der Umgebung (Karte)**
  - SLAM – Simultaneous Localization and Mapping
  - **Semantische Karte (Karte mit Objekten/Orten: Couch, TV, Küche, …)**

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Semantische Karte (Semantic Mapping)



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
https://theophilegervet.github.io/projects/goat/

Semantische Karte (Semantic Mapping)

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

Nächste Vorlesung und Fragen

- Robot Operating System
- Fragen?

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik