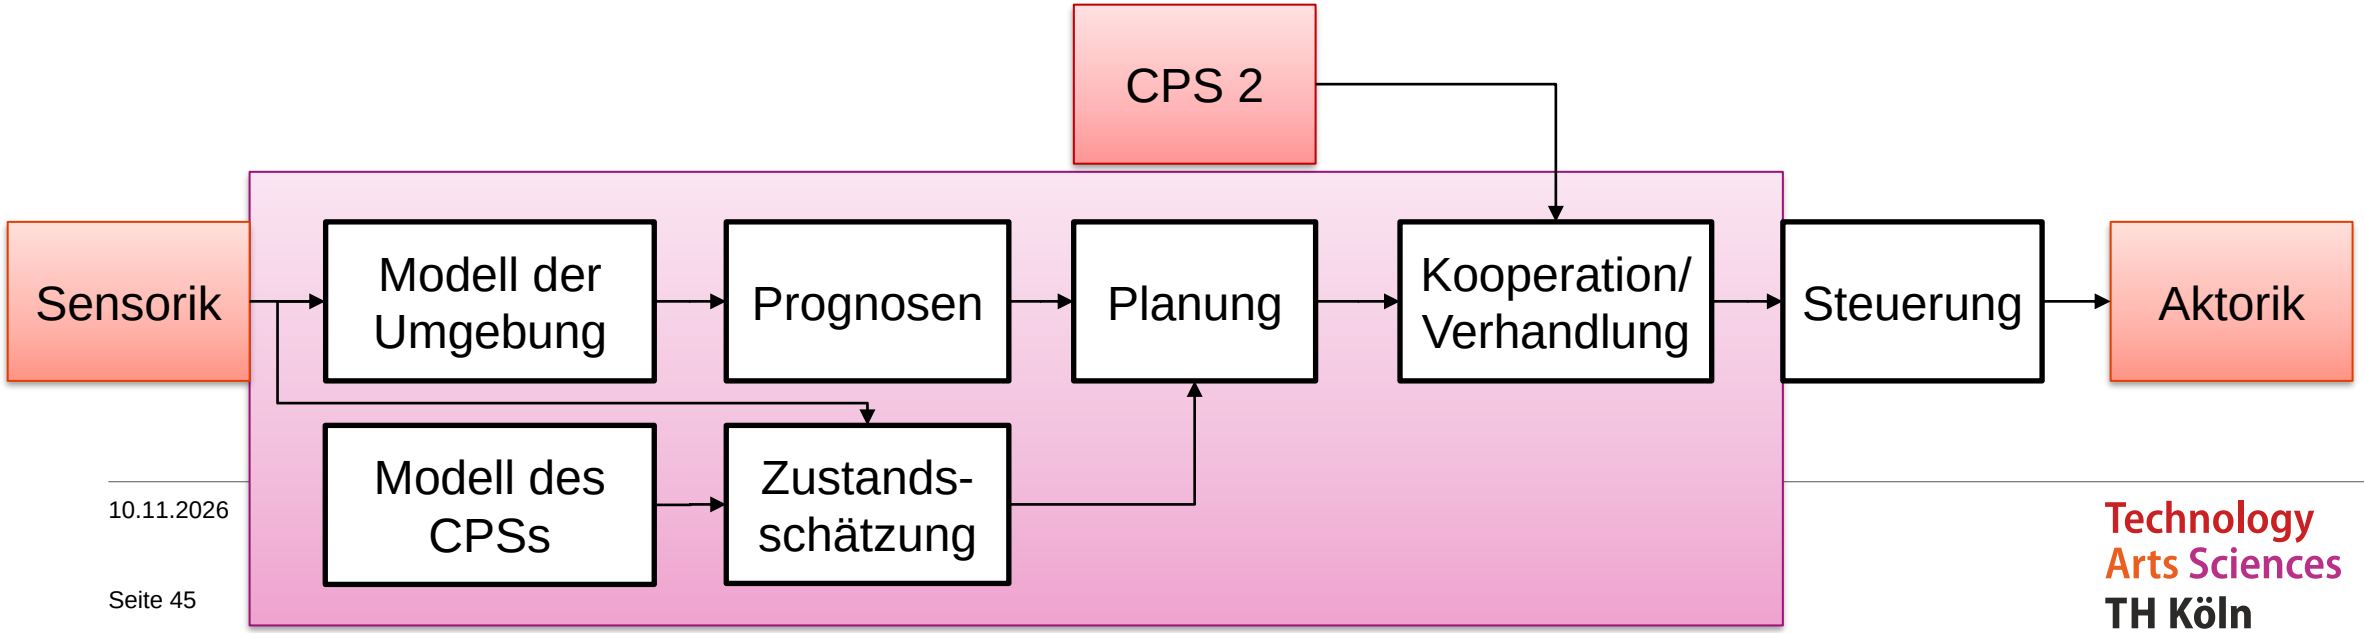


Cyber-Physische Systeme – WS 26/27

Gelesen von Prof. Dr. Daniel Gaida

Inhalt

- Zustandsschätzung
  - Benötigt:
    - Sensordaten
    - Zustandsdiagramm des CPSs (als Mathematisches Modell)



Inhalt & Lernziele

- Ermittlung des Zustands eines Cyber-Physischen Systems
- Mathematische Modellierung von CPS im Zustandsraum
  - Beispiel eines sich 1-dimensional bewegenden Fahrrads
-
  -
-
-

Inhalt & Lernziele

- Ermittlung des Zustands eines Cyber-Physischen Systems

- Mathematische Modellierung von CPS im Zustandsraum
  - Beispiel eines sich 1-dimensional bewegenden Fahrrads
- Besprechung eines Algorithmus zur Zustandsschätzung von CPS
  - Das lineare Kalman-Filter
- Anwendung des linearen Kalman-Filters am Beispiel der Lokalisierung des Fahrrads
- Weitere Anwendungsmöglichkeiten des Kalman-Filters

Modell des CPSs

- Modell als Blockdiagramm:
  - Modelliert aus welchen Komponenten ein CPS besteht und wie diese zusammenarbeiten
  - Fahrrad: Pedale, Kette, Gangschaltung, Lenkrad, …
-
  -
  -
-
  -
  -

Modell des CPSs

- Modell als Blockdiagramm:
  - Modelliert aus welchen Komponenten ein CPS besteht und wie diese zusammenarbeiten
  - Fahrrad: Pedale, Kette, Gangschaltung, Lenkrad, …
- Modell als Zustandsdiagramm - Zustandsraum ist diskret (Finite State Machine):
  - Modelliert wie sich der Zustand des CPSs verändern kann
  - Fahrrad: Fahrrad fährt schnell oder steht still, Fahrrad ist in der Garage oder auf dem Trail

Modell des CPSs

- Modell als Blockdiagramm:
  - Modelliert aus welchen Komponenten ein CPS besteht und wie diese zusammenarbeiten
  - Fahrrad: Pedale, Kette, Gangschaltung, Lenkrad, …
- Modell als Zustandsdiagramm - Zustandsraum ist diskret (Finite State Machine):
  - Modelliert wie sich der Zustand des CPSs verändern kann
  - Fahrrad: Fahrrad fährt schnell oder steht still, Fahrrad ist in der Garage oder auf dem Trail

- Heute interessieren wir uns für kontinuierliche Zustandsräume:
  - Wie verändern sich Position und Geschwindigkeit des Fahrrads?
  - Dynamisches Modell wird durch mathematische Gleichungen beschrieben

Das autonom fahrende Fahrzeug

- Was ist der Zustand eines Cyber-Physischen Systems?
  - Zusammenstellung aller Informationen, die für die Zielerreichung des CPSs relevant sind

Das autonom fahrende Fahrzeug

- Was ist der Zustand eines Cyber-Physischen Systems?
  - Zusammenstellung aller Informationen, die für die Zielerreichung des CPSs relevant sind

- Ziel: Lokalisierung des Fahrzeugs in 1D-Umgebung
  - Zustand: Position, (Geschwindigkeit und Beschleunigung) des Fahrzeugs
    → Ausreichend für Lokalisierung in 1D
-
  -
-
  -
  -
  -

Das autonom fahrende Fahrzeug

- Was ist der Zustand eines Cyber-Physischen Systems?
  - Zusammenstellung aller Informationen, die für die Zielerreichung des CPSs relevant sind

- Ziel: Lokalisierung des Fahrzeugs in 1D-Umgebung
  - Zustand: Position, (Geschwindigkeit und Beschleunigung) des Fahrzeugs
    → Ausreichend für Lokalisierung in 1D
- Ziel: Lokalisierung des Fahrzeugs in 2D-Umgebung
  - Zusätzlich: Fahrtrichtung/Orientierung des Fahrzeugs

-
  -
  -
  -

Das autonom fahrende Fahrzeug

- Was ist der Zustand eines Cyber-Physischen Systems?
  - Zusammenstellung aller Informationen, die für die Zielerreichung des CPSs relevant sind

- Ziel: Lokalisierung des Fahrzeugs in 1D-Umgebung
  - Zustand: Position, (Geschwindigkeit und Beschleunigung) des Fahrzeugs
    → Ausreichend für Lokalisierung in 1D
- Ziel: Lokalisierung des Fahrzeugs in 2D-Umgebung
  - Zusätzlich: Fahrtrichtung/Orientierung des Fahrzeugs

- Ziel: Autonom fahrendes Fahrzeug
  - Zusätzlich: Anzahl Fahrzeuginsassen, Tankfüllung (Batterieladezustand), …
  - Farbe des Fahrzeugs, Fahrtziel, Alter, Tachostand, …
  - Position und Bewegungsrichtung anderer Verkehrsteilnehmer

Das autonom fahrende Fahrzeug

Erhebung von Sensordaten zur Ermittlung des Zustands

- Sensoren
  -

Das autonom fahrende Fahrzeug

Erhebung von Sensordaten zur Ermittlung des Zustands



- Sensoren
  - Inertialmesssystem, LiDAR, Kamera, Radar, Mikrofon, GPS, Touchscreen, Tachometer

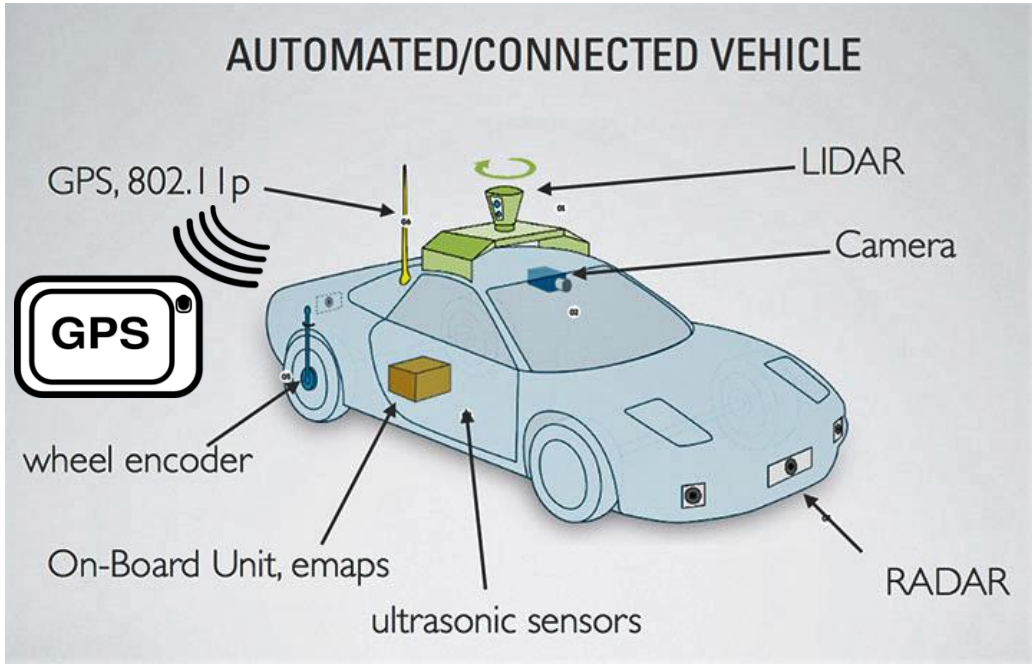


Bild: https://www.embedded.com/the-role-of-artificial-intelligence-in-autonomous-vehicles/





Das autonom fahrende Fahrzeug

- Wie genau können wir den Zustand des Fahrzeugs messen?
  - Annahme: Zustand besteht aus Position, Geschwindigkeit, und Beschleunigung des Fahrzeugs
-
-
-
-







Das autonom fahrende Fahrzeug

- Wie genau können wir den Zustand des Fahrzeugs messen?
  - Annahme: Zustand besteht aus Position, Geschwindigkeit, und Beschleunigung des Fahrzeugs

- GPS misst Position, Tachometer Geschwindigkeit, Beschleunigungssensor die Beschleunigung
- Alle Sensoren haben Messfehler
-
-







Das autonom fahrende Fahrzeug

- Wie genau können wir den Zustand des Fahrzeugs messen?
  - Annahme: Zustand besteht aus Position, Geschwindigkeit, und Beschleunigung des Fahrzeugs

- GPS misst Position, Tachometer Geschwindigkeit, Beschleunigungssensor die Beschleunigung
- Alle Sensoren haben Messfehler
- Aus Beschleunigung können wir Geschwindigkeit berechnen
- Wem vertrauen wir mehr: Der gemessenen oder der berechneten Geschwindigkeit?







Das autonom fahrende Fahrzeug

- Wie genau können wir den Zustand des Fahrzeugs messen?
  - Annahme: Zustand besteht aus Position, Geschwindigkeit, und Beschleunigung des Fahrzeugs

- Wie fusioniert man alle Messwerte, um den Zustand des Fahrzeugs möglichst genau zu erhalten?
- Das Kalman-Filter fusioniert alle Messgrößen und berechneten Größen, um den Zustand des Fahrzeugs möglichst genau zu schätzen.







Warum beschäftigen wir uns mit das Kalman-Filter?



Rudolf E. Kálmán, wikipedia.de

Das Kalman-Filter, entwickelt 1960 von Rudolf E. Kálmán.

Anwendungen:

- Navigation
  - Indoor (Inertialmesssystem (IMS), Kamera)
  - Outdoor (GPS, IMS, Tachometer)
  - Raketen – genutzt im Apollo Programm
-
-
-
-
-

Warum beschäftigen wir uns mit das Kalman-Filter?



Rudolf E. Kálmán, wikipedia.de

Das Kalman-Filter, entwickelt 1960 von Rudolf E. Kálmán.

Anwendungen:

- Navigation
  - Indoor (Inertialmesssystem (IMS), Kamera)
  - Outdoor (GPS, IMS, Tachometer)
  - Raketen – genutzt im Apollo Programm
- Synchronisation von Signalen (Alternative zu Phase-Locked Loop (PLL, Phasenregelung))
- Wettervorhersage (Datenassimilation)
- Ladezustand von Lithium-Ionen-Akkus
-
-

Warum beschäftigen wir uns mit das Kalman-Filter?

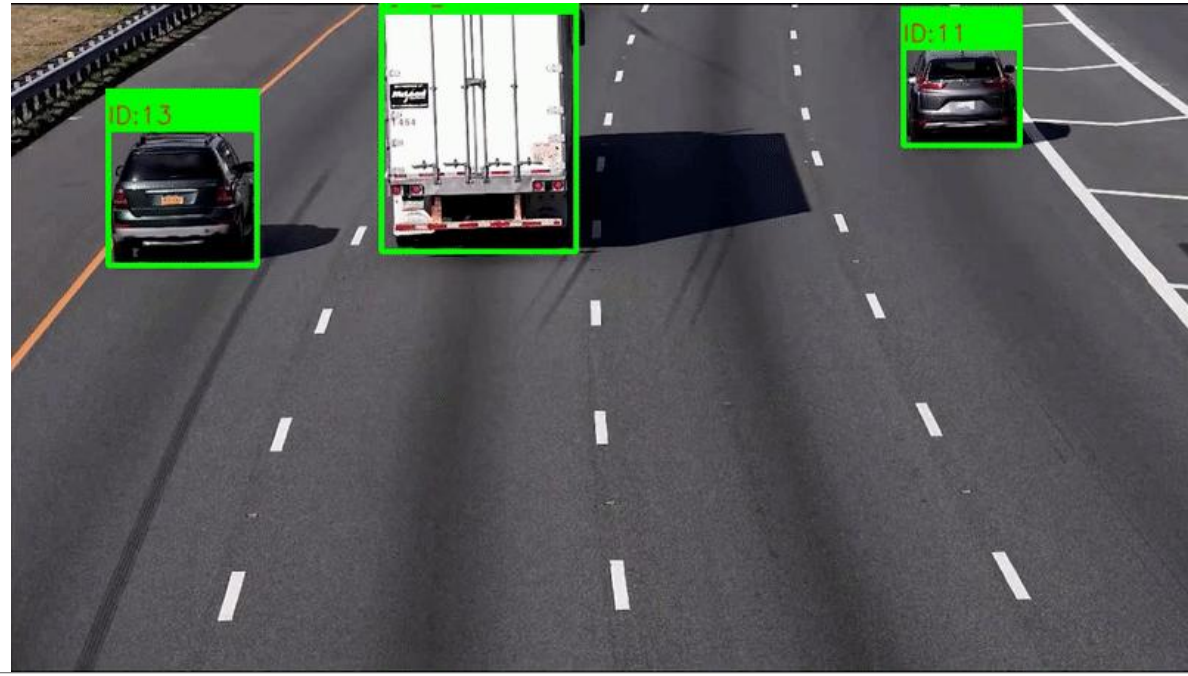


Rudolf E. Kálmán, wikipedia.de

Das Kalman-Filter, entwickelt 1960 von Rudolf E. Kálmán.

Anwendungen:

- Navigation
  - Indoor (Inertialmesssystem (IMS), Kamera)
  - Outdoor (GPS, IMS, Tachometer)
  - Raketen – genutzt im Apollo Programm
- Synchronisation von Signalen (Alternative zu Phase-Locked Loop (PLL, Phasenregelung))
- Wettervorhersage (Datenassimilation)
- Ladezustand von Lithium-Ionen-Akkus
- Visuelles Tracking
- Biologie, Chemie



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Frage – Zustand Ihres Systems

- Ist der Zustand Ihres Systems im Praktikum kontinuierlich oder diskret?
- Ist dieser Zustand direkt messbar oder muss dieser teilweise aus Sensordaten geschätzt werden?

Frage – Zustand Ihres Systems

- Ist der Zustand Ihres Systems im Praktikum kontinuierlich oder diskret?
- Ist dieser Zustand direkt messbar oder muss dieser teilweise aus Sensordaten geschätzt werden?

- Zwei Praktikumsaufgaben zu das Kalman-Filter:
  - Kalman-Filter 2D Lokalisierung: https://dgaida.github.io/wpf_cps_th_public/praktikum/#kalman-filter-2d-lokalisierung
  - TurtleBot Orientierungsschätzung (Kalman): https://dgaida.github.io/wpf_cps_th_public/praktikum/#turtlebot-orientierungssch%C3%A4tzung-kalman

Schätzung des Zustands eines Agenten

Ziel und Vorgehensweise

Ziel:

- Durchgängige Bestimmung des Zustandes (Position, Geschwindigkeit, Beschleunigung) eines sich bewegenden Fahrrads im **1**-dimensionalen



Schätzung des Zustands eines Agenten

Ziel und Vorgehensweise

Ziel:

- Durchgängige Bestimmung des Zustandes (Position, Geschwindigkeit, Beschleunigung) eines sich bewegenden Fahrrads im **1**-dimensionalen

Vorgehensweise:

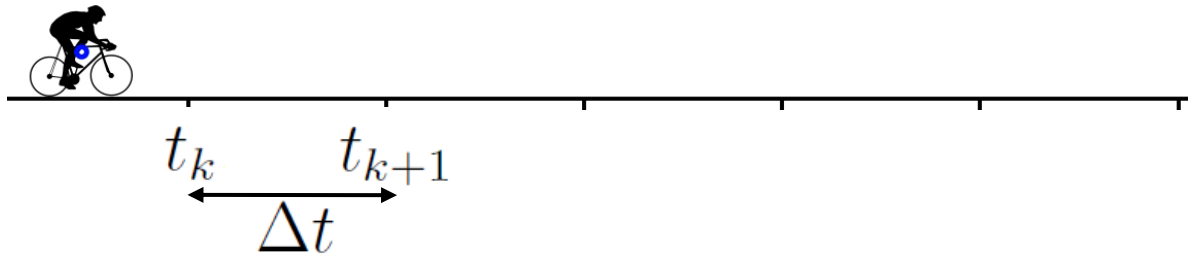
- **Physikalische Gleichungen**, welche ein sich bewegendes Fahrrad beschreiben
- Umformulierung der Gleichungen für das Kalman-Filter
- Das lineare **Kalman-Filter**
- Experimente



Physik eines sich 1-dimensional bewegenden Fahrrads

Wie verändert sich die Position des Fahrrads im Zeitraum $\Delta t := t_{k+1} - t_k$?

Wir nutzen die Notation: $p_k := p(t_k)$ $k = 0, 1, 2, \ldots$



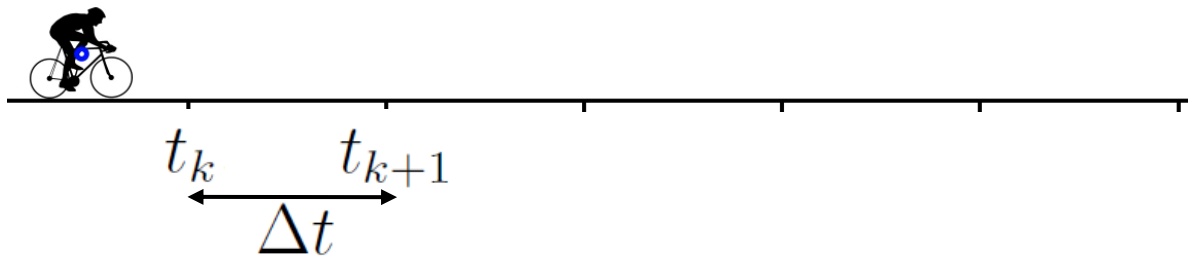
Physik eines sich 1-dimensional bewegenden Fahrrads

Wie verändert sich die Position des Fahrrads im Zeitraum $\Delta t := t_{k+1} - t_k$?

Wir nutzen die Notation: $p_k := p(t_k)$ $\quad k = 0, 1, 2, \ldots$

Position:

$$p_{k+1} = p_k + v_k \cdot \Delta t + \frac{1}{2} \cdot a_k \cdot \Delta t^2$$



Physik eines sich 1-dimensional bewegenden Fahrrads

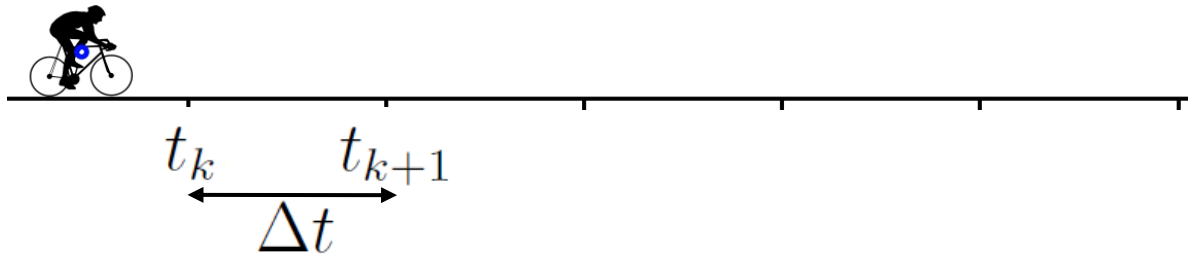
Wie verändert sich die Position des Fahrrads im Zeitraum $\Delta t := t_{k+1} - t_k$?

Wir nutzen die Notation: $p_k := p(t_k)$ $\quad k = 0, 1, 2, \ldots$

Position: $$p_{k+1} = p_k + v_k \cdot \Delta t + \frac{1}{2} \cdot a_k \cdot \Delta t^2$$

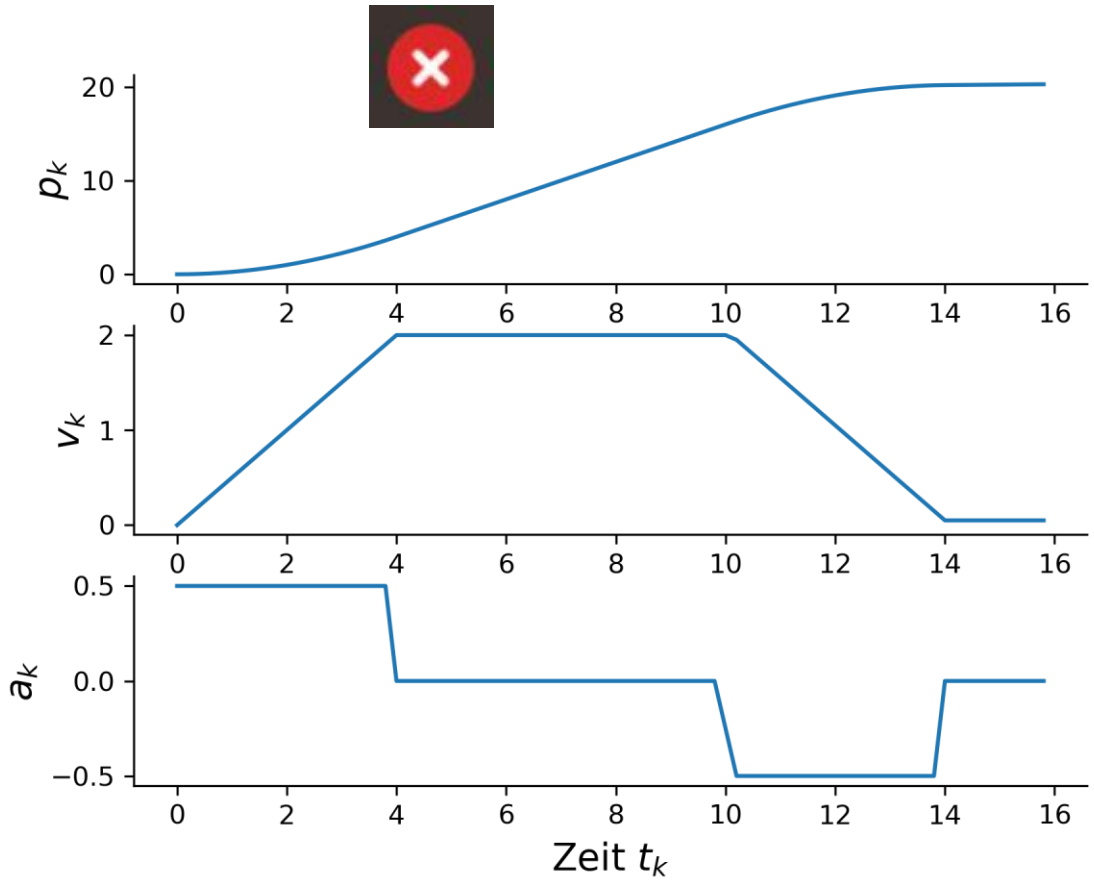
Geschwindigkeit: $$v_{k+1} = v_k + a_k \cdot \Delta t$$

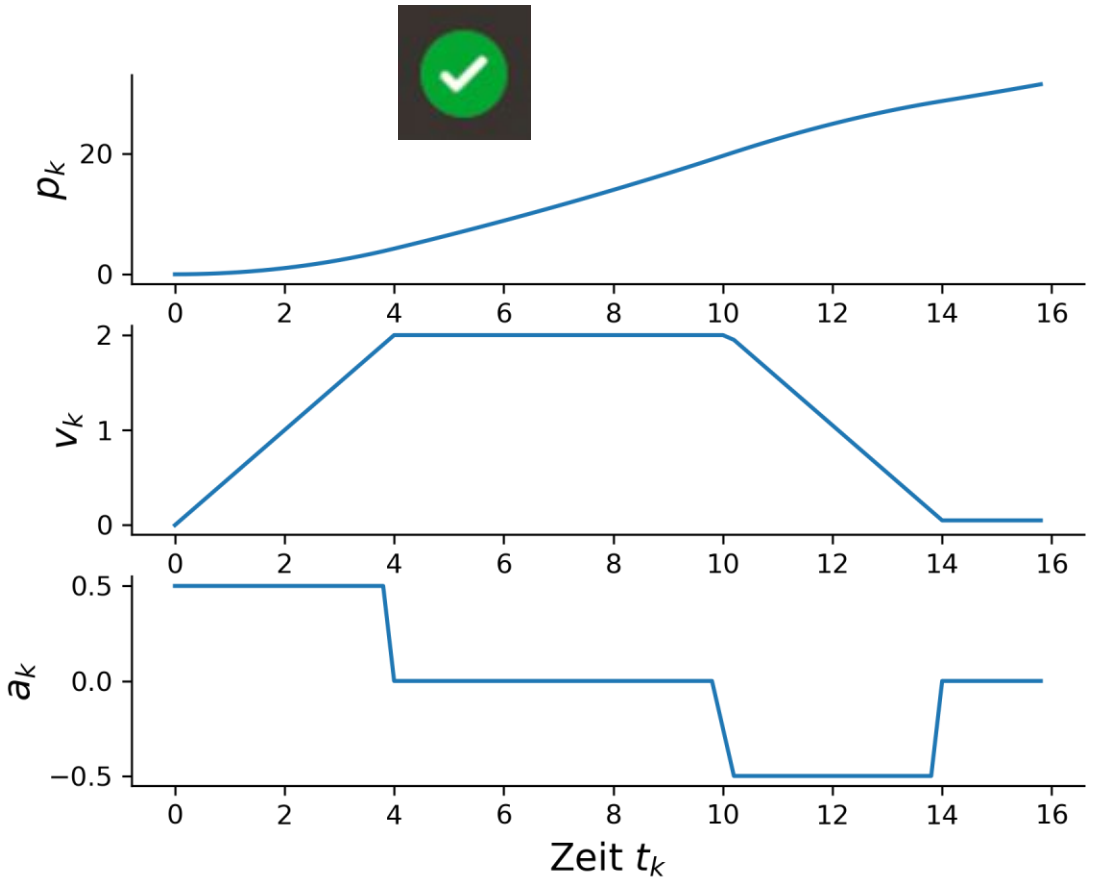
Beschleunigung (konst. über Δt): $$a_{k+1} = a_k$$



Physik eines sich 1-dimensional bewegenden Fahrrads

Welcher Graph ist richtig?





Physik eines sich 1-dimensional bewegenden Fahrrads

$$p_{k+1} = p_k + v_k \cdot \Delta t + \frac{1}{2} \cdot a_k \cdot \Delta t^2$$

$$p_{k+1} = \begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Physik eines sich 1-dimensional bewegenden Fahrrads

$$p_{k+1} = p_k + v_k \cdot \Delta t + \frac{1}{2} \cdot a_k \cdot \Delta t^2$$

$$p_{k+1} = \begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$v_{k+1} = v_k + a_k \cdot \Delta t$$

$$v_{k+1} = \begin{pmatrix} 0 & 1 & \Delta t \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$a_{k+1} = a_k$$

$$a_{k+1} = \begin{pmatrix} 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Physik eines sich 1-dimensional bewegenden Fahrrads

$$p_{k+1} = \begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$\begin{pmatrix} p_{k+1} \\ v_{k+1} \\ a_{k+1} \end{pmatrix} = \begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$v_{k+1} = \begin{pmatrix} 0 & 1 & \Delta t \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$a_{k+1} = \begin{pmatrix} 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Physik eines sich 1-dimensional bewegenden Fahrrads

$$p_{k+1} = \begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$v_{k+1} = \begin{pmatrix} 0 & 1 & \Delta t \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$a_{k+1} = \begin{pmatrix} 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$\underbrace{\begin{pmatrix} p_{k+1} \\ v_{k+1} \\ a_{k+1} \end{pmatrix}}_{\boldsymbol{x}_{k+1} :=} = \underbrace{\begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{pmatrix}}_{\boldsymbol{A} :=} \cdot \underbrace{\begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}}_{\boldsymbol{x}_k =}$$

$$\boldsymbol{x}_{k+1} = \boldsymbol{A}\boldsymbol{x}_k$$

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Physik eines sich 1-dimensional bewegenden Fahrrads

$$p_{k+1} = \begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$v_{k+1} = \begin{pmatrix} 0 & 1 & \Delta t \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$a_{k+1} = \begin{pmatrix} 0 & 0 & 1 \end{pmatrix} \cdot \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$\underbrace{\begin{pmatrix} p_{k+1} \\ v_{k+1} \\ a_{k+1} \end{pmatrix}}_{\boldsymbol{x}_{k+1} :=} = \underbrace{\begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{pmatrix}}_{\boldsymbol{A} :=} \cdot \underbrace{\begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}}_{\boldsymbol{x}_k =}$$

$$\boldsymbol{x}_{k+1} = \boldsymbol{A}\boldsymbol{x}_k$$

A wird als Systemmatrix bezeichnet
$\boldsymbol{x}_k$ als Zustandsvektor

Nomenklatur

- Kleines Symbol, kursiv:
  - Skalar
- Kleines Symbol, fett und kursiv:
  - Vektor
- Großes Symbol, fett:
  - Matrix

$$\underbrace{\begin{pmatrix} p_{k+1} \\ v_{k+1} \\ a_{k+1} \end{pmatrix}}_{\boldsymbol{x}_{k+1} :=} = \underbrace{\begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{pmatrix}}_{\boldsymbol{A} :=} \cdot \underbrace{\begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}}_{\boldsymbol{x}_k =}$$

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Physik eines sich 1-dimensional bewegenden Fahrrads

$$\underbrace{\begin{pmatrix} p_{k+1} \\ v_{k+1} \\ a_{k+1} \end{pmatrix}}_{\boldsymbol{x}_{k+1}} = \underbrace{\begin{pmatrix} 1 & \Delta t & \frac{1}{2} \cdot \Delta t^2 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{pmatrix}}_{\boldsymbol{A}} \cdot \underbrace{\begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}}_{\boldsymbol{x}_k}$$

Gleichung $\boldsymbol{x}_{k+1} = \boldsymbol{A} \cdot \boldsymbol{x}_k$ beschreibt wie die physikalischen Größen zusammenhängen.

Wie kommen wir von einem Zustand zum nächsten Zustand?

Wichtige Gleichung für das Kalman-Filter!

→ Jupyter Notebook

Positionsmessung eines sich 1-dimensional bewegenden Fahrrads

Messgleichung, um Messungen berücksichtigen zu können:

Messvektor:

$$\boldsymbol{y}_k = \boldsymbol{C}\boldsymbol{x}_k$$

Positionsmessung eines sich 1-dimensional bewegenden Fahrrads

Messgleichung, um Messungen berücksichtigen zu können:

Messvektor:

$$\boldsymbol{y}_k = \boldsymbol{C}\boldsymbol{x}_k$$

$$\boldsymbol{x}_k = \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Bsp.: Messung der Position des Fahrrads:

Ausgangsmatrix:

$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}$$

$$\boldsymbol{y}_k = y_{p,k}$$

Positionsmessung eines sich 1-dimensional bewegenden Fahrrads

Wie muss die Ausgangsmatrix aussehen, wenn Sie die

- Geschwindigkeit

messen?

$$\boldsymbol{x}_k = \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Positionsmessung eines sich 1-dimensional bewegenden Fahrrads

Wie muss die Ausgangsmatrix aussehen, wenn Sie die

- Position und Beschleunigung

messen?

$$\boldsymbol{x}_k = \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Positionsmessung eines sich 1-dimensional bewegenden Fahrrads

Wie muss die Ausgangsmatrix aussehen, wenn Sie die

- Position und Beschleunigung

messen?

$$\boldsymbol{x}_k = \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\boldsymbol{y}_k = (y_{p,k}, y_{a,k})^T$$

Was war noch mal unser Ziel?

Wir möchten den Zustandsvektor für alle $k = 0, 1, 2, \ldots$ schätzen, d.h. wir möchten eine Schätzung für

- Die Position $\hat{p}_k$
- Die Geschwindigkeit $\hat{v}_k$
- Die Beschleunigung $\hat{a}_k$

Was war noch mal unser Ziel?

Wir möchten den Zustandsvektor für alle $k = 0, 1, 2, \ldots$ schätzen, d.h. wir möchten eine Schätzung für

- Die Position $\hat{p}_k$
- Die Geschwindigkeit $\hat{v}_k$
- Die Beschleunigung $\hat{a}_k$

Wir definieren den geschätzten Zustandsvektor:

$$\hat{\boldsymbol{x}}_k := \begin{pmatrix} \hat{p}_k \\ \hat{v}_k \\ \hat{a}_k \end{pmatrix}$$

Was ist die Aufgabe des Kalman-Filters?

Unbekannt: $$\boldsymbol{x}_k = \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Liefere zu jedem Zeitpunkt $k = 0, 1, 2, \ldots$ eine Schätzung des Zustandsvektors $\hat{\boldsymbol{x}}_k := \begin{pmatrix} \hat{p}_k \\ \hat{v}_k \\ \hat{a}_k \end{pmatrix}$,

für die gilt:

$$\hat{\boldsymbol{x}}_{k+1} \approx \boldsymbol{x}_{k+1} \quad \text{für alle} \quad k = 0, 1, 2, \ldots$$



Was ist die Aufgabe des Kalman-Filters?

Unbekannt: $$\boldsymbol{x}_k = \begin{pmatrix} p_k \\ v_k \\ a_k \end{pmatrix}$$

Liefere zu jedem Zeitpunkt $k = 0, 1, 2, \ldots$ eine Schätzung des Zustandsvektors $\hat{\boldsymbol{x}}_k := \begin{pmatrix} \hat{p}_k \\ \hat{v}_k \\ \hat{a}_k \end{pmatrix}$,

für die gilt:

$$\hat{\boldsymbol{x}}_{k+1} \approx \boldsymbol{x}_{k+1} \quad \text{für alle} \quad k = 0, 1, 2, \ldots$$

Unter Nutzung der Gleichungen:

$$\boldsymbol{x}_{k+1} = \boldsymbol{A} \cdot \boldsymbol{x}_k$$

$$\boldsymbol{y}_k = \boldsymbol{C} \cdot \boldsymbol{x}_k$$



Das lineare Kalman-Filter

$$\hat{\boldsymbol{x}}_0 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

Algorithm 3.1 Lineares Kalman-Filter

Input: $\hat{\boldsymbol{x}}_0$

Input: $\boldsymbol{P}_0$

1:

2: **for** $k = 0$ to ∞ **do**

3: $\quad \boldsymbol{K}_k^* = \boldsymbol{A}\boldsymbol{P}_k\boldsymbol{C}^T\left(\boldsymbol{C}\boldsymbol{P}_k\boldsymbol{C}^T + \boldsymbol{\Psi}_{\boldsymbol{r},k}\right)^{-1}$

4: $\quad \hat{\boldsymbol{x}}_{k+1} = \boldsymbol{A}\hat{\boldsymbol{x}}_k + \boldsymbol{K}_k^*\left(\boldsymbol{y}_k - \boldsymbol{C}\hat{\boldsymbol{x}}_k\right)$

5: $\quad \boldsymbol{P}_{k+1} = \boldsymbol{A}\boldsymbol{P}_k\boldsymbol{A}^T - \boldsymbol{K}_k^*\boldsymbol{C}\boldsymbol{P}_k\boldsymbol{A}^T$

6: **end for**

Das lineare Kalman-Filter

Algorithm 3.1 Lineares Kalman-Filter

Input: $\hat{\boldsymbol{x}}_0$

Input: $\boldsymbol{P}_0$

$$\boldsymbol{P}_k := \begin{pmatrix} (\hat{p}_k - p_k)^2 & \dots & \dots \\ \dots & (\hat{v}_k - v_k)^2 & \dots \\ \dots & \dots & (\hat{a}_k - a_k)^2 \end{pmatrix}$$

1:

2: **for** $k = 0$ to ∞ **do**

3: $\quad \boldsymbol{K}_k^* = \boldsymbol{A}\boldsymbol{P}_k\boldsymbol{C}^T \left(\boldsymbol{C}\boldsymbol{P}_k\boldsymbol{C}^T + \boldsymbol{\Psi}_{\boldsymbol{r},k}\right)^{-1}$

4: $\quad \hat{\boldsymbol{x}}_{k+1} = \boldsymbol{A}\hat{\boldsymbol{x}}_k + \boldsymbol{K}_k^* \left(\boldsymbol{y}_k - \boldsymbol{C}\hat{\boldsymbol{x}}_k\right)$

5: $\quad \boldsymbol{P}_{k+1} = \boldsymbol{A}\boldsymbol{P}_k\boldsymbol{A}^T - \boldsymbol{K}_k^*\boldsymbol{C}\boldsymbol{P}_k\boldsymbol{A}^T$

6: **end for**

$$\hat{\boldsymbol{x}}_0 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$\boldsymbol{P}_0 = \begin{pmatrix} 5^2 & 0 & 0 \\ 0 & 0.5^2 & 0 \\ 0 & 0 & 0.5^2 \end{pmatrix}$$

P_0 ist die initiale Fehlerkovarianzmatrix

K_k^* ist die optimale Kalman Matrix

Das lineare Kalman-Filter: Wie genau ist die Schätzung?

Was liefert uns das Kalman-Filter zurück?

Geschätzter Zustandsvektor:

$$\hat{\boldsymbol{x}}_{k+1}$$

Das lineare Kalman-Filter: Wie genau ist die Schätzung?

Was liefert uns das Kalman-Filter zurück?

Geschätzter Zustandsvektor:

$$\hat{\boldsymbol{x}}_{k+1}$$

Fehlerkovarianzmatrix zum Zeitpunkt k+1:

$$\boldsymbol{P}_{k+1}$$

$$\boldsymbol{P}_k := \begin{pmatrix} (\hat{p}_k - p_k)^2 & \dots & \dots \\ \dots & (\hat{v}_k - v_k)^2 & \dots \\ \dots & \dots & (\hat{a}_k - a_k)^2 \end{pmatrix}$$

Gibt Unsicherheit des Kalman-Filters über die neue Schätzung $\hat{\boldsymbol{x}}_{k+1}$ an.

D.h., das Kalman-Filter sagt uns, wie sicher es sich über seine Schätzung ist!

Das lineare Kalman-Filter: Wie genau ist die Schätzung?

Kalman-Filter liefert uns geschätzte Position und Information darüber wie genau die Schätzung ist.

→ Gauß-Verteilung mit Varianz aus der aktuellen Fehlerkovarianzmatrix P_k

Kalman-Filter ist sich über seine Positionsschätzung

sicher: unsicher:



Das lineare Kalman-Filter: Wie genau ist die Schätzung?

Kalman-Filter liefert uns geschätzte Position und Information darüber wie genau die Schätzung ist.

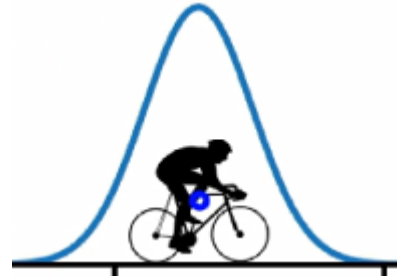
→ Gauß-Verteilung mit Varianz aus der aktuellen Fehlerkovarianzmatrix P_k

Kalman-Filter ist sich über seine Positionsschätzung

sicher:



unsicher:

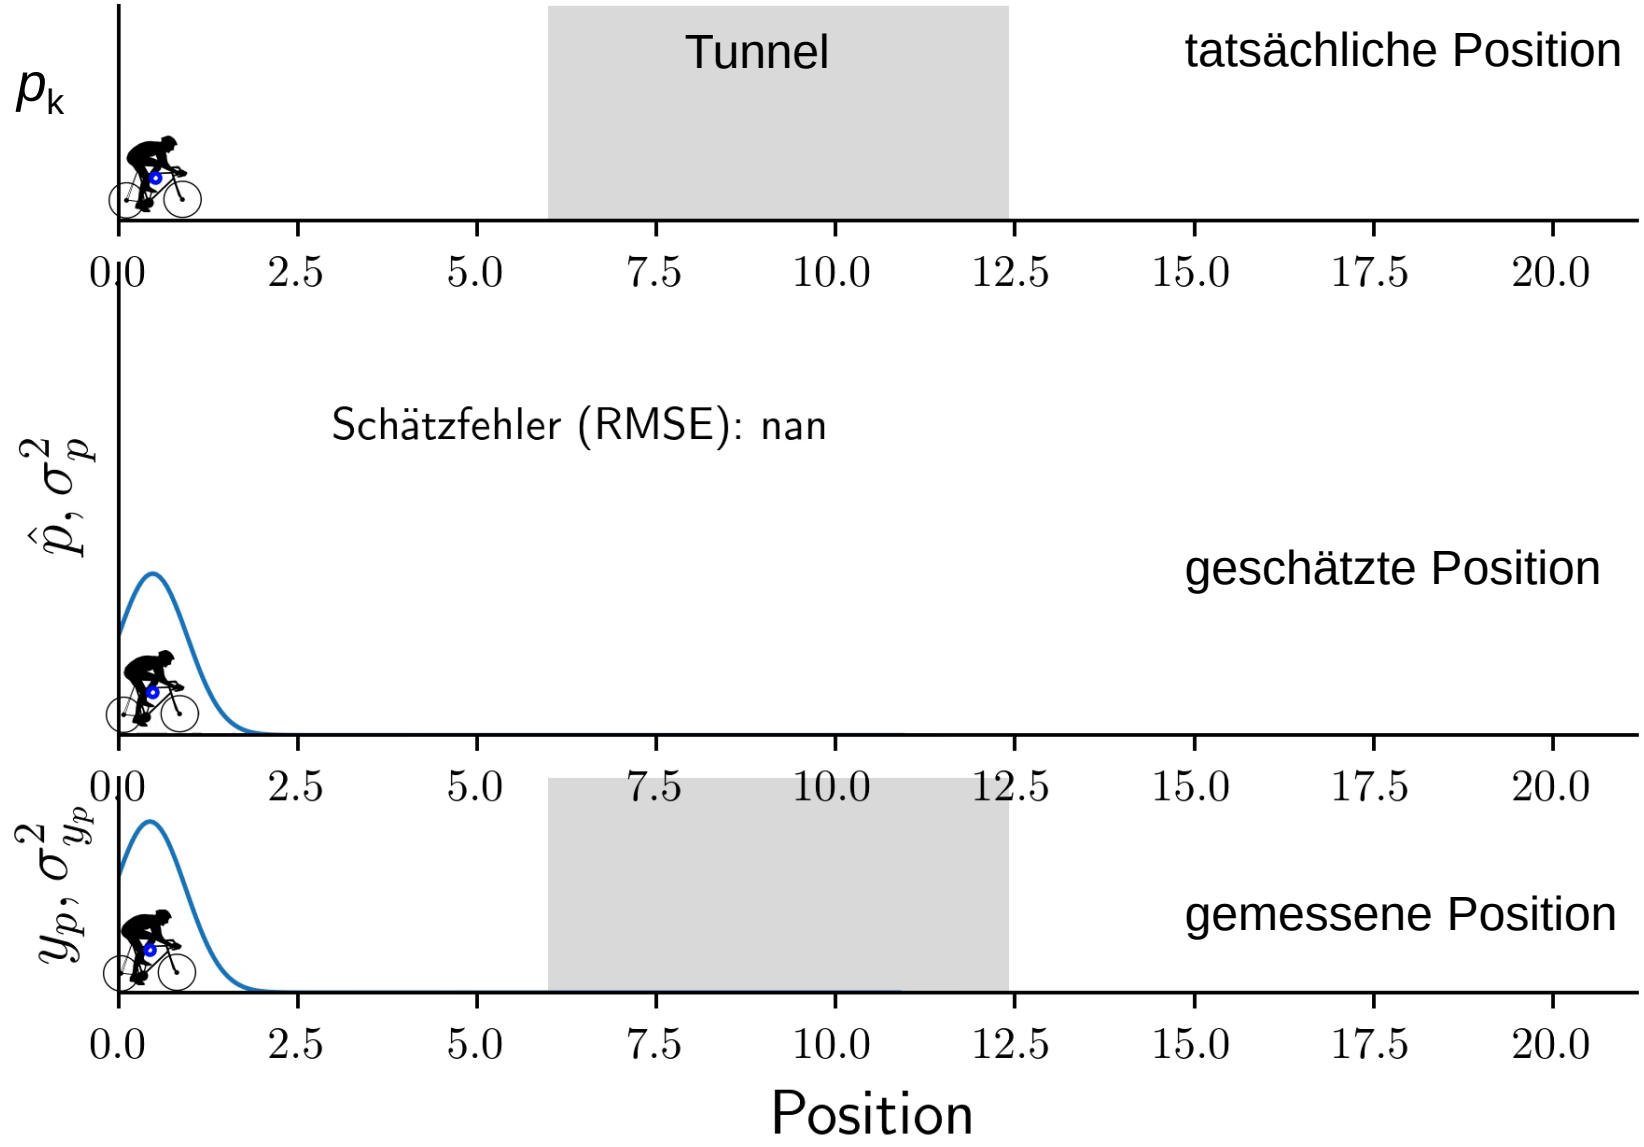


Experimente – Bei Position 6 Fahrt durch Tunnel

Messung der Position

$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 \end{pmatrix}$$

$$\boldsymbol{y}_k = y_{p,k}$$

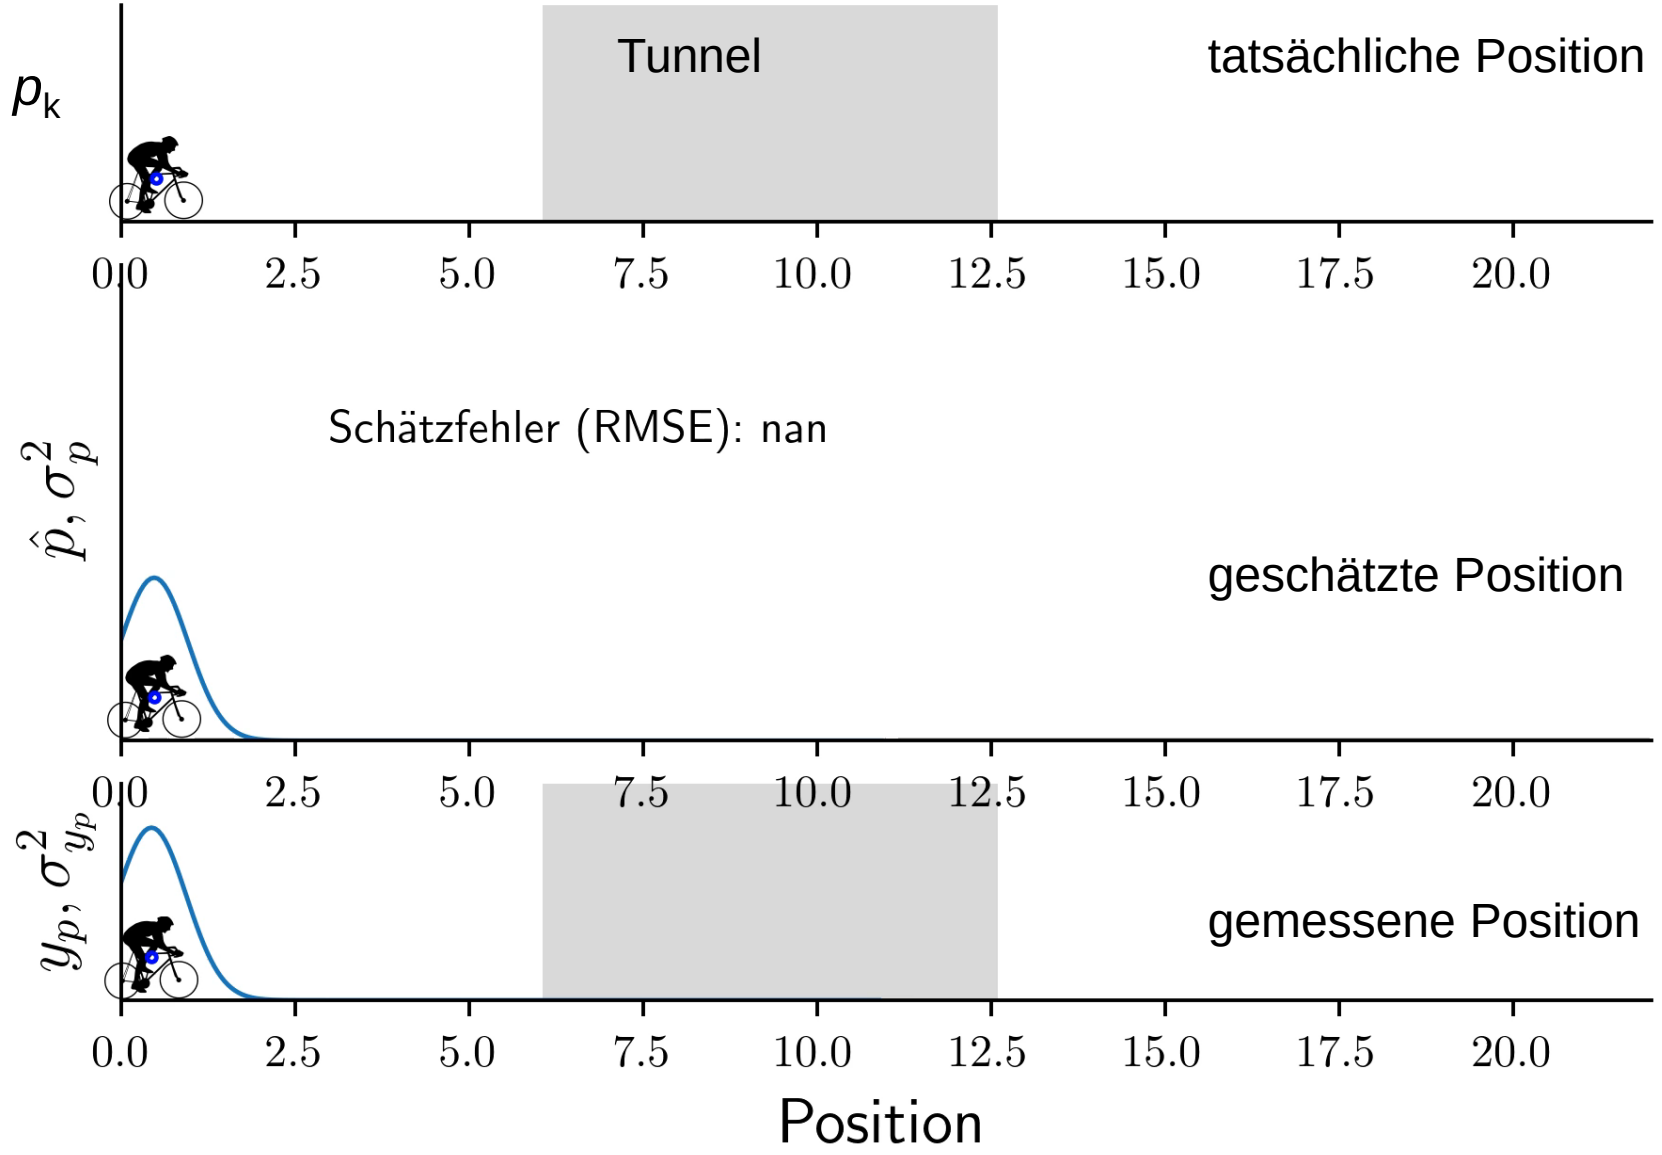


Experimente – Bei Position 6 Fahrt durch Tunnel

Messung der Position
und Beschleunigung

$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\boldsymbol{y}_k = \left(y_{p,k}, y_{a,k}\right)^T$$

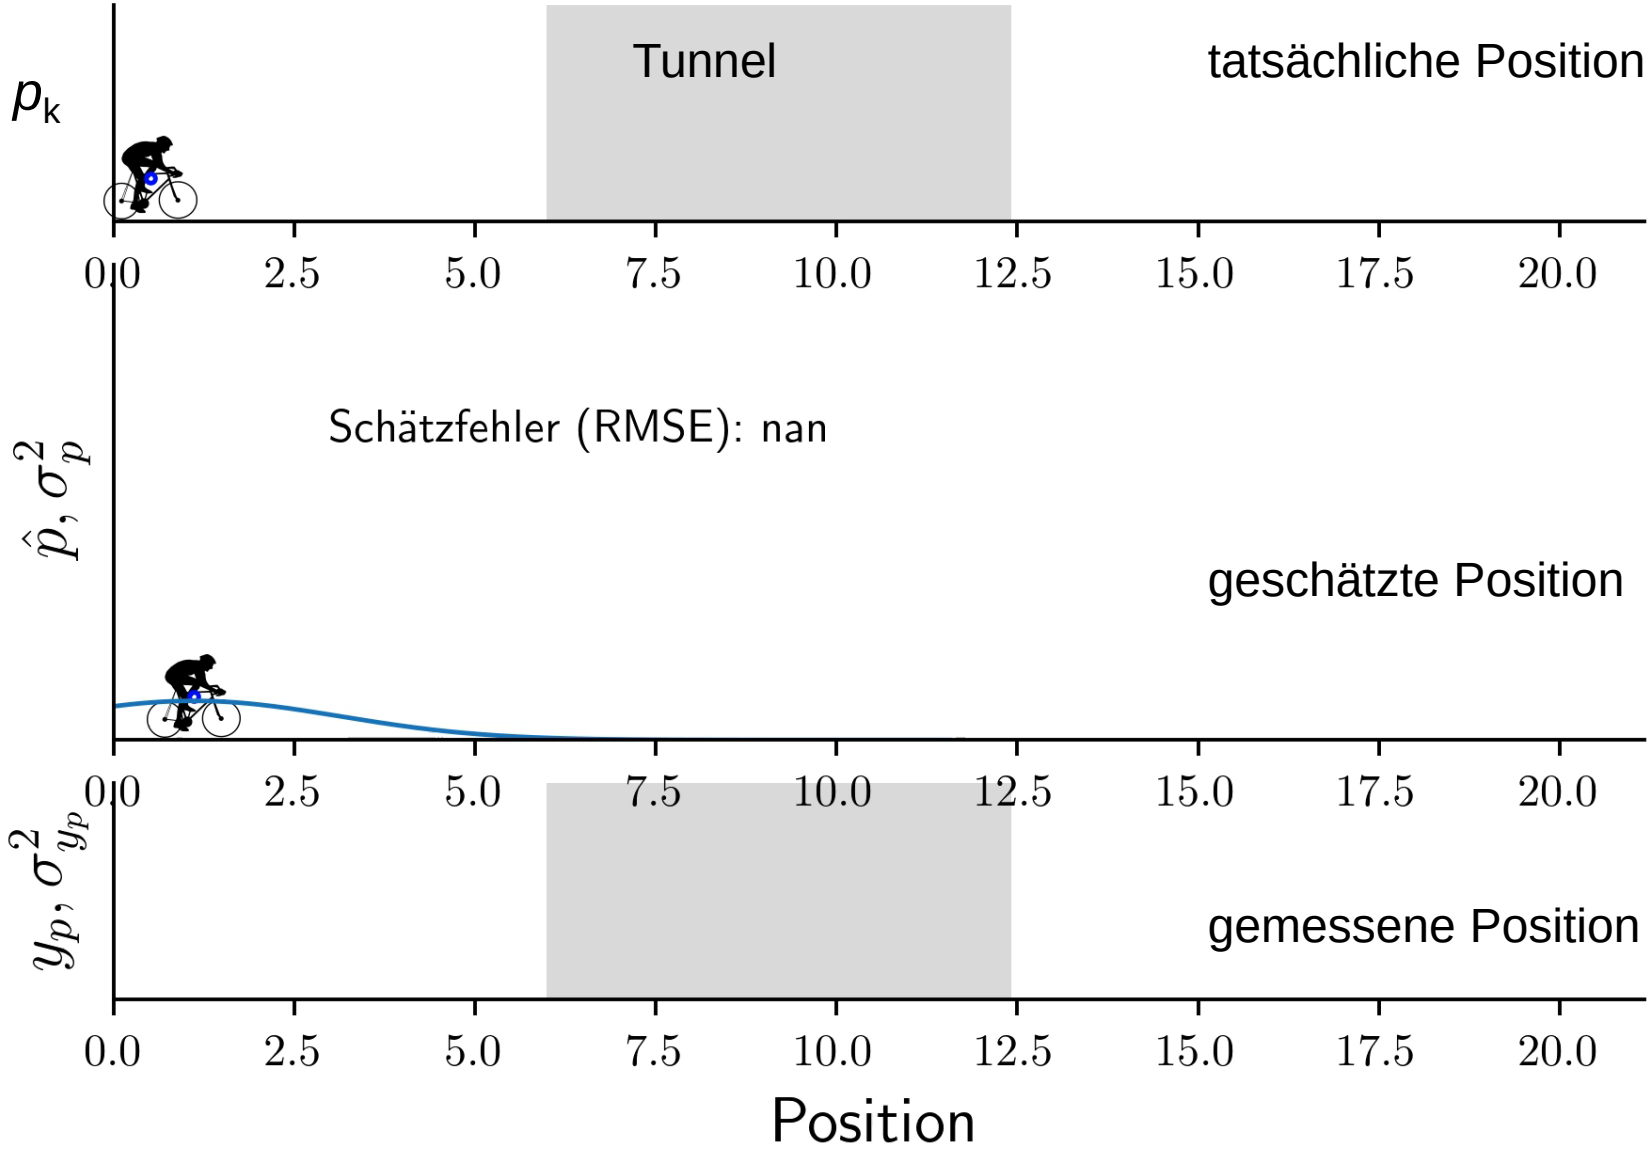


Experimente – Bei Position 6 Fahrt durch Tunnel

Messung der Beschleunigung

$$\boldsymbol{C} := \begin{pmatrix} 0 & 0 & 1 \end{pmatrix}$$

$$\boldsymbol{y}_k = y_{a,k}$$



Kalman-Filter

Implementierung in Python

Übung

- Lineares Kalman-Filter für Lokalisierung in 1D-Welt
- Experimentieren Sie mit Messung von Beschleunigung, Geschwindigkeit und/oder Position
- Vergleichen Sie die geschätzte Position und die Schätzunsicherheit bei den verschiedenen gemessenen Größen

- 02_kalman_localization_1d_linear.ipynb

Weitere Anwendungen des Kalman-Filters



Rudolf E. Kálmán, wikipedia.de

Das Kalman-Filter, entwickelt 1960 von Rudolf E. Kálmán.

Anwendungen:

- Navigation
  - Indoor (Inertialmesssystem (IMS), Kamera)
  - Outdoor (GPS, IMS, Lidar, Radar)
  - Raketen – genutzt im Apollo Programm
- Synchronisation von Signalen (Alternative zu Phase-Locked Loop (PLL, Phasenregelung))
- Wettervorhersage (Datenassimilation)
- Ladezustand von Lithium-Ionen-Akkus
-
-

Weitere Anwendungen des Kalman-Filters

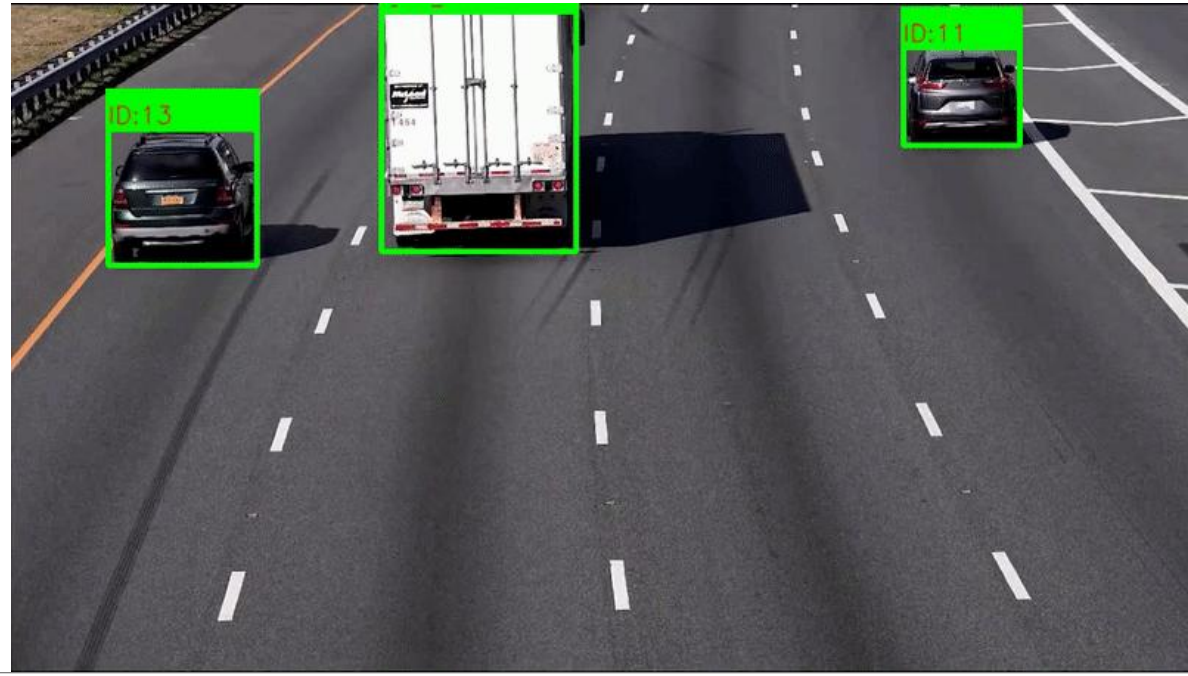


Rudolf E. Kálmán, wikipedia.de

Das Kalman-Filter, entwickelt 1960 von Rudolf E. Kálmán.

Anwendungen:

- Navigation
  - Indoor (Inertialmesssystem (IMS), Kamera)
  - Outdoor (GPS, IMS, Lidar, Radar)
  - Raketen – genutzt im Apollo Programm
- Synchronisation von Signalen (Alternative zu Phase-Locked Loop (PLL, Phasenregelung))
- Wettervorhersage (Datenassimilation)
- Ladezustand von Lithium-Ionen-Akkus
- Visuelles Tracking
- Biologie, Chemie



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

State of the Art der KI in verschiedenen Anwendungen

Computer Vision – Objekt Detektion – mit Kalman Filter

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik

https://github.com/abewley/sort

A. Bewley, Z. Ge, L. Ott, F. Ramos, and B. Upcroft, “Simple online and realtime tracking,” in Proceedings of the 23th IEEE International Conference on Image Processing (ICIP), 2016, pp. 3464–3468

State of the Art der KI in verschiedenen Anwendungen

Computer Vision – Objekt Detektion – mit Kalman Filter



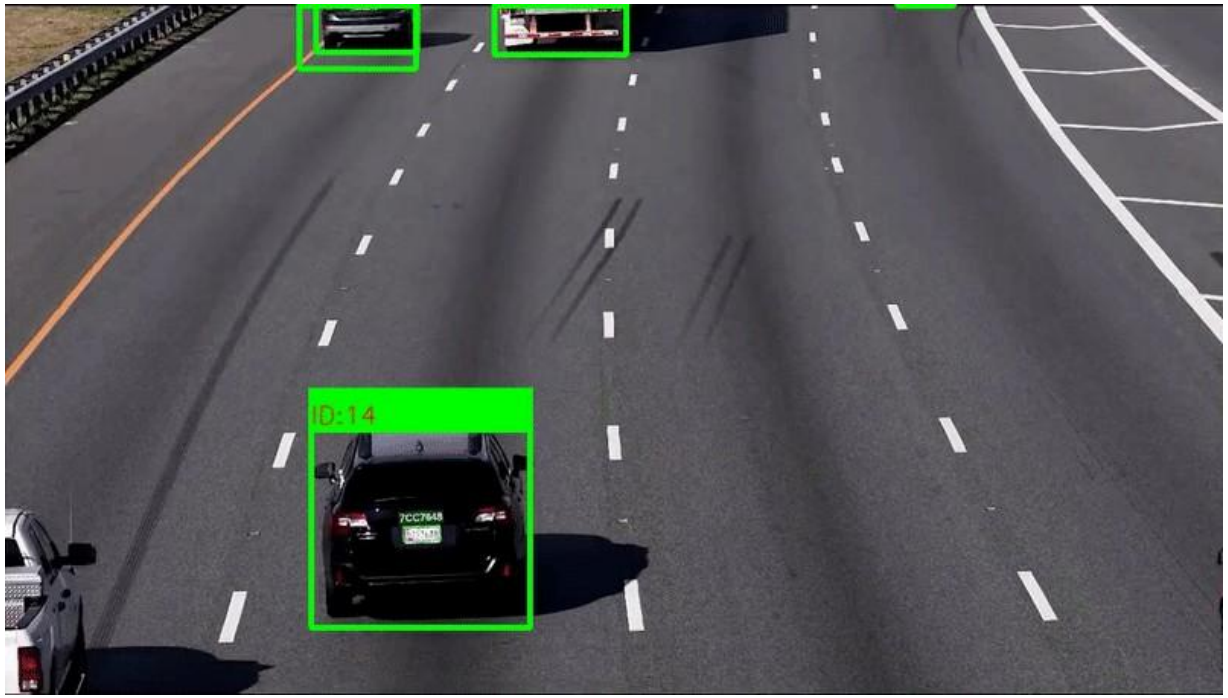
https://github.com/abewley/sort

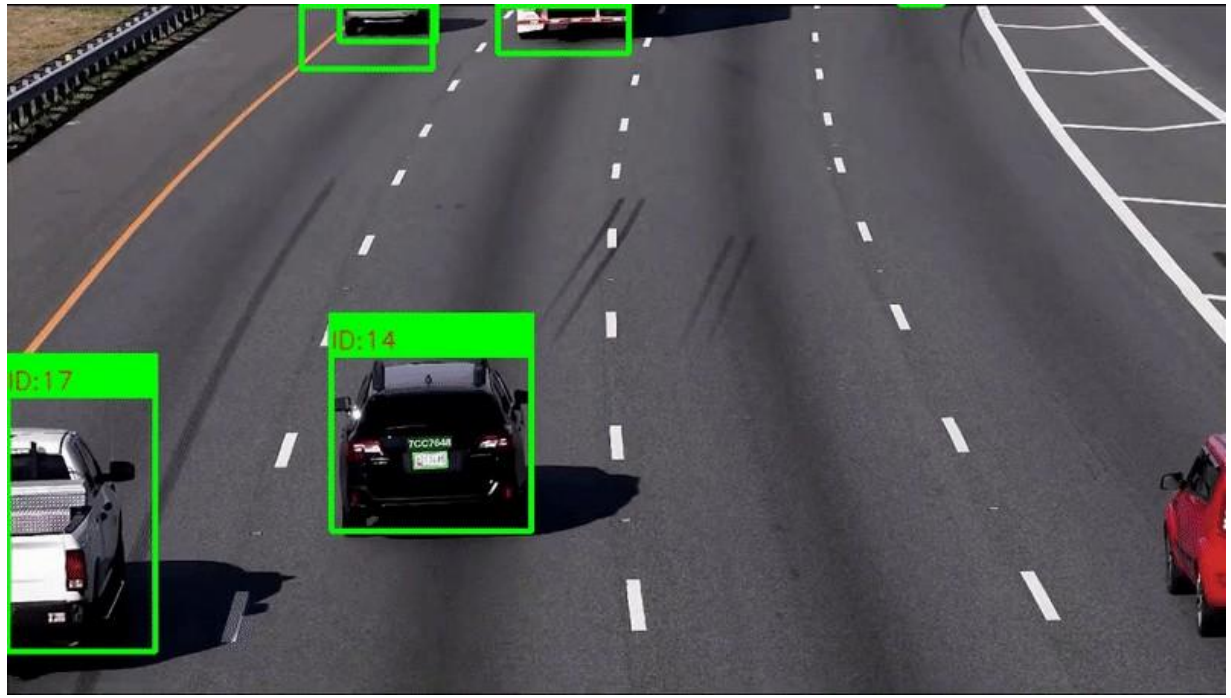
A. Bewley, Z. Ge, L. Ott, F. Ramos, and B. Upcroft, “Simple online and realtime tracking,” in Proceedings of the 23th IEEE International Conference on Image Processing (ICIP), 2016, pp. 3464–3468

Visuelles Tracking

Wie könnte das modelliert werden?

- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

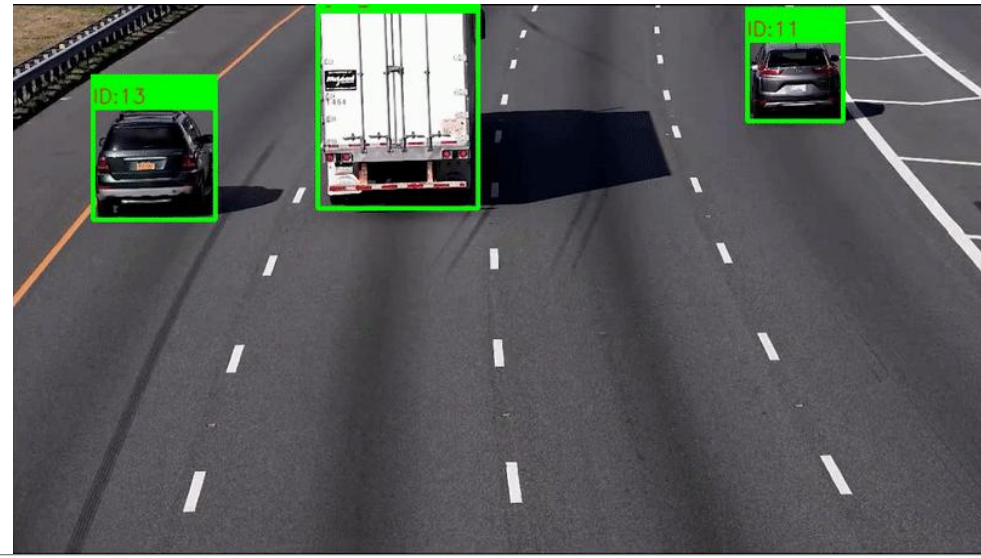




Visuelles Tracking

Wie könnte das modelliert werden?

- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

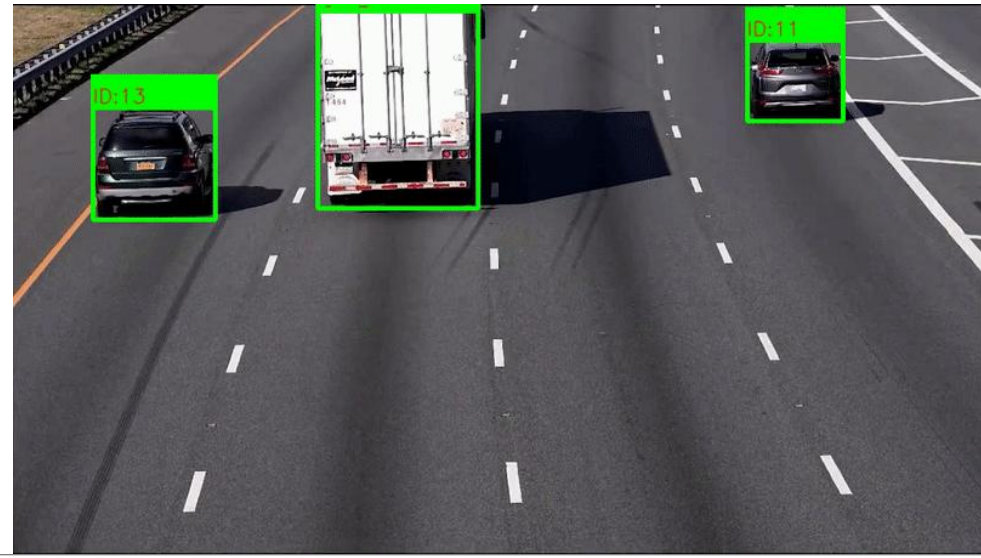
Wie könnte das modelliert werden?

- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

- Zustand? Was wollen wir wissen?
-

-
-

$$
\begin{aligned}
x_{1,k+1} &= x_{1,k} + v_{x,k} \cdot \Delta t \\
y_{1,k+1} &= y_{1,k} + v_{y,k} \cdot \Delta t \\
x_{2,k+1} &= x_{2,k} + v_{x,k} \cdot \Delta t \\
y_{2,k+1} &= y_{2,k} + v_{y,k} \cdot \Delta t \\
v_{x,k+1} &= v_{x,k} \\
v_{y,k+1} &= v_{y,k}
\end{aligned}
$$

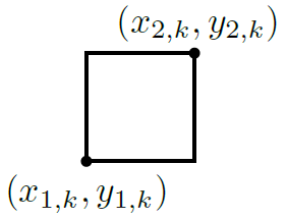


https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Visuelles Tracking

Wie könnte das modelliert werden?



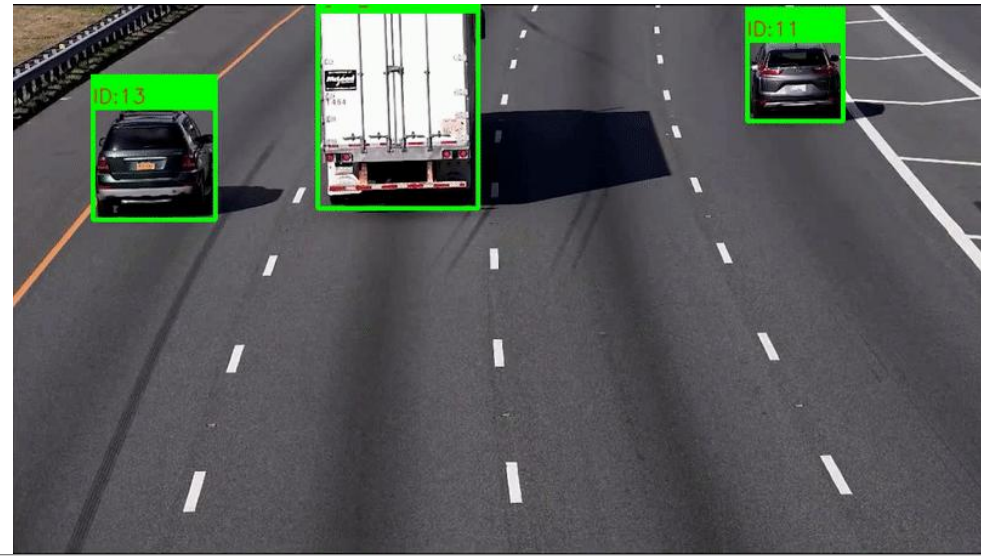
- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

- Zustand? Was wollen wir wissen?

$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

-
-

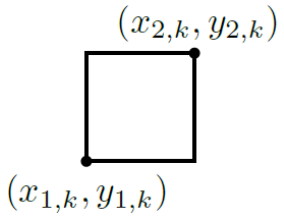
$$x_{1,k+1} = x_{1,k} + v_{x,k} \cdot \Delta t$$
$$y_{1,k+1} = y_{1,k} + v_{y,k} \cdot \Delta t$$
$$x_{2,k+1} = x_{2,k} + v_{x,k} \cdot \Delta t$$
$$y_{2,k+1} = y_{2,k} + v_{y,k} \cdot \Delta t$$
$$v_{x,k+1} = v_{x,k}$$
$$v_{y,k+1} = v_{y,k}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



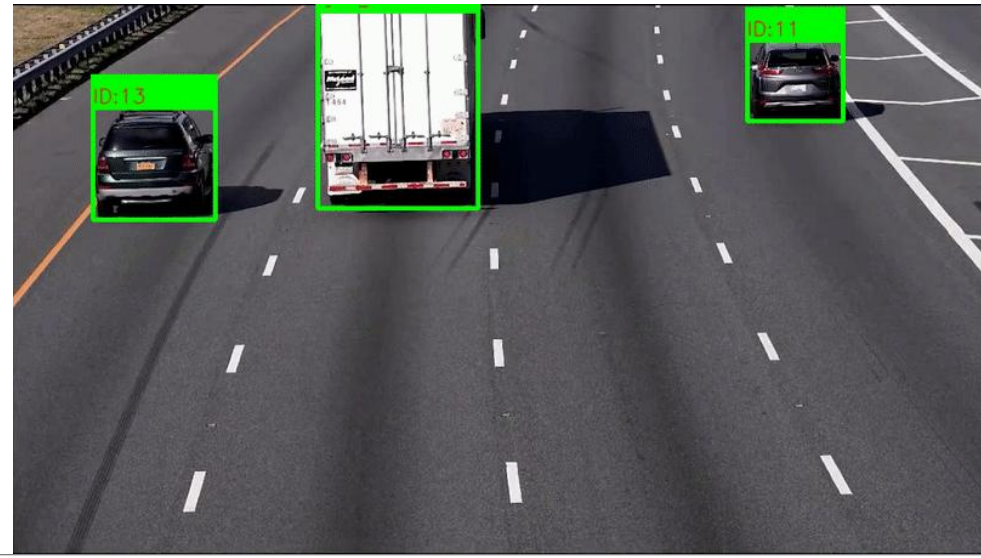
- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

- Zustand? Was wollen wir wissen?
- Was können wir messen? Direkte Messung?
  Gibt es Annahmen, die wir machen können?

$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

-
-

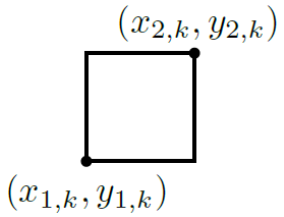
$$x_{1,k+1} = x_{1,k} + v_{x,k} \cdot \Delta t$$
$$y_{1,k+1} = y_{1,k} + v_{y,k} \cdot \Delta t$$
$$x_{2,k+1} = x_{2,k} + v_{x,k} \cdot \Delta t$$
$$y_{2,k+1} = y_{2,k} + v_{y,k} \cdot \Delta t$$
$$v_{x,k+1} = v_{x,k}$$
$$v_{y,k+1} = v_{y,k}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



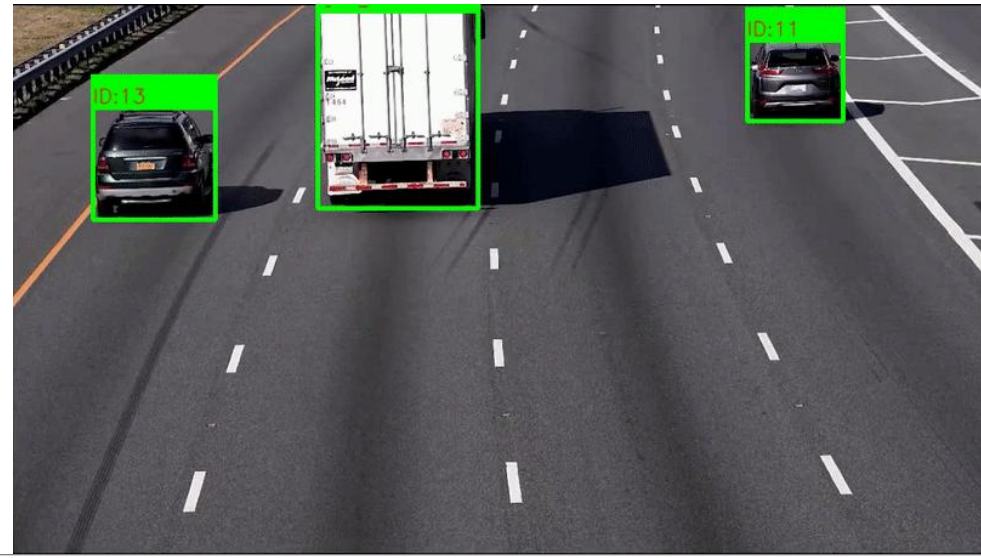
- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

- Zustand? Was wollen wir wissen?
- Was können wir messen? Direkte Messung?
  Gibt es Annahmen, die wir machen können?

$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

- Systembeschreibung?
-

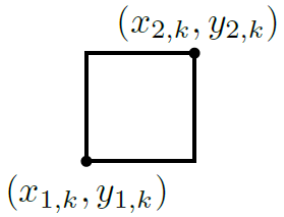
$$\begin{aligned}
x_{1,k+1} &= x_{1,k} + v_{x,k} \cdot \Delta t \\
y_{1,k+1} &= y_{1,k} + v_{y,k} \cdot \Delta t \\
x_{2,k+1} &= x_{2,k} + v_{x,k} \cdot \Delta t \\
y_{2,k+1} &= y_{2,k} + v_{y,k} \cdot \Delta t \\
v_{x,k+1} &= v_{x,k} \\
v_{y,k+1} &= v_{y,k}
\end{aligned}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



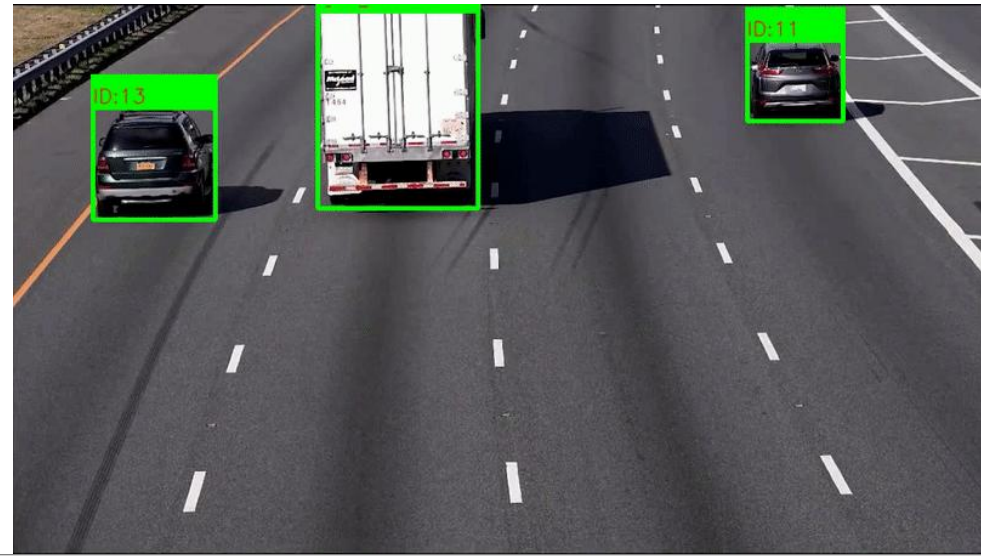
- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

- Zustand? Was wollen wir wissen?
- Was können wir messen? Direkte Messung?
  Gibt es Annahmen, die wir machen können?

$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

- Systembeschreibung?
- Systemmatrix A?

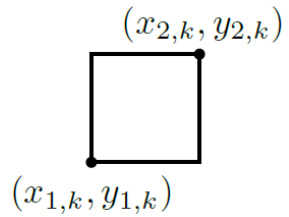
$$\begin{aligned}
x_{1,k+1} &= x_{1,k} + v_{x,k} \cdot \Delta t \\
y_{1,k+1} &= y_{1,k} + v_{y,k} \cdot \Delta t \\
x_{2,k+1} &= x_{2,k} + v_{x,k} \cdot \Delta t \\
y_{2,k+1} &= y_{2,k} + v_{y,k} \cdot \Delta t \\
v_{x,k+1} &= v_{x,k} \\
v_{y,k+1} &= v_{y,k}
\end{aligned}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



$$\boldsymbol{A} := \begin{pmatrix} 1 & 0 & 0 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & 0 & 0 & \Delta t \\ 0 & 0 & 1 & 0 & \Delta t & 0 \\ 0 & 0 & 0 & 1 & 0 & \Delta t \\ 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

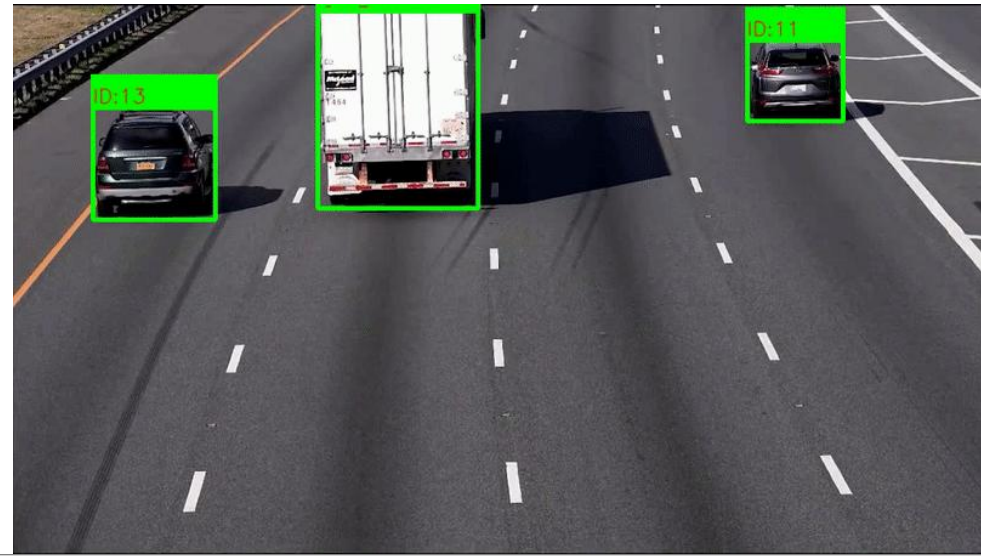
- Visuelles Tracking: In jedem Frame eine Bounding Box um jedes Fahrzeug legen
- Im Folgenden wird nur ein Fahrzeug betrachtet

- Zustand? Was wollen wir wissen?
- Was können wir messen? Direkte Messung? Gibt es Annahmen, die wir machen können?

$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

- Systembeschreibung?
- Systemmatrix A?

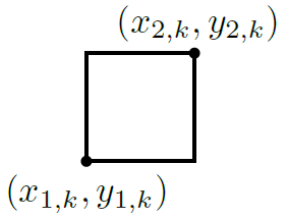
$$\begin{aligned} x_{1,k+1} &= x_{1,k} + v_{x,k} \cdot \Delta t \\ y_{1,k+1} &= y_{1,k} + v_{y,k} \cdot \Delta t \\ x_{2,k+1} &= x_{2,k} + v_{x,k} \cdot \Delta t \\ y_{2,k+1} &= y_{2,k} + v_{y,k} \cdot \Delta t \\ v_{x,k+1} &= v_{x,k} \\ v_{y,k+1} &= v_{y,k} \end{aligned}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

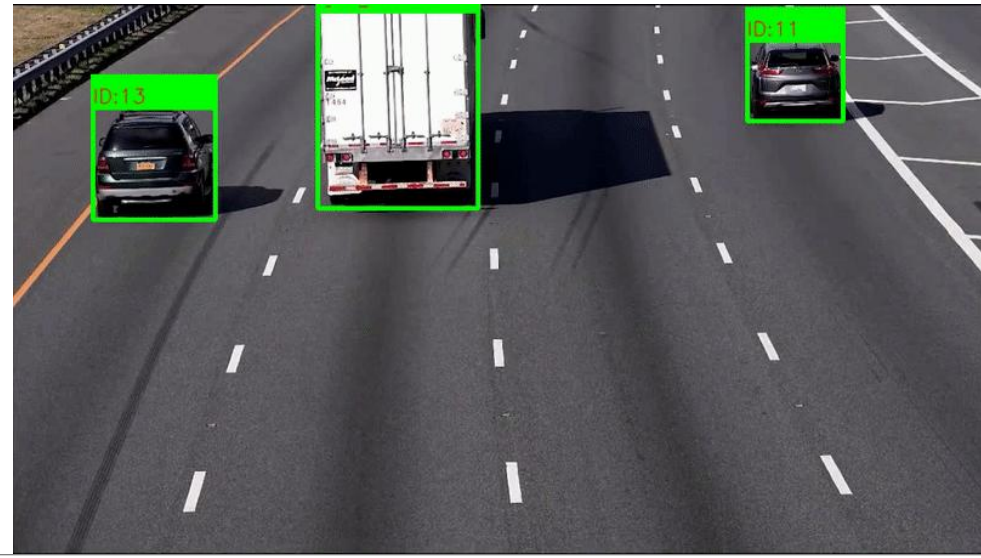
Visuelles Tracking

Wie könnte das modelliert werden?



- Messvektor und Messgleichungen?

$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

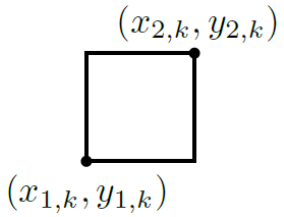


https://github.com/ahmetozlu/tensorflow_object_counting_api

https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



- Messvektor und Messgleichungen?

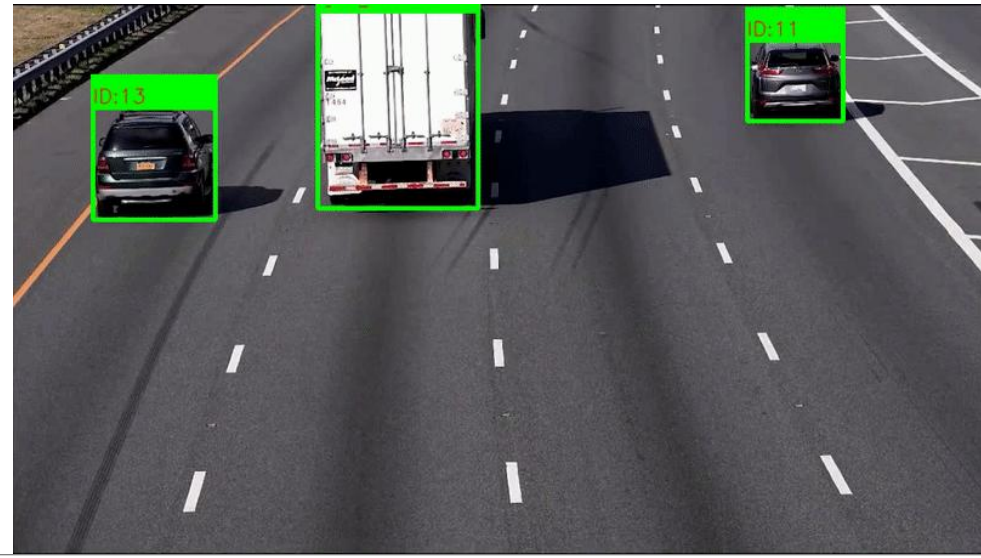
$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

$$y_{x_1,k} = x_{1,k}$$
$$y_{y_1,k} = y_{1,k}$$
$$y_{x_2,k} = x_{2,k}$$
$$y_{y_2,k} = y_{2,k}$$

$$\boldsymbol{y}_k := (y_{x_1,k}, y_{y_1,k}, y_{x_2,k}, y_{y_2,k})^T$$

-

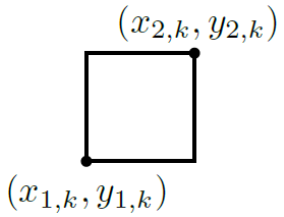
$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

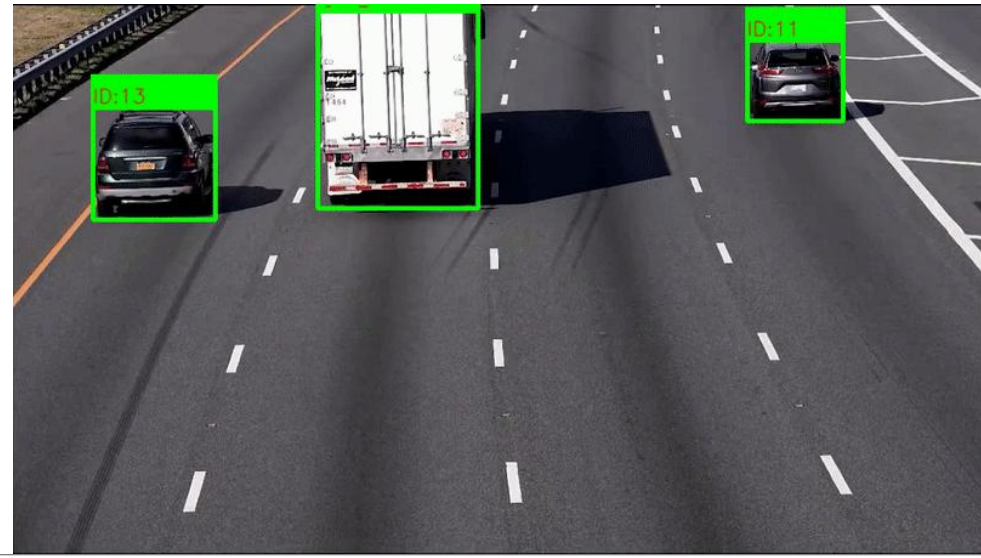
- Messvektor und Messgleichungen?

$$y_{x_1,k} = x_{1,k}$$
$$y_{y_1,k} = y_{1,k}$$
$$y_{x_2,k} = x_{2,k}$$
$$y_{y_2,k} = y_{2,k}$$

$$\boldsymbol{y}_k := (y_{x_1,k}, y_{y_1,k}, y_{x_2,k}, y_{y_2,k})^T$$

- Messmatrix C?

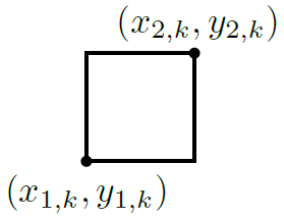
$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

Visuelles Tracking

Wie könnte das modelliert werden?



$$\boldsymbol{x}_k := (x_{1,k}, y_{1,k}, x_{2,k}, y_{2,k}, v_{x,k}, v_{y,k})^T$$

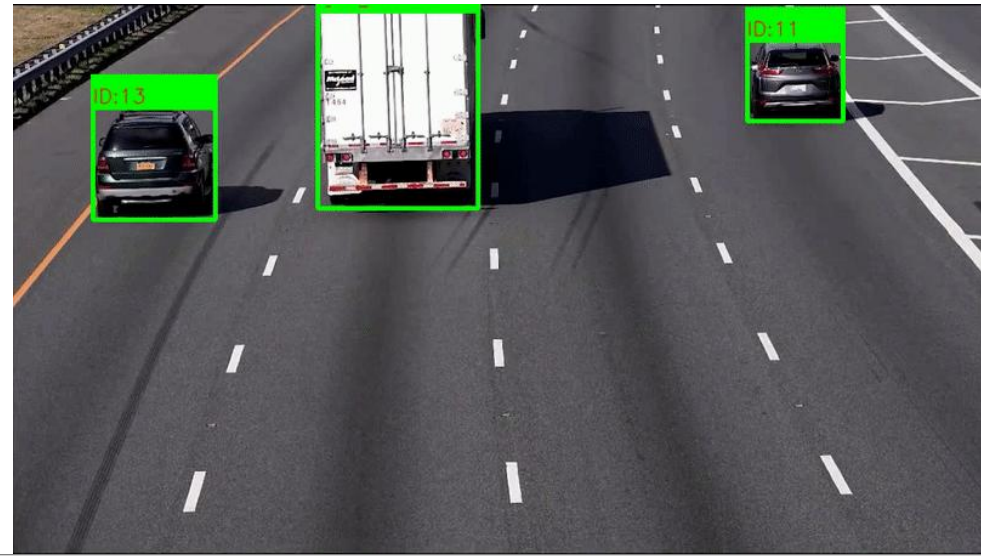
- Messvektor und Messgleichungen?

$$y_{x_1,k} = x_{1,k}$$
$$y_{y_1,k} = y_{1,k}$$
$$y_{x_2,k} = x_{2,k}$$
$$y_{y_2,k} = y_{2,k}$$

$$\boldsymbol{y}_k := (y_{x_1,k}, y_{y_1,k}, y_{x_2,k}, y_{y_2,k})^T$$

- Messmatrix C?

$$\boldsymbol{C} := \begin{pmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 1 & 0 & 0 \end{pmatrix}$$



https://github.com/ahmetozlu/tensorflow_object_counting_api
https://github.com/kcg2015/Vehicle-Detection-and-Tracking

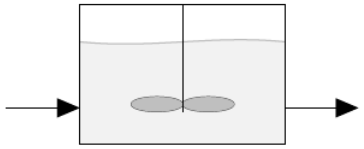
Produktion von Bier oder Biogas

Wie könnte das modelliert werden?

Betrachten wir eine einzelne Bioreaktion, bei der eine Art von Mikroorganismen $x(t)$ ein Substrat $s(t)$ verbraucht und ein Produkt $p(t)$ erzeugt. Diese Bioreaktion kann durch

$$\frac{dx}{dt}(t) = \mu \cdot x(t) - D \cdot x(t)$$
$$\frac{ds}{dt}(t) = -k_1 \cdot \mu \cdot x(t) + (s_{in} - s(t)) \cdot D$$
$$\frac{dp}{dt}(t) = k_2 \cdot \mu \cdot x(t) - p(t) \cdot D$$

beschrieben werden, wobei s_{in} die Substratkonzentration im Zulauf, μ die spezifische Wachstumsrate der Mikroorganismen darstellt, D die Verdünnungsrate und k_1 und k_2 die Ertragskoeffizienten des Substratverbrauchs und der Produktsynthese.



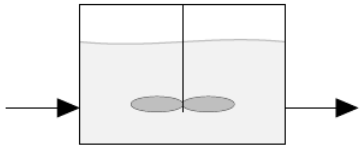
Produktion von Bier oder Biogas

Wie könnte das modelliert werden?

Betrachten wir eine einzelne Bioreaktion, bei der eine Art von Mikroorganismen $x(t)$ ein Substrat $s(t)$ verbraucht und ein Produkt $p(t)$ erzeugt. Diese Bioreaktion kann durch

$$\frac{dx}{dt}(t) = \mu \cdot x(t) - D \cdot x(t)$$
$$\frac{ds}{dt}(t) = -k_1 \cdot \mu \cdot x(t) + (s_{in} - s(t)) \cdot D$$
$$\frac{dp}{dt}(t) = k_2 \cdot \mu \cdot x(t) - p(t) \cdot D$$

beschrieben werden, wobei s_{in} die Substratkonzentration im Zulauf, μ die spezifische Wachstumsrate der Mikroorganismen darstellt, D die Verdünnungsrate und k_1 und k_2 die Ertragskoeffizienten des Substratverbrauchs und der Produktsynthese.



- Systemzustand? Systemmatrix?

$$\boldsymbol{x}(t) := (x, s, p)^T(t)$$

$$\boldsymbol{A} := \begin{pmatrix} \mu - D & 0 & 0 \\ -k_1 \cdot \mu & -D & 0 \\ k_2 \cdot \mu & 0 & -D \end{pmatrix}$$

$$\boldsymbol{x}'(t) = \boldsymbol{A} \cdot \boldsymbol{x}(t) + \begin{pmatrix} 0 \\ D \\ 0 \end{pmatrix} \cdot s_{in}$$

$$\boldsymbol{C} := \begin{pmatrix} 0 & 0 & 1 \end{pmatrix}$$

$$\boldsymbol{C} := \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

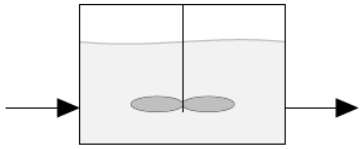
Produktion von Bier oder Biogas

Wie könnte das modelliert werden?

Betrachten wir eine einzelne Bioreaktion, bei der eine Art von Mikroorganismen $x(t)$ ein Substrat $s(t)$ verbraucht und ein Produkt $p(t)$ erzeugt. Diese Bioreaktion kann durch

$$\frac{dx}{dt}(t) = \mu \cdot x(t) - D \cdot x(t)$$
$$\frac{ds}{dt}(t) = -k_1 \cdot \mu \cdot x(t) + (s_{in} - s(t)) \cdot D$$
$$\frac{dp}{dt}(t) = k_2 \cdot \mu \cdot x(t) - p(t) \cdot D$$

beschrieben werden, wobei s_{in} die Substratkonzentration im Zulauf, μ die spezifische Wachstumsrate der Mikroorganismen darstellt, D die Verdünnungsrate und k_1 und k_2 die Ertragskoeffizienten des Substratverbrauchs und der Produktsynthese.



- Systemzustand? Systemmatrix?

$$\boldsymbol{x}(t) := (x, s, p)^T(t)$$

$$\boldsymbol{A} := \begin{pmatrix} \mu - D & 0 & 0 \\ -k_1 \cdot \mu & -D & 0 \\ k_2 \cdot \mu & 0 & -D \end{pmatrix}$$

$$\boldsymbol{x}'(t) = \boldsymbol{A} \cdot \boldsymbol{x}(t) + \begin{pmatrix} 0 \\ D \\ 0 \end{pmatrix} \cdot s_{in}$$

$$\boldsymbol{C} := \begin{pmatrix} 0 & 0 & 1 \end{pmatrix}$$

$$\boldsymbol{C} := \begin{pmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

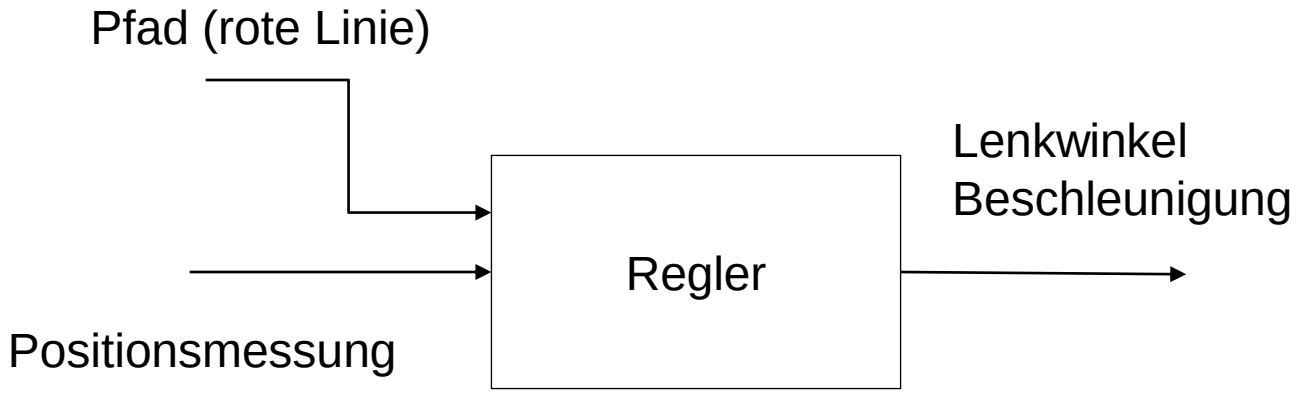
Lokalisierung eines Fahrzeugs in 2D und Pfadverfolgung

Lokalisierung eines Fahrzeugs in 2D und Pfadverfolgung



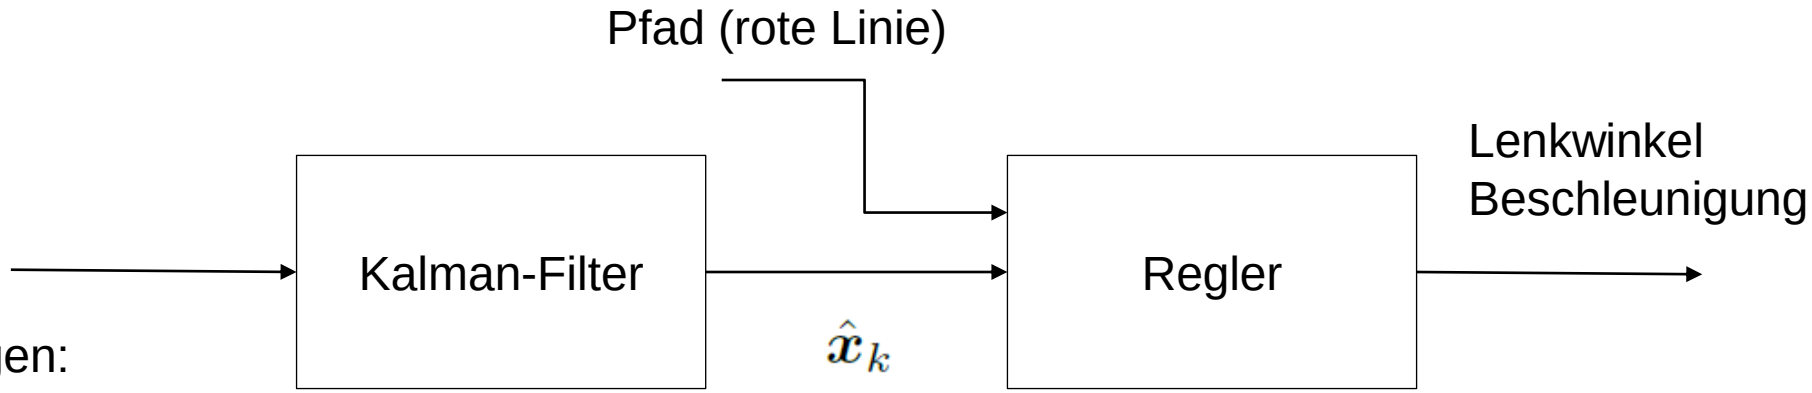
Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Lokalisierung eines Fahrzeugs in 2D und Pfadverfolgung





Lokalisierung eines Fahrzeugs in 2D und Pfadverfolgung



Messungen:
- Position
- Geschwindigkeit
- Beschleunigung

Lokalisierung eines Fahrzeugs in 2D und Pfadverfolgung

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Lokalisierung eines Fahrzeugs in 2D und Pfadverfolgung



Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Zustandsschätzung unter Berücksichtigung externer Infrastruktur

Sonderfall Lokalisierung:

- Gegeben eine Karte der Umgebung:
  - Partikelfilter (bzw. Monte Carlo Lokalisierung)
  - s. KI Vorlesung des Studiengangs Informatik

Workshop (20 Minuten)

Diskutieren Sie in Ihren Projektteams:

- Was ist der Zustand Ihres Systems (Wh.)?
- Können Sie den Zustand messen? Falls ja, wie genau können Sie den Zustand messen?
- Können Sie einen Teil des Zustands aus zwei oder mehreren Sensoren schätzen, um den Zustand genauer zu bestimmen?

Präsentation Ihrer Ergebnisse:

- Jedes Team (1-2 Minuten) präsentiert ihre Ergebnisse

Prof. Dr. Daniel Gaida
Professor für Cyber-Physische Systeme
Fakultät für Informatik und Ingenieurwissenschaften - Institut für Informatik
Technology Arts Sciences TH Köln

Lernziele von heute und Fragen zur Überprüfung der Lernziele

Die Studierenden können Algorithmen umsetzen, die den Zustand einer kontinuierlichen Umgebung online schätzen,

- indem sie kontinuierliche Umgebungen als lineares dynamisches System beschreiben
- und dafür das lineare Kalman-Filter umsetzen können,

um später intelligente Agenten für partiell beobachtbare, dynamische und kontinuierliche Umgebungen entwickeln zu können.

- Die Studierenden wissen, was das lineare Kalman-Filter macht.
  - Wird genutzt zur Sensorfusion verschiedener Messgrößen
  - Liefert Schätzung und Unsicherheit über Schätzung zurück

Nächste Vorlesung und Fragen

- Prognose und Planung bei einem CPS
- Fragen?